
PREDICTING GOOD PROBABILITIES WITH SUPERVISED LEARNING

Alexandru Niculescu-Mizil ALEXN@CS.CORNELL.EDU Rich Caruana CARUANA@CS.CORNELL.EDU Department Of
Computer Science, Cornell University, Ithaca NY 14853

왜 확률 보정 (Calibration)이 중요한가?



- 단순 분류 정확도 (AUC)만으로는 부족
- 실제 의사결정에서는 “확률값”이 중요
- 예: 광고-전환 확률 기반 타겟팅, 금융-부도 확률(PD)

즉, ‘믿을 수 있는 확률’이 중요하다.

논문 소개

주제

모델의 '분류 성능'이 아니라
확률 자체가 얼마나 정확한지를 다루
는 연구

문제 정의

기존 모델들은 AUC, Accuracy는
높지만 예측 확률이 실제 확률과 다
르다.
예: 모델이 0.8이라고 예측 그러나
실제는 0.6

연구 목표

다양한 모델들의 확률 왜곡(distortion) 분석
이를 해결하기 위한:
Calibration 방법 적용
최종적으로:
“정확한 확률을 예측하는 모델” 만들기

AUC는 순위를 평가하고, Calibration은 확률의 정확도를 평가한다

“모델은 잘 맞춰도, 확률은 틀릴 수 있다“

"잘 맞추는 모델 $\neq$ 확률이 정확한 모델"

연구 과정

데이터셋 준비

8개 이진 분류 데이터셋 (UCI, 의료, 이미지 등)
다양한 분포 + 불균형 포함
데이터 분할:
Train (4000)
Calibration (1000)
Test (대규모)

모델 학습

10개 모델 비교
SVM, Boosting, Random Forest, Logistic 등
Train 데이터로 학습

확률 예측

각 모델이 전환 확률 출력
BUT:
모델별 확률 왜곡 존재

Calibration 적용

Platt Scaling (sigmoid)
Isotonic Regression (비선형)

성능 평가

AUC → 순위 성능
Log Loss / Brier → 확률 정확도

결과 분석

AUC
Log Loss / Brier

모델별 확률 왜곡 특징

모델마다 확률이 틀리는 방식이 다르다

SVM/Boosting

확률이 가운데로 몰림(Sigmoid 왜곡)

Naive Bayes

0또는1로 과도하게 치우침

Neural Net/Logistic

비교적 잘 보정됨



모델	왜곡	원인	필요성
Boosting	S자	margin 학습	높음
Boosted Stumps	S자(강함)	bias 누적	높음
SVM	S자	확률 미모델링	높음
Naive Bayes	극단	독립성 가정	높음
Random Forest	약한 S	평균화	중간
Bagging	거의 없음	평균화	낮음
Neural Net	거의 없음	sigmoid 출력	낮음
Logistic	없음	확률 모델	낮음
KNN	불규칙	local noise	중간
Decision Tree	계단	high variance	중간

Calibration 방법

“왜곡된 확률을 다시 ‘진짜 확률’로 바꾸는 과정”

P

Platt Scaling

모델 출력값을 **sigmoid** 함수로 다시 변환하여 확률 보정

$$P(y = 1 | f) = \frac{1}{1 + \exp(Af + B)}$$

- f : 모델 출력값
- A, B : calibration 데이터로 학습

- sigmoid 함수로 보정
- 작은 데이터에서도 안정적
- 데이터 적을 때
- S자 왜곡일 때 주로 사용

왜곡된 S자 형태를 다시 “펴주는 과정”으로 중앙에 몰린 확률 → 양쪽으로 분산시켜주어 under-confident 문제 해결

I

Istonic Regression

예측값 순서를 유지하면서,
실제 비율에 맞게 확률을 재배치

$$y = m(f), \quad m : \text{monotonic increasing}$$


- 자유로운 함수 (monotonic)
- 데이터 많으면 더 강력
- 과적합 위험이 존재

구간별 실제 비율로 확률을 다시 맞춤 : 예측 0.8 → 실제 0.6 → 0.6으로 보정, 예측 0.3 → 실제 0.2 → 0.2로 보정
데이터 기반 “직접 교정”

적은 데이터라면 Platt - 많은 데이터라면 Isotonic S자 왜곡 → Platt -복잡한 왜곡 → Isotonic


모델별 확률 왜곡 특징

모델마다 확률이 틀리는 방식이 다르다



모델별 확률 왜곡 특징

모델마다 확률이 틀리는 방식이 다르다



핵심 해석

- ✓ 모델마다 확률 왜곡 패턴이 다름
- ✓ Calibration 후 대부분의 모델이 대각선($y=x$)에 가까워짐
- ✓ 특히 Boosting, SVM, Naive Bayes에서 큰 개선 효과

변화 요약 (Log Loss / Brier Score 기준)

- **크게 개선:** Boosting, SVM, Naive Bayes
- **일부 개선:** Random Forest, KNN, Decision Tree
- **거의 변화 없음:** Logistic Regression, Neural Network, Bagging



모델	Log Loss 개선	효과
Boosting	↓ 0.15~0.20	매우 큼
SVM	↓ 0.10~0.12	큼
Naive Bayes	↓ 0.20+	매우 큼
Random Forest	↓ 0.05~0.07	중간
KNN	↓ 0.05	작음
Logistic	거의 없음	없음
Neural Net	없음 / 악화	없음
Bagging	없음	없음

우리 프로젝트와의 연결

“논문의 문제 상황이 우리 데이터에서도 그대로 발생”

우리 프로젝트:
광고 전환 확률 예측 (Logistic Regression 기반)

문제 상황:
예측 확률이 실제 전환율과 불일치할 가능성

해결:
Calibration 적용 (Sigmoid / Platt)

논문: “확률 왜곡 존재”
우리: “실제 데이터에서도 동일 문제 발생”

이론 vs 실제 데이터

Logistic Regression은 구조 자체가 sigmoid라서
확률값이 잘 calibrated 되는 모델

But, 현실 데이터에서는 깨짐

이유 1: 데이터 분포 변화

이유 2: 샘플 불균형 / 희소성

이유 3: 모델 미스펙

“Logistic Regression은 이론적으로는 잘 보정된 모델
이지만,
우리 데이터에서는 분포 차이와 불균형 문제로 인해 확률
이 왜곡되었기 때문에 추가적인 calibration을 적용

우리 결과에서 Calibration 의미

“Calibration은 모델을 바꾸는게 아니라 ‘확률을 믿을 수 있게 만드는 것’”

프로젝트 결과

AUC → 거의 동일
Log Loss / Brier → 개선

해석:
순위는 그대로 유지
확률 정확도만 향상

광고 관점 의미

ROI 계산 정확도 증가
타겟팅 신뢰도 향상

“모델은 맞췄지만 확률은 틀릴 수 있고 → Calibration으로 확률을 현실에 맞게 만든다 → 우리 프로젝트에서도 동일하게 효과 확인”

THANK YOU