

생성형 AI 광고의 ROI 효율성 분석 프로젝트

중간 발표 보고서

AIM | 조하연 · 지우진 · 최서린 · 최은서

1. Abstract

본 보고서는 AIM 팀의 프로젝트가 현재 어느 단계까지 진행되었는지를 중심으로 정리한 중간 발표용 문서이다. 우리 팀의 연구 주제는 생성형 AI 광고가 인간 제작 광고 대비 더 낮은 제작비를 가진다는 장점에도 불구하고, 광고 성과 저하 가능성까지 고려했을 때 실제로도 비용 대비 효율성이 높은지를 ROI 관점에서 검증하는 것이다. 2 차 세션 발표에서는 Criteo 의 사용자 행동 로그 데이터셋¹을 기반으로 User Journey 를 구성하고, 관여도 분류와 외생 변수 생성, 캠페인 단위 ROI 시뮬레이션을 수행하였다. 그 결과 단순 패널티를 적용하더라도 AI 광고의 평균 ROI 가 더 높게 나타났으나, 이 결과는 제작비 가정과 객단가 가정의 영향이 크게 반영된 것으로 판단되었다. 이에 4 차 세션 발표에서는 분석 구조를 고도화하여, 전환 이후 정보가 포함되는 누수 문제를 제거한 Snapshot 기반 전환확률 예측 모델을 새롭게 설계하고, Calibrated Logistic Regression 을 ROI Expansion 단계의 입력값으로 연결하는 파이프라인을 구축하였다. 현재까지 데이터 전처리, 행동 기반 피처 설계, 모델 비교 및 최종 모델 선정, 확률 보정 구조 설계까지 완료되었으며, 이후에는 산업군 benchmark 보정, AI 광고와 인간 광고의 비교 시나리오 정교화, 민감도 분석 및 최종 해석 작업을 진행할 예정이다.

2. Introduction

생성형 AI 는 광고 이미지 및 콘텐츠 제작 시간을 줄이고 제작비를 절감할 수 있다는 점에서 실무적으로 빠르게 도입되고 있다. 그러나, 생성형 AI 광고는 소비자가 이를 인공지능이 만든 광고로 인식할 경우 신뢰도나 구매의도가 낮아질 수 있다는 우려도 함께 제기된다.² 따라서 AI 광고의 성과를 단순 클릭 수나 노출 수만으로 판단하기보다, 광고 성과 저하 가능성과 비용 절감 효과를 함께 반영한 ROI 관점에서 평가할 필요가 있다.

더 나아가, 우리는 제품의 관여도별로 기업의 광고 전략이 달라진다는 점에 착안했다. 저관여 제품의 광고는 광고 한 개당 매출 기여도가 낮아 제작비를 아끼는 것 자체가 순이익 증대로 직결된다. 반면에, 고관여 제품의 광고는 광고 한 개로 고객 한 명만 더 유치해도 수백만 원을 벌 수 있다. 즉, 제작비 몇 천만 원을 아끼는 것보다 품질 하락 리스크를 방어해서 단 한 명의 고객이라도 놓치지 않는 것이 합리적인 경영 판단이다. 이에 우리 팀은 관여도별로 생성형 AI 광고와 인간 제작 광고를 비교하여 어느 쪽이 더 높은 경제적 타당성을 가지는지 분석하고자 하였다. 본 프로젝트의 핵심 질문은 다음과 같다. 첫째, 광고 성과 감소 패널티를 고려하더라도 AI 광고가 인간 광고보다

¹ Criteo 에서 제공하는 「Attribution Modeling for Bidding Dataset」 데이터셋을 사용함.

² MDPI 의 「The Impact of Generative AI Images on Consumer Attitudes in Advertising」를 간접 인용함.

높은 ROI 를 보이는가? 둘째, 단순 CTR 중심 분석을 넘어 사용자 행동 기반 전환확률과 산업군 benchmark 를 결합하면 보다 현실적인 ROI 평가가 가능한가? 셋째, 결과가 특정 가정에 과도하게 의존하지 않는지 민감도 분석으로 확인할 수 있는가?

3. Study Contents and Analytical Framework

3-1. 스터디 내용과 문제 재정의

사전 스터디 단계에서 우리 팀은 기존 Kaggle 정제 데이터셋을 사용하는 방식의 한계를 먼저 점검하였다. 정제 데이터는 분석 연습에는 적합하지만, 실제 광고 행동 로그가 가진 순차성과 비용 구조를 충분히 반영하지 못한다는 문제가 있었다. 또한 제작비를 임의의 단일 값으로 두고 ROI 를 계산하면 결과가 지나치게 단순화된다는 점도 확인하였다. 이에 2 차 세션 발표에서는 raw 수준의 행동 데이터와 선행연구·통계를 바탕으로 보다 현실적인 분석 구조를 재설계하였다.

이론적 배경 측면에서는 CTR 중심 분석의 한계를 보완하기 위해 클릭의 양이 아니라 클릭의 질이 중요하다는 문제의식을 설정하였다. 이를 위해 전환에 직접 연결된 클릭(*high*), 탐색 단계의 클릭(*mid*), 전환과 무관한 클릭(*low*)을 구분하고, Zaichkowsky(1985)의 관여도 개념³을 행동 데이터에 연결하여 *clicks_before_conversion*⁴, *decision_time*⁵, *journey_length*와 같은 지표가 소비자의 관여도를 간접적으로 반영할 수 있는지 검토하였다. 또한, 광고 성과 해석을 위해 CTR, CVR, ROAS, ROI 의 차이를 정리하고, 최종 의사결정 지표는 제작비까지 포함하는 ROI 로 설정하였다.

3-2. 전체 분석 흐름

PHASE 1 데이터 전처리	PHASE 2 관여도 분류	PHASE 3 외생 변수 생성 및 AI 데이터셋 생성	PHASE 4 전환확률 예측 모델	PHASE 5 ROI 확장 계산
--------------------	-------------------	-------------------------------------	-----------------------	----------------------

4. Project Progress

4-1. 2 차 세션 발표 내용

2 차 세션 발표에서는 분석의 기초가 되는 데이터 전처리와 ROI baseline 시뮬레이션을 중점적으로 수행하였다. 먼저 사용자의 광고 접촉, 클릭, 전환 로그를 시간 순으로 정렬하여 User Journey 를 구성하고, 전환이 발생하지 않은 경우에는 *conversion_id* 를 결측으로 처리하여 전환 데이터가 분석 단계에서 명확히 구분되도록 정리하였다. 이후 사용자가 실제 구매하기 전까지의 행동만 유지하도록 흐름을 정제하여, 전환 이전 클릭 수(*clicks_before_conversion*), 첫 광고 접촉부터 전환까지 걸린 시간(*decision_time*), 광고 접촉 횟수(*journey_length*)를 생성하였다.

³ Zaichkowsky, J. L. (1985), "Measuring the Involvement Construct," *Journal of Consumer Research*, 재인용함.

⁴ Petty & Cacioppo(1986)의 ELM(Elaboration Likelihood Model)을 재인용함.

⁵ Howard & Sheth(1969)의 구매의사결정 모델을 참고함.

다음으로는 저관여 상품군에 가까운 소비자 행동 패턴을 추출하기 위해 관여도 분류를 진행하였다. click 수와 decision time 을 Min-Max 정규화한 뒤 involvement score 를 구성하고, 하위 30%를 저관여, 중간 40%를 중관여, 상위 30%를 고관여로 분류하였다. 이 과정에서 journey_length 는 보조 지표로 활용되었으며, 우리 팀은 저관여 상품을 직접 식별한 것이 아니라 저관여적 소비 패턴 집단을 추출했다는 점을 명확히 하였다.

ROI 계산을 위해서 데이터셋에 존재하지 않는 제작비와 객단가(AOV) 변수를 외생적으로 생성하였다. 인간 광고 제작비는 한국디자인진흥원의 디자인 대가기준을 참고하여 기준값 50 만 원과 민감도 범위(0.5 배, 1 배, 1.5 배)를 설정하였고, AI 광고 제작비는 BCG 의 생성형 AI 콘텐츠 제작 효율 개선 사례를 바탕으로 인간 광고 제작비의 70%, 50%, 20% 수준 시나리오로 구성하였다. AOV 는 저관여 소비재 카테고리 평균 주문금액을 참고해 약 60 달러로 반올림하여 사용하였다.

이러한 가정을 바탕으로 Human 광고와 AI 광고의 ROI 를 비교한 결과, 인간 광고의 평균 ROI 는 0.1835, AI 광고의 평균 ROI 는 0.4239 로 나타났고, Wilcoxon signed-rank test 에서도 두 차이가 유지되었다. 그러나, 우리 팀은 이 결과를 그대로 결론으로 받아들이지 않고, 제작비 절감폭과 분모 구조 때문에 AI ROI 가 과대하게 좋아 보일 수 있다는 점을 문제로 인식하였다. 즉, 2 차 세션 발표의 핵심 성과는 AI 광고가 더 좋아 보였다는 결과 자체보다, 단순 패널티만 적용한 ROI 계산만으로는 현실적인 의사결정을 설명하기 어렵다는 한계를 발견한 데 있다.

4-2. 4 차 세션 발표 기준 진행 내용

4 차 세션 발표에서는 2 차 세션 발표 피드백을 반영해, 분석의 중심을 고정 패널티가 적용된 단순 ROI 비교에서 행동 기반 전환확률을 활용한 ROI Expansion 으로 전환하였다. 먼저 기존 피쳐들 가운데 *decision_time*, *journey_length*, *time_last_click_to_conversion*, *high*, *mid*, *low* 처럼 전환 이후에만 확정되는 정보가 예측 피쳐에 섞여 있다는 점을 데이터 누수로 규정하고, 현실적인 예측 구조를 확보하기 위해 Snapshot 방식을 도입하였다.

Snapshot 구조에서는 관측창을 첫 5 개 touch 로 제한하고, 그 이후에 전환이 일어났는지를 라벨로 두었다. 이 방식에 따라 *clicks_first_k*, *cost_first_k*, *n_unique_campaigns_first_k*, *campaign_switches_first_k*, *observation_span_first_k*, *max_gap_between_touchees_first_k*, *clicked_in_first_k*, *time_to_first_click_first_k*, *avg_gap_between_clicks_first_k*, *max_gap_between_clicks_first_k*, *clicked_ratio_first_k*, *click_rate_per_min_first_k*, *cost_per_click_first_k*, *campaign_diversity_ratio_first_k* 등 총 14 개의 행동 기반 피쳐를 최종 사용하였다. 기존 절대량 중심 피쳐에 더해 새롭게 추가한 4 개의 파생 변수는 초기 노출 대비 클릭 비율(*clicked_ratio_first_k*), 관측 시간 대비 클릭 속도(*click_rate_per_min_first_k*), 클릭 1 회당 평균 비용(*cost_per_click_first_k*), 초기 노출 대비 캠페인 다양성(*campaign_diversity_ratio_first_k*)으로, 단순 집계값으로는 포착하기 어려운 초기 행동의 반응 비율·속도·효율·다양성을 반영하기 위해 추가하였다. 실제로 로지스틱 계수 분석에서도 *cost_per_click_first_k*, *campaign_diversity_ratio_first_k* 등 새 파생 변수들이 상위 영향 변수로 확인되어, 추가된 피쳐가 모델에서 실질적으로 작동하고 있음을 확인하였다. 또한 *cost*, *observation_span*, *time_to_first_click* 등 오른쪽 꼬리가 긴 변수들에는 log1p 변환을 적용하여

극단값 영향을 완화하고 로지스틱 회귀가 각 피처를 보다 안정적으로 해석할 수 있도록 전처리하였다. 즉, 모델이 예측 시점에 실제로 이용 가능한 정보만을 바탕으로 전환 가능성을 점수화하도록 구조를 바꾼 것이다.

모델 비교 단계에서는 Logistic Regression, Random Forest, XGBoost 를 검토하였다. Random Forest 와 XGBoost 는 초기 성능이 높게 보이는 구간이 있었지만 일반화 성능이 흔들렸고, 회귀 전환 환경에서 ranking 안정성과 해석 가능성을 동시에 확보한 Logistic Regression 이 최종 채택되었다. 로지스틱 회귀 튜닝 단계에서는 기존 L2 규제만 비교하던 방식에서 나아가 Elastic Net 규제를 포함한 더 넓은 하이퍼파라미터 조합을 탐색하였으며, class imbalance 대응을 위해 class_weight=balanced 설정도 함께 비교하고 average precision 을 평가 기준으로 하여 회귀 전환 환경에서의 ranking 성능을 직접 최적화하였다. 또한 OBS_TOUCHES 를 3, 5, 7 회로 달리하여 비교한 결과, 7 회 관측은 AUC 가 가장 높았지만 top-10% 타게팅 성능이 완전히 무너졌고, 5 회 관측이 validation PR-AUC 와 top-10% precision/recall/f1 모두에서 가장 안정적임을 확인하여 최종 snapshot 기준으로 확정하였다. 이후 base logistic 예측확률의 과대추정 문제를 보완하기 위해 Sigmoid calibration 을 적용하였고, threshold 기반 이진분류보다 상위 10% 후보군 중심의 운영 전략이 더 적절하다는 판단을 내렸다.

최종 Logistic 모델(base)은 validation ROC-AUC 0.892, validation PR-AUC 0.097, test ROC-AUC 0.749, test PR-AUC 0.026, Top-10% Lift 3.73 을 기록하였다. Calibration 적용 후에는 test ROC-AUC 0.747, PR-AUC 0.029 로 소폭 변동하였으나 Top-10% Lift 는 동일하게 유지되어, ranking 보존을 우선하여 base logistic 을 최종 downstream 모델로 선택하였다. 절대적인 분류 정확도보다는 회귀 전환 환경에서 전환 가능성이 높은 대상을 상위 구간에 집중시키는 능력이 중요하므로, 우리 팀은 이 결과를 ROI 입력값으로 충분히 활용 가능한 수준의 ranking 성능으로 해석하였다. 이후 PHASE 5 에서는 Calibrated propensity score 에 산업군 benchmark(CVR, AOV)를 결합하고 광고비·제작비를 반영하여 기대 매출과 최종 ROI 를 계산하는 구조를 설계하였다.

4-3. 결과 요약

구분	핵심 수치/상태	해석
1 차 ROI baseline	Human 평균 ROI 0.1835 AI 평균 ROI 0.4239	AI ROI 가 더 높게 나타났지만, 단순 비용 가정이 결과를 크게 좌우할 수 있어 구조 고도화가 필요하다는 점을 확인
최종 예측 모델	Calibrated Logistic Regression	회귀 전환 환경에서 ranking 안정성과 해석 가능성이 높아 ROI Expansion 입력값으로 채택
2 차 모델 성능	Test ROC-AUC 0.749 PR-AUC 0.026 Top-10% Lift 3.73	전환자를 상위 구간에 밀집시키는 능력이 확인되어 이후 시나리오 비교 단계로 연결 가능

5. Current Status and Future Plan

5-1. 현재 프로젝트 진행 상태

단계	진행 상태	내용
PHASE 1	완료	<u>데이터 전처리</u> (User Journey 생성, 전환 이전 행동만 유지, 소비자 행동 지표 생성, 클릭 수 세분화)
PHASE 2	완료	<u>관여도 분류</u> (관여도 이론 근거 명시, 관여도 점수 생성, 저/중/고관여 분류, 분류 결과 검증 시각화)
PHASE 3	완료	<u>외생 변수 생성 및 AI 데이터셋 생성</u> (제작비 설정, AOV 설정, 마케팅 지표 계산, AI 광고 데이터셋 생성)
PHASE 4	완료	<u>전환확률 예측 모델</u> (피처 선정, 모델 학습, 모델 평가, 산업군 보정)
PHASE 5	진행 중	<u>ROI 확장 계산</u> (캠페인 단위 집계, 베이스라인 테스트, 시각화 개선)
PHASE 6	시작 전	<u>민감도 분석</u> (변동 변수 설정, 몬테카를로 시뮬레이션, 결과 분석)
PHASE 7	시작 전	<u>최종 결론 도출</u> (핵심 결과 요약, 한계점 명시, 향후 연구 확장)

5-2. 앞으로의 계획

앞으로의 핵심 과제는 PHASE 5의 ROI Expansion을 실제 비교 분석까지 완결하는 것이다. 구체적으로는 Criteo 기반 행동 점수와 calibrated propensity score를 산업군 benchmark의 CVR, AOV와 연결하여 기대 전환 수와 기대 매출을 계산하고, 광고비와 제작비를 포함한 비용 구조를 반영해 AI 광고와 Human 광고의 ROI를 동일 기준에서 다시 비교할 예정이다.

또한, 결과가 특정 가정에 지나치게 민감할 수 있으므로, 객단가, 광고비, 제작비, AI 광고 성과 패널티의 크기를 달리한 시나리오를 구성하고 몬테카를로 기반 민감도 분석을 수행할 계획이다. 이를 통해 현재 관찰된 결과가 단순 비용 구조의 산물인지, 혹은 저관여 상품군에서도 실제로 유지되는 경향인지를 점검할 수 있다.

최종 보고서 단계에서는 분석 파이프라인 전체를 정리하고, 생성형 AI 광고의 경제적 타당성에 대한 해석, 마케팅 실무적 시사점, 데이터 한계와 확장 가능성을 함께 제시할 예정이다. 즉, 현재 프로젝트는 아이디어 검토 단계가 아니라, 핵심 분석 파이프라인을 구축한 뒤 마지막 비교·해석 단계로 넘어가는 시점에 와 있다고 정리할 수 있다.

6. Conclusion & Limitations

지금까지 우리 팀은 생성형 AI 광고의 ROI를 단순 비용 비교가 아닌 행동 기반 전환확률과 benchmark 보정을 결합한 구조로 해석하기 위해 분석 틀을 단계적으로 고도화해 왔다. 2차 세션 발표에서 baseline ROI 계산과 그 한계를 확인했고, 4차 세션 발표에서는 누수 없는 전환확률 예측 모델과 ROI Expansion 구조를 마련하였다. 따라서 현재 프로젝트는 문제 정의와 기초 전처리 단계는 이미 지나, 최종 비교 분석의 신뢰도를 높이기 위한 정교화 단계에 진입한 상태라고 볼 수 있다.

다만 아직 산업군 보정과 민감도 분석이 완료되지 않았고, 회귀 전환 환경의 특성상 PR-AUC 수준만으로 모델의 실무적 유효성을 단정하기 어렵다는 한계도 남아 있다. 또한, 외생적으로 부여한 AOV, 제작비, 광고비 가정은 최종 결론에 영향을 줄 수 있으므로, 이후 단계에서는 다양한 시나리오를 통해 결과의 안정성을 함께 검증해야 한다. 그럼에도 현재까지의 진행 결과는 생성형 AI 광고의 경제적 타당성을 CTR 중심 보고에서 벗어나 보다 실질적인 ROI 의사결정 문제로 전환했다는 점에서 의미가 있다.