

DAT 7 기 캡스톤 프로젝트 보고서

저관여 제품에서 생성형 AI 광고의 리스크와 ROI 임계점 기반 기업 의사결정 시스템 연구

: AdTrace AI 기반 실증 분석 및 웹 의사결정 시스템

DAT 7 기

AIM

조하연 · 지우진 · 최서린 · 최은서



Data Analysis & Technology



DAT 7 기 캡스톤 프로젝트 보고서

저관여 제품에서 생성형 AI 광고의 리스크와 ROI 임계점 기반 기업 의사결정 시스템 연구

: AdTrace AI 기반 실증 분석 및 웹 의사결정 시스템

A Study on Generative AI Advertising Risk and
ROI Threshold-Based Corporate Decision-Making System
for Low-Involvement Products

이 보고서를 캡스톤 프로젝트 보고서로 제출합니다.

2026 년 06 월 01 일

DAT 7 기

AIM

조하연 · 지우진 · 최서린 · 최은서



Data Analysis & Technology



DAT 7기 캡스톤 프로젝트 보고서

저관여 제품에서 생성형 AI 광고의 리스크와 ROI 임계점 기반 기업 의사결정 시스템 연구

: AdTrace AI 기반 실증 분석 및 웹 의사결정 시스템

국문 요약

본 연구는 생성형 AI 광고의 ROI 우위 조건을 분석하고 이를 웹 기반 의사결정 시스템으로 확장하였다. Criteo 로그를 바탕으로 Human/AI ROI 임계점을 계산한 뒤, EfficientNet-B0 CNN이 광고 이미지의 AI-like probability를 추론하도록 설계하였다. 해당 확률은 이미지별 신뢰 하락 패널티로 변환되어 ROI 시뮬레이션에 반영된다. 분석 결과 AI 광고의 경제성은 고정값이 아니라 AI 유사도, 제작비, 성과 패널티에 따라 달라진다. 최종적으로 Criteo ad_spend 스케일 문제를 해결하기 위해 광고비 A 를 $\lambda=4.0$ 기반으로 재정의하고, H·r·p 3 변수 민감도 분석에서 breakeven_p 히트맵을 핵심 출력으로 도출하였다. 또한 414명 대상 사전 설문을 통해 Human/AI 광고 선호와 AI 제작 인식의 관계를 보조적으로 확인하였으며, 이후 웹 A/B 테스트를 통한 실증 검증 계획을 수립하였다.

Abstract

This study analyzes the conditions under which generative AI advertising can outperform human-produced advertising in terms of ROI and extends the analysis into a web-based decision-support system. Using Criteo advertising log data, the study estimates Human/AI ROI thresholds and designs an EfficientNet-B0 CNN module to infer the AI-like probability of uploaded advertising creatives. The inferred probability is converted into an image-specific trust penalty and incorporated into ROI simulation. The findings indicate that the economic advantage of AI advertising is not fixed, but varies according to AI-likeness, production cost, and performance penalty. To address the scale issue of Criteo ad_spend, advertising cost A is redefined based on $\lambda=4.0$, and a three-variable sensitivity analysis of H , r , and p produces a breakeven_p heatmap as the core output. In addition, a preliminary survey of 414 respondents provides supporting evidence on the relationship between Human/AI ad preference and perceived AI production, while a future web A/B test is proposed for empirical validation.



목차

초록	0
I. 서론	2
1. 연구의 배경 및 목적	2
2. 연구의 범위 및 방법	2
II. 이론적 배경	3
1. 선행연구 검토	3
2. 용어의 정의 및 개념적 틀	5
III. 연구 설계 / 분석 방법	6
1. 연구 대상 및 자료 수집	6
2. 분석 도구 및 절차	8
3. CNN 기반 웹 의사결정 시스템 설계	11
IV. 연구 결과 / 실증 분석	13
1. 자료의 특성	13
2. 분석 결과	14
3. 시스템 적용 가능성과 검증 계획	18
4. 결과에 대한 논의	21
V. 결론	22
1. 연구 요약	22
2. 정책적 제언 및 시사점	22
3. 연구의 한계 및 향후 과제	23
참고문헌	24



I. 서론

1. 연구의 배경 및 목적

생성형 AI는 광고 이미지 제작의 비용 구조와 작업 속도를 빠르게 바꾸고 있다. 기존 광고 제작은 기획, 촬영, 디자인, 수정, 검수 등의 단계가 필요했으며 외주 제작이나 디자이너 인건비가 상당한 비중을 차지하였다. 반면 생성형 AI 도구는 짧은 시간 안에 다수의 시안을 만들 수 있어, 소재 테스트와 반복 제작이 많은 디지털 광고 환경에서 높은 실무적 관심을 받고 있다.

그러나 AI 광고가 낮은 제작비를 가진다고 해서 반드시 기업 성과에 유리한 것은 아니다. 본 연구는 AI 광고가 소비자에게 인위적이거나 신뢰하기 어려운 광고로 인식될 경우 구매 의도와 전환 성과가 하락할 수 있다는 문제에 주목하였다. 특히 선행연구(Zhang et al.)에서 제시된 AI 인식 시 평균 19.1% 성과 하락 효과를 초기 분석의 기준 파라미터로 설정하였다.

이 연구의 문제의식은 바로 이 상충 관계에서 출발한다. AI 광고는 제작비를 줄이는 동시에 성과도 낮아질 가능성이 있다. 인간 제작 광고는 제작비가 높지만 품질과 신뢰 측면에서는 높은 평가를 받는다. 따라서 기업이 실제로 알고 싶은 것은 'AI 광고가 성과 측면에서 더 우위인가'가 아니라 'AI 광고의 성과가 일부 낮아져도 제작비 절감이 그 손실을 보상할 만큼 충분인가'이다.

본 연구의 목적은 저관여 제품 광고 맥락에서 생성형 AI 광고가 인간 제작 광고보다 ROI 측면에서 우위가 되는 조건을 정량적으로 도출하는 것이다. 저관여 제품은 가격 부담과 지각된 위험이 비교적 낮고, 소비자가 긴 탐색보다 직관적 판단에 따라 반응하는 경향이 있어 광고 소재의 반복 제작과 비용 효율성이 중요하다. 따라서 저관여 제품 광고 맥락은 AI 광고의 경제성을 평가하기에 적합한 연구 맥락이다.

2. 연구의 범위 및 방법

본 연구는 초기 문제 정의, 데이터 후보 탐색, 행동 로그 기반 모델링, ROI 임계점 분석, CNN 기반 웹 프로토타입 개발의 순서로 진행되었다. 초기 단계에서는 marketing campaign dataset 과 influencer marketing ROI dataset 을 비교하며 프로젝트 문제의식을 구체화하였고, 이후 사용자 행동 순서를 복원할 수 있는 Criteo 기반 로그 데이터로 분석 대상을 전환하였다.

분석 범위는 크게 다섯 부분이다. 첫째, 광고 접촉-클릭-전환의 순서를 복원하여 사용자 여정(User Journey)을 구성한다. 둘째, 클릭 품질과 의사결정 시간 등 행동 지표를 이용해 저관여 행동 집단을 추출한다. 셋째, 인간 광고를 baseline 으로 두고 AI 광고에 성과 패널티와 제작비 절감 효과를 적용한 반사실적 ROI 시뮬레이션을 수행한다. 넷째, 전환확률 모델과 산업군



benchmark 보정, 3 변수 민감도 분석을 통해 AI 광고가 우위가 되는 임계 조건을 계산한다. 다섯째, CNN 기반 AI-like probability 추론 모델과 웹 대시보드를 결합하여 기업이 업로드한 광고 이미지별로 동적 패널티와 ROI 임계점을 계산하는 시스템 구조를 제안한다.

초기 연구 방법은 관측 로그 기반 counterfactual simulation 이었다. 원본 광고 로그에는 실제 AI 광고 여부가 명시되어 있지 않으므로, 원본 성과를 인간 제작 광고의 결과로 간주하고 AI 광고 성과를 가정 기반으로 생성하였다. 그러나 최종 시스템은 이에서 한 단계 더 나아간 구조를 취한다. 19.1% 패널티는 최종 고정값이 아니라 선행연구에서 출발한 초기 기준이며, 실제 서비스에서는 CNN 이 광고 이미지의 AI-like probability 를 추정하고 이 값을 패널티 가중치로 변환한다.

따라서 본 연구는 분석 모형의 제시에 그치지 않고 AdTrace AI 라는 applied AI prototype 의 설계까지 포함한다. 기업 사용자는 웹사이트에 광고 이미지를 업로드하고, 시스템은 EfficientNet-B0 기반 CNN 으로 AI 처럼 보이는 정도를 계산한다. 이후 해당 점수는 trust penalty 로 변환되어 CTR, CVR, ROI 하락 가정에 반영되고, 기업은 수정·A/B 테스트·재제작·집행 가능 여부를 판단할 수 있다.

II. 이론적 배경

1. 선행연구 검토

본 연구는 생성형 AI 광고 연구의 한계를 두 방향으로 파악하였다. 첫째, AI 광고 인식 효과 연구는 AI 생성 사실이 소비자 태도, 신뢰, 구매 의도에 미치는 부정적 영향을 설명하는 데에는 기여하였으나, 광고 제작비를 포함한 경제성 분석으로는 충분히 이어지지 못하였다. 둘째, 마케팅 성과 분석은 CTR, CVR, CPA, ROAS 등 단일 지표에 집중하는 경우가 많아 제작비 절감과 성과 하락을 동시에 반영한 ROI 임계점 분석으로 확장되지 못하는 한계가 있다.

Atlan(2026)의 「AI ROI Analysis: Evidence from 200 B2B Deployments (2022-2025)」는 2022~2025 년 프랑스 B2B 기업의 200 개 AI 도입 프로젝트를 대상으로 ROI 분포, 손익분기 기간, 실패율, Human-in-the-Loop 운영과 교육 투자 효과를 분석한 자료이다. 본 연구는 이 문헌을 통해 AI 도입의 경제적 성과가 기술 자체가 아니라 도입 방식, 운영 조건, 비용 구조에 따라 달라진다는 점을 참고하였다. 이는 본 연구가 AI 광고를 단순 자동화 도구로 보지 않고, 성과 패널티와 운영 조건을 함께 고려해야 한다는 문제의식을 강화한다.

행동 데이터 기반 구매 예측 연구도 본 연구의 중요한 선행연구이다. Wen, Lin, Liu(2023)는 익명 사용자의 클릭스트림 데이터를 활용하여 구매 의도를 예측할 수 있음을 보였다. 해당 연구는



로그인 이력이나 개인 식별 정보가 없어도 클릭 수, 체류 시간, 장바구니 행동, 상품 인기와 같은 세션 단위 행동 신호가 구매 가능성을 설명할 수 있다고 보았다. 이는 본 연구가 Criteo 로그에서 클릭 수, 광고 접촉 횟수, 첫 클릭까지의 시간, 전환 이전 행동 등을 이용해 전환확률과 관여도 수준을 간접적으로 추정한 것과 연결된다. 다만 기존 연구가 주로 “누가 구매할 것인가”를 예측하는 데 초점을 두었다면, 본 연구는 이러한 행동 기반 예측 구조를 광고 성과와 ROI 분석으로 확장하여 “어떤 조건에서 AI 광고가 경제적으로 타당한가”를 설명하고자 한다.

또한 예측확률의 해석 가능성과 보정 가능성에 관한 연구도 본 연구의 모델 설계에 영향을 주었다. Niculescu-Mizil 과 Caruana(2005)는 분류 모델의 AUC 나 정확도가 높더라도 예측확률이 실제 발생확률과 일치하지 않을 수 있으며, 의사결정에 확률값을 직접 사용하는 경우 calibration 이 중요하다고 설명하였다. 본 연구에서도 전환확률 모델의 pred_proba 는 사용자 간 상대적 ranking 정보를 제공하지만, 산업군의 실제 CVR 과 동일한 절대확률로 해석하기에는 한계가 있다. 따라서 calibration 및 benchmark CVR 보정 과정을 통해 내부 모델의 ranking 정보는 유지하되, ROI 계산에 필요한 기대 전환 수와 기대 매출은 현실적인 산업군 평균 전환율에 맞추어 조정하였다.

CNN 기반 이미지 판별 연구는 본 연구의 웹 시스템 설계와 직접적으로 연결된다. 김지연·홍승아·김하민(2019)은 「합성곱신경망 기반의 StyleGAN 이미지 탐지모델」에서 StyleGAN 으로 생성된 얼굴 이미지가 사람의 눈에는 자연스럽게 보일 수 있지만, CNN 은 픽셀 패턴, 질감, 경계, 반복적 시각 특징 등 사람이 놓치기 쉬운 미세한 흔적을 학습하여 Real/Fake 이미지를 분류할 수 있음을 보였다. 해당 연구는 300,000 장의 이미지와 48 개 실험 조건을 바탕으로 CNN 구조와 파라미터 조합에 따른 탐지 성능을 비교하였으며, 생성 이미지 탐지에서 CNN 기반 특징 추출이 유효한 접근임을 제시하였다.

본 연구는 이러한 CNN 탐지 관점을 광고 이미지 분석에 적용하였다. 즉, AI 광고를 단순히 “생성 여부”로 이분법적으로 판단하는 것이 아니라, 소비자에게 AI 생성물처럼 인식될 가능성이 높은 시각적 단서들을 탐지하고 이를 AI-like probability 및 리스크 점수로 변환한다. 제품 경계의 어색함, 질감의 과도한 매끈함, 조명·그림자 불일치, 로고·라벨·텍스트 왜곡, 인물 디테일의 비자연성 등은 광고 신뢰도와 구매 의도에 영향을 줄 수 있는 시각적 요인이다. 따라서 CNN 은 본 연구에서 최종 판정자가 아니라, 기업이 광고 집행 전 수정·검수·A/B 테스트 여부를 판단하도록 돕는 1 차 리스크 필터로 활용된다.

또한 몬테카를로 시뮬레이션, 베이지안 최적화, 순현재가치 평가, 보증비용 추정 등 불확실성 기반 의사결정 연구를 참고하였다. 이 연구들은 직접적인 광고 연구는 아니지만, 불확실한 변수를



범위로 설정하고 반복 시뮬레이션 또는 민감도 분석을 통해 의사결정 임계값을 도출하는 방법론적 근거를 제공한다.

관여도 이론 역시 핵심 배경이다. 본 연구에서 ‘저관여’는 특정 상품 카테고리를 기계적으로 지칭하는 개념이 아니라, 광고 접촉 이후 짧은 시간 안에 낮은 정보 탐색 수준으로 반응하는 소비자 행동 패턴을 의미한다. Zaichkowsky(1985)의 관여도 개념을 바탕으로 관여도를 소비자가 제품 및 의사결정에 부여하는 개인적 중요성으로 이해하고, Petty 와 Cacioppo(1986)의 정교화가능성모형(ELM)에 따라 저관여 상황에서는 중심경로보다 주변단서에 의존한 처리 가능성이 높다고 보았다. 또한 Howard 와 Sheth(1969)의 구매행동모형에서 제시한 정보탐색과 의사결정 과정의 차이를 고려하여 clicks_before_conversion, decision_time, journey_length, impressions_before_first_click 등 행동 지표가 소비자의 관여도를 간접적으로 반영한다고 보았다.

2. 용어의 정의 및 개념적 틀

용어	정의	본 연구에서의 조작적 활용
생성형 AI 광고	AI 도구로 이미지 또는 광고 소재를 생성한 광고	Human 성과에 19.1% 패널티와 제작비 절감 효과를 적용한 반사실적 시나리오
인간 제작 광고	디자이너·에이전시 등 인간 제작자가 만든 광고	Criteo 원본 광고 성과의 baseline
저관여 제품/행동	정보 탐색과 구매 위험이 낮은 소비 맥락	관여도 점수 하위 30% 행동 집단으로 정의
ROI	총비용 대비 순수익	광고 집행비와 제작비를 모두 포함해 계산
성과 패널티 p	AI 인식 또는 품질 저하로 인한 성과 감소율	기준값 19.1%, 민감도 분석에서 0~40%
AI-like probability	광고 이미지가 AI 처럼 보일 CNN 추론 확률	이미지별 동적 패널티 산출의 핵심 입력값
Risk band	AI-like score 를 운영 의사결정 등급으로 변환한 값	Low, Medium, High, Critical 에 따라 집행·수정·재제작 권고
Trust penalty	AI-like 신호가 소비자 신뢰와 구매 행동에 주는 하락 가정	$p = \text{base penalty} + \text{AI-like score} \times \text{weight}$
AI 제작비 비율 r	Human 제작비 대비 AI 제작비 비율	3%, 5%, 10%, 20%, 30%, 50% 범위 분석

임계점	AI ROI 가 Human ROI 이상이 되는 조건	breakeven_r, breakeven_p 로 산출
λ (광고비/제작비 비율)	$A_{ref} = H_BASELINE \times \lambda$ 로 재정의된 광고비 보정 계수	기준값 $\lambda=4.0$ (한국 SMB 퍼포먼스 마케팅 기준: 월 광고비 200 만원 / 제작비 50 만원)

본 연구의 개념적 틀은 'AI-like 리스크 → 신뢰 하락 패널티 → ROI 변화 → 집행 의사결정'으로 확장된다. 초기 분석에서는 성과 패널티 p 를 19.1% 고정값으로 두었지만, 최종 시스템은 이 값을 이미지별 동적 값으로 바꾼다. AI 광고는 AI 처럼 보일수록 신뢰 하락과 CTR·CVR 감소 위험이 커지고, 이 위험은 ROI 계산에서 매출 하락 또는 전환율 하락 패널티로 반영된다.

이 구조는 다음 식으로 표현된다. Human 광고의 매출을 R , 광고 집행비를 A , 인간 제작비를 H 라고 할 때 Human ROI 와 AI ROI 는 각각 다음과 같이 계산된다.

$$Human\ ROI = (R - A - H) / (A + H)$$

$$AI\ ROI = (R \times (1 - p) - A - rH) / (A + rH)$$

$$p_dynamic = base_penalty + AI\text{-}like\ probability \times risk_weight$$

최종 민감도 분석은 위 식에서 H , r , p 를 동시에 변화시키며 AI ROI 가 Human ROI 를 초과하는 지점을 탐색한다. AdTrace AI 구조에서는 p 가 고정값이 아니라 CNN 이 산출한 AI-like probability 에 따라 달라진다. 예를 들어 base penalty 10%, AI-like score 82.7%, weight 15%라면 최종 패널티는 약 22.4%로 계산된다.

III. 연구 설계 / 분석 방법

1. 연구 대상 및 자료 수집

본 연구의 자료는 크게 사용자 행동 로그, 광고 이미지 레퍼런스, 산업군 benchmark, 비용 가정 자료로 구성된다. 사용자 행동 로그는 ROI 및 전환확률 분석에 사용하였고, 광고 이미지 레퍼런스는 CNN 기반 AI-like probability 모델 학습에 사용하였다. 산업군 benchmark 와 비용 가정은 실제 기업 의사결정에 가까운 ROI 시뮬레이션을 구성하기 위해 사용하였다.



연구 단계	활용 자료	분석 목적
문제 정의	생성형 AI 광고 선행연구, AI ROI 연구	AI 광고의 성과 하락과 비용 절감 효과를 동시에 고려
행동 로그 분석	Criteo Attribution Dataset	User Journey, 저관여 행동 집단, 전환확률 모델 구성
ROI 시뮬레이션	AOV, 제작비, 광고비, 산업군 benchmark	Human/AI ROI 비교와 임계점 계산
이미지 인식 모델	AI 광고 124 장, Human 광고 115 장	EfficientNet-B0 기반 AI-like probability 추론
웹 의사결정 시스템	Vercel UI, FastAPI inference, ROI simulator	업로드 광고별 동적 패널티와 집행 적합도 제공
실증 검증 계획	웹 A/B 테스트 행동 로그	CTR, CVR, 구매버튼 행동, ROI 패널티 재보정

초기 데이터 탐색 단계에서는 marketing campaign dataset, influencer marketing ROI dataset, Advertising dataset with character target 등 여러 캠페인형 자료를 비교하였다. 이 자료들은 캠페인 단위 성과와 ROI 변수를 포함한다는 장점이 있었으나, 사용자별 광고 접촉 순서와 전환 전 행동을 충분히 복원하기 어렵다는 한계가 있었다. 이에 최종 분석에서는 사용자 여정 구성이 가능한 Criteo Attribution Dataset 을 선택하였다.

Criteo 변수	의미	분석 활용
timestamp	광고 접촉 시점	User Journey 시간 순서 구성
uid	사용자 ID	사용자 단위 행동 연결
campaign	캠페인 ID	캠페인 단위 ROI 집계
click	클릭 여부	CTR 및 클릭 품질 분류
conversion	전환 여부	전환확률 모델 타깃
conversion_timestamp	전환 발생 시점	전환 이전 행동만 추출
attribution	전환 기여 클릭 여부	high/mid/low 클릭 품질 구분
cost	광고 비용 프록시	광고비와 민감도 분석 기초



2. 분석 도구 및 절차

가. 데이터 전처리와 User Journey 구성

분석 파이프라인은 먼저 Criteo 데이터 80 만 행을 읽고 uid 와 timestamp 기준으로 정렬하였다. 원본 데이터에서 전환이 없는 경우 conversion_timestamp 와 conversion_id 가 -1 로 표시되어 있었으므로 이를 결측값으로 변환하였다. 이후 전환이 발생한 사용자만 추출하고, timestamp 가 conversion_timestamp 이하인 로그만 유지해 전환 이전 여정을 구성하였다.

이 절차는 전환 이후 행동이 분석에 섞이는 것을 방지하기 위한 것이다. 전환 이후 광고 접촉이나 클릭이 전환 예측 피처에 포함되면 실제 운영 상황에서 사용할 수 없는 정보가 모델에 들어가게 된다. 따라서 본 연구는 초기 분석 단계부터 '전환 이전 행동만 유지'를 핵심 전처리 원칙으로 설정하였다.

나. 저관여 행동 집단 분류

관여도 분류는 단순 상품 카테고리가 아니라 행동 지표 기반으로 수행되었다. 클릭 품질은 high, mid, low 로 나누었다. high 는 전환 여정에 포함되고 attribution 이 있는 클릭, mid 는 전환 여정에는 포함되지만 attribution 은 없는 클릭, low 는 단순 클릭 또는 전환과 직접 연결되지 않는 클릭으로 정의하였다.

이후 clicks_before_conversion, decision_time, journey_length, impressions_before_first_click, avg_time_between_clicks, time_last_click_to_conversion 등을 정규화하여 involvement score 를 계산하였다. 점수 하위 30%는 저관여, 중위 40%는 중관여, 상위 30%는 고관여로 분류하였다. 이때 본 연구의 '저관여'는 엄밀히 말해 저관여 제품 그 자체가 아니라 저관여적 소비 패턴을 보이는 행동 집단이다.

다. Human/AI ROI 시뮬레이션과 통계 검정

Human 광고는 원본 광고 성과를 기준선으로 사용하였다. AI 광고는 동일한 광고 접촉 구조를 유지하되, 선행연구에서 제시된 AI 인식에 따른 성과 하락 효과를 반영하여 19.1%의 성과 패널티를 적용하고, 제작비를 낮추는 방식으로 반사실적 AI 광고 시나리오를 구성하였다. 초기 baseline 분석에서는 인간 제작비를 캠페인당 50 만 원, AI 제작비를 인간 제작비의 50%인 25 만 원으로 설정하였다. 인간 제작비 50 만 원은 국내 프리랜서 광고·디자인 제작비와 퍼포먼스 에이전시 제작비 범위를 함께 고려한 보수적 기준값으로, 저관여 소비재 광고 소재를 외주 제작하는 상황을 반영한다. 제작비 범위의 세부 설정 근거 및 3 변수 민감도 분석 단계에서의 H 조정 구간은 이후 마. Benchmark-adjusted ROI 단계에서 확장하였다.

초기 AOV 는 저관여 소비재의 평균 주문금액을 보수적으로 반영하기 위해 60 달러로 설정하였고, 2025 년 3 월 15 일 기준 환율 1,509 원을 적용하여 원화 기준 전환당 매출로 환산하였다. 이 기준값은 초기 Human/AI ROI 시뮬레이션을 위한 공통 가정이며, 이후 분석에서는 산업군 benchmark CVR 및 AOV 를 결합한 Benchmark-adjusted ROI 구조로 확장하였다.

이후 캠페인 단위로 CTR, CVR, CPA, ROAS, ROI 를 계산한 뒤 Human ROI 와 AI ROI 의 차이를 검정하였다. 검정에는 one-sample t-test, paired t-test, Wilcoxon signed-rank test 를 사용하였다. one-sample t-test 는 Human baseline 자체가 수익성을 가지는지를 확인하기 위한 절차이며, paired t-test 는 동일 캠페인에 AI 시나리오를 적용하였을 때 ROI 차이가 통계적으로 유의한지를 검정하기 위한 절차이다. Wilcoxon signed-rank test 는 ROI 분포가 정규성을 충족하지 않을 가능성을 고려하여, 비정규 분포에서도 Human 과 AI 간 차이가 유지되는지를 확인하기 위해 사용하였다.

라. Snapshot 기반 전환확률 예측 모델

단순 ROI 계산의 한계를 보완하기 위해 전환확률 예측 모델을 도입하였다. 본 연구는 Logistic Regression, Random Forest, XGBoost 를 비교 검토한 뒤 최종 모델을 선정하였다. 모델 비교 과정에서 Random Forest 와 XGBoost 는 일부 validation 구간에서 높은 성능을 보였으나, 희귀 전환 데이터에서 fold 또는 hold-out 구성에 따라 성능 변동이 컸고 top-k 타게팅 성능이 안정적으로 유지되지 않는 문제가 있었다. 특히 tree 기반 모델은 복잡한 상호작용을 포착하는 장점이 있지만, 본 연구처럼 양성 전환 비율이 매우 낮고 이후 ROI 계산에 확률값과 ranking 을 연결해야 하는 상황에서는 과적합과 해석 가능성 저하가 의사결정 리스크로 작용하였다. 반면 Logistic Regression 은 규제(L2 및 Elastic Net)와 class weight 를 조정하면서도 변수 방향성과 영향 해석이 가능하였고, test ROC-AUC 0.749, PR-AUC 0.026(랜덤 기준선 대비 약 3.2 배), Top-10% Lift 3.73 으로 downstream ROI 분석에 필요한 ranking 안정성을 확보하였다. 따라서 최종 모델은 성능 수치 하나만이 아니라 누수 방지, 일반화 안정성, 해석 가능성, ROI 파이프라인 연결성을 종합해 Logistic Regression 으로 선정하였다.

Logistic Regression 기반 snapshot 모델은 처음 5 회 광고 접촉만을 사용한다. 3 회 관측은 정보가 부족하고, 7 회 관측은 AUC 가 높아 보이지만 실제 top-10% 타게팅 성능이 무너지는 문제가 있었다. 따라서 5 회 snapshot 은 현실적이고 안정적인 관측 범위로 선택되었다.

또한, 추가 피처로 clicked_ratio_first_k, click_rate_per_min_first_k, cost_per_click_first_k, campaign_diversity_ratio_first_k 가 도입되었다. 이는 단순 클릭 수가 아니라 초기 반응 비율, 반응 속도, 클릭 효율, 캠페인 다양성을 반영하기 위한 것이다. heavy-tail 을 가진 비용·시간 변수에는 log1p 변환을 적용해 분포 안정성을 높였다.



마. Benchmark-adjusted ROI 와 민감도 분석

전환확률 모델의 pred_proba 는 사용자 간 상대적 전환 가능성을 나타내지만, 산업군의 실제 CVR 과 반드시 일치하지 않는다. 따라서 본 연구는 내부 propensity score 를 산업군 benchmark CVR 에 맞추어 보정하였다. 이 과정은 Criteo 모델이 제공하는 ranking 정보와 산업군의 현실적 평균 전환율·AOV 를 결합하는 절차이다.

산업군 benchmark CVR 및 AOV 는 Blend Commerce 2026 CRO Benchmarks 의 산업군별 CVR 및 AOV 를 Base 기준으로 사용하였다. Dynamic Yield XP² Conversion Rate Benchmarks 의 산업군별 CVR 은 보조 검증값 및 Optimistic 시나리오 참고값으로 반영하였으며, IRP Commerce 의 e-commerce CVR benchmark 는 외부 전환율 범위 점검 자료로 참고하였다. 즉, 내부 모델의 pred_proba 는 사용자 간 상대적 구매 가능성, 즉 ranking 정보를 제공하고, 산업군 benchmark 는 현실적인 절대 전환율과 객단가를 제공한다. 본 연구는 이를 Food & Beverage / Base 시나리오의 benchmark CVR 및 AOV 와 결합하여 기대 전환 수와 기대 매출로 변환하였다.

최종 단계에서는 AI 가 경제적으로 우위가 되는 임계 조건을 계산하기 위해 인간 제작비 H, AI 제작비 비율 r, AI 성과 패널티 p 를 동시에 변화시키는 3 변수 민감도 분석을 수행하였다. 인간 제작비 H 는 20 만~150 만 원으로 설정하였으며, 이는 프리랜서 제작비 20 만~50 만 원(크몽 평균 및 숨고 평균 약 32 만 원)과 국내 퍼포먼스 에이전시 제작비 50 만~150 만 원 범위를 포괄하기 위한 것이다. 다. Human/AI ROI 시뮬레이션 단계에서 baseline 으로 사용한 H=50 만 원은 이 범위 내에서 프리랜서 제작비와 에이전시 제작비의 경계에 해당하는 보수적 기준값이다. AI 제작비 비율 r 은 3%, 5%, 10%, 20%, 30%, 50%로 설정하여 다양한 제작비 절감 시나리오를 반영하였다. AI 성과 패널티 p 는 0%~40% 범위에서 5% 단위로 변화시켜, 성과 하락이 거의 없는 경우부터 소비자 신뢰 저하가 크게 발생하는 보수적 상황까지 검토하였다.

또한 Criteo cost 는 실제 캠페인 광고비나 제작비와 스케일이 다르기 때문에, 광고비 A 를 $H_{\text{baseline}} \times \lambda$ 로 재정의하였다. 기준 λ 는 4.0 으로 설정하였다. 이는 중규모 SMB 퍼포먼스 마케팅 상황에서 광고비가 제작비의 약 4 배 수준이라는 가정을 반영한 것이다. $\lambda=1$ 일 때 H 임계값은 약 118,000 원, $\lambda=4$ 일 때 약 473,000 원으로 나타났으며, λ 선택에 따라 breakeven_p 탐색 가능 여부와 AI 우위 가능 구간이 달라진다.



3. CNN 기반 웹 의사결정 시스템 설계

가. CNN 기반 AI-like probability 추론

프로토타입 개발 단계에서 ROI 분석을 실제 서비스형 시스템으로 확장하였다. 기존에는 19.1% 성과 패널티를 기준값으로 두고 민감도 분석을 수행하였지만, 실제 기업 환경에서는 광고 이미지마다 AI 처럼 보이는 정도가 다르다. 따라서 최종 시스템은 기업이 업로드한 광고 이미지의 AI-like probability 를 CNN 으로 추론하고, 이 확률을 이미지별 성과 패널티에 반영하도록 설계되었다.

이미지 분류 모델은 EfficientNet-B0 transfer learning 구조를 사용하였다. ImageNet 사전학습 backbone 위에 광고 분류용 classifier head 를 올리고, backbone freeze 단계, last blocks fine-tuning 단계, full fine-tuning 단계를 거쳐 광고 이미지의 AI-like 신호를 학습하였다. 학습 데이터는 AI 광고 124 장, 인간 제작 광고 115 장, 총 239 장의 curated reference dataset 으로 구성되었다.

모델은 광고 이미지가 AI 광고처럼 보일 확률, confidence, risk band 를 출력한다. 내부 full-set TTA accuracy 는 95.0%, 5-fold CV 평균은 73.3%였다. 이는 내부 레퍼런스 구분 가능성은 높지만, 실제 매체 광고 전체로 일반화하려면 외부 hold-out set 과 카테고리별 calibration 이 필요하다는 점을 함께 보여준다.

나. 웹사이트 연동과 ROI 대시보드

웹 시스템은 Vercel 기반 React/Vite 프론트엔드, serverless proxy, FastAPI CNN inference service 로 구성된다. 사용자가 JPG, PNG, WebP 형식의 광고 이미지를 업로드하면, 프론트엔드가 해당 이미지를 추론 API 로 전달하고, FastAPI 서버는 EfficientNet-B0 모델을 이용해 업로드된 크리에이티브의 AI-like probability 를 계산한다. 이후 결과 화면은 업로드된 크리에이티브, AI 유사도 리스크 점수, 분석 근거, 월 매출·광고비 기반 ROI 적합도, 발견 이슈와 수정 제안을 함께 제시한다.

AI 유사도 리스크 점수는 광고 이미지가 소비자에게 AI 생성물처럼 인식될 가능성을 0~100 점으로 환산한 지표이다. 점수가 높을수록 이미지의 시각적 비자연성, 합성 흔적, 브랜드 신뢰 저하 가능성이 크다는 의미로 해석한다. 본 연구는 최종 점수를 비주얼 아티팩트 30%, 조명·그림자 일관성 20%, 인물 디테일 20%, 문구 자연스러움 15%, 브랜드 신뢰도 15%의 가중합으로 산출하도록 설계하였다.

비주얼 아티팩트 항목은 제품 경계의 뭉개짐, 패키지 구조의 어색함, 배경 패턴의 비현실적 반복, 로고·라벨·텍스트의 깨짐, 과도하게 매끈한 질감 등 AI 생성 이미지에서 자주 관찰되는




시각적 결함을 평가한다. 조명·그림자 일관성 항목은 제품과 배경의 광원 방향, 그림자 강도, 반사와 하이라이트, 피사체 경계가 하나의 촬영 환경 안에서 자연스럽게 통합되어 있는지를 확인한다. 인물 디테일 항목은 손, 얼굴, 피부, 시선, 신체 비율 등 인물이 포함된 광고에서 AI 생성 흔적이 나타나기 쉬운 세부 요소를 평가한다. 문구 자연스러움 항목은 광고 카피, 제품명, 라벨 문구가 정상적으로 읽히고 브랜드 맥락에 맞게 배치되어 있는지를 판단하며, 브랜드 신뢰도 항목은 전체 이미지가 실제 브랜드 광고로서 충분한 완성도와 진정성을 갖추었는지를 종합적으로 평가한다.

따라서 본 시스템의 AI 유사도 리스크 점수는 단순히 이미지가 AI로 생성되었는지를 이분법적으로 판정하는 값이 아니라, 광고 집행 시 소비자가 느낄 수 있는 시각적 어색함과 신뢰 저하 가능성을 정량화한 위험 지표이다. 점수는 Low, Medium, High, Critical의 네 단계 리스크 밴드로 변환된다. Low는 일반 집행 가능, Medium은 일부 요소 수정 또는 A/B 테스트 권장, High는 배포 전 수정 필요, Critical은 재제작 또는 강한 human realism 보장 권장으로 해석된다. 다만 이 threshold는 모델이 산출한 절대적 진실값이 아니라, 광고 집행 전 수정·검수·테스트 여부를 결정하기 위한 operating point이다.

ROI 통합 구조에서는 AI-like probability와 리스크 점수가 이미지별 trust penalty로 변환된다. 본 시스템은 $p = \text{base_penalty} + \text{ai_like_score} \times \text{weight}$ 구조를 사용한다. 예를 들어 base penalty가 10%, AI-like score가 82.7%, risk weight가 15%이면 최종 penalty는 약 22.4%로 계산된다. 이 값은 ROI 임계점 분석에서 AI 성과 페널티 p로 입력되므로, 동일한 제작비 절감 효과를 가진 AI 광고라 하더라도 AI 처럼 보이는 정도가 높을수록 더 큰 성과 하락 위험을 반영하게 된다. 결과적으로 대시보드는 단순히 광고 이미지의 AI 여부를 판정하는 도구가 아니라, 이미지별 리스크를 ROI 의사결정 변수로 전환하여 기업이 집행, 수정, A/B 테스트, 재제작 여부를 판단하도록 돕는 의사결정 시스템으로 기능한다.

Risk band	Score range	운영 해석
Low	0-30	AI-like 신호가 낮아 일반 집행 가능
Medium	31-60	일부 요소 수정 또는 A/B 테스트 권장
High	61-80	비진정성 리스크가 커 배포 전 수정 필요
Critical	81-100	재제작 또는 강한 human realism 보장 권장

AdTrace AI 시스템 구조: AI-like probability → trust penalty → ROI decision



검증 계획: 웹 A/B 테스트에서 인간 광고와 AI 광고를 랜덤 노출하고 CTR·CVR·구매버튼 클릭·ROI 패널티를 관측해 weight를 재보정
현재 19.1%는 고정 결론이 아니라 초기 기준값이며, 최종 시스템은 업로드 이미지별 동적 패널티를 산출한다.

[그림 1] AdTrace AI 시스템 구조

IV. 연구 결과 / 실증 분석

1. 자료의 특성

최종 분석에 사용된 Criteo 데이터셋은 약 80 만 행의 광고 접촉 로그로 구성되며, 이 중 다수 행은 전환이 발생하지 않은 일반 노출·클릭 기록이다. 따라서 conversion_id, conversion_timestamp, attribution 등 전환 관련 변수는 비전환 로그에서 구조적으로 비어 있다. 본 연구는 이를 단순 결측치로 제거하지 않고, 전환 여부를 구분하는 로그 구조의 특성으로 해석하였다.

전환 사용자 중 전환 이전 행동만 유지한 df_journey 는 39,263 행으로 구성되었다. 이후 관여도 점수 하위 30%를 저관여 행동 집단으로 추출한 결과 9,755 행이 분석 대상이 되었다. 이 집단은 저관여 제품 그 자체가 아니라 빠른 반응, 짧은 탐색, 낮은 접촉량을 보이는 저관여적 소비 패턴 집단으로 해석된다.

전환확률 모델용 snapshot 데이터는 4,926 명 규모였고, 이 중 양성 전환은 37 건으로 전체 양성률은 약 0.75%였다. 이는 전환 예측이 전형적인 희귀 이벤트 문제임을 의미한다. 따라서 모델 평가는 정확도보다 ROC-AUC, PR-AUC, Brier Score, top-k 성능을 중심으로 이루어졌다.

분석 단계	규모	해석
원자료 표본	800,000 행	Criteo 광고 접촉 로그
전환 이전 여정	39,263 행	전환 사용자 중 전환 이전 행동만 유지
저관여 행동 집단	9,755 행	관여도 점수 하위 30%
ROI 비교 캠페인	534 개	저관여 집단의 캠페인 단위 분석
Snapshot 모델 표본	4,926 명	초기 5 회 터치 기반 전환확률 예측
Snapshot 양성 전환	37 건	희귀 이벤트 구조

2. 분석 결과


가. Human 광고와 AI 광고의 ROI 비교

캠페인 단위 비교에서 Human ROI 평균은 0.1026, AI ROI 평균은 0.3438 로 나타났다. 평균 Delta ROI 는 0.2412 였으며, 534 개 캠페인 중 91.4%에서 AI ROI 가 Human ROI 보다 높았다. 집계 기준으로도 Human ROI 는 0.7583, AI ROI 는 0.9763 으로 AI 가 더 높았다.

paired t-test 결과 p-value 는 $2.91e-50$ 이었고, Wilcoxon signed-rank test 의 p-value 는 $1.83e-63$ 이었다. 이는 동일 캠페인에 AI 성과 패널티와 제작비 절감 구조를 적용했을 때 ROI 차이가 통계적으로 매우 유의하다는 것을 의미한다.

다만 이 결과는 AI_PRODUCTION_RATIO=0.50 일 때의 수치이며, 이후 reduction_rate=0.10 으로 보수적 재설정 시 revenue/cost ratio 기준 Human 약 21.31, AI 약 146.55 로 재계산되었다.

지표	Human	AI	해석
집계 ROI	0.7583	0.9763	AI 가 집계 비용 효율에서 우위
캠페인 평균 ROI	0.1026	0.3438	평균 차이 +0.2412
ROI 중앙값	-0.4616	-0.1541	AI 분포가 상대적으로 우측 이동
AI 우위 캠페인 비율	-	91.4%	대부분 캠페인에서 Delta ROI > 0
Paired t-test p-value	-	$2.91e-50$	Human/AI ROI 차이 유의
Wilcoxon p-value	-	$1.83e-63$	비모수 검정에서도 차이 유지
재계산 (r=10%)	revenue/cost ≈ 21.31	revenue/cost ≈ 146.55	보수적 reduction_rate 적용 결과



[그림 2] Human ROI 와 AI ROI 분포 비교

나. 전환확률 모델과 Benchmark-adjusted ROI

최종 Logistic Regression 모델은 Human snapshot 기준 ROC-AUC 0.7491, PR-AUC 0.0256 을 보였다. AI 데이터셋 기준 ROC-AUC 는 0.7641, PR-AUC 는 0.0280 이었다. calibration 전후 AUC 는 거의 유지되었고, AI 데이터에서는 Log Loss 와 Brier Score 가 소폭 개선되었다. 이는 calibration 이 ranking 성능을 높이는 절차라기보다 확률값을 현실적인 입력값으로 보정하는 단계임을 보여준다.

Benchmark-adjusted ROI 에서는 내부 propensity score 를 산업군 benchmark CVR 에 맞춰 보정하였다. Food & Beverage/Base 기준에서 LR ROI 평균은 20.31, 중앙값은 14.72 로 산출되었다. 세그먼트별 평균 매출은 Bottom 20% 486 만 원, Middle 60% 863 만 원, Top 20% 2,353 만 원으로 나타났다.

다. 3 변수 민감도 분석과 임계점


민감도 분석 단계에서 H 는 20 만~150 만 원, r 은 3%~50%, p 는 0~40% 범위로 설정되었다. 기준 분석에서는 A=200 만 원, $\lambda=4.0$, R=10,869,327 원을 사용하였다. 총 756 개 조합($H \times r \times p = 14 \times 6 \times 9$)에 대해 Human ROI 와 AI ROI 가 계산되었다.

여기서 인간 제작비 H 의 범위는 프리랜서 제작비 20~50 만 원(크몽 평균 및 숨고 평균 약 32 만 원)과 국내 퍼포먼스 에이전시 제작비 50~150 만 원을 포괄하도록 20 만~150 만 원으로 설정하였다. AI 제작비 비율 r 은 Zocket 2026, Best Buy, Target 2024 사례에서 언급된 22~62% 제작비 절감 범위를 참고하되 보수적 하한을 포함하기 위해 3%, 5%, 10%, 20%, 30%, 50%로 구성하였다. 그리고 AI 성과 패널티 p 는 Taboola 2026의 AI CTR 우위 사례를 패널티 없음(0%)의 하한으로 두고, AmraElma 2025의 구매의도 및 신뢰도 하락 범위, IAB 2026의 Gen Z 비진정성 인식 25~35%를 고려하여 보수적 상한을 40%로 설정하였다.

$p=19.1\%$ 고정 조건에서 H 가 20 만~40 만 원일 때는 AI 제작비가 0에 가까워도 AI가 Human ROI를 이기기 어려웠다. $H=50$ 만 원에서는 최대 허용 r 이 4.5%였고, $H=100$ 만 원에서는 42.7%, $H=150$ 만 원에서는 55.4%까지 상승하였다. 즉 인간 제작비가 높을수록 AI가 성과 패널티를 감수하면서도 ROI 우위를 확보할 여지가 커진다.


성과 패널티 p 별 AI 우위 조합 비율은 $p=0\%$ 에서 100%, $p=10\%$ 에서 89.3%, $p=20\%$ 에서 57.1%, $p=30\%$ 에서 25.0%, $p=40\%$ 에서 2.4%였다. breakeven_p (각 $H \cdot r$ 조합에서 AI가 Human ROI를 이길 수 있는 최대 허용 패널티)의 중앙값은 22.2%로, 기준 패널티 19.1%보다 높았다. 이는 절반 이상의 조합에서 현재 기준 패널티를 적용해도 AI 우위가 가능함을 의미한다.

인간 제작비 H	Human ROI	최대 허용 r	판단
20 만 원	394.1%	AI 불가	AI 우위 어려움
30 만 원	372.6%	AI 불가	AI 우위 어려움
40 만 원	352.9%	AI 불가	AI 우위 어려움
50 만 원	334.8%	4.5% ($\lambda=4.0$ 기준)	매우 낮은 AI 비용 필요
70 만 원	302.6%	26.3%	AI 우위 가능
100 만 원	262.3%	42.7%	AI 우위 가능성 높음
120 만 원	239.7%	49.1%	AI 우위 안정화
150 만 원	210.6%	55.4%	AI 비용 여유 큼




[그림 3] 제작비 × AI 패널티 민감도 종합

3변수 민감도 종합 | A=200만원 / λ=4.0



[그림 4] 패널티별 AI 우위 구간 비율 및 breakeven_p 분포




[그림 5] λ 변화에 따른 breakeven_p 민감도

3. 시스템 적용 가능성과 검증 계획

AdTrace AI는 분석 결과를 실제 기업용 의사결정 흐름으로 연결했다는 점에서 적용 가능성이 있다. 기업은 광고 이미지를 업로드하고, CNN이 산출한 AI-like probability와 risk band를 확인한 뒤, 제작비·광고비·예상 매출을 입력해 ROI 임계점을 계산할 수 있다. 즉 시스템은 AI 광고를 감각적으로 거르는 도구가 아니라, AI처럼 보이는 정도를 확률과 비용 변수로 번역하는 대시보드이다.

다만 현재 CNN 모델은 curated reference dataset 기준으로 학습·검증되었기 때문에 외부 일반화에는 한계가 있다. 내부 full-set TTA accuracy 95.0%와 5-fold CV 평균 73.3%의 차이는 이 한계를 보여준다. 내부 레퍼런스 구분에는 강하지만, 실제 매체 광고, 브랜드별 광고 스타일, 카테고리별 시각 문법으로 확장하려면 외부 hold-out set과 카테고리별 threshold calibration이 필요하다.

또한 현재 AI-like score가 CTR, CVR, ROI를 얼마나 떨어뜨리는지에 대한 직접 근거는 주로 선행논문과 이론적 가정에 의존한다. 이는 실무 적용에서 신뢰도를 낮출 수 있다. 따라서 최종 검증 단계에서는 웹 A/B 테스트를 통해 실제 소비자 행동 데이터를 수집해야 한다. 사용자에게 인간 제작 광고와 AI 광고를 랜덤으로 노출하고, 노출, 클릭, 구매 버튼 클릭, 전환 의향, 실제 구매 또는 모의 구매 행동을 기록하여 AI-like score별 CTR, CVR, ROI 패널티를 추정한다.



[그림 6] 실제 Adtrace AI 웹사이트 화면

가. 사전 소비자 설문 기반 Human/AI 광고 선호 분석

웹 A/B 테스트에 앞서 본 연구는 Human 광고와 AI 광고에 대한 소비자 반응을 보조적으로 확인하기 위해 구매 유도 광고 선호도 설문조사를 실시하였다. 설문에는 총 414 명이 응답하였으며, 응답자는 5 개의 광고 비교 문항에서 구매를 더 유도한다고 느껴지는 광고를 선택하였다. 선택지 위치에 따른 편향을 줄이기 위해 1 번, 3 번, 5 번 문항에서는 1 번을 Human 광고, 2 번을 AI 광고로 제시하였고, 2 번과 4 번 문항에서는 1 번을 AI 광고, 2 번을 Human 광고로 제시하였다.

분석 결과 전체 2,070 건의 광고 선택 중 Human 광고 선택은 1,177 건(56.9%), AI 광고 선택은 893 건(43.1%)으로 나타났다. 응답자 단위로 보아도 5 개 문항 중 Human 광고를 더 많이 선택한 응답자는 235 명, AI 광고를 더 많이 선택한 응답자는 179 명으로 Human 광고 선호가 다소 우세하였다. 다만 문항별 결과는 일관된 방향으로만 나타나지 않았다. 1 번, 2 번, 5 번 문항에서는 Human 광고가 각각 58.2%, 89.1%, 60.9%의 선택률을 보였으나, 3 번과 4 번 문항에서는 AI 광고가 각각 60.9%, 63.0%의 선택률을 보였다. 이는 AI 광고가 모든 상황에서 낮은 구매 유도력을 보이는 것이 아니라, 소재의 완성도와 시각적 자연스러움에 따라 Human 광고보다 더 높은 선호를 얻을 수도 있음을 의미한다.

문항	Human 선택률	AI 선택률	우세 광고	해석
1 번	58.2%	41.8%	Human	Human 우세
2 번	89.1%	10.9%	Human	Human 압도적 우세
3 번	39.1%	60.9%	AI	AI 우세
4 번	37.0%	63.0%	AI	AI 우세
5 번	60.9%	39.1%	Human	Human 우세

특히 2 번 문항에서는 Human 광고가 2 번 위치에 제시되었음에도 89.1%의 선택률을 기록하였고, 4 번 문항에서는 AI 광고가 1 번 위치에 제시되었음에도 63.0%의 선택률을 기록하였다. 따라서 본 설문 결과는 단순한 선택지 위치 편향만으로 설명되기 어렵고, 광고 소재 자체의 시각적 품질과 구매 유도력 차이가 응답자의 선택에 영향을 미쳤을 가능성을 보여준다.

또한 응답 과정에서 AI 로 제작되었다고 느껴진 광고가 있었는지 묻는 문항에서는 ‘어느 정도 있었다’가 176 명, ‘매우 많았다’가 162 명으로 나타나 전체 응답자의 81.6%가 AI 제작 광고의 존재를 일정 수준 이상 인식한 것으로 확인되었다. AI 제작 인식 정도와 Human 광고 선택 수 사이에는 완만한 양의 관계가 관찰되었으며($r \approx 0.31$), AI 제작 느낌을 강하게 인식한 집단일수록 Human 광고 선택 비율이 높아지는 경향이 나타났다. 다만 이는 상관관계이므로 AI 인식이 Human 광고 선호를 직접적으로 유발한다고 단정하기보다, AI-like 인식이 광고 선호와 일정 부분 관련될 수 있음을 보여주는 보조적 근거로 해석하는 것이 적절하다.

따라서 본 설문 결과는 본 연구의 핵심 가정, 즉 AI 광고의 경제성은 단순 제작비 절감만으로 판단할 수 없으며 소비자가 AI 생성물처럼 인식하는 정도를 함께 고려해야 한다는 점을 보완적으로 뒷받침한다. 동시에 일부 문항에서는 AI 광고가 Human 광고보다 높은 선택률을 보였으므로, AI 광고를 일괄적으로 배제하기보다 이미지별 AI-like risk score 와 구매 유도 반응을 함께 측정하여 집행 여부를 판단하는 접근이 필요하다. 이러한 결과는 향후 웹 A/B 테스트에서 AI-like score 별 CTR, CVR, 구매 버튼 클릭 및 ROI 패널티를 직접 검증해야 하는 이유를 강화한다.

검증 요소	측정 방식	활용 목적
광고 노출	웹 A/B 테스트에서 Human/AI 광고 랜덤 노출	노출 조건 통제
CTR	광고 클릭 수 / 광고 노출 수	AI-like score 가 초기 반응에 미치는 영향 검증
CVR	구매 버튼 클릭 또는 구매 행동 / 클릭 수	AI-like score 가 전환 행동에 미치는 영향 검증
ROI penalty	Human 조건 대비 AI 조건의 ROI 하락률	CNN score $\rightarrow$ trust penalty weight 재보정
세그먼트 차이	저관여/중관여/고관여 또는 카테고리별 비교	제품군별 threshold calibration
정성 반응	광고 신뢰도, 자연스러움, AI 인식 여부 설문	행동 데이터와 인식 데이터 연결

4. 결과에 대한 논의

첫째, baseline 에서 AI 광고가 높은 ROI 를 보인 것은 AI 광고가 광고 성과 자체에서 더 우수하다는 의미가 아니다. 본 연구는 AI 광고 성과를 오히려 19.1% 낮추어 계산하였다. 그럼에도 ROI 가 높게 나타난 것은 제작비 절감으로 비용 분모가 크게 낮아졌기 때문이다. 따라서 결과는 AI 의 성과 우수성이 아니라 AI 의 비용 구조 우위를 보여준다.

둘째, 19.1% 성과 패널티는 최종 고정값이 아니라 선행연구에서 출발한 초기 기준값으로 해석되어야 한다. 본 프로젝트는 AI-like probability 를 이미지별 동적 패널티로 변환하는 방향으로 발전하였다. 따라서 어떤 AI 광고는 사람 광고처럼 자연스러워 낮은 패널티를 받을 수 있고, 어떤 광고는 AI 특유의 synthetic cue 가 강해 19.1%보다 높은 패널티를 받을 수 있다.

셋째, AI 광고의 경제적 우위는 인간 제작비가 높은 상황에서 강화된다. 인간 제작비가 낮은 간단한 소재 제작에서는 AI 가 절감할 수 있는 금액이 작아 성과 패널티를 상쇄하기 어렵다. 반면 에이전시 외주, 다량 소재 제작, 반복 테스트 캠페인처럼 제작비 부담이 큰 상황에서는 AI 도입의 ROI 효과가 커진다.

넷째, 광고비/제작비 비율 λ 가 커질수록 제작비 절감 효과는 상대적으로 약해진다. $\lambda=1, 2, 4, 6$ 별로 breakeven_p 히트맵을 비교한 결과, λ 가 클수록 H 임계값이 상승하고 AI 우위 가능 구간이 축소되는 것을 확인하였다. 대규모 광고비 집행 캠페인에서는 제작비 절감 효과가 희석되므로, AI 도입 여부는 소재 품질·브랜드 신뢰·전환율 유지 여부에 더 크게 좌우된다.

다섯째, Top 20% 고가치 세그먼트에서는 기대 매출이 크기 때문에 AI 성과 패널티로 인한 손실의 절대 규모도 크다. 따라서 AI 광고는 모든 타겟에 일괄 적용하기보다, 낮은 위험의 반복 제작 영역에서 먼저 테스트하고 고가치 타겟에는 인간 검수와 후처리를 결합한 hybrid creative 방식으로 적용하는 것이 합리적이다.

V. 결론

1. 연구 요약

본 연구는 생성형 AI 광고의 ROI 순위 조건을 분석하고, 이를 CNN 기반 AI-like 리스크 측정 시스템으로 확장하였다. 초기 단계에서는 AI 광고의 성과 하락 가능성과 제작비 절감 효과를 동시에 고려하는 ROI 구조를 설계하였다. 이후 클릭 품질, 관여도 분류, snapshot 전환확률 모델, calibration, 산업군 benchmark 보정을 결합하여 ROI 임계점 분석을 고도화하였다. 마지막으로 광고 이미지별 AI-like probability를 산출하는 웹 프로토타입을 구축해 분석 결과를 기업 의사결정 화면으로 연결하였다.

분석 결과 AI 광고는 평균 ROI에서 Human 광고보다 높았고, 캠페인의 91.4%에서 우위를 보였다. 그러나 민감도 분석은 AI 우위가 무조건적이지 않음을 보여주었다. AI 우위는 인간 제작비가 충분히 높고, AI 제작비 비율이 낮으며, 성과 패널티가 일정 수준 이하일 때 강하게 나타난다. 최종 시스템에서 이 성과 패널티는 19.1% 고정값이 아니라 광고 이미지의 AI-like probability에 따라 조정되는 동적 값으로 재정의되었다.

따라서 본 연구의 결론은 AI 광고가 인간 광고를 전면 대체해야 한다는 것이 아니다. 생성형 AI 광고는 제작비 절감 효과가 이미지별 신뢰 하락 패널티를 초과하는 조건에서 ROI를 개선할 수 있는 도구이다. 기업은 AI 도입 여부를 유행이나 감각적 판단이 아니라 CNN 기반 AI-like score, 제작비 H , AI 제작비 비율 r , 동적 패널티 p , 광고비/제작비 비율 λ 를 이용한 임계점 기반 의사결정으로 판단해야 한다.

2. 정책적 제언 및 시사점

첫째, 기업은 AI 광고 도입 전 자사 캠페인의 제작비와 광고비 구조를 분리해 측정해야 한다. 제작비 비중이 높을수록 AI 도입의 경제적 가치가 커지지만, 광고비 비중이 지나치게 높으면 제작비 절감 효과가 제한된다.

둘째, 기업은 AI 광고 소재를 업로드해 AI-like probability 와 risk band 를 확인한 뒤 집행 여부를 판단할 수 있다. Low 구간은 일반 집행, Medium 구간은 A/B 테스트, High 구간은 수정 후 집행, Critical 구간은 재제작 또는 human realism 보강으로 연결하는 방식이 적절하다.

셋째, AI 광고는 controlled test, pilot, scale-up 순서로 도입하는 것이 바람직하다. 먼저 동일 타겟과 동일 예산 조건에서 Human 소재와 AI 소재의 웹 A/B 테스트를 수행해 실제 CTR, CVR, 구매 버튼 클릭, ROI 패널티를 측정해야 한다. 이후 실측 패널티가 임계값 이하이고 제작비 절감 효과가 충분한 세그먼트에서 제한적으로 확대해야 한다.

넷째, AI 광고는 단순 대체가 아니라 hybrid workflow 로 운영될 때 실무적 가치가 높다. AI 는 다량의 초기 시안 제작과 반복 테스트에 활용하고, 인간 제작자는 브랜드 적합성, 이미지 품질, 카피 톤앤매너, 고가치 타겟 캠페인의 최종 검수에 집중하는 방식이 적절하다.

3. 연구의 한계 및 향후 과제

첫째, 본 연구는 실제 AI 광고와 인간 광고를 무작위 배정한 실험이 아니라 기존 인간 광고 로그에 AI 패널티와 제작비 절감 가정을 적용한 반사실적 시뮬레이션이다. 따라서 결과는 실제 시장에서 관찰된 AI 광고 효과가 아니라 주어진 가정하의 의사결정 기준으로 해석해야 한다.

둘째, AI 성과 패널티 19.1%는 선행연구에서 출발한 초기 기준값이다. 본 프로젝트는 CNN 기반 동적 패널티 구조로 확장되었지만, AI-like probability 가 실제 CTR·CVR·ROI 를 얼마나 떨어뜨리는지는 아직 웹 A/B 테스트로 검증되어야 한다.

셋째, CNN 모델은 AI 124 장, Human 115 장, 총 239 장의 curated reference dataset 으로 구축되었다. 내부 full-set TTA 정확도는 높지만, 5-fold CV 평균이 73.3%인 점을 고려하면 외부 광고 데이터로의 일반화는 보수적으로 해석해야 한다. 향후 실제 집행 광고 hold-out set, 카테고리별 calibration, Grad-CAM/SHAP 기반 설명가능성 보강이 필요하다.

넷째, Criteo 데이터의 cost 는 실제 캠페인 광고비나 제작비와 스케일이 다르다. 본 연구는 $\lambda=4.0$ 기반 A_ref 재정의로 이를 보완하였고, λ 민감도 분석($\lambda=1, 2, 4, 6$)을 통해 λ 선택이 breakeven_p 결과에 미치는 영향을 정량화하였다. 실제 기업의 회계 데이터와 광고 집행 데이터를 확보한다면 더 정교한 ROI 분석이 가능하다.

다섯째, 본 연구의 저관여 집단은 상품 카테고리가 아니라 행동 패턴으로 정의되었다. 향후에는 제품 가격, 브랜드 관여도, 소비자 설문, 실제 상품군 정보를 결합해 저관여 개념을 더 엄밀하게 측정할 필요가 있다.



참고문헌

- Atlan, D. (2026). AI ROI Analysis: Evidence from 200 B2B Deployments (2022-2025).
- Criteo. Criteo Attribution Dataset.
- Zhang et al. (2025). The impact of generative AI images on consumer attitudes, trust, and purchase intention in advertising.
- Zaichkowsky, J. L. (1985). Measuring the involvement construct. *Journal of Consumer Research*.
- Petty, R. E., & Cacioppo, J. T. (1986). *Communication and Persuasion: Central and Peripheral Routes to Attitude Change*. Springer.
- Howard, J. A., & Sheth, J. N. (1969). *The Theory of Buyer Behavior*. Wiley.
- Zocket (2026). State of AI Ad Creation. <https://www.zocket.com/blog/state-of-ai-ad-creation>
- IAB (2026). The AI Gap Widens. <https://www.iab.com/insights/the-ai-gap-widens/>
- AmraElma (2025). AI-Generated Ad Creative Performance Statistics. <https://www.amraandelma.com/ai-generated-ad-creative-performance-statistics/>
- Wen, H., Lin, Z., & Liu, Y. (2023). Machine-Learning-Based Approach for Anonymous Online Customer Purchase Intentions Using Clickstream Data. *Systems*.
- Niculescu-Mizil, A., & Caruana, R. (2005). Predicting Good Probabilities with Supervised Learning. *Proceedings of the 22nd International Conference on Machine Learning*.
- 김지연, 홍승아, 김하민. (2019). 합성곱신경망 기반의 StyleGAN 이미지 탐지모델. *멀티미디어학회논문지*, 22(12), 1447-1456.

