

익명 사용자의 구매 의도 예측

클릭스트림 데이터 기반 머신러닝 접근법

Wen, Lin & Liu (2023) | Systems, MDPI

📌 **논문:** Machine-Learning-Based Approach for Anonymous Online Customer Purchase Intentions Using Clickstream Data

핵심 질문: "사용자를 몰라도 행동만으로 구매를 예측할 수 있는가?"

01 문제 정의

왜 이 연구가 필요한가?

✕ 기존 연구의 한계

- 로그인 사용자의 구매 이력에 의존
- 이력 없는 사용자 → 예측 불가
- 전체 구매의 ~50%가 익명 사용자
- Cold-start 문제 해결 안 됨



✓ 본 연구의 접근

- 이력 없이 현재 세션 행동만 사용
- 클릭·장바구니·리뷰 등 암묵적 신호 활용
- 상품 인기 + 트렌드 = 사회적 신호
- 실시간 구매 예측 가능

02 도메인 설명

클릭스트림 데이터란 무엇인가?

클릭스트림(Clickstream)이란? 고객이 온라인 쇼핑 중 남기는 디지털 발자국 — 클릭, 이동 경로, 체류 시간, 장바구니 행동 등을 포함한 순차적 행동 로그

클릭 행동

- 상품 페이지 열람 (LL)
- 장바구니 추가 (GWC)
- 찜하기 (SC)
- 리뷰 작성 (PL)

시간 정보

- 세션 체류 시간 (DT)
- 방문 월·요일·공휴일
- 세션 내 클릭 수 (CN)
- recency: 최근 행동 중심

구매 가정

- 구매 = 행동의 결과
- 익명이어도 행동은 남음
- 세션 단위로 분석 가능
- 1 세션 = 1 의사결정 과정

03 데이터 구조

JD 정동물 실제 데이터 사용

445K

세션 수

3.3M

총 클릭 수

126K

상품 수

1.7%

구매 세션 비율

세션 단위 분석이란?

- 1 세션 = 1명의 방문자가 한 번 쇼핑한 흐름
- 익명이므로 사용자 ID 대신 세션 ID로 분석
- 종속 변수: 구매 여부 (0 = 미구매 / 1 = 구매)
- → 이진 분류 (Binary Classification) 문제

왜 0/1인가?

- 구매했다 / 안 했다 → 두 결과만 존재
- 모델은 구매 확률 $P(\text{구매})$ 계산
- $P > 0.5$ 이면 구매 예측
- F1-Score로 성능 평가

04 변수 설계 (핵심)

행동 + 시장 흐름을 함께 반영한 구조

🖱️ 행동 변수 (MBT)

- 클릭.찜.장바구니.리뷰 = 4가지 암묵적 행동
- 구매 세션 vs 비구매 세션 비율로 트렌드 계산
- 다중 행동(MBT) > 단순 클릭(CT) — 더 정확
- Why: 행동 다양성이 구매 의도를 더 잘 반영

🕒 시간 변수

- 월(Month), 요일(Weekday), 공휴일(Festival)
- 세션 체류 시간 (Dwell Time)
- 클릭 횟수 (Clicks Count)
- Why: 8번 이상 클릭 시 구매 확률 급증

★ 상품 인기 (POP)

- 긍정 리뷰 수 - 부정 리뷰 수 = 인기 점수
- 전자구전(eWOM)의 동적 변화 반영
- Social Proof: 타인 평가가 구매 영향
- Why: 트렌드 변화를 실시간 포착 가능

💡 핵심: 변수 설계 = 행동 신호 + 시장 흐름 신호의 결합 → 모델 성능을 결정하는 가장 중요한 단계

05 Feature Engineering

클릭 행동 데이터를 모델이 읽는 숫자로

1

원시 데이터

클릭 로그·리뷰 로그
(텍스트·이벤트)



2

행동 수치화

MBT, CT, POP
공식으로 계산



3

슬라이딩 윈도우

최근 n일 집계
(n = 2~6일)



4

세션 데이터셋

각 세션에
변수값 매핑



데이터 불균형 문제

- 비구매 세션 >> 구매 세션 (약 98% vs 2%)
- 모델이 무조건 '비구매'로만 예측해도 높은 정확도
- → Random Under-Sampling 적용으로 균형 맞춤



데이터 분할

- 60% → 동적 특성 학습 (MBT, POP 계산)
- 40% → 세션 데이터셋 생성
- 80% 훈련 / 20% 테스트 분할

06 모델 설명

어떤 알고리즘으로 예측하는가?

Logistic Regression

Baseline

입력 변수로 구매 확률 p 를 직접 계산하는 선형 확률 모델. 해석이 쉽고 기준선(baseline) 역할.

한계: 선형 관계만 포착

Random Forest

★ Best

수백 개의 결정 트리를 만들어 다수결로 예측. 비선형 패턴을 잘 포착하며 본 논문 최고 성능.

강점: 비선형 + 앙상블

Gradient Boosting

HGBDT

이전 트리가 틀린 데이터에 집중하여 다음 트리를 학습. 오류를 반복 수정하는 구조.

강점: 오류 집중 학습

XGBoost

고속

Gradient Boosting을 최적화한 버전. 병렬 처리와 정규화로 속도·성능 모두 우수.

강점: 최적화된 부스팅

💡 행동 데이터는 비선형 → 트리 기반 모델(RF, XGBoost)이 선형 모델보다 훨씬 적합

07 실험 결과


MBT-POP + Random Forest = 최강 조합

F1

0.9031

Random Forest
MBT-POP, 2-day

시간 윈도우별 F1 성능 (Random Forest)



- 최적 조합: MBT-POP + Random Forest + 2일 윈도우 → F1 = 0.9031
- 윈도우 늘어날수록 F1 하락 → 최신 정보일수록 예측 정확도 높음
- MBT-POP은 5일 윈도우 소규모 데이터에서도 F1 0.8966 (대조군 대비 +9.47%)

08 핵심 인사이트

무엇을 발견했는가?

구매 예측 = 행동 트렌드 (MBT) + 상품 인기 (POP) + 시간 패턴

변수 설계 > 모델 선택

같은 Random Forest라도 MBT+POP 추가 시 성능이 대폭 향상. 알고리즘보다 '어떤 신호를 넣느냐'가 더 중요.

사회적 영향력 중요

POP(리뷰 기반 인기)를 추가하면 성능 향상. 사람들은 다른 사람의 평가를 따라 구매.

최신 정보가 핵심

2일 윈도우 > 6일 윈도우. 구매 의도는 빠르게 변하므로 최근 행동이 더 강력한 신호.

트리 모델이 적합

행동 데이터는 비선형 패턴 → Logistic Regression은 한계. RF/XGBoost가 압도적으로 우수.

09 우리 연구와 비교 및 확장

기존 논문 → 우리 연구로의 확장

유사점

- 행동 기반 구매 분석
- Binary Classification 구조
- F1-Score로 모델 평가
- 고객 행동 데이터 활용

차이점

- 기존: 구매 예측 (Prediction)
- 우리: 광고 효과 분석 (Explanation)
- 기존: 행동 데이터 중심
- 우리: 광고 + 관여도 + CTR

적용 방안

- LR 계수로 광고 효과 해석
- AI vs 인간 광고 성과 비교
- 광고 ROI 분석 가능
- 관여도 기반 전략 도출

"기존 연구는 누가 구매하는지를 맞추는 데 집중했다면,
우리 연구는 무엇이 구매를 만드는지를 설명하는 방향으로 확장된다."