

Enhancing Supply Chain Visibility with Knowledge Graphs and Large Language Models

Sara AlMahri, Liming Xu & Alexandra Brintrup

[이종민]

나비효과

2026-03-12

공급망 가시성 문제 (Supply Chain Black-Box)

Tier-1 vs N-tier 블랙박스 현상

기업들은 직접 거래하는 1차 협력사(Tier-1) 정보는 파악하고 있으나, 2차(Tier-2), 3차(Tier-3) 이하의 심층 공급망은 **블랙박스** 상태로 남아있음.

구조적 정보 공유의 한계

공급망 참여자 간의 신뢰 부족 및 경쟁 우려로 인해 자발적인 정보 공유가 이루어지지 않음.
이로 인해 전체 네트워크의 구조적 가시성(Structural Visibility) 결핍 발생.

Ripple Effect: 리스크의 연쇄 전이

사례: COVID-19 팬데믹 당시, 말단 공급망(Tier-3)의 부품 공급 중단이 전체 생산 라인의 마비로 이어짐.

영향: 작은 병목 현상이 증폭되어 심각한 재무적 충격과 운영 중단을 초래 (Bullwhip Effect).

Why Visibility Matters?

가시성은 단순한 모니터링을 넘어 **리스크 관리(Risk Management)**, **신속한 의사결정(Decision Making)**, 그리고 **운영 효율성(Operational Efficiency)**의 핵심 전제 조건임.

기존 접근의 한계 (Supervised NLP)

대량의 수작업 라벨링(Manual Labeling) 필요

전통적인 Supervised NLP 모델(BERT 등)은 학습을 위해 수만 건 이상의 고품질 라벨링 데이터가 필수적임. 이는 막대한 비용과 시간이 소요되며, 전문가 개입 없이는 구축이 어려움.

도메인 전환 시 재학습(Re-training) 필수

특정 산업(예: 배터리)에 맞춰진 모델은 다른 산업(예: 반도체)에 그대로 적용 불가. 산업 전환 시 처음부터 다시 학습해야 하여 확장성(Scalability)이 매우 낮음.

데이터 편향 및 커버리지 한계

편중(Bias): 학습 데이터가 주로 유명 대기업(Tier-1) 위주로 구성되어 있어, 중소기업(N-tier) 정보 누락.

단일 관계: 주로 Buyer-Supplier 관계만 학습하여, 경쟁/소유/협력 등 복합 관계 모델링에 한계.

Core Limitation: "Static & Narrow"

기존 방식은 **정적(Static)**이고 **좁은 범위(Narrow Scope)**에 머물러 있어, 급변하는 공급망 리스크와 복잡한 N-tier 의존성을 실시간으로 포착하기 어려움.

논문의 핵심 기여 (Core Contributions)

Zero-shot LLM 기반 정보 추출 (Automated Extraction)

GPT-4o와 같은 대형 언어 모델(LLM)의 **Zero-shot prompting**을 활용하여, 별도의 라벨링 데이터(Labeled Data) 없이 Named Entity Recognition(NER)과 Relation Extraction(RE)을 동시에 수행.

Knowledge Graph 자동 구축 및 Entity Disambiguation

공개 웹문서에서 추출한 비정형 텍스트를 구조화된 트리플(Triplet)로 변환하여 공급망 지식 그래프(KG)를 자동 구축. 특히, **Entity Disambiguation**을 통해 파편화된 기업명(예: Tesla Inc., 테슬라)을 단일 노드로 통합하여 데이터 무결성 확보.

EV 배터리 공급망 Case Study: 심층 의존성 발견

발견: Tier-1을 넘어 Tier-2/3 공급망(광산, 제련소 등)의 숨은 의존성 및 병목 구간 식별.
성과: 특정 광물(코발트 등)에 대한 지정학적 리스크 노출 확인 및 대체 공급 경로 제안.


Quantitative Performance (Wiki-based Evaluation)

Zero-shot Training Data Required	0.973 Micro-Precision (Disambiguation)	High Extraction Accuracy	N-tier Visibility Scope Extended
--	--	--	--

Contribution Summary

기존 Supervised Learning의 한계(데이터 부족, 확장성 저하)를 극복하고, **비용 효율적이고 즉시 배포 가능한(Scalable & Ready-to-deploy)** 공급망 가시성 솔루션을 제시함.

3단계 파이프라인 개요 (3-Stage Pipeline)



운영 최적화 (Operational Enhancement)

Neo4j 증분 인입 (Incremental Ingestion): 전체 재구축 대신 새로운 문서만 추가 처리하여 비용 효율성 확보. 충돌 발생 시 최신 정보 우선 정책 적용.

데이터 품질 (Data Quality)

다중 출처 검증 (Multi-source Verification): 최소 3개 이상의 신뢰할 수 있는 소스(Credible Sources)에서 동일 사실이 관측될 때만 엣지로 승격하여 환각 방지.

Phase A+B 상세 (Ontology & Extraction)

Phase A: Ontology Definition

사전 정의된 스키마로 추출 범위 한정

Entity Types (Nodes)

ORG Company
PROD Product
LOC Location
MAT Material
PER Person
MINE Mine

Relation Types (Edges)

suppliesTo (Supply Chain)
locatedIn (Geography)
owns (Ownership)
produces (Manufacturing)

** Note: Evaluation ontology strictly limited to these 4 types.*

Prompt Engineering Strategy

1. 각 타입별 명확한 **정의(Definition)** 제공
2. **Few-shot 예시(Examples)** 포함하여 모호성 제거
3. 출력 포맷(JSON) 강제 및 동의어 처리 규칙 명시

Phase B: Zero-shot Extraction

GPT-4o 기반 Triplet (Subject, Relation, Object) 추출

output_triplets.json

Success

// Input Sentence: "Tesla sources lithium batteries from CATL."

```
[
  {
    "subject": "CATL",
    "subject_type": "ORG",
    "relation": "suppliesTo",
    "object": "Tesla",
    "object_type": "ORG",
    "confidence": 0.98
  },
  {
    "subject": "CATL",
    "subject_type": "ORG",
    "relation": "produces",
    "object": "Lithium-ion battery",
    "object_type": "PROD",
    "confidence": 0.95
  }
]
```

모델 아키텍처 상세: Zero-shot 프롬프트와 T1~T16

KG Construction Pipeline

1. Ontology Definition

Company, Product, Location 등
엔티티 및 관계 스키마 정의

2. Prompt 1 (Extraction)

Zero-shot NER & Relation Extraction
T1~T16 서브태스크 수행

3. Prompt 2 (Disambiguation)

문맥 기반 엔티티 식별 및 병합
(String Matching 한계 극복)

4. Knowledge Graph

노드(Node)와 엣지(Edge)로 구성된
공급망 네트워크 구축

Prompt 1 구조 (T1~T16 서브태스크)

T1-T4

엔티티 정의 & 출력 포맷

명확한 정의와 3개 이상의 예시 제공, JSON
키-값 구조 강제

T5-T8

데이터 처리 지침

미정의 데이터는 속성으로 처리, 노드 라벨링
규칙 적용

T9-T10

관계(Relation) 정의

SuppliesTo, Owns 등 핵심 관계 정의 및 동의
어(Provides 등) 포함

T11-T16

엄격한 포맷 준수

Strict Compliance 경고를 통해 환각
(Hallucination) 및 포맷 오류 방지

Prompt 2 (Entity Disambiguation)

LLM에게 의미론 전문가 역할을 부여하여, 단순 문자열 매칭이 아닌 문맥 기반으로
동일 엔티티(예: 'Tesla Inc.' vs 'Tesla')에 고유 ID 부여


나비효과 프로젝트 적용 포인트

논문의 Zero-shot 프롬프트 구조화(예시 포함 시 성능 급상승) 결과는 나비효과 프로젝
트의 Hybrid LLM-SLM 설계 근거가 됨. 대량 데이터는 SLM으로 처리하되, 모호성이 높은
구간은 본 논문의 Prompt 2 방식을 적용하여 정확도 확보.

Phase C: Entity Disambiguation + 실험 결과

Before & After: Node Unification

파편화된 엔터티(Alias, 오타, 약어)를 LLM 시맨틱 분석으로 단일 노드로 통합



Performance & Dataset Stats

Wikipedia 기반 EV 공급망 데이터셋 평가 결과



0.973

Micro-Precision



High

Consistency

Evaluation Dataset Overview		
Metric	Count	Description
 Sentences	1,277	Wikipedia Raw Text
 Entities	1,158	Unique Nodes Annotated
 Relations	641	Valid Edges

* Ground Truth: Wikipedia EV Manufacturer & Supply Chain Pages 수동 라벨링 데이터셋과 비교

정량 결과: 엔티티 및 관계 성능 (Table 1)

Named Entity Recognition (NER)

ENTITY TYPE	PRECISION	RECALL	F1 SCORE
Company	0.747	0.515	0.608
Location	0.790	0.617	0.693
Material	0.878	0.325	0.472
Mine	0.716	0.400	0.511
Person	0.871	0.374	0.521
Product	0.521	0.177	0.264
Overall	0.729	0.405	0.520

Critical Issue: Low Recall in Product (0.177)

제품(Product) 엔티티의 재현율이 매우 낮음. 이는 일반적인 LLM이 특정 도메인의 세부 부품이나 원자재를 놓칠 가능성이 높음을 시사함.

Relation Extraction (RE)

RELATION TYPE	PRECISION	RECALL	F1 SCORE
locatedIn	0.471	0.288	0.355
owns	0.351	0.341	0.345
produces	0.578	0.197	0.294
suppliesTo	0.326	0.629	0.420
Overall	0.449	0.259	0.328

나비효과 프로젝트 솔루션

suppliesTo의 낮은 Precision(0.326)은 관계 오탐지가 많다는 의미. 이를 보완하기 위해 Seed Edges(검증된 관계)를 초기 주입하고, LLM 추출 결과에 대한 사후 검증 규칙을 적용해야 함.

Entity Disambiguation 방법 비교 (Table 2)



String Matching

0.894

단순 문자열 일치 여부만 확인. 'Tesla'와 'Tesla Inc.'를 다른 개체로 인식하여 노드 중복 발생 가능성 높음 (#Entities: 534).

Embedding-based

0.939

벡터 유사도를 기반으로 판단. 문맥적 의미는 파악하나, 미묘한 차이(자회사 vs 모회사) 구분에 한계가 있음 (#Entities: 560).

LLM-based (Ours)

0.973


LLM의 추론 능력을 활용해 문맥과 의미를 정확히 파악. **가장 높은 정확도로** 노드 고유성을 보장 (#Entities: 554).

KG Integrity & Node Uniqueness

LLM 기반 Disambiguation은 KG 구축의 핵심인 **노드 중복 (Duplication)**을 **최소화**하고, 네트워크의 연결성을 강화하여 **나비효과 시뮬레이션의 신뢰도**를 결정짓는 핵심 요소임.

Case Study 네트워크 시각화 (Figure 9–11)


Figure 9
Audi: Tier-N Visibility



Key Insight

Audi의 Tier-2/3 공급망인 **Ganfeng Lithium** 식별. 이 공급업체가 경쟁사인 BMW, Tesla 와도 연결됨을 시각화하여 잠재적 리스크(병목) 파악.


Figure 10
LG Chem: Diversification



Key Insight

Audi의 Tier-1인 LG Chem이 **Chrysler, Ford, SAIC** 등 다수 경쟁사에도 공급 중임을 확인. 대체 공급자 확보 전략 수립의 근거 제공.



Figure 11
Nickel: Material Mapping



Key Insight

전략 광물(Nickel)의 **생산-위치-소유 구조**를 매핑. 특정 국가(인도네시아) 및 기업(Vale)에 대한 의존도를 정량적으로 식별.

일관성(Consistency) 분석: 10회 반복 (Table 3)



High Variance Detected

'owns' 관계의 표준편차가 ± 19 로 매우 높음. 이는 LLM이 실행될 때마다 소유 구조 파악 결과가 달라질 수 있음을 의미하며, 데이터의 신뢰성에 영향을 줄 수 있는 위험 요소임.

나비효과 프로젝트 적용: Uncertain KG

LLM 출력의 확률적 특성(Stochasticity)을 반영하여, 나비효과 프로젝트는 정적 그래프 대신 **확률적 엣지(Probabilistic Edge)**를 가진 **Dynamic & Uncertain KG**를 구축함. 링크별 신뢰도 점수(P(link))를 메타데이터로 관리하여 분석 시 가중치로 활용.

계산 비용 및 확장성 분석 (Section 5.5)

Processing Time

249.3s

17 Articles (99.9% LLM Latency)

Total Cost

\$0.65

Cheap for small batch, linear scale

Output Scale

281


Triples (Entities + Edges)

Complexity

$O(T + E)$

Linear: $T(\text{Tokens}) + E(\text{Edges})$

Scalability: Pure LLM vs Hybrid Strategy



나비효과 프로젝트의 전략: Hybrid Approach

Cost & Latency Optimization

논문의 순수 LLM 접근법은 $O(T+E)$ 의 선형 복잡도를 가지므로, GDELT와 같은 전 세계 실시간 대량 데이터를 처리하기엔 비용과 시간 부담이 큼.

따라서 나비효과 프로젝트는 **Hybrid LLM-SLM** 전략을 채택함. 단순 정보 추출은 빠르고 저렴한 **SLM(Small Language Model)**으로 대량 처리하고, 문맥 파악이 난해하거나 핵심적인 연결고리(Ambiguous/Critical Links)에만 선별적으로 **LLM(GPT-4o)**을 투입하여 **비용 효율성과 정확도**를 동시에 확보함.

비판적 검토: 강점(Strengths) vs 한계(Limitations)

Core Strengths

Zero-shot Adaptability

라벨링 데이터 구축 및 파인튜닝 비용 제거. 산업 도메인 변경 시 (예: 배터리 → 반도체) 즉시 적용 가능하여 확장성이 뛰어남.

Multi-Relational Graph

단순 공급(Supply) 관계를 넘어 소유(Owns), 경쟁(Competes), 위치 (LocatedIn) 등 복합 관계를 모델링하여 N-tier 가시성을 획기적으로 확대.

Model-Agnostic Reproducibility

특정 모델에 종속되지 않고 GPT-4, Claude 3 등 다양한 고성능 LLM으로 재현 가능. 프롬프트 엔지니어링만으로 성능 유지.

Critical Limitations

Long-tail Hallucination

비상장 중소기업(Tier-3 이하) 정보 부족 시 LLM이 존재하지 않는 관계를 창조하거나 잘못된 병합을 수행할 위험 존재.

Temporal Lag (Static KG)

LLM 학습 데이터의 시점(Cut-off)에 의존. 실시간 공급망 변화(부도, M&A, 공장 폐쇄 등)를 즉각 반영하지 못하는 정적 한계.

Coverage vs Precision Trade-off

3개 이상의 신뢰 소스 교차 검증(Triangulation) 요구 시, 정보가 희소한 N-tier 영역의 커버리지가 급격히 감소하는 딜레마.

한계의 구체적 예시와 운영 상 고려 (Limitations & Considerations)

데이터 편향성 (Data Bias in Public Sources)

위키피디아/뉴스 의존: 상장기업이나 유명 공급망 관계에 정보가 쏠려있음.

Long-tail 누락: 비상장 중소기업(SME)이나 신흥국 원자재 공급처 정보는 빈약하거나 업데이트 지연.

프롬프트 민감도 (Sensitivity to Prompt Design)

Zero-shot의 양면성: 정의·예시·동의어(Synonyms) 설계 품질에 따라 추출 성능이 급격히 변동.

오류 전파: 모호한 정의는 잘못된 관계 추출(False Positive)로 이어져 전체 그래프 신뢰도 하락.

정적 지식 그래프의 한계 (Static Nature of KG)

Temporal Lag: 공급망은 동적으로 변하나(계약 종료, 신규 소싱), 정적 KG는 이를 즉시 반영하지 못함.

과거 정보 잔존: 이미 끊어진 관계가 여전히 유효한 것으로 남아 리스크 분석 왜곡 가능성.

검증 트레이드오프 및 확장성 (Trade-off & Scalability)

3-Source Verification: 사실성(Factuality)은 높이나, 희소한 정보(N-tier 핵심 정보)의 커버리지는 희생.

대형 KG 관리: 데이터 증가 시 노드 중복 해결(Entity Resolution)과 충돌 관리 비용이 기하급수적 증가.

Critical Implication for Risk Analysis

단순한 관계 추출을 넘어, 시간적 동적성(Dynamics)과 데이터 불확실성(Uncertainty)을 어떻게 다룰 것인가가 실전 적용의 핵심 과제.

나비효과 프로젝트 개요

프로젝트 목표 (Project Goal)

2차전지 공급망 리스크 전이 분석 및 이를 활용한 포트폴리오 헤지 전략 수립

뉴스 기반의 리스크 이벤트를 감지하고, 공급망 KG를 통해 전파 경로를 추적하여 기업 가치(주가)에 미치는 영향을 정량화

핵심 가설 (Core Hypothesis)

뉴스에서 추출된 리스크 노드로부터 공급망 KG 상의 거리가 가깝고(Short Path), 연결 강도(Edge Strength)가 높은 기업일수록 사건 발생 후 비정상수익률(CAR)이 유의미하게 낮다. -> 해당 기업이 공급망 리스크로 인해 타격을 입었다.

분석 스코프 (Scope)

Target: 2차전지 밸류체인

광산(Mining) > 제련(Refining) > 소재(Material) > 셀/팩(Cell/Pack) > OEM(EV)

*지정학적 리스크 및 원자재 가격 변동에 민감한 구조

분석 파이프라인 (Pipeline)

뉴스 수집 (GDELT)



Entity Resolution & KG 구축



노출도 산출 & CAR 검증

기술적 차별화 (Technical Differentiation)

논문 (AlMahri et al.)

Zero-shot LLM Only

GPT-4o 기반 Zero-shot Prompting만으로 정보 추출. 라벨링 비용은 낮으나, 복잡한 추론이나 모호한 케이스에서 정확도 한계 존재.

Static KG (정적 그래프)

특정 시점의 스냅샷으로 고정됨. 시간의 흐름에 따른 관계 변화나 최신 뉴스 반영이 어려움 (Temporal Lag).

Wikipedia 기반

잘 정리된 백과사전식 데이터 의존. 데이터 품질은 높으나 실시간 리스크 탐지에는 부적합. 정밀도(Precision) 중심 평가.

단순 Entity Disambiguation

이름 기반의 병합 위주. 도메인 특화 지식보다는 일반적인 언어 모델의 추론 능력에 의존.

나비효과 프로젝트

Hybrid LLM-SLM Pipeline

SLM 대량 문장 필터링/후보 생성
LLM 애매한 관계 판정 및 검증
비용/속도/정확도의 최적 균형 달성.

Dynamic KG (동적 그래프)

시간 감쇠(Temporal Decay), 스냅샷 저장, 이벤트 주입 지원. 과거 정보의 영향력을 점차 줄이고 최신성을 반영.

Seed Edges + Confidence

전문가 지식(Seed Edges)으로 뼈대 구축 후 확장. 확률(P(link))과 강도(Strength)를 분리하여 환각 방지 및 신뢰도 제어.

(Optional) Graph-Agentic RAG

LLM 에이전트가 스키마 위배, 논리 충돌을 능동적으로 검증하여 무결성 강화.

1. 노출도(Exposure) 산출

- Weighted Shortest Path (가중 최단거리)
- Random Walk with Restart (RWR)
- Centrality (PageRank/Betweenness) for XAI
- Graph Attention Network (GAT) 기반 Attention Score
- evidence_text, confidence_plink, strength 분리 저장

2. 이벤트 스터디 (Event Study)

- Windows: [0,1], [0,3] (단기 충격), [0,10] (전이 지연)
- Market Model (OLS) 기본 적용
- Fama-French 3-Factor Model (Optional 확장)
- Macro Factors (Oil, VIX, Exchange Rate) 통제

3. 강건성 검증 (Robustness Check)

- Event Date Shuffle (가짜 날짜로 검증)
- Entity Mapping Shuffle (랜덤 매핑으로 검증)
- Static vs Dynamic KG (시간 감쇠 효과 확인)
- Weighted vs Unweighted Edges

4. 포트폴리오 전략 (Backtest)

- Exclude High-Risk (Top-k Exposure 기업 제외)
- Benchmark 대비 MDD/Sharpe Ratio 개선 확인
- Long Low-Risk / Short High-Risk (L/S Strategy)

핵심 인사이트와 기여 (Core Insights)

Zero-shot LLM의 실용적 가치와 한계

N-tier 공급망 가시성 확대를 위한 획기적 출발점(Starting Point)이나, **금융 리스크 분석(Financial Risk Analysis)**에는 실시간성·정확도·무결성 보강이 필수적임.

Hybrid Methodology

순수 LLM의 비용과 속도 문제를 **Hybrid LLM-SLM**으로 해결하고, Seed Edges로 환각 (Hallucination)을 제어하여 신뢰성 확보.

Dynamic Visibility

정적(Static) 그래프의 한계를 넘어, 뉴스 타임스탬프 기반의 **Dynamic KG (시간 감쇠)**로 최신 공급망 변화를 즉시 반영.

Financial Validation

학술적 지표(Precision)를 넘어, **CAR(비정상수익률) 및 백테스트**를 통해 실전 투자 전략으로서의 효용성을 정량 검증.

Conclusion: From Visibility to Actionable Strategy

나비효과 프로젝트는 LLM 기반 공급망 가시성을 단순한 '모니터링 도구'에서 '**실질적 리스크 헤지 수단**'으로 진화시킴.

결론 (Conclusion)

논문 기여 (Contribution)

Zero-shot LLM과 Knowledge Graph를 결합하여 라벨링 없이 공급망 가시성을 획기적으로 확대하고, EV 배터리 공급망의 숨은 의존성을 성공적으로 식별함.

한계 (Limitations)

Long-tail 기업에 대한 환각(Hallucination) 위험과 정적 그래프의 시간 지연(Temporal Lag)으로 인해 실시간 금융 리스크 분석에는 적용하기 어려움.

나비효과 프로젝트 해결책 (Solution)

Hybrid LLM-SLM + Dynamic KG + Seed Edges를 통해 환각을 방지하고 실시간성을 확보하며 CAR 및 백테스트를 통해 금융적 효용성을 실전 검증함.

Thank You

Q&A