

금융 분야의 다국어 감성 분석: WordNet을 통한 영-불 매핑 프레임워크

Computational Linguistics Methods for Multilingual Financial Sentiment Classification

Karol Marek Klimczak, Jan Makary Fryczak, Dominika Hadro, Justyna Fijałkowska

연구 배경 및 동기 (Motivation)



언어 자원의 불균형

영어는 풍부한 금융 감성 사전과 디지털 코퍼스를 보유하고 있으나, 기타 언어는 텍스트 분석 시스템이 매우 미비한 실정입니다.



비교 가능성의 한계

수치 데이터는 IFRS를 통해 비교 가능하지만, 비정형 텍스트 공시는 언어 장벽으로 인해 글로벌 비교가 어렵습니다.



자동화된 확장 필요성

대규모 텍스트를 효율적으로 처리하기 위해 수동 번역이 아닌 전산 언어학 기반의 자동 매핑 기술이 필수적입니다.

금융 특화 감성 사전 (Seed Lexicons)

Loughran-McDonald (LM)

금융 공시(10-K)의 특수성을 반영하여 개발되었습니다. 일반적인 부정적 단어가 금융에서는 중립적일 수 있다는 점에 착안했습니다.


- 부정적 단어: 2,354개 (비관적 효과 중시)
- 긍정적 단어: 353개 (상대적 희소성)

Henry (2008)

투자자 반응이 즉각적인 수익 보도 자료(Press Releases)를 대상으로 최적화된 사전입니다.

- 긍정적 단어: 118개
- 부정적 단어: 93개
- 고도로 정교하게 선택된 어휘 구성

기존 연구의 한계와 새로운 도전



단어 중심에서 의미 중심으로

단순한 사전적 번역은 **다의어(Polysemy)** 문제를 해결하지 못합니다.
예를 들어 'Action'은 법적 분쟁일 수도, 일반적인 활동일 수도 있습니다.

본 연구는 **WordNet Synset(의미 단위)**을 활용하여 어휘가 아닌
'개념'을 매핑함으로써 번역의 정확도를 획기적으로 높였습니다.


연구 방법론 (1): WordNet 매핑

1단계: 영문 사전의 구조화

표제어 추출 (Lemmatization): 어간 추출(Stemming) 대신 문법적 의미를 보존하는 Lemmatization 적용.

Synset 식별: 각 단어를 Princeton WordNet의 유의어 집합인 Synset으로 변환.

의미 변별 (Disambiguation): 훈련 코퍼스 내 빈도를 점수화하여 가장 적절한 비즈니스 의미 선택.



연구 방법론 (2): 다국어 확장

Open Multilingual WordNet (OMW)

언어 간 인덱스(ILI)를 통해 영문 Synset을 프랑스어(WOLF) 대응 Synset으로 자동 매핑합니다.

구조적 일관성: Princeton WordNet의 정신적 구조를 타 언어에 투영하여 범언어적 의미 일관성을 확보합니다.

굴절어 대응: 프랑스어와 같이 굴절이 심한 언어에서도 형태소가 아닌 의미 단위로 접근하여 분석의 정밀도를 유지합니다.



수동 검토 및 정교화 (Refinement)



Black-list (배제)

'avoir'(가지다)와 같은 너무 일반적인 단어나, 'puits'(우물)와 같이 번역 오류로 포함된 부적절한 단어를 제거하여 노이즈를 최소화합니다.



White-list (추가)

WordNet에서 누락된 핵심 금융 용어나 특정 언어에서만 사용되는 비즈니스 관용구를 수동으로 보완하여 포괄성을 높입니다.



빈도 검증 (Frequency)

훈련 코퍼스 내 출현 빈도가 10회 미만인 희귀 단어를 제외하여 사전의 실효성과 통계적 안정성을 확보합니다.

데이터 및 코퍼스: SEDAR Bitext

특징 (Feature)	설명 (Description)	통계 (Stats)
Source	캐나다 상장기업 공시 시스템 (SEDAR)	퀘벡 주 규정상 영/불 병기 필수
Structure	동일 의미를 가진 문장 단위 병렬 정렬 (Aligned)	총 860만 개 문장 쌍 보유
Sample	검증을 위해 무작위로 추출된 문장 세트	70,000 Sentence Pairs 사용
Metric	감성 지수 산출 (Net-Positivity Index)	$(\text{Pos} - \text{Neg}) / (\text{Pos} + \text{Neg})$

내부 검증: 원본 vs WordNet 기반 (EN)

사전 유형별 감성 분류 상관관계 (Correlation)

LM Lexicon Correlation

0.91 (High Accuracy)

Henry Lexicon Correlation

0.98 (Near Perfect)

WordNet으로 변환된 사전이 영어 원본 사전의 감성 측정값을 매우 일관되게 복제하고 있음을 확인했습니다. 이는 방법론의 기반이 되는 '의미 매핑'의 유효성을 증명합니다.

교차 언어 결과: 영어 vs 프랑스어 (EN-FR)

언어 간 감성 지수 상관계수 (Pearson Coefficient)



*샘플 규모가 매우 큼에도 불구하고 통계적으로 유의미한 상관관계가 지속적으로 도출됨.

연구의 공헌 및 시사점

-  **방법론적 공헌:** 수동 번역의 한계를 극복하고 WordNet을 활용한 투명하고 검증 가능한 다국어 사전 확장 프로세스 정립.
-  **글로벌 투자 전략:** 국가별 언어 차이에도 불구하고 일관된 기준의 텍스트 마이닝을 통해 글로벌 포트폴리오 관리 효율성 증대.
-  **학술적 확장성:** 프랑스어뿐만 아니라 독일어, 폴란드어, 스페인어 등 WordNet이 구축된 200여 개 언어로 즉각 확장 가능.

프로젝트 연계 방향성

Net-Positivity Index를 CAR 회귀 통제변수로 추가

CAR ~ Exposure + controls 회귀식에서 이벤트 당일 뉴스 기사들의 감성 지수를 통제변수로 포함.
"공급망 노출도 때문에 CAR이 낮아진 건지, 아니면 그냥 그날 뉴스 전체가 부정적이어서인지"를
분리하는 데 활용

Severity 계산에 LM 부정어 사전 직접 사용

프로젝트 파이프라인에서 GDELT 기사에 severity를 매기는 단계 존재
지금 설계(v0)는 키워드 빈도 단순 합산인데, 여기에 LM 사전의 부정어 목록을 그대로 넣는 방향성.
GDELT 기사가 영어 중심이고, LM 사전은 영어 금융 텍스트에서 검증된 2,354개 부정어 목록이라
호환 가능성 기대.

감사합니다