



Retrieval-Augmented Machine Translation with Unstructured Knowledge

Jiaan Wang, Fandong Meng, Yingxue Zhang, Jie Zhou

(Tencent WeChat AI)

EMNLP 2025 Findings



연구 배경 및 문제의식

기존 RAG 번역의 한계:

번역 메모리(TM)나 구조화된 지식그래프(KG)에만 의존하여, 세상 지식의 대부분을 차지하는 **비정형 문서** 활용에는 공백이 존재함.

언어 간 대응 문제:

언어 간 완전 대응이 어려운 실제 환경에서, 소스/타겟 언어가 아닌 **제3언어 문서**를 제대로 활용하지 못하는 한계가 있음.

연구 목표:

위키피디아(Wikipedia)와 같은 **비정형 문서**를 RAG로 결합하여, 기계번역의 품질과 강건성을 획기적으로 향상시키는 것.

데이터 선정 기준 및 번역 어노테이션

데이터 선정 기준

- ✓ 지식 집약적: 소스 문장은 풍부한 지식을 포함해야 함
- ✓ 수집 용이성: 기존 리소스에서 관련 문서를 쉽게 확보 가능
- ✓ 다국어 확장: 다른 언어의 관련 문서도 수집 가능해야 함

RAGtrans 데이터셋

이 논문에서 구축한 최초의 RAG 기계번역 벤치마크

- 소스: 위키피디아 각 페이지의 첫 단락 (169K개)
- 관련 문서: 같은 페이지의 나머지 단락 활용
- 다국어 문서: Wikipedia의 병렬 문서(중국어, 독일어, 프랑스어, 체코어)도 함께 제공
- 노이즈 문서: 일부 샘플엔 Wikipedia에서 무작위 추출한 문서 포함

번역 어노테이션 구성

구분	방법	수량
GPT-4o 훈련/검증	자동 번역 (CoT 방식)	En→Zh 77K En→De 88K
Test set	전문 인간 번역가 17명	En→Zh 2K En→De 2K

처리 방식:

각 샘플은 <소스 문장, 문서, 번역> 삼중쌍으로 구성
테스트 샘플은 영어·중국어·독일어 문서 3개를 모두 포함한 5중쌍
토큰 길이: 소스 문장 평균 85토큰, 문서 평균 326~370토큰

학습 단계 개요와 SFT (Supervised Fine-Tuning)

Step 1: SFT

→

Step 2: CSC 멀티태스크

실험 설정 및 환경

기본 모델	Qwen2.5-7B/14B-Instruct, Llama-3-8B, Mistral-7B
검색기	BM25 (키워드) + BGE-m3 (다국어 밀집벡터)
평가 지표	BLEU (n-gram), COMET (의미 유사도), GRB/GRF (GPT-4o)
학습 환경	NVIDIA A100 GPU 8개 (40G), LlamaFactory 활용

학습 파이프라인

2단계 학습 전략: 먼저 기본적인 지도 학습(SFT)을 수행한 후, 논문의 핵심 기여인 CSC(Cross-lingual Self-Consistent) 멀티태스크 학습을 통해 모델의 RAG 능력을 극대화함.

1단계: SFT 프롬프트 구조

문서와 소스 문장의 경계를 명확히 구분하기 위해 특수 토큰을 사용함.

```
<document>[관련 문서 내용]</document>
<input sentence>[번역할 소스 문장]</input sentence>
```

SFT 성능 향상 (Zero-shot 대비)

En → Zh (중국어)	BLEU +4.5 / COMET +2.1
En → De (독일어)	BLEU +3.1 / COMET +3.0

* 단순 SFT만으로도 RAG 능력이 활성화되어 상당한 성능 향상을 달성함.

CSC 멀티태스크 학습: 3가지 보조 목적함수

CLIC (Cross-lingual Info Completion)

방식: 다국어 혼합 문서(d_mix)와 잘린 요약(y)으로 완전 요약(y) 복원
목표:다국어 정보 정제 능력 학습

SKET (Self-Knowledge-Enhanced)

방식: 모델이 관련 지식을 자체 생성 후 이를 참고해 번역 (Self-RAG)
목표:외부 검색 없는 지식 활용 강화

CLRD (Cross-Lingual Relevance)

방식: 서로 다른 언어 문서 쌍의 관련성 여부(Relevant/Irrelevant) 판단
목표:노이즈 문서 구별 능력 배양

CSC 훈련 데이터 생성 방식

항목	내용
CLIC 데이터	Wikipedia 다국어 병렬 문서 재구성 (MMR 알고리즘으로 단락 선별)
SKET 데이터	TED Talks 다국어 병렬 코퍼스 + LLM 프롬프팅으로 관련 지식 자동 생성
CLRD 데이터	Wikipedia 병렬 문서 (같은 페이지 = 관련 있음, 다른 페이지 = 관련 없음)
샘플 수	각 목적함수당 40K 샘플 생성 (총 120K)

학습 효과 및 확장성

- ✓ CSC 샘플 120K 초과 시 성능 향상이 **Plateau(정체)**에 도달함 (효율적 학습 규모 확인)
- ✓ 기존 다국어 코퍼스를 재구성하므로 **추가 레이블링 비용 = 0**

평가 지표

BLEU
n-gram

COMET
의미 유사도

GRB/GRF
GPT-4o 평가

결과 해석 및 향후 방향

Zero-shot LLM의 한계:

관련 문서를 줘도 번역 성능이 오르지 않음 → RAG 능력이 없는 상태
소스/타겟 언어 외의 제3언어 문서를 주면 성능이 오히려 하락
노이즈 문서에 매우 취약
→ RAG능력은 학습을 통해서만 획득 가능함을 시사

SFT 후 개선:

RAGtrans로 파인튜닝하면 전반적으로 성능 대폭 향상
관련 문서를 줬을 때 성능이 올라가고, 노이즈 문서에 대한 강건성도 향상
Zero-shot → SFT: BLEU +4.5 (En→Zh) / BLEU +3.1 (En→De)

SFT+CSC의 추가 개선:

SFT 대비 BLEU +1.6~3.1, COMET +1.0~2.0 (En→Zh) 향상
특히 제3언어 문서 활용 능력이 크게 향상됨
SFT → SFT+CSC: BLEU +1.6~3.1 (En→Zh) / BLEU +1.7~2.9 (En→De)

에블레이션 (기여도 분석):

빈 문서/동일 언어 문서 조건: SKET이 가장 중요 (모델 자체 번역 능력 강화)
제3언어 문서 조건: CLIC, CLRD가 더 중요 (다국어 정보 정제 능력)

인간 평가 결과

가장 흔한 오류 유형: Word-level 오류 > Phrase-level 오류
CSC 학습 + 관련 문서 제공 → 두 오류 유형 모두 감소 확인

말모이 프로젝트 연결점

비교 항목	RAGtrans 논문	말모이 프로젝트
핵심 과제	비정형 외부 문서 → 번역 품질 향상	인물/관직 KB → 고유명사 오역 방지
RAG 역할	Wikipedia 문서로 지식 보충	인물·관직 지식베이스 실시간 참조
멀티태스크	CLIC+SKET+CLRD 3가지 목적함수	MLM 복원 + NMT 멀티태스크
도메인 적용	Wikipedia 도메인 지식 활용	조선왕조실록 DAPT → 승정원일기 TAPT
엔티티 문제	제3언어 문서 → 엔티티 잘못 번역	한문 고유명사 → 현대 한국어 오역
해결 전략	(미해결, 향후 과제로 제시)	Entity-Anchored BPE 토크나이저
평가 지표	BLEU + COMET	BLEU-4 + KoreanBERTScore

시사점: RAGtrans가 비정형 문서의 일반 번역 품질을 높이는 데 주력했다면, 말모이 프로젝트는 특정 도메인의 고유명사 정확도를 해결하는 데 특화된 RAG 전략을 사용함.