

LLM 기반 승정원일기 번역 프로젝트

TEAM 말모이 | 길다인 오성민 이승민 배진형

조선왕조실록 크롤링

조선왕조실록 번역본 크롤링 및 데이터 정제 프로세스

01 광해군 – 순종까지 문단 단위 코퍼스 구축

02 데이터 정제 과정

03 모델 학습 계획

```
▼<article id="kwa_10007004_004">
  <translation>국역 특별히 생기(省記)037) 된 사람은 철직(撤直)하고 원상(院相)038) 은 그대로 머물러 직숙(直宿)하라고 명하였다. 【태백산사고본】 1책 1권 3장 A면 【국편영인본】 47책 326면
  【분류】 군사-중앙군(中央軍) / [註 037] 생기(省記) : 궐내(闕內) 각처(各處)의 입직 인원(入直人員)과 하례(下隷), 각영(各營)·각문(各門)의 입직 장사(入直壯士)의 성명을 적어서 승정원을
  거쳐 상주(上奏)하는 문서임.[註 038] 원상(院相) : 임시 벼슬의 하나로 임금이 승하한 뒤 어린 임금을 보좌하여 정무(政務)를 맡아 다스리던 직책임. ◎ 세종대왕기념사업회</translation>
  <original>원문 ○命別省記人撤直, 院相仍留。 【태백산사고본】 1책 1권 3장 A면 【국편영인본】 47책 326면 【분류】 군사-중앙군(中央軍) /</original>
</article>
▼<article id="kwa_10007004_005">
  <translation>국역 이에 앞서 대행 대왕(大行大王)의 병세(病勢)가 위독한 상태에 있을 적에 대왕 대비(大王大妃)가 언서(諄書)로 하교하여 전 승지 윤행임(尹行僔)을 발탁하여 승정원 도승지로 삼고
  이어 구유(口諭)를 내려 빈령(殯敍)에 입참(入參)하게 하였었다. 윤행임은 곧 대행조(大行朝)에서 권우(眷遇)를 받은 신하인데 복상중(服喪中)에서 아직 담제(禫祭)를 지내기 전이었다. 또 대신
  (大臣) 심환지(沈煥之)의 말에 따라 연교(諍敎)를 내려 어영 대장 신대경(申大諱)을 체차시키고 전 참의 박준원(朴準源)을 발탁하여 제수하고서 이어 호위(扈衛)하게 하였다. 박준원은 가순
  궁(嘉順宮)의 아버지이다. 또 심환지의 말에 따라 창성위(昌城尉) 황인점(黃仁點), 광은 부위(光恩副尉) 김기성(金其性), 의령 현감(宜寧縣監) 김종선(金宗善), 돈녕 주부(敦寧主簿) 김재창(金在昌),
  전 직장(直長) 김재삼(金在三), 한성 주부(漢城主簿) 김기운(金基允), 전 도사(都事) 박종보(朴宗輔), 경모궁 영(景慕宮令) 박종경(朴宗慶)을 종척(宗戚)의 집사(執事)로 삼았다. 【태백산
  사고본】 1책 1권 3장 A면 【국편영인본】 47책 326면 【분류】 왕실-비빈(妃嬪) / 왕실-국왕(國王) / 왕실-의식(儀式) / 인사-임면(任免) ◎ 세종대왕기념사업회</translation>
  <original>원문 ○先是, 大行大王大漸時, 大王大妃, 以諄書下敎, 擢前承旨尹行僔爲承政院都承旨, 仍宣口諭, 使之入參殯敎。 行僔卽大行朝眷遇之臣, 而守制未及禫也。 又以大臣沈煥之言, 下諍敎,
  遞御營大將申大諱, 擢前參議朴準源授之, 仍令扈衛。 準源, 嘉順宮父也。 又以煥之言, 以昌城尉 黃仁點、光恩副尉金其性、宜寧縣監金宗善、敦寧主簿金在昌、前直長金在三、漢城主簿金基允、前都事
  朴宗輔、景慕宮令朴宗慶爲宗戚執事。 【태백산사고본】 1책 1권 3장 A면 【국편영인본】 47책 326면 【분류】 왕실-비빈(妃嬪) / 왕실-국왕(國王) / 왕실-의식(儀式) / 인사-임면(任免)</original>
</article>
```



```
▼<article id="kwa_10007004_004">
  <translation>특별히 생기(省記)037) 된 사람은 철직(撤直)하고 원상(院相)038) 은 그대로 머물러 직숙(直宿)하라고 명하였다.</translation>
  <original>命別省記人撤直, 院相仍留。</original>
</article>
▼<article id="kwa_10007004_005">
  <translation>이에 앞서 대행 대왕(大行大王)의 병세(病勢)가 위독한 상태에 있을 적에 대왕 대비(大王大妃)가 언서(諄書)로 하교하여 전 승지 윤행임(尹行僔)을 발탁하여 승정원 도승지로 삼고
  이어 구유(口諭)를 내려 빈령(殯敍)에 입참(入參)하게 하였었다. 윤행임은 곧 대행조(大行朝)에서 권우(眷遇)를 받은 신하인데 복상중(服喪中)에서 아직 담제(禫祭)를 지내기 전이었다. 또 대신
  (大臣) 심환지(沈煥之)의 말에 따라 연교(諍敎)를 내려 어영 대장 신대경(申大諱)을 체차시키고 전 참의 박준원(朴準源)을 발탁하여 제수하고서 이어 호위(扈衛)하게 하였다. 박준원은 가순궁(嘉
  順宮)의 아버지이다. 또 심환지의 말에 따라 창성위(昌城尉) 황인점(黃仁點), 광은 부위(光恩副尉) 김기성(金其性), 의령 현감(宜寧縣監) 김종선(金宗善), 돈녕 주부(敦寧主簿) 김재창(金在昌),
  전 직장(直長) 김재삼(金在三), 한성 주부(漢城主簿) 김기운(金基允), 전 도사(都事) 박종보(朴宗輔), 경모궁 영(景慕宮令) 박종경(朴宗慶)을 종척(宗戚)의 집사(執事)로 삼았다.</translation>
  <original>先是, 大行大王大漸時, 大王大妃, 以諄書下敎, 擢前承旨尹行僔爲承政院都承旨, 仍宣口諭, 使之入參殯敎。 行僔卽大行朝眷遇之臣, 而守制未及禫也。 又以大臣沈煥之言, 下諍敎,
  遞御營大將申大諱, 擢前參議朴準源授之, 仍令扈衛。 準源, 嘉順宮父也。 又以煥之言, 以昌城尉 黃仁點、光恩副尉金其性、宜寧縣監金宗善、敦寧主簿金在昌、前直長金在三、漢城主簿金基允、前都事朴宗
  輔、景慕宮令朴宗慶爲宗戚執事。</original>
</article>
```

기술적 개선사항

01 언어 및 런타임 전환 (Python → Go)

- GIL 한계 극복: Python의 Global Interpreter Lock으로 인한 멀티스레딩 성능 저하 문
하 문제를 해결하였습니다.
- Goroutine 도입: 경량화된 병렬 처리를 통해 시스템 리소스 소모를 최소화하고 수
수집 속도를 비약적으로 향상시켰습니다.

03 병렬 처리 및 처리량 최적화

- 동시성 모델 적용: Go Channel을 활용하여 수천 개의 커넥션을 효율적으로 관리하
며 I/O Wait 시간을 최소화했습니다.
- 처리 효율 증대: 단일 채널 요청 방식의 병목 현상을 제거하여 대규모 데이터 수집
시간을 단축했습니다.

02 Proxy 인프라 도입

- IP 차단 회피: 단일 IP 기반 요청 시 발생하는 Rate Limiting을 우회하기 위해 Proxy
Proxy Pool 시스템을 구축했습니다.
- 서비스 가용성 확보: 유료 SmartProxy 서버를 순환 방식으로 사용하여 트래픽을
분산하고 안정적인 접속을 유지합니다.

```
// 스마트 프록시 로테이션 엔진
func fetchArticle(targetUrl string) (string, string, string) { 1개 사용 위치
    proxyURL, _ := url.Parse(ProxyAddress)
    client := &http.Client{
        Transport: &http.Transport{Proxy: http.ProxyURL(proxyURL)},
        Timeout:    15 * time.Second,
    }

    req, _ := http.NewRequest(http.MethodGet, targetUrl, http.NoBody)
    req.Header.Set("User-Agent", "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/122.0.0.0 Safari/537.36")

    resp, err := client.Do(req)
    if err != nil { return "ERROR", "", "" }
    defer resp.Body.Close()

    if resp.StatusCode == 404 { return "NONE", "", "" }
    if resp.StatusCode != 200 { return "ERROR", "", "" }

    doc, err := goquery.NewDocumentFromReader(resp.Body)
    if err != nil { return "ERROR", "", "" }

    doc.Find(selector.Br).ReplaceWithHtml(htmlStr + "\n")
    doc.Find(selector.P).AppendHtml(htmlStr + "\n")

    doc.Find(selector.Script, selector.Style, selector.DivInsNav, selector.DivBtnArea, selector.DivPrintArea, selector.SpanUrlCopy).Remove()

    left := cleanText(doc.Find(selector.DivViewItemLeft).Text())
    right := cleanText(doc.Find(selector.DivViewItemRight).Text())

    return "OK", left, right
}
```

조선왕조실록 크롤링

크롤링 과정

- 대량 수집 시 발생할 수 있는 IP 차단을 방지하기 위해 사용자 인증 정보가 포함된 유료 스마트 프록시(SmartProxy) 서버 주소를 설정
- 수집한 실록 기사 내용 구조화 및 병렬 수집을 위한 작업단위 설정
- 공백 정리 및 줄바꿈, 뮤텍스를 통한 데이터 안전성 보장
- 기존에 저장된 XML 파일에서 데이터를 읽어와 현재 수집 상태를 복구하는 '이어받기(Resume)' 기능 추가
- 설정된 프록시를 통해 차단을 피하며 웹페이지에 접속한 뒤, goquery를 사용하여 실록의 번역문과 원문을 추출하고 불필요한 요소를 제거
- 중복 수집 방지 및 요청 실패 시 자동 IP 로테이션과 5회 재시도를 통해 수집의 안정성을 극대화

```
main.go
func main() {
    fmt.Printf(format: "크롤링 시작")
    os.MkdirAll(SaveDir, perm: 0755)

    year := StartYear
    for year <= MaxYear {
        loadExistingArticles(year)
        fmt.Printf(format: "\n--- 재워 %d년 수집 시작 ---\n", year)

        jobs := make(chan Job, 12)
        var wg sync.WaitGroup

        for w := 1; w <= 12; w++ {
            wg.Add(delta: 1)
            go worker(w, jobs, &wg)
        }

        for m := 1; m <= 12; m++ {
            jobs <- Job{KingCode: TargetKingCode, Year: year, Month: m}
        }
        close(jobs)
        wg.Wait()
        fmt.Printf(format: "\n📁 %d년 수집 종료.\n", year)
        year++
    }

    fmt.Println(a...: "🏁 모든 수집 완료.")
}
```

크롤링 데이터 정제

데이터 정제

서지 및 출처 정보: 본문 끝에 붙는 【태백산사고본】, 【국편영인본】 등 데이터의 출처를 나타내는 정보를 삭제

학술용 각주 및 주석: 문장 중간이나 끝에 삽입된 각주 번호([註 087])와 그 해설 텍스트를 모두 제거

저작권 및 기관 표기: © 한국고전번역원, © 세종대왕기념사업회 등의 반복적인 저작권 문구를 삭제

불필요한 말머리: 번역문 앞의 국역이나 원문 앞의 원문 ○ 같은 식별용 꼬리표를 제거

원문의 날씨 및 날짜 데이터: 한문 원문 시작 부분에 습관적으로 붙는 날짜 표기와 날씨 기호(晴, 陰, 雨 등)를 삭제

```
import sys

# 저장된 XML 파일들의 실제 경로로 변경하십시오 .
TARGET_DIR = r"C:\Users\kevin\OneDrive\Desktop\sillok_crawler\Sillok_Corpus_Final"

def clean_ml_corpus(text, is_translation): 2개의 사용 위치
    if not text:
        return ""

    text = text.strip()

    # 1. 공통: 서지 사항, 각주, 저작권 텍스트 일괄 제거
    text = re.sub(r"【태백산사고본】.*$", "", text, flags=re.DOTALL)

    if is_translation:
        # 2-A. 번역문 정제
        text = re.sub(r"【註\s*\d+\】.*$", "", text, flags=re.DOTALL)
        text = re.sub(r"©\s*한국고전번역원.*$", "", text, flags=re.DOTALL)
        text = re.sub(r"^\s*국역\s*", "", text)

    else:
        # ^{1,15}/ : 맨 처음부터 슬래시(/)가 나올 때까지 (최대 15글자 이내일 때만 작동하여 본문 내 슬래시 오작동 방지)
        # \s*(?:【[^】]+】|【晴陰雨雪點】?。)?\s* : 슬래시 직후의 날짜 주석이나 날씨 한자
        text = re.sub(r"^[^/]{1,15}/\s*(?:【[^】]+】|【晴陰雨雪點】?。)?\s*", "", text)

        # 혹시 모를 "원문 ○" 찌꺼기 방어
        text = re.sub(r"^\s*원문\s*○(?:[가-힣甲-顙]+/)?", "", text)

    # 3. 양끝 공백 최종 정리
    return text.strip()
```