

2090

software developer

# Entity Linking with Wikidata : A systematic Literature Review

TEAM malmoi | 길다인 오성민 배진형 이승민

# 목차

## 01

### 연구 배경 및 개체 연결 개념

- AI가 텍스트의 의미를 읽는 법
- 개체 연결의 기초 개념 정리

## 02

### 위키데이터와 핵심 난제

- 위키데이터의 강점과 필요성
- 개체 연결의 5가지 핵심 난제

## 03

### 개체 연결 프로세스 및 시스템

- 표준 파이프라인 6단계
- 주요 시스템 및 기술 접근법

## 04

### 8차원 분석 프레임워크

- 본 논문의 독보적 강점
- 8개 차원 확장 분석

## 05

### 연구 공백 및 미래 비전

- 현재 기술의 한계점
- 결론 및 미래 비전

## 06

### 프로젝트 적용 전략

- EL 기반 고유명사 번역 고도화
- 4가지 핵심 전략

# 연구 배경: AI가 텍스트의 '진짜 의미'를 읽는 법

## 핵심 질문

컴퓨터는 '사과를 먹었다'와 '사과는 혁신적인 기업이다'라는 문장에서 '사과'의 차이를 어떻게 알까요?

## 개체 연결(EL)의 필요성

- 단순 키워드 매칭을 넘어선 기술
- 텍스트 속 단어를 지식 그래프의 고유 ID에 매핑하는 과정
- 챗봇, 검색 엔진, 질의응답 시스템의 핵심

## 비정형 데이터의 구조화

- 위키데이터를 활용한 개체 연결 연구 분석
- 텍스트의 문맥을 정확히 파악하는 기술
- 지식 그래프 기반 의미 이해

## 본 연구의 목적

- 초보자부터 전문가까지 참고 가능
- 통합 가이드라인 제시
- 파편화된 연구들을 하나의 지도로 통합함



# 기초 개념: 개체 연결(Entity Linking)이란 무엇인가?

## 핵심 용어 정리

- 언급(Mention): 텍스트 내에서 개체를 가리키는 단어 (예: 아이폰)
- 개체(Entity): 지식 베이스에 등록된 실제 항목 (예: 위키데이터 ID Q212)
- 지식 그래프(KG): 개체와 개체 사이의 관계를 연결한 거대한 그물망

## EL의 본질: 중의성 해소

- '뉴욕'이 도시인지, 주인지, 영화 제목인지 문맥을 통해 결정하는 작업
- 고도의 지능형 처리 과정
- 동일한 단어의 서로 다른 의미를 구분함

## 작업의 범위

- 단순히 단어를 찾는 것을 넘어선 작업
- 지식 베이스에 없는 새로운 개체 감지
- NIL 예측까지 포함하는 포괄적 범위

# 왜 위키데이터(Wikidata)인가?



## 위키백과 vs 위키데이터

- 위키백과: 사람이 읽기 좋은 글
- 위키데이터: 기계가 이해하는 데이터
- 완전 구조화된 정보



## 3대 강점

- 다국어 지원
- 공동 편집 시스템
- 하이퍼-관계형 구조
- 실시간 업데이트



## 결론

- 차세대 AI의 핵심 지식창고
- 전 세계 언어를 ID로 통합
- 복잡한 속성의 연계 지원

# 개체 연결의 핵심 난제

## 역동성

- 실시간으로 정보가 변하기 때문에  
어제의 데이터가 오늘 틀릴 수 있음
- 지식 그래프의 지속적인 업데이트  
필요
- 동적 환경에 대응하는 알고리즘 요  
구됨

## 모호성

- 이름은 같지만 실제로는 다른 개체  
들이 너무나 많음
- 예: '이승만'이라는 이름의 동명이  
인들
- 정확한 구분이 어려움

## 별칭의 다양성


- 'BTS', '방탄소년단', '비티에스'가  
모두 같은 대상임을 알아야 함
- 다양한 표현 방식 처리
- 동일 개체의 여러 이름 인식

## 복잡한 계층과 방대함

- '강아지'를 '동물'로 연결할지 '반려  
동물'로 연결할지 정교한 구분 필요
- 위키데이터의 방대한 정보량
- 짧은 문장에서의 문맥 부족 문제



# 개체 연결 수행 프로세스 (Standard Pipeline)



## 1. 언급 탐지 (Mention Detection)

- 문장에서 고유 명사를 찾아냄
- '이 문장에서 고유 명사는 무엇인가?'를 탐지하는 첫 단계임

## 2. 개체 인코딩 (Encoding)

- 단어와 주변 문맥을 숫자(벡터) 형태로 변환함
- AI가 계산할 수 있도록 준비하는 과정임

## 3. 후보 생성 (Candidate Generation)

- 수억 개의 개체 중 '애플'과 관련 있을 법한 후보 10~20개를 추림
- 효율적인 탐색을 위한 필터링 단계임

## 4. 순위 지정 및 중의성 해소

- 후보 중 문맥상 점수가 가장 높은 개체 하나를 선택함
- 중의성을 해소하는 핵심 단계임

## 5. NIL 예측 및 최종 연결

- 후보 중에 정답이 없다면 신규 개체로 판단함 (NIL)
- 선택된 개체의 고유 주소(URI)를 텍스트에 연결함



# 주요 시스템 및 기술적 접근법

## OpenTapioca

- 가벼운 구조로 설계되어 속도가 매우 빠름
- 실시간 서비스에 적합한 시스템임

## Falcon

- 규칙(Rule)을 정교하게 짜서 개체와 관계를 한꺼번에 찾아냄
- 개체뿐만 아니라 그들 사이의 관계까지 탐지함

## KBPearl

- 주변 지식 정보를 최대한 끌어모음
- 오타가 많거나 노이즈가 낀 텍스트에서도 강한 성능을 보임

## 핵심 기술

- BERT와 같은 언어 모델을 사용하여 단어의 숨은 의미를 파악함
- 그래프 신경망을 통해 개체 간의 연결망 정보를 학습함



# 본 논문의 차별점: 8차원 분석 프레임워크

## 기존 연구의 한계

- 어떤 알고리즘을 썼는가?와 성능이 얼마인가?에만 집중함
- 2차원 분석에 그쳤음
- 전체적인 맥락과 응용 가능성을 놓침

## 본 논문의 차별화

- 정의, 작업, 유형, 도메인, 접근법, 데이터셋, 응용, 과제 등 8개 차원으로 확장 분석함
- 37개 문헌의 정의를 비교 분석하여 표준을 제시함
- 전체 파이프라인의 세부 단계를 정립함

## 실용적 기여

- 인물, 장소 외에 '제품', '시간' 등으로 분석 범위를 확장함
- 뉴스뿐만 아니라 의료, 소셜 미디어 등 다양한 환경을 분석함
- 실제 서비스 연결성을 확인함

| 정의                         | 작업                  | 유형                                 | 도메인                              | 접근법                        | 데이터셋             | 응용                           | 과제                    |
|----------------------------|---------------------|------------------------------------|----------------------------------|----------------------------|------------------|------------------------------|-----------------------|
| 37개 문헌의 정의를 비교 분석하여 표준 제시. | 전체 파이프라인의 세부 단계 정립. | 인물, 장소 외에 '제품', '시간' 등으로 분석 범위 확장. | 뉴스뿐만 아니라 의료, 소셜 미디어 등 다양한 환경 분석. | 규칙 기반 vs 학습 기반 모델의 장단점 비교. | 벤치마크 데이터의 특성 분석. | 질의응답, 관계 추출 등 실제 서비스 연결성 확인. | 현재 기술의 한계점과 미래 방향 제시. |

## 연구 공백(Gaps) 및 해결 제안

### 도메인의 편중

- 뉴스 연구는 많지만 전문 분야 연구는 턱없이 부족함
- 수학, 프로그래밍 코드, 법률 등 전문 분야 연구가 필요함

### 엔티티 유형의 불균형

- 인물(Person) 연구에만 쏠려 있음
- 음악, 소프트웨어, 역사적 사건 등 '롱테일(Long-tail) 개체'에 대한 관심이 필요함

### 데이터셋의 한계

- 영어 중심에서 벗어나야 함
- 다국어(Multilingual) 데이터셋이 더 많이 구축되어야 함
- 이미지/텍스트가 섞인 멀티모달 데이터셋이 필요함

### 방법론의 진화

- 규칙 기반의 정확성과 딥러닝의 유연성을 결합해야 함
- 하이브리드 모델이 미래의 정답임

# 결론: 개체 연결의 미래와 비전



## 요약

- 위키데이터 기반 EL 연구를 체계적으로 정리함
- 파편화된 연구들을 하나의 지도로 통합함



## 시사점

- 용어와 작업 절차의 표준화가 연구 효율을 높일 것임
- 실시간 대응 알고리즘이 핵심 경쟁력이 될 것임



## 마무리

- 개체 연결은 AI가 세상의 지식과 소통하게 만드는 가교임
- 인간의 언어를 넘어선 지능형 시스템의 핵심 기술임



# 말모이 프로젝트 적용 전략: EL 기반 고유명사 정밀 번역 고도화

## 중의성 해소 엔진 구축

- 시간 순서별 관직 데이터를 활용함
- 동명이인 중 해당 시점에 실존한 인물을 정확히 선택하여 오역을 방지함

## 하이퍼-관계형 지식 그래프 활용

- 인물-관직-가족관계-사건을 연결한 미니 지식 그래프를 구축함
- 번역의 문맥적 일관성을 강화함

## NIL 예측을 통한 미번역 개체 관리

- 실록 데이터셋에 존재하지 않는 '롱테일 개체'를 감지함
- 신규 개체를 별도의 고유명사 사전에 등록하여 학습 피드백 루프를 만듦

## 8차원 프레임워크 기반 성능 평가

- 도메인 및 엔티티 유형별로 정밀 분석함
- SIKUBERT의 User Vocab에 등록된 토큰들을 시각화하여 집중적으로 튜닝함