





LLM 기반 승정원일기 번역 프로젝트

TEAM 말모이 | 길다인 오성민 이승민 배진형

일시

2026-04-29



피드백 및 반영 계획

피드백

- 1 파이프라인 아키텍처를 **그래프/다이어그램 형식**으로 최종 보고서에 추가
- 2 **Computing time** 문제 여부 다음 발표 때 보고
- 3 적응가능성 및 확장가능성 **discussion** 최종 보고서에 추가
- 4 우리가 새로 한 것 vs 기존 연구에서 참조한 것 **명확히 구분**하여 기재
- 5 **참고문헌 인용 방식** 보완

이번주 진행 내용

KB 인조/정조 시기 분리
구축 완료

SillokBERT 인조 시기 단독 재학습
진행 중

NER Fine-tuning 수정
진행 중

지난 발표 이후 변경사항 개요

1. 모델 호환성 문제

- 인코더(SillokBERT)와 디코더(Gemma)의 입력/출력 아키텍처 구조 불일치
- 가중치 직접 이관이 불가능하여 프롬프트 형식으로 지식을 전달하도록 수정

2. 학습 범위 조정

- 인조+정조 전체를 동시에 다루던 방식에서 범위를 축소
- 인조 시기에 특화하여 선 성능 검증
- 검증 성공 시 정조 시기로 확장하는 단계적 전략 채택

기존 계획 요약

가중치 직접 주입 방식

SillokBERT 가중치를 번역 모델에 직접 전달

→ 구조적 한계로 적용 불가 판정 및 계획 전면 수정

수정된 방향

프롬프트 기반 지식 주입형 파이프라인


지식을 프롬프트 형식으로 변환하여 Gemma 4 E4B 에 전달

→ NER → EL → 프롬프트 증강 → 번역의 다단계화

핵심 수정 방향: 모델 간 직접 결합 대신, 명시적 지식 추출 및 프롬프트를 통한 번역 품질 향상

수정된 파이프라인 전체 구조

전체 파이프라인은 아래 6단계로 구성된다.



사용 모델 스택

SillokBERT-NER

원문 내 개체명(인물/관직/지명)
추출

SillokBERT

(승정원일기 사전학습본)

실록 배경지식 기반으로 KB 대조
및 인물 특정

고전 특화 지식 베이스 (KB)

인물 팩트 제공, 엔티티 링킹
레퍼런스

Gemma 4 E4B

프롬프트로 전달받은 지식 기반
최종 번역 생성

성능 비교 설계

번역 성능의 객관적 검증을 위한 비교 실험 설계

비교 모델 설정

Gemma 4 단독

지식 주입 없이 기본적인 번역을
수행합니다.

하한선 baseline

SillokBERT + Gemma 4 E4B

실록 배경지식을 프롬프트로
증강하여 전달하는 지식 주입형
파이프라인입니다.

우리 시스템

3개 비교군으로 성능 검증

GPT 범용 모델

의미 전달력이 우수한 범용
고성능 생성 모델입니다.

상한선 비교군

검증 전략

정답지 처리: 정조 시기는 미번역본이 다수 존재하므로, GPT
번역본을 **pseudo 정답지**로 활용하여 성능을 측정합니다.

단계적 검증: 인조 시기로 먼저 성능을 검증한 뒤, 해당 시기의
성과를 바탕으로 정조 시기도 동일한 방법론으로 확장 가능성을
입증합니다.

평가 지표

정밀도 및 재현율

용어 및 개체명 번역의 정확성 측정

의미 보존도

원문 맥락의 보존 및 전달력 평가

문체 적합성

고전 특화 도메인 어투 및 전문가 평가 보강

완성된 산출물 — 지식 베이스(KB) 파일

5개 JSON 파일로 구성된 고전 특화 지식 베이스 시스템

person_master.json

통합 인물 DB

무엇인가: 인조+정조 시기 등장 인물 전체의 표준 정보를 담은 마스터 데이터베이스

왜 만들었는가: 모든 인물 정보의 원천이 되는 단일 진실 공급원(Single Source of Truth) 필요

인물 ID

표준 성명

관직 이력

inverted_index_injo.json

인조 시대 검색 엔진

무엇인가: 인조 시기 등장 인물의 이름을 키로, 인물 ID를 값으로 매핑한 역색인 구조

왜 만들었는가: '김중수', '중수', '금릉공' 등 다양한 호칭을 빠르게 검색

본명

자

호

id_lookup_injo.json

인조 시대 상세 사전

무엇인가: 인조 시기 인물 ID를 키로, 관직 이력과 활동 연도를 값으로 담은 조회 사전

왜 만들었는가: 일기 작성 날짜와 인물의 활동 시기를 대조하여 동명이인을 걸러내기 위함

시공간 필터링

관직명 교차 검증

inverted_index_jeongjo.json

정조 시대 검색 엔진

무엇인가: 정조 시기 인물 대상의 역색인 구조 (inverted_index_injo와 동일한 방식)

왜 만들었는가: 인조와 정조는 시대가 다르므로 같은 이름이라도 다른 인물일 수 있음

정조 시기

왕조 분리

id_lookup_jeongjo.json

정조 시대 상세 사전

무엇인가: 정조 시기 인물 ID 기반 관직/연도 조회 사전

왜 만들었는가: 정조 시기 동명이인 해소 및 번역 프롬프트 구성을 위해 필요

정조 시기

상세 조회

SillokBERT 학습 결과 및 재학습 계획

기존 CPT(인조+정조 혼합) 결과 분석 및 인조 시기 단독 특화 재학습 전략

학습 Loss 그래프

Loss가 초반 5.8 수준에서 5.1~5.2 수준으로 전반적 감소 및 정상 학습 확인



기존 학습 결과 (인조+정조)

코퍼스: 승정원일기 원문 (약 25MB, 50% 랜덤 추출)

학습 방식: Continued Pretraining (CPT)

학습 스텝: 총 3 Epoch, 24,546 스텝

결과물 저장:

- SillokBERT_SJW_Adapted
- SillokBERT_CPT_Results_50pct

재학습 계획

목표: 인조 시기 단독 특화 (코퍼스 교체)

사유: 각 시기 고유의 문체적 특성 희석 방지 및 행정 용어·문법 패턴의 정밀한 내재화

기대 효과: 인조 시기 NER 정확도 향상 및 정조 시기 확장 방법론의 논리적 근거 확보

현재 진행 상황 및 향후 계획

프로젝트 진행 현황

SillokBERT CPT (인조+정조 통합본)	완료
SillokBERT-NER 모델 구축	완료
5개 KB 파일 구축	완료
SillokBERT CPT 재학습 인조 시기 단독 코퍼스로 교체	진행중
NER Fine-tuning 수정 실버/골드 라벨 데이터 기반	진행중
Entity Linking 구현	예정
Gemma 4 E4B 연동 및 프롬프트 증강	예정
성능 평가	예정