

KoBE: Knowledge-Based Machine Translation Evaluation

레퍼런스 없이 번역 품질을 평가하는 새로운 방법

저자

Zorik Gekhman, Roei Aharoni, Genady Beryozkin, Markus Freitag, Wolfgang Macherey

Google Research

Accepted as a short paper in

Findings of EMNLP 2020

기존 방법의 문제점

BLEU 등의 n-gram 기반 평가가 가지는 한계

1 레퍼런스 번역 필요

전문 번역가가 작성한 고품질 레퍼런스가 필요하며, 도메인별 커버리지가 제한적 / 비전문 번역가의 결과는 품질이 낮을 수 있음

2 유효한 의역 패널티

동일한 의미를 가진 다른 단어 표현에 대해 부당하게 낮은 점수를 받음 / 여러 참조문이 있어도 이 문제를 완화하기 어려움

3 Translationese 편향

인간 번역의 특수한 특성("Translationese")으로 인해 유효한 대체 번역이 낮은 점수를 받을 수 있음

4 해석 어려움

절대적 품질 신호가 아닌 상대적 개선만 측정하며, 해석이 어려움 / n-gram 매칭만으로는 의미를 파악하기 어려움

5 다중 레퍼런스 희소

실제로는 하나의 레퍼런스만 사용하는 경우가 대부분이며, 다중 참조는 거의 사용되지 않음

KoBE란?

Knowledge-Based Machine Translation Evaluation - 레퍼런스 없이 번역 품질을 평가하는 새로운 방법

KoBE는 대규모 다국어 지식 베이스(KB)를 활용하여 소스 문장과 번역 결과의 엔티티를 연결하고, 소스 대비 후보에서 발견된 엔티티의 재현률(recall)을 측정하는 평가 방법

1 다국어 지식 베이스(KB)에 소스와 후보 번역의 엔티티를 연결

Named Entity Recognition을 통해 인명, 기관명, 지명 등을 식별하고, 대규모 다국어 지식 베이스(Google Knowledge Graph)에 연결

2 소스 대비 후보에서 발견된 엔티티의 recall 측정 (같은 KB ID로 매칭)

매칭된 엔티티 수를 소스의 총 엔티티 수로 나누어 재현률을 계산 / 엔티티가 여러 번 등장하면 각각 개별 매치로 계산

3 Entity Count Penalty(ECP)로 과도한 엔티티 생성 방지

후보 엔티티 수(c)가 소스 엔티티 수(s)의 2배 이상이면 패널티를 적용하여 과도한 엔티티 생성 방지

4 레퍼런스 불필요, 언어쌍 독립적

번역 결과만으로 품질을 평가할 수 있어, 레퍼런스 번역이 없는 상황에서도 사용 가능

5 해석 가능한 절대적 품질 신호 제공

엔티티 기반 매칭을 통해 의미론적 유사성을 측정하므로, 표면적 n-gram 매칭의 한계 극복

KoBE 작동 원리

Entity Linking + Recall 측정으로 번역 품질 평가

1. 소스와 후보 번역에서 엔티티 추출

Named Entity Recognition을 통해 인명, 기관명, 지명 등을 식별/ 소스 문장과 번역 결과에서 개체(entity) 추출

2. 다국어 KB에 엔티티 연결

추출된 엔티티를 대규모 다국어 지식베이스(Google Knowledge Graph)에 연결

3. 같은 KB ID로 매칭

소스와 번역의 엔티티가 같은 KB ID를 가리키는지 확인 / 다른 표현도 같은 의미로 매칭

4. 전체 코퍼스에서 recall 계산

매칭된 엔티티 수 / 소스의 총 엔티티 수로 재현율 계산

5. ECP 적용

Entity Count Penalty를 적용하여 과도한 엔티티 생성을 패널티

핵심 원리

KoBE는 소스 문장과 번역 결과의 엔티티를 KB에 연결하여, 매칭된 엔티티의 재현율(recall)을 측정 이를 통해 레퍼런스 없이도 번역 품질을 평가할 수 있음

수식 & 점수 계산

Recall 공식, Entity Count Penalty(ECP) 개념을 시각적으로 설명

Recall

$$\text{Recall} = \frac{\sum |\text{matches}(\text{entities}(\text{source}), \text{entities}(\text{candidate}))|}{\sum |\text{entities}(\text{source})|}$$

소스 문장의 엔티티와 후보 번역의 엔티티를 매칭하여 재현률을 계산 / 엔티티가 여러 번 등장하면 각각 개별 매치로 계산

ECP

$$\text{ECP} = 1 \text{ (if } c < 2s), \text{ECP} = \exp(1 - c/2s) \text{ (if } c \geq 2s)$$

후보 엔티티 수(c)가 소스 엔티티 수(s)의 2배 이상이면 패널티를 적용하여 과도한 엔티티 생성을 방지

KoBE Score

$$\text{KoBE} = \text{ECP} \times \text{Recall}$$

최종 점수는 Entity Count Penalty와 Recall을 곱하여 계산

c = 후보의 엔티티 수

s = 소스의 엔티티 수

반복된 엔티티도 개별 카운트

소스 빈도로 매칭 clip

실험 결과 (WMT19)

18개 언어쌍에서 9개 언어쌍 1위 달성, ru-en에서 0.928 상관계수 기록

언어쌍별 상관계수 (Pearson)

언어쌍	BLEU	KoBE	개선
ru-en	0.879	0.928	+ 5.6%
de-en	0.849	0.863	+ 1.6%
zh-en	0.899	0.907	+ 0.9%
fi-en	0.982	0.961	- 2.1%
gu-en	0.834	0.961	+ 15.2%
kk-en	0.946	0.899	- 5.0%
lt-en	0.961	0.704	- 26.7%

* 녹색: KoBE가 BLEU보다 성능이 좋음 | 빨간색: BLEU가 KoBE보다 성능이 좋음

성능 요약

9/18

언어쌍 1위

0.928

최고 상관계수

1.8M

엔티티 멘션

28K

고유 엔티티

핵심 성과

- 9/18 언어쌍에서 1위 달성
- 4개 언어쌍에서 BLEU보다 높은 상관관계
- ru-en에서 0.928 상관계수 기록

KoBE vs BLEU (Reference-based)

레퍼런스 기반 평가에서 KoBE가 BLEU보다 우수한 성능을 보임

언어쌍	BLEU	KoBE	차이	상태
de-en	0.849	0.906	+ 0.057	✓
fi-en	0.982	0.961	-0.021	✗
gu-en	0.834	0.850	+ 0.016	✓
kk-en	0.946	0.961	+ 0.015	✓
lt-en	0.961	0.901	-0.060	✗
ru-en	0.879	0.926	+ 0.047	✓
zh-en	0.899	0.947	+ 0.048	✓

레퍼런스 기반 메트릭으로 사용 시 5/7 언어쌍에서 KoBE가 BLEU를 능가

엔티티 기반 매칭이 n-gram 매칭과 경쟁력 있는 성능을 보여줌

KoBE의 점수가 인간 판단과의 절대값 차이가 더 작음

KoBE의 장점

레퍼런스 없이도 번역 품질을 평가하는 새로운 방법

1 레퍼런스 불필요

전문 번역가가 작성한 고품질 레퍼런스 없이도 번역 품질을 평가할 수 있음 / 비용을 절감하고 다양한 도메인에서 평가를 수행할 수 있음

비용 절감: 레퍼런스 번역 제작 비용 없음

도메인 확장성: 새로운 도메인에서도 즉시 평가 가능

언어 쌍 독립성: 특정 언어 쌍에 구애받지 않음

2 절대적 품질 신호

상대적 개선이 아닌 절대적인 품질 지표를 제공하여 번역의 실제 품질 평가 / 엔티티 재현율로 의미 보존 정도를 직접 측정

실제 품질 측정: 엔티티 재현율 기반 평가

해석 가능성: 명확한 점수 해석 가능

안정성: 시스템 간 일관된 평가

3 세밀한 오류 분석

엔티티 타입별, 도메인별로 세밀한 오류 분석이 가능하여 시스템의 약점을 정확히 파악할 수 있음

엔티티 타입별 분석: 인명, 기관, 지명 등

도메인별 분석: 뉴스, 기술, 법률 등

진단 가능: 구체적인 개선 방향 제시

한계점

알아야 할 제약사항과 고려사항

엔티티 없는 문장 (~8%)

약 8%의 문장에서 엔티티가 감지되지 않아 평가 신호를 제공하지 못함 / 특히 짧은 문장이나 일반적인 표현에서 이 문제 발생

영어 타겟 성능 편향

엔티티 연결 시스템이 영어에서 가장 잘 작동하여 영어가 타겟 언어일 때 성능이 더 좋음 / 비영어 언어쌍에서는 정확도가 낮아질 수 있음

KB 및 linker 품질에 의존

지식 베이스의 커버리지와 엔티티 연결 시스템의 품질에 크게 의존 / KB에 없는 엔티티는 평가에서 누락될 수 있음

타겟 언어 필터링 필요

일부 저자원 언어쌍에서 MT 시스템이 입력을 번역하지 않고 복사하는 경우, 타겟 언어 필터링이 필요

결론 & 향후 연구

KoBE의 주요 성과와 미래 발전 방향

주요 성과

- **WMT19 벤치마크 9/18 언어쌍 1위**
9개 언어쌍에서 가장 높은 인간 판단과의 상관관계 달성
- **BLEU 대비 4개 언어쌍에서 더 높은 상관관계**
레퍼런스 없이도 BLEU보다 우수한 성능
- **1.8M 엔티티 멘션 데이터셋 공개**
18개 언어쌍에 대한 대규모 엔티티 주석 데이터 제공

향후 연구

- **YiSi-2, XMoverScore 등과 결합 가능성**
Multilingual BERT 기반 YiSi와 결합하여 더 강력한 평가 지표 개발
- **도메인 특화 코퍼스로 확장**
대규모 도메인 특화 데이터셋으로 스케일 업 및 적용 범위 확대
- **타 태스크 적용**
요약, 텍스트 단순화 등 다른 NLP 태스크로 확장

핵심 인사이트: KoBE는 레퍼런스 없이도 번역 품질을 평가할 수 있는 강력한 대안으로, 엔티티 중심의 의미 보존을 측정합니다.

Q&A
