

지식 주입형 언어 모델 기반 고전 한문 번역 : 《승정원일기》를 중심으로 한 SillokBERT 와 Gemma 파이프라인 심층 분석

1. 연구 배경

역사 기록물은 단순한 과거의 사실의 나열을 넘어, 당대 사회의 정치, 경제, 문화, 철학을 포괄하는 국가의 핵심적 학술 자산이다. 특히 대한민국의 대표적인 기록유산인 《승정원일기》는 유네스코(UNESCO) 세계기록유산으로 등재된 세계 최대 규모의 단일 역사 기록물로서 그 가치가 지대하다. 인조(1623 년)부터 순종(1907 년)에 이르기까지 조선 후기 왕실과 조정의 동향을 매일 기록한 이 문헌은 총 3,243 책, 약 2 억 4,250 만 자에 달하는 방대한 텍스트로 구성되어 있다.¹ 그러나 이토록 막대한 학술적, 문화적 가치에도 불구하고 《승정원일기》가 현대 사회에서 온전히 활용되는 데에는 극복하기 어려운 언어적 장벽이 존재한다. 바로 한문 원문을 현대 국어로 변환하는 국역 작업의 지연이다.

현재 국가 기관과 다수의 학계 전문가들이 참여하여 국역 사업을 진행하고 있으나, 전통적인 인력 기반 번역 프로세스의 한계로 인해 전체 번역 완료율은 37.4% 수준에 머무르고 있다. 전문적인 고전 한문 해독 능력을 갖춘 인력의 공급은 제한적인 반면, 해석해야 할 텍스트의 규모는 물리적 한계를 초과하기 때문에, 현재의 속도를 유지할 경우 완역은 2062 년에나 가능할 것으로 추산된다 . 이러한 병목 현상을 타개하고 지식 자산의 대중화 및 디지털화를 가속하기 위해 최근 자연어 처리와 인공지능에 기반한 기계 번역 기술이 대안으로 적극 검토되어 왔다.

초기 고전 한문 번역에는 범용 트랜스포머 모델이나 중국의 방대한 고문헌 코퍼스인 《사고전서(四庫全書)》 등을 학습한 언어 모델이 투입되었다. 대표적으로 SikuRoBERTa 아키텍처를 기반으로 한 AnchiLm 모델이나 기존 SikuBERT 와 대형 언어 모델(LLM)을 결합한

파이프라인이 시도되었다.³ 그러나 이들 모델은 일정 부분 문맥을 파악하는 데는 기여했으나, 전반적인 번역 품질을 나타내는 BLEU 지표가 0.37~0.54 의 낮은 수준에 정체되는 한계를 드러냈다. 더욱 심각한 문제는 원문에 등장하는 인칭대명사, 인명, 관직명, 지명 등 고유명사를 정확히 인식하고 번역하는 정확도가 8.3%에 불과했다는 점이다. 역사 번역에서 고유명사의 오역은 단순한 텍스트의 오류를 넘어 역사적 사실자체를 왜곡하는 결과를 초래하므로, 이는 인공지능 기반 번역 기술이 실무에 도입되는 것을 가로막는 가장 결정적인 장애물로 작용해 왔다.

본 연구 보고서는 기존 기계 번역 시스템이 지니고 있던 도메인 불일치와 환각 현상을 근본적으로 극복하기 위해 제안된 지식 주입형파이프라인의 핵심 로직과 기술적 타당성을 심층적으로 제시한다. 본 파이프라인은 기존 SikuBERT 와 Solar Pro 의 조합을 폐기하고, 오직 《조선왕조실록》 등 조선 시대 문헌만을 학습하여 도메인 특화 능력을 극대화한 SillokBERT 와, 다국어 처리 및 맥락 이해 능력이 뛰어난 구글의 경량 파운데이션 모델 Gemma 를 결합한 새로운 아키텍처를 채택하였다.⁵ 단순히 텍스트를 입력받아 블랙박스 형태로 출력하는 End-to-End 번역 방식을 탈피하여, 개체명 인식(NER), 고전 특화 지식 베이스(KB) 연동, 엔티티 링킹(Entity Linking)을 통한 동명이인 해소, 그리고 프롬프트 증강을 통한 최종 지식 주입 번역이라는 체계적인 5 단계 구조를 확립하였다.

2. 문제 정의

지식 주입형 파이프라인의 필요성을 명확히 이해하기 위해서는, 먼저 기존에 적용되었던 고전 한문 번역 모델들의 구조적 결함과 기술적 한계를 구체적으로 짚어볼 필요가 있다. 기존 모델들은 언어 능력과 사실적 지식을 하나의 모델 파라미터 내에 혼재하여 학습시키는 구조를 취했으며, 이는 고전문헌 번역에서 심각한 오류를 야기했다.

2.1 AnchiLm 및 SikuBERT 기반 모델의 도메인 불일치

고전 한문을 현대어로 번역하기 위한 선행 연구 중 하나인 AnchiLm 모델은 12 개 층의 인코더(Encoder)와 6 개 층의 디코더(Decoder)를 갖춘 트랜스포머 기반 구조를 사용하였다.³ 이 모델은 인코더 초기화에 SikuRoBERTa 를 사용하였으며, 병렬 코퍼스의 확장을 위해 바이트

페어 인코딩(BPE) 분할 과정을 무작위로 교란하는 bpe-drop 전략을 채택하였다.³ 이를 통해 EvaHan2023 번역 대회에서 BLEU 점수 21.75 를 기록하며 전통적인 베이스라인 모델을 상회하는 성과를 거두었다.³

그러나 AnchiLm 이나 SikuBERT 와 같은 모델들은 그 학습 코퍼스의 근간이 중국의 고문헌에 편중되어 있다는 태생적 한계를 지닌다. 중국의 《사고전서》와 조선의 《승정원일기》는 한자라는 표의문자를 공유하지만, 그 이면에 깔린 문법적 구조와 어휘의 용례, 특히 행정 체계와 관직명에서 극명한 차이를 보인다. 조선 시대 한문은 고유의 이두(吏讀)식 표현과 한국식 한자어, 그리고 독자적인 관직 및 지명 체계를 포함하고 있으므로, 중국 고문헌에 최적화된 모델은 조선 시대 텍스트의 맥락을 오독할 확률이 높다.⁷ 이는 모델이 보유한 사전 학습 가중치와 대상 텍스트 간의 심각한 도메인 불일치를 유발하며, 궁극적으로 0.37~0.54 라는 저조한 BLEU 점수를 기록하는 원인이 되었다.

2.2 암묵적 지식 의존에 따른 고유명사 환각 현상

기존 LLM 이나 신경망 기계 번역(NMT) 모델의 가장 치명적인 단점은 앞서 언급한 바와 같이 고유명사 번역 정확도가 8.3%에 불과하다는 점이다. 이러한 현상이 발생하는 근본적인 이유는 신경망 모델이 지식을 저장하고 추출하는 메커니즘 자체에 있다. 범용 번역 모델은 방대한 파라미터 네트워크 속에 수많은 정보가 암묵적 지식의 형태로 압축되어 있다. 원문 텍스트 내에 "命金鍾秀(김종수에게 명하여)"라는 구문이 주어졌을 때, 띄어쓰기가 없는 한문의 특성상 기존 모델은 '金(김)', '鍾(종)', '秀(수)'를 각각 개별적인 형태소로 분리하여 해석하려는 경향을 보인다. 혹은 '金鍾秀'를 하나의 인명으로 인식하더라도, 이 인물이 조선 영조와 정조 시대에 활동했던 특정 관료라는 역사적 팩트를 파라미터 내부에서 정확히 고집어내어 현대 국어 표기로 매핑하는 것은 불가능에 가깝다. 그 결과, 모델은 확률적으로 가장 등장 빈도가 높은 다른 한자어의 조합으로 치환하거나, 전혀 엉뚱한 인물이나 관직명으로 번역하는 환각 현상을 필연적으로 발생시킨다. 이는 언어 구조를 디코딩하는 능력과 외부 세계의 팩트를 검증하는 능력을 철저히 분리하지 않고 하나의 모델에 전적으로 의존했기 때문에 발생하는 구조적 한계이다.⁸

3. 지식 주입형 파이프라인 아키텍처 및 현재 진행상황

본 연구가 제안하는 지식 주입형 파이프라인은 이러한 기존 모델의 구조적 한계를 타파하기 위해, '구문론적 언어 변환'과 '팩트 복원'의 과정을 명확히 분리하여 각각 최적의 하위 모델에 할당하는 모듈화 철학을 따른다.⁸ 전체 파이프라인은 입력된 《승정원일기》 원문에서 개체명을 추출하고, 이를 지식 베이스와 대조하여 식별자를 특정한 뒤, 최종적으로 거대 언어 모델(Gemma)에 관련 지식을 증강하여 번역을 수행하는 5 단계로 구성된다.

3.1 지식 주입형 파이프라인 아키텍처

본 연구는 인조 및 정조 시기 『승정원일기』의 고도화된 기계 번역을 실현하기 위해 도메인 특화 지식베이스(KB)와 개체명 인식(NER) 및 엔티티 링킹 기술을 유기적으로 결합한 지식 주입형 번역 파이프라인을 제안한다.

우선 『조선왕조실록』을 기반으로 구축된 SillokBERT 모델에 『승정원일기』 원문 데이터를 활용한 마스크 언어 모델링(MLM)을 수행함으로써, 해당 사료 고유의 문법 체계와 문체를 모델 가중치에 사전 학습한다. 이어지는 단계에서는 학습된 가중치를 전이하여 개체명 인식(NER) 전용 출력층을 미세 조정함으로써 원문 내 인물 및 관직명 추출의 정밀도를 확보하며, 이를 고전 특화 인물 정보 사전과 대조하는 다단계 엔티티 링킹 프로세스—성명 기반 후보군 검색, 활동 시기 검증, 관직명 문맥 대조—를 통해 개체의 고유 식별자를 확정한다.

최종적으로 식별된 지식베이스 정보와 원문을 결합한 프롬프트 증강(전략을 활용하여 Gemma 3 와 같은 대규모 언어 모델(LLM)이 역사적 맥락과 고유 명사의 정확성이 엄밀하게 담보된 고품질의 번역본을 도출하도록 구조화하였다.

3.2 승정원일기 특화 언어 모델 구축을 위한 도메인 적응

기존의 범용 고전 모델이 지닌 일반적인 한문 해석 능력을 넘어, 조선 시대 최대의 국정 기록물인 《승정원일기》 특유의 일기체 기술 방식과 실무적 행정 용어를 완벽히 체화하기 위한 도메인 적응 과정을 수행하였다. 이를 위해 본 프로젝트는 실록 데이터로 1차 학습된 SillokBERT를 기반 모델로 삼아, 미번역 승정원일기 원문 코퍼스를 활용한 Continued Pretraining(CPT)을 단행하였다.

학습 설정 및 하드웨어 최적화 규격

항목	상세 설정 및 파라미터 규격
기본 모델	SillokBERT (Architecture: bert-base-multilingual-cased)
대상 코퍼스	《승정원일기》 원문 코퍼스 ½ 랜덤추출 (약 25MB)
학습 방법론	Masked Language Modeling (MLM), 비지도 학습 기반 도메인 전이
마스킹 전략	전체 토큰의 15% 임의 마스킹 및 복원 추론
최적화 도구	AdamW (Learning Rate: 5e-5 ~ 2e-5)
연산 가속 (	fp16 혼합 정밀도 학습 및 Gradient Accumulation (Step 4) 적용

도메인 적응 과정의 기술적 고도화

위 설정과 같이, 본 단계에서는 《조선왕조실록》에 최적화되어 있던 모델의 언어적 무게중심을 《승정원일기》로 이동시키는 데 주력하였다. 특히 승정원일기는 실록에 비해 이두(吏讀) 표현의 빈도가 높고 비서실 특유의 보고 체계와 대화체가 혼재되어 있으므로, 이를 학습하기 위해 기존 모델의 지식을 유지하면서 새로운 문맥적 패턴을 주입하는 계속 사전 학습(Continued Pretraining) 방식을 채택하였다.

토큰화 과정에서는 원문의 역사적 가치와 훼손된 문맥을 온전히 보존하기 위해, 손상된 기호(\$\square\$, ○ 등)를 제거하지 않고 데이터의 일부로 수용하였다. 이는 모델이 물리적 결락이 존재하는 문장에서도 앞뒤 문맥을 통해 개체명을 유추할 수 있는 '역사적 추론 능력'을 갖추게 하기 위함이다.

학습 효율 측면에서는 T4 GPU의 VRAM 제약(15GB) 하에서 성능을 극대화하기 위해, 배치 사이즈를 2로 최소화하되 그래디언트 누적(Gradient Accumulation)을 4단계로 설정하여 실질적으로 8의 배치 사이즈 효과를 거두도록 설계하였다. 또한, torch-xla 환경과의 정밀한 버전 정렬을 통해 하드웨어 자원의 안정성을 확보하였다.

이러한 정밀한 도메인 적응 과정을 거친 후, 완성된 모델은 승정원일기 내부의 인물, 관직, 지명을 식별하는 NER(개체명 인식) 단계로 진입하게 된다. 이는 단순한 텍스트 분석을

넘어, 미번역본의 국역 품질을 결정짓는 Gemma 3 디코더의 지식 보조 인코더로서 핵심적인 역할을 수행하게 될 것이다.

3.3 고전 특화 지식 베이스(Knowledge Base, KB)의 구축

지식베이스의 구조 및 데이터 스키마는 실시간 번역 공정의 병목 현상을 방지하고 LLM 주입 효율을 극대화하기 위해 3중 계층의 경량 JSON 구조로 설계되었다.

1. 마스터 DB(person_master.json): 인물별 표준 식별자(ID)를 중심으로 구축된 원천 사전이다. 표준 국·한문 성명, 본관과 더불어 생몰년 미상 인물의 경우 해당 인물의 최초·최후 관직 발령 연도를 활용한 Fallback 로직을 적용하여 활동 시기를 추정·보완하였다. 특히, 인물의 관직 이력을 단순 집합이 아닌 연대순으로 정렬 및 압축하여 제공함으로써, 모델이 인물의 생애 주기와 문맥적 배경을 정밀하게 파악할 수 있도록 하였다.
2. 역색인 인덱스(inverted_index.json): 고문헌 특유의 성씨 탈락 현상(예: '경혼'을 '혼'으로 지칭) 및 자(字)·호(號) 중심의 호칭 체계에 대응하기 위한 멀티 키 탐색 엔진이다. 인명의 부분 문자열 및 별칭을 독립적인 키로 등록하여 검색 가용성을 극대화하였으며, 이를 통해 O(1) 복잡도의 고속 엔티티 후보군 추출을 지원한다.
3. 경량 조회 사전(id_lookup.json): 엔티티 링킹 완료 후, 최종 번역 모델인 Gemma에 주입할 핵심 메타데이터만을 선별한 사전이다. 검색용 메타데이터를 제거하고 표준명, 활동기, 관직 이력 등 번역에 직결되는 정보로만 구성하여 프롬프트 토큰 소모를 최적화하고 모델의 추론 효율을 높였다.

또한, 본 시스템은 구축된 KB 를 기반으로 지능형 엔티티 링킹 엔진을 가동한다. 1 차 인덱스 검색 후 동명이인이 발견될 경우, 일기 작성 시점과 인물의 활동기를 대조하는 필터를 적용한다. 이때 사후 추증이나 회고적 서술의 누락을 방지하기 위해 사망 연도 필터링은 의도적으로 완화하였다. 최종적으로는 원문 내 등장하는 관직명과 KB 내의 관직 이력을 교차 검증하며, 중의성이 해소되지 않는 모호한 케이스는 후보군 전체를 LLM 에 전달하여 딥러닝 문맥 파악 능력을 통한 최종 식별을 유도하는 구조를 취한다.

4. 추후 계획

본 연구는 고전 한문 텍스트의 특수성을 반영하여, 단순 번역을 넘어선 지식 기반의

고도화된 번역 시스템 구축을 목표로 한다. 이를 위해 수행될 세부 계획은 다음과 같다.

4.1 도메인 특화 NER 모델의 미세 조정 및 지식 정교화

사전 학습된 SillokBERT의 가중치를 기반 모델로 활용하여, 고전 한문의 복잡한 문맥적 의존성을 개체명 인식(NER)에 최적화한다. MLM 결과물을 바탕으로 상단에 개체명 분류를 위한 출력층을 결합하여 미세 조정을 단행한다.

비정형 텍스트 입력 시, 모델은 MLM 학습 단계에서 축적한 토큰 간 어텐션 정보를 활용하여 개체명 후보군을 식별한다. 예를 들어 "傳曰, 命金鍾秀..."와 같은 문장에서 '命(명하다)'과 같은 특정 동사 뒤에 위치한 '金鍾秀(김종수)'를 인물로 식별하는 방식이다. 오분류 발생 시 정답지와 교차 엔트로피 손실을 계산하고 역전파를 통해 가중치를 재조정함으로써, 승정원일기 등 고전 사료 특유의 문법 구조와 도메인 지식을 내재화한 전용 식별 안목을 확보한다.

4.2 3중 계층 지식 베이스(KB) 구축 및 다단계 엔티티 링킹

NER 단계에서 추출된 텍스트 덩어리(Mention)를 역사적 실체와 연결하기 위해 고전 특화 지식 베이스와 엔티티 링킹 프로세스를 최적화한다. 동명이인 및 중의성 문제 해결을 위해 3단계 필터링을 수행한다. 1차 후보군 생성 단계에서 매칭되는 모든 인물을 선별한 후, 2차 시공간적 검증을 통해 사료 작성 시점과 인물의 생존 시기 및 관직 재임 기간을 대조하여 불가능한 후보를 배제한다. 최종적으로 3차 문맥적 교차 검증을 통해 원문의 주변 관직명과 지식 베이스 내 인물 경력을 비교하여 고유 식별자를 확정한다.

4.3 지식 주입형 프롬프트 증강 및 번역 최적화

최종 번역 모델(Gemma 3)이 역사적 사실에 입각한 결과물을 생성할 수 있도록, 확정된 지식 데이터를 프롬프트에 동적으로 삽입하는 지식 주입형 번역을 수행한다.

단순 원문 전달 방식에서 벗어나, 검색된 지식(인물의 표준명, 당시 관직, 가문 관계 등)을 프롬프트의 컨텍스트로 제공하는 프롬프트 증강 기술을 적용한다. 이를 통해 모델이 내부의 불확실한 암묵적 지식에 의존하여 발생하는 환각 현상을 억제하고, 명시적 팩트를 바탕으로 고유명사 오역을 원천 차단한다. 결과적으로 사료적 가치가 극대화된 정교한 현대어 번역문을 도출한다.

5. 정리

본 연구는 현재까지 sillokBERT 를 활용한 고전 한문 문맥 파악 모델 학습을 완료하고 개체명 추출을 위한 전용 모델의 설계를 마쳤다. 이와 함께 인물 표준 정보와 연대기 자료를 체계화한 3 중 계층 지식 베이스를 구축하였으며, 시공간 정보를 대조하여 동명이인을 식별하는 엔티티 링킹 알고리즘의 개발과 논리적 정합성 검토를 수행하였다.

향후에는 검증된 지식 데이터를 최종 번역 모델인 Gemma3 에 동적으로 주입하여 고유명사 오역을 방지하는 통합 파이프라인을 완성할 예정이다. 이후 고유명사 복원율과 의미 유사도 지표를 활용하여 번역 성능에 대한 정량적 검증을 실시하고, 역사 전문가 그룹의 정성 평가를 통해 번역문의 사료적 신뢰성을 최종 확인하며 연구를 마무리할 계획이다.

참고 자료

1. 국사편찬위원회, 4 월 7, 2026 에 액세스, <https://www.history.go.kr/>
2. 승정원일기, 4 월 7, 2026 에 액세스,
<https://sjw.history.go.kr/main.do;jsessionid=494F3C6D343003058D6E110CEE20C179>
3. AnchiLm: An Effective Classical-to-Modern Chinese Translation Model Leveraging bpe-drop and SikuRoBERTa - ACL Anthology, 4 월 7, 2026 에 액세스,
<https://aclanthology.org/2023.alt-1.8.pdf>
4. AnchiLm: An Effective Classical-to-Modern Chinese Translation Model Leveraging bpe-drop and SikuRoBERTa - ACL Anthology, 4 월 7, 2026 에 액세스,
<https://aclanthology.org/2023.alt-1.8/>
5. Multilingual innovation in LLMs: How open models help unlock global communication, 4 월 7, 2026 에 액세스, <https://developers.googleblog.com/unlock-global-communication-gemma-projects/>
6. [2601.09012] TranslateGemma Technical Report - arXiv, 4 월 7, 2026 에 액세스,
<https://arxiv.org/abs/2601.09012>
7. ddokbaro/SillokBert-NER · Hugging Face, 4 월 7, 2026 에 액세스,
<https://huggingface.co/ddokbaro/SillokBert-NER>
8. Knowledge-Injected Transformer (KIT): A Modular Encoder–Decoder Architecture for Efficient Knowledge Integration and Reliable Question Answering - MDPI, 4 월 7, 2026 에 액세스, <https://www.mdpi.com/2076-3417/16/3/1601>