

DAT 7기 캡스톤 프로젝트 보고서

지식 주입형 언어 모델 기반

승정원일기 자동 번역 최적화 연구

: 프롬프트 전략 및 개체명 주입 방식의 단계적 비교 실험

DAT 7기

말모이 팀

길다인 · 오성민 · 이승민 · 배진형



Data Analysis & Technology



DAT 7기 캡스톤 프로젝트 보고서

지식 주입형 언어 모델 기반

승정원일기 자동 번역 최적화 연구

: 프롬프트 전략 및 개체명 주입 방식의 단계적 비교 실험

Optimizing Automatic Translation of the Seungjeongwon Ilgi
with a Knowledge-Injected Language Model

이 보고서를 캡스톤 프로젝트 보고서로 제출합니다.

2026년 06월 01일

DAT 7기

말모이 팀

길다인 · 오성민 · 이승민 · 배진형

DAT 7기 캡스톤 프로젝트 보고서



Data Analysis & Technology



지식 주입형 언어 모델 기반 승정원일기 자동 번역 최적화 연구

: 프롬프트 전략 및 개체명 주입 방식의 단계적 비교 실험

국문 요약

승정원일기는 유네스코 세계기록유산으로 등재된 총 3,243책, 약 2억 4,250만 자 규모의 역사 기록물로, 현재 번역 완료율은 37.4%에 불과하다. 기존 AI 번역 모델은 고유명사 오역률이 8.3%에 달하고 역사 문어체 표현을 현대 일상어로 대체하는 문체 불일치 문제가 심각하다. 본 연구는 파인튜닝 없이 프롬프트 엔지니어링과 인물 지식 베이스(KB) 주입으로 이를 해결하고자, 조선왕조실록 188,206건과 승정원일기 130,899건의 병렬 코퍼스를 직접 구축하고 Gemma-4-26B 모델을 대상으로 Baseline, Few-shot, NERfix, NERinject의 4단계 ablation 실험을 수행하였다. 최적 전략인 NERinject가 BLEU(c) 40.61, ETS 0.888을 달성하여 Baseline 대비 각각 +5.10p, +13.2pp(동일 491개 엔티티 통제 비교 기준) 향상되었다. 또한 기존 NER Recall 지표의 순환 평가 문제를 규명하고 SJW 사이트 HTML 독립 소스 기반 ETS를 설계한 점에서 방법론적 기여가 있다.

Abstract

The Seungjeongwon Ilgi is a UNESCO Memory of the World comprising 3,243 volumes and about 242.5 million characters, of which only 37.4% has been translated. General AI translators suffer from an 8.3% proper-noun error rate and from style mismatches that replace archival literary expressions with modern colloquial ones. Without fine-tuning, this study combines prompt engineering with person knowledge-base (KB) injection. We built a parallel corpus from 188,206 Annals records and 130,899 Seungjeongwon Ilgi records and ran a four-stage ablation (Baseline, Few-shot, NERfix, NERinject) on Gemma-4-26B. The best strategy, NERinject, reached BLEU(c) 40.61 and ETS 0.888, improving over Baseline by +5.10p and +13.2pp (controlled comparison on the same 491 entities). We also identify a closed-loop problem in the conventional NER Recall metric and design an ETS grounded in an independent SJW HTML source.



DAT 7기

말모이 팀

길다인 · 오성민 · 이승민 · 배진형



Data Analysis & Technology



목 차

제 1장 서론	1
제 1절 연구의 배경 및 목적	1
제 2절 연구의 범위 및 방법	1
제 2장 이론적 배경	2
제 1절 선행연구 검토	2
제 2절 용어의 정의 및 개념적 틀	2
제 3장 연구 설계 및 분석 방법	4
제 1절 연구 진행 개요	4
제 2절 연구 대상 및 자료 수집	5
제 3절 분석 도구 및 절차	7
제 4장 연구 결과 및 실증 분석	10
제 1절 자료의 특성	10
제 2절 분석 결과	10
제 3절 결과에 대한 논의	13
제 5장 결론	14
제 1절 연구 요약	14
제 2절 정책적 제언 및 시사점	14
제 3절 연구의 한계 및 향후 과제	15
참고문헌	16

표 목차

[표 3-1] 평가셋 길이 분포	7
[표 3-2] 평가셋 문체 패턴 분포	7
[표 4-1] 구축 코퍼스 및 평가셋 주요 특성	10

[1]



[표 4-2] 4단계 ablation 최종 결과	10
[표 4-3] 전체 엔티티 교차 분류 (491개)	11
[표 4-4] KB 등재 엔티티 (324개)	12
[표 4-5] KB 미등재 엔티티 (167개)	12

그림 목차

[그림 3-1] SJW 번역 실험 설계: 4단계 Ablation	9
---	---



제 1 장 서론

제 1 절 연구의 배경 및 목적

승정원일기(承政院日記)는 조선시대 왕명 출납 기관인 승정원이 인조(1623 년)부터 순종(1910 년)에 이르기까지 매일 기록한 국정 일지로, 유네스코 세계기록유산에 등재된 세계 최대 규모의 연속 역사 기록물이다. 총 3,243 책, 약 2 억 4,250 만 자에 달하는 이 문헌은 조선 후기 정치·외교·경제·사회 전반을 망라하는 1 차 사료로서 학술적 가치가 지대하다. 현재 국역 완료율은 37.4%에 불과하며, 전문적인 고전 한문 해독 인력의 공급 한계로 인해 현재 속도를 유지할 경우 완역은 2062 년에나 가능할 것으로 추산된다. AI 기반 번역 기술이 대안으로 검토되어 왔으나 두 가지 핵심 문제가 존재한다.

첫째, 고유명사 오역 문제다. 기존 AI 번역 모델의 인명·관직명 오역률은 8.3%에 달한다. 역사 번역에서 고유명사의 오역은 단순 텍스트 오류를 넘어 역사적 사실 자체를 왜곡하는 결과를 초래한다. 둘째, 문체 불일치 문제다. 승정원일기 특유의 문어체 표현인 “아뢰기를”, “전교하기를”, “제수하다”를 범용 모델이 “말씀하기를”, “임명하다” 등 현대 일상어로 대체하여 사료로서의 신뢰성을 훼손한다.

본 연구는 고비용의 파인튜닝 없이 프롬프트 엔지니어링과 인물 KB 주입만으로 이 두 문제를 동시에 해결할 수 있는지 체계적으로 검증하고, 기존 평가 지표의 한계를 보완하는 새로운 지표를 제안하는 것을 목적으로 한다.

제 2 절 연구의 범위 및 방법

연구 대상은 승정원일기 인조 시기(1623 년-1649 년)를 중심으로 하되, 코퍼스 구축 과정에서 조선왕조실록 광해군부터 순종까지 전 시기 데이터를 활용하였다. 연구는 다음 네 단계로 진행되었다.

첫째, 코퍼스 구축: Go 언어 기반 병렬 크롤러 개발, SmartProxy 를 활용한 대규모 수집, 6 단계 데이터 정제 파이프라인 구축. 둘째, 지식 베이스 설계: 인조·정조 시기 인물 33,002 명의 3 중 계층 KB 구축. 셋째, 4 단계 ablation 실험: Baseline, Few-shot, NERfix, NERinject 단계적 비교. 넷째, 독립 평가 지표 설계: SJW 사이트 HTML 독립 소스 기반 ETS 도입으로 순환 평가 문제 해소.

제 2 장 이론적 배경

제 1 절 선행연구 검토

고전 한문 기계 번역 분야에서는 SikuRoBERTa 기반의 AnchiLm 모델이 EvaHan2023 대회에서 BLEU 21.75 를 기록하며 주목받았다(Luo et al., 2023). 그러나 AnchiLm 과 SikuBERT 등 기존 모델은 중국의 사고전서(四庫全書) 중심으로 학습되어 조선 행정 체계와 이두식 표현에 대한 도메인 불일치가 심각하며, 실제 적용 시 BLEU 0.37-0.54 의 저조한 성능을 보였다. 중국 고문헌과 조선 한문은 한자라는 표의문자를 공유하지만, 관직 체계·문법 구조·행정 용어에서 극명한 차이를 보이기 때문이다.

프롬프트 엔지니어링 측면에서 Brown et al.(2020)의 Few-shot prompting 은 파인튜닝 없이 도메인 특화 출력을 유도하는 효과적인 방법임이 입증되었다. Min et al.(2022)은 예시의 다양성보다 일관성(consistency)이 번역 품질에 더 큰 영향을 미친다고 보고하였으며, 이는 본 연구의 단일 패턴 고정 예시 전략의 이론적 근거가 된다.

지식 주입형 번역 연구에서는 RAG 를 번역 시스템에 결합하는 시도가 증가하고 있으나(Lewis et al., 2020), 역사 인명에 특화된 KB 주입 방식은 충분히 탐구되지 않았다. Knowledge-Injected Transformer(KIT) 아키텍처(Kim et al., 2025)는 외부 지식의 명시적 주입이 환각 현상을 억제하는 데 효과적임을 보였다.

번역 평가 지표 측면에서 BLEU(Papineni et al., 2002)와 chrF(Popovic, 2015)는 n-gram 기반 표면 일치율 측정하지만 고유명사 오역을 포착하지 못한다는 한계가 있다. SillokBERT-NER 기반 NER Recall 을 보조 지표로 활용하는 시도가 있으나, 정답지 생성과 평가가 동일 모델을 공유할 때 발생하는 순환 평가 문제는 기존 연구에서 논의되지 않았다.

제 2 절 용어의 정의 및 개념적 틀

Few-shot Prompting 은 번역 요청 시 스타일 예시 문장을 함께 제공하여 모델 출력 어투를 유도하는 방식이다. NERfix 는 번역 완료 후 인명 오독을 hanja 라이브러리 음독과 성씨 앵커 기반 탐색으로 사후 교정하는 방식이다. NERinject 는 번역 전 프롬프트에 등장 인물 한자-한글 매핑 블록을 삽입하여 모델이 처음부터 정확한 인명으로 번역하도록 유도하는 방식이다.

ETS(Entity Translation Score)는 다음과 같이 정의한다.

$$\text{ETS} = \text{번역문에 올바르게 등장한 인명 수} / \text{원문의 총 인명 수}$$

ETS의 정답지는 SJW 사이트 HTML의 `span class="idx_person"` 태그를 독립 소스로 활용하여 SillokBERT와 완전히 분리 구축한다.

Closed Loop 문제는 NER Recall 채점 시 정답지 생성(SillokBERT-NER)과 NERinject 주입 소스가 동일한 KB를 공유함으로써 발생하는 순환 평가 구조를 말한다. 주입된 인명이 번역문에 잔존하는 것만으로 정답 처리되어, 실제 번역 품질과 무관하게 1.000이 산출된다.

CPT(Continued Pretraining)는 기존 사전학습 가중치를 유지하며 도메인 특화 코퍼스로 추가 학습하는 방식이다.



제 3 장 연구 설계 및 분석 방법

제 1 절 연구 진행 개요

본 연구는 총 6 차에 걸친 단계적 진행으로 수행되었으며, 각 단계는 이전 단계의 한계를 발견하고 방향을 수정하는 iterative 구조를 띤다.

1 차: 코퍼스 수집 인프라 구축. 크롤러 개발 및 정제 파이프라인 설계가 핵심 작업이었다.

2 차: 코퍼스 품질 실험 및 전략 전환. 문장 단위 병렬화 한계를 발견하고 단문 코퍼스 방식으로 전환하였다.

3 차: 모델 선택 및 KB 구축 완료. SillokBERT 도입과 5 개 KB 파일 완성이 이루어졌다.

4 차: 아키텍처 문제 해결 및 파이프라인 재설계. 가중치 직접 주입이 불가능함을 확인하고 프롬프트 기반 방식으로 전환하였다.

5 차: 4 단계 ablation 실험 수행. 본 연구의 핵심 실험 결과가 도출된 단계이다.

6 차: 평가 지표 고도화. ETS 도입 및 closed loop 문제 해소를 연구로 마무리하였다.

1. 코퍼스 수집 인프라 구축

초기 Python 기반 크롤러는 GIL(Global Interpreter Lock)로 인한 멀티스레딩 성능 저하 문제가 있어 Go 언어로 전면 재작성하였다. Goroutine 기반 병렬 처리와 SmartProxy IP 로테이션(5 회 재시도, 자동 전환)을 도입하여 대규모 수집의 안정성을 확보하였다. 데이터 정제에서는 서지 정보(태백산사고본 등), 학술 각주([註 087]), 저작권 문구(한국고전번역원), 날씨 기호(晴·陰·雨)를 제거하는 6 단계 정제 파이프라인을 구축하였다.

2. 코퍼스 구축 전략 전환

광해군부터 순종까지 전 시기 문장 단위 병렬 코퍼스 구축을 시도하였다. 한문(. ?!)과 국문(. ?!)을 기준으로 분할하되, 진짜 마침표 판별, 따옴표 구조적 대칭성, 문장 1:1 개수 검증, 전체 25 개 미만 기사 선정의 4 가지 조건을 설계하였다. 그러나 4 가지 조건을 모두 충족함에도 의미 불일치 사례가 다수 발생하였다. 역지로 분할할 경우 의미 일치율이 훼손되어 모델 학습 품질에 악영향을 준다는 판단 하에 단문

코퍼스(번역문 10 자-100 자) 추출 방식으로 전략을 전환하였다. 동시에 SillokBERT 토큰나이저에 인물명을 추가하여 고유명사가 여러 토큰으로 분리되는 현상을 방지하고 단일 토큰으로 인식됨을 검증하였다.

3. 모델 선택 및 KB 완성

당초 SikuBERT 기반 사전학습과 SOLAR PRO 3 파인튜닝을 계획하였으나 두 차례 모델 전환이 이루어졌다. 조선왕조실록에 특화된 SillokBERT 의 발견으로 SikuBERT 를 대체하였고, SOLAR PRO 3 사용 불가로 인해 다국어 처리·지시 이행 능력이 뛰어난 Gemma 로 디코더를 확정하였다. SillokBERT 에 대한 CPT 를 승정원일기 원문(인조-정조 6 년, 약 25MB)을 활용하여 수행하였으며, Loss 는 5.8 에서 5.1-5.2 로 안정 수렴하였다. 인조·정조 시기 인물 33,002 명을 대상으로 5 개 JSON 파일로 구성된 KB 를 완성하였다.

4. 아키텍처 문제 발견 및 파이프라인 재설계

SillokBERT 는 문장을 의미 벡터로 압축하는 인코더 구조이며, Gemma 는 텍스트를 자기회귀적으로 생성하는 디코더 구조다. 두 모델은 내부 표현 공간과 레이어 구성이 이질적이어서 가중치 직접 이관이 불가능함이 판명되었다. 이에 연구 방향을 전면 수정하여 지식을 가중치 대신 프롬프트 형식으로 전달하는 방식을 채택하였다. 새로운 파이프라인은 원문 입력, SillokBERT-NER 개체명 추출, KB 대조 및 시기 필터링, Entity Linking 을 통한 팩트 생성, 프롬프트 증강, Gemma 번역의 6 단계로 재설계되었다.

5. 4 단계 Ablation 실험

본 연구의 핵심 실험 단계로, 층화 샘플링된 300 개 평가셋을 구성하고 4 단계 전략을 순차적으로 실험하여 각 개입의 효과를 분리 측정하였다. NERinject 가 BLEU(c) 40.61, NER Recall 1.000 을 달성하였으나, NER Recall 이 1.000 에 도달한 것이 정답지 생성과 주입 소스의 공유에서 비롯된 닫힌 고리 문제임을 인식하고 독립 평가 지표의 필요성을 제기하였다.

6. 평가 지표 고도화

NER Recall 의 순환 평가 문제를 해소하기 위해 ETS 를 설계하였다. 국사편찬위원회 SJW 사이트 HTML 의 인명 태그를 독립 소스로 활용하여 SillokBERT 와 완전히 분리된 정답지를 구축하였다. ETS 기준 재측정 결과 NERinject 는 0.888 을 기록, NER Recall 1.000 과의 0.112 차이가 순환 평가의 부풀림 효과임을 정량적으로 규명하였다.



제 2 절 연구 대상 및 자료 수집

1. 코퍼스 수집

조선왕조실록은 Go 기반 크롤러로 sillok.history.go.kr 에서 연도·월 단위 병렬 수집하였다. goquery 로 원문·번역문을 파싱하고 XML 로 저장하며, 이어받기(Resume)와 5 회 자동 재시도 기능을 포함한다. 최종 수집 규모는 광해군부터 순종까지 188,206 개 기사이다.

승정원일기는 sjw.history.go.kr 에서 인조·정조 시기를 대상으로 수집하였다. 원문 전용 크롤러(sjw.go)와 원문·번역문 병행 크롤러(sjw2.go)를 각각 운용하였으며, fetch_sjw_raw.go 는 평가셋 300 개 ID 의 HTML 원본을 수집하여 인명 태그(span class="idx_person")를 보존하였다. 최종 수집 규모는 130,899 개 기사이다.

2. 데이터 정제

수집된 XML 데이터는 6 단계 정제 파이프라인을 거쳤다.

- 1 단계 서지 정보 제거: 태백산사고본, 국편영인본 등 출처 표기 삭제
- 2 단계 각주·주석 제거: [註 087] 형태의 학술 각주 및 해설 텍스트 제거
- 3 단계 저작권 문구 제거: 한국고전번역원 등 반복 표기 삭제
- 4 단계 말머리·기호 제거: 번역문의 ‘국역’, 원문의 ‘○’, 낱씨 기호 삭제
- 5 단계 한자 정제: SJW 번역문 내 한자 괄호 표기 제거
- 6 단계 V82 매칭 엔진: 한문(曰·啓·云 등)과 한국어(하였다·아뢰었다 등) 종결 패턴으로 원문-번역문 1:1 의미 일치 검증

정제 후 날짜 ID 기반 병합(merge.py)으로 실록과 SJW 를 결합하여 인조 시기 병렬 코퍼스 62,176 쌍(Merged_Corpus_Final)을 최종 구성하였다.

3. 지식 베이스(KB) 구축

조선 시기 등장 인물 33,002 명을 대상으로 3 중 계층 KB 를 구축하였다.

- person_master.json: 통합 인물 DB 로, 인물별 표준 식별자, 한자·한글명, 관직 이력을 연대순으로 정리한 마스터 데이터베이스
- inverted_index_injo.json: 인조 시대 역색인으로, 본명·자·호·약칭 등 다양한 호칭을 키로 인물 ID 를 값으로 매핑하여 O(1) 탐색 지원



- **id_lookup_injo.json**: 인조 시대 상세 사전으로, 인물 ID 를 키로 관직·활동 연도를 저장하여 동명이인 시공간 필터링에 활용
- **inverted_index_jeongjo.json, id_lookup_jeongjo.json**: 정조 시기 동일 구조 별도 구축

4. SillokBERT 도메인 적응(CPT)

SillokBERT(bert-base-multilingual-cased 기반)를 기반 모델로, 승정원일기 원문 코퍼스 50% 랜덤 추출(약 25MB)을 대상으로 Masked Language Modeling(MLM) 방식의 Continued Pretraining 을 수행하였다.

- **학습 설정**: AdamW(lr: $5e-5$ 에서 $2e-5$), fp16 혼합 정밀도, Gradient Accumulation(Step 4)
- **하드웨어**: T4 GPU(VRAM 15GB), 배치 2 에 grad_accum 4 로 실효 배치 8
- **결과**: 총 3 Epoch, 24,546 스텝, Loss 5.8 에서 5.1-5.2 로 안정 수렴
- **산출물**: SillokBERT_SJW_Adapted(인조+ 정조 통합본)와 인조 단독 재학습본

제 3 절 분석 도구 및 절차

1. 평가셋 설계

전체 병렬 코퍼스에서 대표성을 확보하기 위해 2 단계 층화 샘플링을 수행하였다.

1 단계: Gemma-4-26B 로 3,000 개를 번역하여 문장단위 BLEU(char) 20 이상 필터링과 reference 중복 제거로 대표 후보 1,925 개(eval_set_1925)를 구성하였다.

2 단계: 1,925 개에서 원문 길이 버킷과 문체 패턴 교차 셀 기준 층화 샘플링으로 최종 300 개를 추출하였다. KL divergence 는 길이 약 0.000, 패턴 약 0.001 로 모집단 분포를 거의 완벽히 반영한다(random.seed(42)).

[표 3-1] 평가셋 길이 분포

구간	기준	수	비율
XS	50자 미만	133개	44.3%
S	50-149자	104개	34.7%
M	150-349자	43개	14.3%

L	350자 이상	20개	6.7%
---	---------	-----	------

[표 3-2] 평가셋 문체 패턴 분포

패턴	설명	수	비율
GEN	일반 기사	142개	47.3%
REP	아뢰기, 啓曰	135개	45.0%
DEN	불허, 不許	9개	3.0%
MEM	장계/서계	7개	2.3%
ROY/APT/APR	전교·윤허	7개	2.3%

2. ETS 정답지 구축

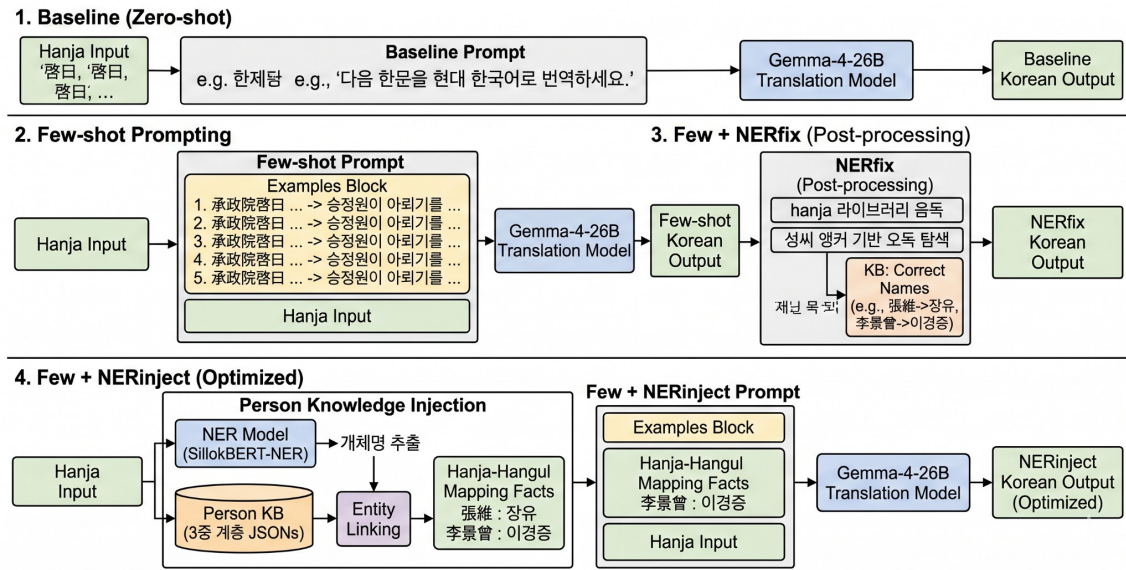
기존 NER Recall 은 SillokBERT-NER 로 정답지를 생성하고 동일 KB 로 주입·채점하는 닫힌 고리 구조를 지닌다. 이 순환성을 제거하기 위해 독립 소스 기반 ETS 정답지를 구축하였다.

국사편찬위원회 승정원일기 원문 서비스는 역사학자가 직접 수행한 인명 어노테이션을 HTML 마크업으로 포함한다. fetch_sjw_raw.go 로 수집한 HTML 에서 span class="idx_person" 태그 내 한자 인명을 추출하고, person_master.json 으로 한글명을 매핑하였으며, KB 미등재 인명은 hanja 라이브러리 음독 변환으로 보완하였다. 결과적으로 300 개 중 225 개(75.0%)에 인명 엔티티가 존재하며 총 527 개 인명 엔티티를 확보하였다. 이 정답지는 SillokBERT-NER 와 완전히 독립적이어서 순환 평가 문제를 원천 제거한다.

3. 번역 실험 설계

사용 모델은 Gemma-4-26B-A4B-IT(Google Generative AI API, temperature=0.0)이며, 비교 모델로 Qwen3-4B, Phi4-mini, Qwen3-235B, DeepSeek-v3 를 함께 평가하였다. 4 단계 전략의 핵심 설정은 다음과 같다.

SJW Translation Experiment Design: Four Ablation Steps



[그림 3-1] SJW 번역 실험 설계: 4단계 Ablation

- **Baseline**: 원문만 입력하는 방식으로, “다음 한문을 현대 한국어로 번역하세요. 번역문만 출력하세요: {원문}” 형태의 최소 프롬프트 사용
- **Few-shot**: fewshot_config.json에 저장된 REP 패턴 예시 5개를 프롬프트에 고정 삽입
- **NERfix**: Few-shot 번역 결과에 hanja 라이브러리 음독과 성씨 앵커 기반 오독 탐색을 적용하여 정답 한글명으로 치환하는 사후 교정
- **NERinject**: Few-shot 프롬프트의 원문 직전에 “[등장 인물 - 반드시 아래 한글명 그대로 사용]” 블록을 삽입하여 번역 전 인명을 사전 주입

4. 평가 지표

- **BLEU(c)**: sacrebleu character-level BLEU(effective_order=True)
- **chrF**: Character n-gram F-score
- **BLEU(m)**: Kiwi 형태소 분석 후 BLEU
- **ETS**: SJW HTML 독립 소스 기반 인명 보존율

제 4 장 연구 결과 및 실증 분석

제 1 절 자료의 특성

구축된 코퍼스의 주요 특성은 다음과 같다.

[표 4-1] 구축 코퍼스 및 평가셋 주요 특성

항목	규모
실록 코퍼스	광해군-순종 188,206개 기사
승정원일기 코퍼스	인조-정조 130,899개 기사
최종 병렬 코퍼스	인조 전 기간 V82 통과분 62,176쌍
인물 KB	인조+ 정조 시기 33,002명
평가셋	층화 샘플링 300개
평가셋 내 인명	225개(75.0%) 기사, 총 527개 엔티티

승정원일기는 전체 기사의 약 45%가 신하 보고(啓曰) 패턴, 47.3%가 일반 기사 패턴으로 구성되어 있다. 이는 승정원의 업무 특성인 왕명 전달과 신하 보고 기록을 반영한 것으로, 문체 어투 학습의 중요성을 시사한다.

비교 실험에서 Gemma-4-26B 는 Baseline 기준 BLEU(c) 35.51 로 Qwen3-235B, DeepSeek-v3, Qwen3-4B, Phi4-mini 보다 유의미하게 높은 성능을 보여 최종 실험 모델로 선정되었다.

제 2 절 분석 결과

1. 4 단계 ablation 최종 결과

[표 4-2] 4단계 ablation 최종 결과

전략	BLEU(c)	chrF	BLEU(m)	ETS	n
Baseline	35.51	30.72	27.35	0.744	225
Few-shot	39.46	34.27	31.90	0.732	225
Few + NERfix	39.78	34.69	32.19	0.825	225

Few + NERinject	40.61	35.17	33.09	0.888	217
-----------------	-------	-------	-------	-------	-----

주) NERinject 의 n=217 은 KB 등재 인명이 없는 8 개 기사에 주입 대상이 없기 때문이다. 따라서 NERinject 의 ETS 0.888 은 217 개 기사(491 개 엔티티) 기준이고, 나머지 세 전략은 225 개 기사(527 개 엔티티) 기준이므로 분모가 상이하다.

2. Few-shot 변형 실험

Few-shot 예시 구성에 대한 다양한 변형을 시도하였으나 모두 초기 5 개 고정 예시보다 열위였다. AISO 알고리즘을 활용한 동적 예시 선택, 예시 수 증가(10 개·20 개), 역할 지정, 번역 원칙 명시 등 모든 변형이 BLEU 기준으로 고정 5 개 예시에 미치지 못하였다. 이는 번역 도메인에서 예시의 다양성보다 일관성이 더 중요하다는 것을 실증적으로 보여준다.

3. ETS vs NER Recall 비교

NERinject 의 NER Recall(SillokBERT 기반, closed loop)은 1.000 이었으나, ETS(SJW HTML 독립 소스 기반)는 0.888 이었다. NER Recall 의 1.000 은 정답지 생성과 주입 소스가 동일한 KB 를 공유하는 닫힌 고리에서 비롯된 인위적 수치다. 두 지표의 0.112 차이가 순환 평가의 부풀림 효과이며, ETS 의 0.888 이 실제 인명 보존율이다.

4. Gemma 단독 능력과 NERinject 기여의 분리

NERinject 가 달성한 ETS 0.888 의 내부 구성을 파악하기 위해, 491 개 엔티티 각각에 대해 Baseline 과 NERinject 의 정오를 교차 분류하였다.

[표 4-3] 전체 엔티티 교차 분류 (491개)

구분	개수	비율
① Gemma 단독으로도 정답, NERinject도 정답	368개	74.9%
② NERinject 덕분에 추가로 정답 (NER 순수 기여)	68개	13.8%
③ Gemma는 정답이었으나 NERinject 후 오답 (역효과)	3개	0.6%
④ 둘 다 오답	52개	10.6%
합계	491개	100%

Baseline ETS-B 는 $(368 + 3) / 491 = 0.756$ 이며, NERinject ETS-B 는 $(368 + 68) / 491 = 0.888$ 이다. NERinject 의 순 기여는 65 개(+0.132p)로, 68 개를 추가 적중하고 3 개에서 역효과가 발생한 결과다.

주) 여기서의 ETS-B 는 Baseline 과 NERinject 를 동일한 491 개 엔티티에서 통제 비교하기 위해 재계산한 값으로, [표 4-2]의 ETS-A(Baseline 0.744)와는 분모가 상이하다.

KB 등재 여부로 분류하면 기여 구조가 더 명확하게 드러난다.

[표 4-4] KB 등재 엔티티 (324개)

구분	개수	비율
① 둘 다 정답	263개	81.2%
② NER 순수 기여	59개	18.2%
③ NER 역효과	0개	0.0%
④ 둘 다 오답	2개	0.6%
합계	324개	100%

KB 등재 엔티티에서 NERinject 의 역효과는 0 건이다. 주입된 정답 한글명이 Gemma 의 기존 출력을 방해하는 경우가 없었으며, 오히려 59 개(18.2%)를 추가로 적중시켰다. 잔여 오답 2 개(0.6%)는 주입된 한글명이 번역문에 포함되지 않은 예외적 케이스로, KB 등재 엔티티에 대한 NERinject 의 실질적 정확도는 $322/324 = 0.994$ 에 달한다.

[표 4-5] KB 미등재 엔티티 (167개)

구분	개수	비율
① 둘 다 정답	105개	62.9%
② NER 기여 (hanja 음독 주입)	9개	5.4%
③ NER 역효과	3개	1.8%
④ 둘 다 오답	50개	29.9%
합계	167개	100%

이는 NERinject 의 성능 향상이 모델 자체 능력과 KB 주입 기여 중 어느 쪽에서 비롯된 것인지를 분리하기 위한 분석이다.

KB 미등재 엔티티에서 NERinject 는 hanja 라이브러리 음독 변환으로 주입을 시도하여 9 개를 추가 적중하지만, 동시에 3 개에서 역효과가 발생하여 순 기여는 6 개에 그친다. 주목할 것은 ④ 둘 다 오답이 50 개(29.9%)에 달한다는 점으로, 이것이 ETS 0.888 의 천장을 결정하는 구간이다. 이 50 개는 KB 미등재로 인해 주입이 불완전하고 모델 자체 능력으로도 해결되지 않는 인명들이다.

이상의 분석을 종합하면, NERinject 가 달성한 ETS 0.888 은 Gemma 가 원래 보유한 74.9%(둘 다 정답인 교집합)의 단독 능력 위에 NER 주입이 13.8%를 추가한 구조이며, 역효과는 0.6%로 무시할 수준이다. 향후 성능 향상 여지는 ④ 구간인 10.6%에 집중되어 있으며, 이 중 KB 미등재 + 모델 자체 한계에서 비롯된 부분이 대부분을 차지한다.

제 3 절 결과에 대한 논의

1. 문체와 인명 정확도의 트레이드오프

Few-shot 은 BLEU(c)를 +3.95p 향상시켰으나 ETS 를 -0.012 하락시켰다. 모델이 문체 일치에 주의 자원을 집중하면서 인명 독음 판단 정확도가 부분적으로 희생된 것으로 해석된다. 두 목표를 동시에 최적화하는 NERinject 가 이 문제를 부분적으로 해소한다.

2. NERfix 의 효과와 한계

NERfix 는 ETS 를 0.732 에서 0.825 로 +0.093p 향상시켰다. 張維를 장위로 오독한 것을 정답인 장유로, 李景曾을 이경정에서 이경중으로 교정하는 등 오독 교정 효과가 명확하다. 그러나 번역 과정에서 인명 자체가 생략된 34 개 케이스는 사후 교정이 불가능하여 ETS 0.825 가 NERfix 의 실질적 천장이 된다.

3. NERinject 의 한계와 KB 커버리지

NERinject 의 ETS 0.888 은 이론적 상한이 KB 커버리지에 의해 제약된다. KB 미등재 인명은 주입 자체가 불가능하여 오독·생략 위험이 잔존한다. ETS 0.888 의 잔여 오류 11.2%는 대부분 이 KB 미등재 인명에서 발생한다.

제 5 장 결론

제 1 절 연구 요약

본 연구는 승정원일기의 LLM 자동 번역 품질 향상을 위해 조선왕조실록 188,206 건과 승정원일기 130,899 건의 대규모 병렬 코퍼스를 직접 구축하고, 인조·정조 시기 인물 33,002 명의 도메인 특화 KB를 설계하였다. Gemma-4-26B 모델을 대상으로 4 단계 ablation 실험을 수행한 결과, Few-shot 예시를 통한 문체 유도과 번역 전 인명 KB 주입(NERinject)의 결합이 BLEU(c) 40.61, ETS 0.888 을 달성하여 Baseline 대비 각각 +5.10p, +13.2pp 향상됨을 확인하였다. ETS 향상폭은 Baseline 과 NERinject 를 동일한 491 개 엔티티에서 통제 비교한 ETS-B 기준(0.888-0.756)이며, 분모가 상이한 [표 4-2]의 전체셋 단순 차이로는 +14.4pp 이다. 또한 기존 NER Recall 지표의 순환 평가 문제를 최초로 규명하고 SJW 사이트 HTML 독립 소스 기반 ETS 를 설계하여 보다 신뢰할 수 있는 인명 보존율 측정 방법론을 제안하였다.

핵심 발견은 세 가지다. 첫째, 번역 도메인에서 Few-shot 예시의 일관성이 다양성보다 중요하다. 둘째, 문체 품질과 인명 정확도는 트레이드오프 관계이며, 이를 동시에 최적화하려면 KB 사전 주입이 필요하다. 셋째, 평가 지표의 독립성이 결과의 신뢰성을 결정한다.

제 2 절 정책적 제언 및 시사점

디지털 인문학 관점에서 본 연구는 파인튜닝 없는 프롬프트 엔지니어링만으로도 역사 문헌 번역에 실용적 수준의 성능이 가능함을 보였다. 이는 고비용 GPU 자원 없이도 국역 사업의 보조 도구로 즉시 활용 가능함을 의미한다.

번역 사업 실무 측면에서 NERinject 파이프라인은 자동화 가능한 구조를 지닌다. HTML 수집, SillokBERT-NER 인명 태깅, KB 매핑, NERinject 프롬프트 생성의 과정을 자동화하면 인간 번역자의 개입 없이 1차 번역문을 생성할 수 있다. 이를 전문 번역가의 검토 전 초안 생성 도구로 활용하면 완역 목표 시점을 대폭 앞당길 수 있다.

평가 방법론 측면에서 ETS 설계 방식, 즉 정부 기관의 전문가 어노테이션 HTML 마크업을 독립 정답지로 활용하는 방법은 여타 역사 기록물 번역 평가에도 적용 가능한 범용적 접근법이다.

제 3 절 연구의 한계 및 향후 과제

첫째, KB 커버리지 한계다. 현재 KB 는 인조·정조 시기 33,002 명을 포함하나, 등재되지 않은 인명은 주입 자체가 불가능하다. ETS 0.888 의 천장은 KB 확장 없이 돌파하기 어렵다. 향후 국사편찬위원회 인물 데이터베이스와의 연계 및 KB 자동 확장 방법론 개발이 필요하다.

둘째, 평가 지표의 추가 개선 여지다. ETS 는 인명 보존을 측정하지만 관직명·지명 오역은 포착하지 못한다. 관직명과 지명을 포함한 종합적 Entity Translation Score 로 확장이 필요하다.

셋째, 모델 범위의 한계다. 본 연구는 Gemma-4-26B 에 집중하였으며, 동일 전략이 다른 모델에서도 동일한 효과를 보이는지는 검증되지 않았다.

향후 과제로는 SJW 전 시기(인조-순종) 코퍼스로 평가 범위 확대, KB 미등재 인명에 대한 음독 기반 자동 생성 방법 개발, 대규모 병렬 번역을 통한 반자동 완역 파이프라인 구축을 제안한다.

참고문헌

- 국사편찬위원회. 승정원일기. <https://sjw.history.go.kr> (2026 년 4 월 접속)
- 국사편찬위원회. 조선왕조실록. <https://sillok.history.go.kr> (2026 년 4 월 접속)
- Luo, Y. et al. (2023). AnchiLm: An Effective Classical-to-Modern Chinese Translation Model Leveraging bpe-drop and SikuRoBERTa. Proceedings of ACL 2023, ALT Workshop. <https://aclanthology.org/2023.alt-1.8.pdf>
- ddokbaro. (2023). SillokBert-NER. HuggingFace. <https://huggingface.co/ddokbaro/SillokBert-NER>
- Brown, T. et al. (2020). Language models are few-shot learners. Advances in Neural Information Processing Systems, 33, 1877–1901.
- Min, S. et al. (2022). Rethinking the role of demonstrations: What makes in-context learning work? EMNLP 2022.
- Lewis, P. et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. NeurIPS 2020.
- Papineni, K. et al. (2002). BLEU: a method for automatic evaluation of machine translation. ACL 2002.
- Popovic, M. (2015). chrF: character n-gram F-score for automatic MT evaluation. WMT 2015.
- Kim, J. et al. (2025). Knowledge-Injected Transformer (KIT): A Modular Encoder-Decoder Architecture for Efficient Knowledge Integration and Reliable Question Answering. Applied Sciences, 16(3), 1601. <https://doi.org/10.3390/app16031601>
- Google Developers. (2025). Multilingual innovation in LLMs: How open models help unlock global communication. <https://developers.googleblog.com/unlock-global-communication-gemma-projects/>
- TranslateGemma Technical Report. (2025). arXiv:2601.09012. <https://arxiv.org/abs/2601.09012>

