

AnchiBERT: A Pre-Trained Model for Ancient Chinese Language Understanding and Generation

Team 말모이

목차

01

선행 연구 소개

02

연구 배경 및 문제 인식

03

핵심 제안 및 방법

04

실험 및 결과

05

시사점

06

적용 방안

선행 연구 소개: BERT

배경: Sequential(순차)에서 Contextual(문맥)로

- Traditional (RNN/LSTM): 단방향 처리의 한계로 인한 정보 소실 및 중의성 해결 미흡
- BERT: Transformer 구조를 활용한 전방향 문맥 참조

EX) “금융 결제를 위해 은행에 갔다” : 은행 (열매vs금융)

BERT는 '은행' 이라는 단어 주변에 '결제', '송금'이 있다면 금융 기관으로, '가로수', '노란색'이 있다면 나무로 이해하는 능력을 가짐

BERT가 똑똑해진 방법: Masked Language Model (MLM)

EX)

- 원문: "나는 오늘 점심에 맛있는 파스타를 먹었다."
- 변형: "나는 오늘 [MASK] 에 맛있는 [MASK] 를 먹었다."

BERT는 빈칸([MASK])의 앞뒤 문맥을 보고, 첫 번째 빈칸에는 시간대인 '점심'이나 '저녁'이, 두 번째 빈칸에는 음식 이름인 '파스타'나 '피자'가 들어갈 확률이 높다는 것을 스스로 깨우침

연구 배경 및 문제 인식

기존 연구의 한계

병렬 데이터의 희소성

고대 중국어 원문은 방대하지만, 현대 중국어와의 번역 쌍(Pair) 데이터는 구축 비용이 높고 전문가 주석이 필요하여 매우 부족

도메인 시프트 (Domain Shift)

현대 중국어 위키백과 등으로 학습된 일반 BERT 모델은 고대 중국어의 문체, 어휘, 문법 구조와 괴리가 커서 성능 저하 발생



번역, 생성, 분류 등 다양한 태스크에서 기존 모델의 한계 노출

→

대규모 고대 중국어 코퍼라로 도메인 특화 학습을 수행하면, 이해(NLU)와 생성(NLG) 태스크 모두에서 성능이 향상되는가?

AnchiBERT의 접근


대규모 단일언어 코퍼라 활용

병렬 데이터 대신 구하기 쉬운 고대 중국어 원문 텍스트만을 대량으로 수집하여 사전 학습에 활용

도메인 특화 사전 학습

기존 BERT 모델에 고대 중국어 코퍼라를 추가로 학습시켜, 고문의 언어적 특성을 '모국어'처럼 이해하게 만들

핵심 제안 및 방법




- Standard Architecture
BERT-Base 구조를 그대로 유지하여 호환성 확보
- Continual Pre-training
처음부터 학습하지 않고 기존 중국어 BERT에서 이어서 학습하여 효율성 극대화
- Generation Pipeline
생성 태스크를 위해 AnchiBERT를 인코더로, 랜덤 초기화된 Transformer를 디코더로 결합



기존 BERT-base 모델을 기반으로 추가 pre-training을 수행
학습 방식은 Masked Language Modeling (MLM)만 사용

실험 및 결과

1. 시 주제 분류 (PTC)



2. 생성 태스크 성능 비교 (AFT, CCG)

Model	AMCT (BLEU-4)	CPG (2-2) (BLEU-4)	CPG (1-3) (BLEU-4)	CCG (BLEU-2)
Std-Transformer	27.80	27.47	19.52	27.14
BERT-Base	28.89	29.82	21.63	33.01
AnchiBERT (Ours)	31.22	30.08	22.10	33.37
Improvement (vs BERT)	+2.33	+0.26	+0.47	+0.36

Analysis & Human Evaluation Summary



일관된 성능 향상

이해(NLU)와 생성(NLG) 모든 태스크에서 BERT-Base 및 비-비-사전학습 모델을 능가함. 특히 데이터가 적은 분류 태스크에서 큰 폭 상승.



인간 평가 결과 (Human Eval)

문법성(Syntactic)과 의미성(Semantic) 측면에서 AnchiBERT가 가장 높은 점수 획득. 고전 시의 운율과 길이를 더 잘 준수함.



도메인 특화 효과 검증

일반 도메인 BERT보다 고대 중국어 특화 학습이 저자원 환경에서도 효과적임을 입증 (SOTA 달성).

시사점

PRE-TRAINING >
NON-PRETRAINING

데이터 부족 문제
해결 전략 = 사전학습

복잡한 구조보다
사전 학습이 더 중요

DOMAIN SPECIFIC >
GENERAL MODEL

도메인 특화 모델이
성능 핵심 요소



고문 NLP는 곧 “도메인 적합성 + 사전학습”

적용 방안

Model Comparison	AnchiBERT (Baseline)	SikuBERT (Selected) 
1. 시대적 정합성 Target: 영조 시대(18C)	기원전(Pre-Qin) 중심 18세기 관료제 용어/문장과 '언어적 세대 차이' 존재. 복잡한 행정 용어 처리에 한계.	청 건륭제(18C) 《사고전서》 영조 시대와 동시대 문체 학습. 당시의 어휘와 행정적 맥락을 '모국어'처럼 구사.
2. 데이터 & RAG 시너지 33만 건 인물-관직 데이터	39.5M 토큰 (제한적) 어휘 사전(Vocab)의 한계로 고유명사(NER) 인식 및 RAG 결합 시 불안정할 수 있음.	5억 자 (500M+) 압도적 규모 방대한 어휘 보유. Entity-Anchored BPE 적용 시 인명/관직명 맥락을 이미 파악하여 RAG 효율 극대화.

Why SikuBERT?

- 1. 학습 데이터의 시대적 배경
- 2. 데이터 규모와 개체명 인식(NER) 성능

감사합니다