

LLM 기반 승정원일기 번역 프로젝트

TEAM 말모이 | 길다인 오성민 이승민 배진형

문장 단위 코퍼스 구축 시도

```
<article id="koa_10002001_017">
  <translation>대내에서 봉함된 유교를 빈청으로 내렸는데 이는 전일 미령할 때 봉함하여 두었던 글이다. 세자에게 유시하였다. "동기들을 내가 살아 있을 때처럼 사랑하고 참소하는 말을 하는 사
람이 있으면 부디 그 말을 따르지 말라. 이런 내용으로 너에게 부탁하노니, 모쪼록 나의 뜻을 깊이 유념하기 바란다."</translation>
  <original>以內封遺教下于賓廳，前日未寧時所封書也。 諭世子曰："愛同氣如予在時，人有讒言，慎勿聽之。 以此托於汝，須體予意。"</original>
</article>
```



```
▼<article id="koa_10002001_017">
  ▼<sensences>
    ▼<s id="1">
      <original>以內封遺教下于賓廳，前日未寧時所封書也。</original>
      <translation>대내에서 봉함된 유교를 빈청으로 내렸는데 이는 전일 미령할 때 봉함하여 두었던 글이다.</translation>
    </s>
    ▼<s id="2">
      <original>諭世子曰："愛同氣如予在時，人有讒言，慎勿聽之。</original>
      <translation>세자에게 유시하였다. "동기들을 내가 살아 있을 때처럼 사랑하고 참소하는 말을 하는 사람이 있으면 부디 그 말을 따르지 말라.</translation>
    </s>
    ▼<s id="3">
      <original>以此托於汝，須體予意。</original>
      <translation>이런 내용으로 너에게 부탁하노니, 모쪼록 나의 뜻을 깊이 유념하기 바란다.</translation>
    </s>
  </sensences>
</article>
```

파이썬 코드를 이용하여 광해군부터 순종범위의
문장 단위 코퍼스 구축을 시도

문장 단위 코퍼스 구축 시도

문장 종결 기호 기반의 1:1 개수 검증

원문(한문): 。 , ? , !를 기준으로 분할
번역문(국문): . , ? , !를 기준으로 분할

문장 개수 상한선 설정

전체 문장 개수가 25개 미만인
기사만 선정



문장 단위 코퍼스 구축을 위한 기사선정

언어별 특수 패턴을 고려한 '진짜 마침표' 판별

"~하였다" 등 대화가
시작되거나 끝나는 지점은
개수 검증에서 제외

따옴표 기반의 구조적 대칭성

원문 문장이 따옴표(" , ")로 시작한다면
번역문도 반드시 따옴표로 시작

문장 단위 코퍼스 구축 시도

```
<article id="koa_10002001_004">
  <sentences>
    <s id="1">
      <original>持平申光立 司憲府啓曰："李挺元等皆以鬼蜮妖邪之徒，敢生交亂傾陷之謀，附會鄭仁弘誣罔陰慘之說，以試含沙射影之計，其受人指嗾嫁禍士林之罪，不可不痛懲。</original>
      <translation>지평 신광립이 아뢰기를, "이정원 등은 요망하고 간사한 귀역 같은 무리로서 감히 나라를 교란시켜 경함케 할 계모를 품고 정인홍의 거짓된 음참스러운 논설을 견강 부회하여 남을 무함하여 해칠 계교를 시험하였으니, 남의 사주를 받아 사람에게 화를 전가시킨 죄를 통렬히 징계하지 않을 수 없습니다.</translation>
    </s>
    <s id="2">
      <original>李挺元請命遠竄以明好惡。</original>
      <translation>이정원을 원찬시켜 호오를 분명히 밝히소서.</translation>
    </s>
    <s id="3">
      <original>平安都事李惺、前佐郎鄭造俱以險陂邪僻之人，與李爾瞻、李慶全結爲心腹，乘鄭仁弘誣罔構捏之疏，陰嗾其弟壻族親表裏相應，使李挺元輩繼上陰慘之言，以試鬼蜮之謀。</original>
      <translation>평안 도사 이성과 전 좌랑 정조는 모두 음험하고 간사한 사람들로서 이이첨 · 이경전과 교결하여 심복이 되었는데, 정인홍이 거짓으로 날조한 소장을 올린 것을 이용하여 은밀히 자제 · 사위 · 족친들을 사주, 안팎에서 서로 호응하게 하였습니다.</translation>
    </s>
    <s id="4">
      <original>請竝命遠竄。"</original>
      <translation>그리하여 이정원의 무리로 하여금 계속해서 음참스런 내용의 소장을 올리게 함으로써 귀역 같은 계모를 시험하였으니, 원찬시키소서."</translation>
    </s>
    <s id="5">
      <original>發落未及下。</original>
      <translation>하였으나, 발락이 제때에 내려지지 않았다.</translation>
    </s>
  </sentences>
</article>
```

4가지 조건을 모두 만족함에도 불구하고 나누면 의미가 일치하지 않는 사례가 다수 발생

계획 수정

```
"index": 1579,
"article_id": "koa_10402015_006",
"original": "卯時，日暈兩珥。暈上有冠，色內赤外青。巳時、未時、申時，日暈。",
"translation": "묘시에 햇무리가 지고 양이가 있었다. 햇무리 위에는 관이 있었는데 안쪽은 적색, 바깥쪽은 청색이었다. 사시·미시·신시에 햇무리가 졌다."
```

```
"index": 1580,
"article_id": "koa_10402015_009",
"original": "有政。以柳寅吉爲司諫院大司諫，洪履祥爲成均館大司成，鄭廣成兼侍講院弼善，趙希逸爲司憲府持平，韓縝男爲弘文館校理，吳靖爲弘文館副校理，張維爲藝文館奉教兼春秋館記事官。",
"translation": "유인길을 대사간으로, 홍이상을 대사성으로, 정광성을 검필선으로, 조희일을 지평으로, 한찬남을 교리로, 오정을 부교리로, 장유를 봉교 겸 춘추관 기사관 으로 삼았다."
```

```
"index": 1581,
"article_id": "koa_10402016_002",
"original": "傳曰：\"石灰三百石，令京畿監司，措給于文陽府院君永葬處。\"",
"translation": "전교하였다. \"경기 감사로 하여금 석회 3백 석을 마련하여 문양 부원군 장지에 보내도록 하라.\""
```

```
"index": 1582,
"article_id": "koa_10402018_004",
"original": "司諫院連啓南暉罷職事。答曰：\"已諭，不允。\"",
"translation": "사간원이 남탁의 파직에 관한 일을 연계하니 답하기를, \"이미 하유하였다. 윤허하지 않는다.\" 하였다."
```

원문과 번역문 간의 의미의 일치율이 모델 학습에 영향을 끼치기 때문에
억지로 쪼개기보단 단문 만을 겹치는 문장을 제외하고 json형식으로 추출

인물명 코퍼스 및 사전 구축

```
{
  "index": 2,
  "article_id": "koa_10002001_002",
  "original": "以金大來爲直提學，睦長欽爲執義，崔有源爲典翰，黃敬中、奇協爲校理，成時憲爲副修撰，李士慶爲正言。",
  "translation": "김대래를 직제학으로, 목장흠을 집의로, 최유원을 전한으로, 황경중·기협을 교리로, 성시헌을 부수찬으로, 이사경을 정언으로 삼았다.",
  "person_tags": [
    "黃 敬 中",
    "奇 協",
    "金 大 來",
    "成 時 憲",
    "睦 長 欽",
    "崔 有 源",
    "李 士 慶"
  ]
}
```

SillokBert-NER로 추출된 인명 데이터를 기반으로 도메인 특화 사전을 확장하여,
모델이 모르는 단어(OOV)를 줄이고 고유명사 인식 정확도를 극대화함

SikuBERT 토크나이저 업데이트 및 임베딩 확장 검증

```
1 # 실제 인물명으로 검증
2 test_names = ['黃敬中', '李眞儒', '金尙奎', '申光立', '李光佐']
3
4 for name in test_names:
5     in_vocab = name in tokenizer.get_vocab()
6     token_id = tokenizer.convert_tokens_to_ids(name)
7     ids = tokenizer.encode(name)
8     is_single = len(ids) == 3 # CLS + 토큰 + SEP
9
10    status = '통째로 토큰화' if is_single else f'⚠ {len(ids)-2}개로 분리됨'
11    print(f"{name} → vocab:{in_vocab} | ID:{token_id} | {status}")
```



```
黃敬中 → vocab:True | ID:43931 | 통째로 토큰화
李眞儒 → vocab:True | ID:36617 | 통째로 토큰화
金尙奎 → vocab:True | ID:42084 | 통째로 토큰화
申光立 → vocab:False | ID:100 | ⚠ 3개로 분리됨
李光佐 → vocab:True | ID:34874 | 통째로 토큰화
```

정제된 고유 인물명 리스트를 모델 사전에 추가(add_tokens)하고 임베딩 레이어를 확장하여,
이름이 여러 글자로 쪼개지는 현상을 방지하고 단일 토큰(Single Token)으로 온전히 인식됨을 검증함


전체 코퍼스 토큰화 및 학습 데이터 구축

도메인 특화 사전 적용




업데이트된 SikuBERT 토크나이저를
전체 조선왕조실록 원문 및 국역문
데이터에 일괄 적용하여 전처리 진행

단일 토큰화



고유 인물명이 여러 글자로 쪼개지는
현상을 방지하고, 하나의 독립된 의미
단위(Single Token)로 온전히 보존

학습 데이터 규격화




전체 텍스트 데이터를 AI 모델이 연산
할 수 있는 형태인 고유 숫자
ID(input_ids)와 어텐션 마스크
(attention_mask)로 변환

대규모 데이터셋 완성



인물명 의미 손실이 없는
고품질 데이터 정제를 완료하여,
파인튜닝(Fine-tuning)에 즉시 투입 가능한
최종 코퍼스 구축

향후 계획



감사합니다