

말모이 팀

승정원일기 자동 번역 실험 보고서

Gemma-4-26B-A4B-IT · 평가셋 n=300 · 4단계 실험

40.61

BLEU(c) 최고

35.17

chrF 최고

1.000

NER Recall

300

평가 샘플

실험 구성 한눈에

01	평가셋 300개 구성	층화 샘플링 · 길이/패턴 · NER 정답지
02	Baseline	기본 번역 성능 확인
03	Few-shot	예시 5개로 실록 어투 확보
04	Few + NERfix	번역 후 개체명 후보정
05	Few + NERinject	KB 주입으로 NER Recall 1.000 달성
06	최종 결과 & 향후	4-way 비교 · SJW 크롤링 계획

평가셋 300개 구성

층화 샘플링 · 길이/패턴 균형

모집단 설계

1단계 연구팀 설계 대표 후보 1,925개 구성 (eval_set_1925)

2단계 길이 버킷 × 문체 패턴 층화 샘플링 → 최종 300개

KL divergence: 길이 ≈ 0.000 · 패턴 ≈ 0.001 | seed: random.seed(42)

NER 정답지

- 188개(62.7%)에 인명 엔티티 존재 · 총 385개
- SillokBERT-NER로 원문에서 개체명 자동 추출
- 말모이 인물 KB (33,002개) → 한자→한글 매핑
- 정답 번역문 미사용 — 공정성 확보

길이 분포

버킷	기준	n	비율
XS	50자 미만	133	44.3%
S	50~149자	104	34.7%
M	150~349자	43	14.3%
L	350자+	20	6.7%

문체 패턴

패턴	의미	n	비율
GEN	일반 기사	142	47.3%
REP	아뢰기 (啓曰)	135	45.0%
DEN	불허 (不許)	9	3.0%
MEM	장계/서계	7	2.3%
ROY/APT/APR	전교·윤허	7	2.3%

Baseline

그냥 돌려봤더니

프롬프트

다음 한문을 현대 한국어로 번역하세요. 번역문만 출력하세요:
{원문}

결과

BLEU(c)	chrF	BLEU(m)	NER Recall
35.51	30.72	27.35	0.803

해석

문제 지점	모델 출력 (잘못)	정답 표현
임명 표현	"임명하다"	"제수하다"
발화 표현	"말씀하기를"	"전교하기를"

Few-shot

우연히 넣은 예시 5개가 고점

설정

어두 문제 해결을 위해 실록 번역 예시를 프롬프트에 추가. 처음 넣은 5개는 전부 아뢰기.전교 패턴(REP)이었습니다.

이후 다양한 시도 → 전부 고점 이하

AISO 동적 예시 선택

BLEU -2.2 하락

예시 개수 변화

유의미한 향상 없음

역할 지정 추가

유의미한 향상 없음

번역 원칙 명시

유의미한 향상 없음

결론: 단일 패턴(REP) 고정 예시 5개가 최적

결과

	BLEU(c)	chrF	BLEU(m)	NER Recall
Baseline	35.51	30.72	27.35	0.803
Few-shot	39.46	34.27	31.90	0.792
Δ	+3.95	+3.55	+4.55	-0.011

BLEU(c) 향상

Baseline

35.51

Few-shot

39.46

Few + NERfix

번역 후 개체명 교정

문제 인식

오류 유형	예시	
잘못된 음독	張維 → 장위 (정답: 장유)	
잘못된 음독	李景曾 → 이경정 (정답: 이경증)	
생략	인물 자체가 번역문에서 제거됨	—

후처리 파이프라인

- ① SilIoKBERT-NER로 원문 개체명 추출
- ② 말모이 KB에서 한자명 → 한글명 조회
- ③ hanja 라이브러리 + 성씨 앵커로 오독 탐색 후 치환

교정 결과

	BLEU(c)	chrF	NER Recall
Few-shot	39.46	34.27	0.792
+ NERfix	39.78	34.69	0.938
Δ	+0.32	+0.42	+0.146

한계: 이름이 생략된 34개는 후처리로 수정 불가 — 번역 단계에서 해결 필요

Few + NERinject

KB 주입으로 NER Recall 1.000 달성

핵심 아이디어

번역 전에 인물 정보를 모델에게 직접 알려줍니다.
few-shot 예시 뒤에 [등장 인물] 블록을 추가합니다.

[등장 인물 – 반드시 아래 한글명 그대로 사용]

- 金埴 → 김육
- 李時白 → 이시백


닫힌 고리 (Closed Loop)

SillokBERT-NER	정답지 생성
Python 전처리	프롬프트 주입
SillokBERT-NER	NER Recall 채점

결과 (n=291)

	BLEU(c)	chrF	NER Recall
Few + NERfix	39.78	34.69	0.938
Few + NERinject	40.61	35.17	1.000
Δ	+0.83	+0.48	+0.062

NER Recall 변화



최종 결과 & 향후 계획

Baseline 대비 BLEU(c) +5.10, NER Recall +0.197

4-way 최종 비교

단계	핵심 아이디어	NER Recall	BLEU(c)
Baseline	그냥 번역	0.803	35.51
Few-shot	예시 5개 (우연히 최적)	0.792	39.46
Few + NERfix	번역 후 개체명 교정	0.938	39.78
Few + NERinject ★	번역 전 개체명 주입	1.000	40.61

차기 작업: SJW 크롤링 + Entity Preservation Score

단계	방법	목적
SJW Raw 크롤링	sjw.history.go.kr 자동 수집	reference 없이 원문만 확보
자동 엔티티 태깅	SillokBERT-NER + 말모이 KB	한자→한글 매핑 자동 생성
NER Inject 번역	태깅 엔티티를 프롬프트에 주입	대규모 번역 자동화
EPS 평가	Entity Preservation Score	reference 없는 자동 평가

요약

말모이 팀 — 4단계 실험 결과

단계	핵심 아이디어	NER Recall	BLEU(c)
Baseline	그냥 번역	0.803	35.51
Few-shot	예시 5개 (우연히 최적)	0.792	39.46
+ NERfix	번역 후 개체명 교정	0.938	39.78
+ NERinject	번역 전 개체명 주입	1.000	40.61

스타일 앵커

일관성이 다양성보다 중요하다

KB 주입

번역 품질과 NER 정확도를 동시에 향상

Closed Loop

NER이 채점도 하고 정답지도 만든다