

지식 주입형 언어 모델 기반 승정원일기 번역 프로젝트

SillobERT와 Gemma 3를 활용한 《승정원일기》 번역 최적화

말모이 팀 | 길다인, 이승민, 배진형, 오성민

목차



I. 진행 사항

데이터 코퍼스 수집 및
기초 도메인 적응 학습 과정



II. 수정 사항

효율적인 번역을 위한
모델 및 디코더 전략 변경



III. 향후 계획

개체명 인식 고도화 및
최종 지식 주입형 번역 수행

연구 배경 및 목적

국가 기록 유산 번역의 한계:

- ⌘ 《승정원일기》 완역까지 향후 수십 년 소요 예상
- ⚠ 기존 AI 모델의 고유명사 오역 문제(정확도 8.3%)
- ⚙ 도메인 특화 모델 부재로 인한 '환각 현상' 발생

→ 언어 능력과 역사적 지식을 결합한
새로운 번역 파이프라인 제안



진행 사항 01: 고전 문헌 코퍼스 수집

```
{
  "index": 18828,
  "article_id": "kpa_12702011_002",
  "original": "以昭儀 趙氏爲貴人。",
  "translation": "소의 조씨를 귀인으로 삼았다."
},
{
  "index": 18829,
  "article_id": "kpa_12702014_001",
  "original": "日有重暈，內暈有兩珥，內暈上、外暈上，皆有戴，色內赤外青。",
  "translation": "해에 중륜이 있었다. 내륜에 양이가 있었고 내륜 위와 외륜 위에 다 대가 있었는데 안은 적색이고 밖은 청색이었다."
},
{
  "index": 18830,
  "article_id": "kpa_12702014_002",
  "original": "諫院啓曰：\「李令新設殘邑，保障重地，府使李紱等年少驕妄，不識軍機，拋棄軍餉，餽遺殘民。」",
  "translation": "간원이 아뢰기를, \「질곡은 새로 설치한 잔읍이고 보장의 중지인데, 부사 이지형은 나이가 젊은데다 교만하고 경망하여 직무를 삼가지 않고 군항을 포기하여 잔민을 침략합니다.»"
},
{
  "index": 18831,
  "article_id": "kpa_12702014_002",
  "original": "諸罷職。\" 上從之。",
  "translation": "파직하소서. \" 하니, 상이 따랐다."
},
{
  "index": 18832,
  "article_id": "kpa_12702018_001",
  "original": "上御仁政殿，冊封元孫爲王世孫。",
  "translation": "상이 인정전에 나아가 원손을 왕세손으로 책봉하였다."
},
{
  "index": 18833,
  "article_id": "kpa_12702018_002",
  "original": "夜，流星出北斗星下，入軫星上。",
  "translation": "밤에 유성이 북두성 아래에서 나와 천성 위로 들어갔다."
},
{
  "index": 18834,
  "article_id": "kpa_12702019_005",
  "original": "遭禍曹參判許啓，往三陟，齎祭黃池 蘆洞。",
  "translation": "예조 참판 허계를 보내어 삼척에 가서 황지의 노동을 살피게 하였다."
},
}
```

○ 上在昌德宮。

○ 夜三更，期會于洪濟院，金瑬爲大將，上率親兵，至延曙驛，迎李曙軍長湍兵七百餘人。金瑬李貴沈器遠崔鳴吉金自點宋英望申景裕等所領諸軍，亦六七百人。夜三鼓，至彰義門，斬關而入，遇宣傳官伺察城門者，前軍斬之，遂鼓噪而進。直至昌德宮。李興立，陳於闕門洞口，按兵不動，哨官李沆，開敦化門，義兵直入闕內，衛士皆散。光海，由後苑門出走。兵人爭入寢殿，燃炬搜覓，火延亂簾，因燒諸殿。上踞繩床，坐仁政殿階上。禁中直宿之官，皆寤伏。捕都承旨李德洞，輔德尹知敬至，兩人初皆不拜，審知義舉，乃拜出。命牌招李廷龜等，厥明，百官咸集，朴鼎吉，以兵曹參判先至，判書權繼繼至言，鼎吉，與宗室恒山君，聚軍而今入來，恐有內應之意，卽引出鼎吉斬之。拿問恒山君，無事實釋之。誅尙宮金氏，承旨朴弘道。光海走匿于醫官喪人安國臣家，着國臣白衣冠，國臣來告，遣將士昇至，廢世子亦亡匿，爲軍人所得。上初入宮，卽送金自點李時昉，啓達反正之意于王大妃，大妃下教曰，十年幽閉之中，無人來問，爾是何人，乃於中夜，無承旨史官而如是直啓乎？兩人還奏。己上因傳敕考出實錄

○ 上在慶運宮。上命大將李貴，都承旨李德洞，同副承旨閔聖微等，備儀仗往請奉迎。李貴等，詣慶運宮陳啓事狀，屢請奉往，大妃不許。上乃親詣慶運宮，有司進輦設儀衛，上命徹去，請乘輦亦不從，乘馬而行，昇光海以隨。上至慶運宮下馬，步入西廳門外，再拜痛哭，侍衛將士及侍臣，皆痛哭。上仍俯伏待罪，慈殿下教曰，綏陽君，宗子也，入承大統，宜矣。克成莫大之功，有何待罪之事？上對曰，搶攘之中，事多未達，今始來詣，不勝惶恐。慈殿命納傳國寶及啓字。李貴奏曰，慈殿當出御正殿，招大臣傳寶，何必徑入國寶，以致人疑乎？慈殿屢促之，上命左議政朴弘弼，奉入國寶，而久無成命。上伏地良久，至于夜深。上謂群臣曰，予欲退家待罪，群臣力諫止之。俄而慈殿，命引見嗣君，上進入內庭，諸將皆從。慈殿，設先王虛座，上再拜痛哭，侍臣皆哭。慈殿御寢殿垂簾，置御寶於床，引上入。上俯伏而哭，慈殿曰，勿哭。宗社大慶，何用哭爲？上避席而拜曰，大事未定，日暮始來，臣罪萬死。慈殿曰，勿辭。有何罪？予以薄命，不幸遭人倫之變，逆魁逞憾先王，以我爲厲，屢戮我父母，魚肉我宗族，剝殺我孺子，幽囚我別宮，寡身久處深宮，人間消息，邈不聞知，不意今日，乃見是事。又謂群臣曰，逆魁於先王，實是仇讎，朝廷之上，奸臣布列，加予以大惡之名，而拘囚十餘年，疇昔之夢，先王，語予以此事，賴卿等復明人倫，得見今日，卿等之功，何可勝言？群臣請速傳寶，慈殿曰，未亡人，得至今日，實是上帝之靈貺，嗣君，可拜謝上帝。閔聖微曰，爲此舉措，殊極未安，不敢承命。傳寶然後，嗣君當出外討捕凶黨，以定人心。群臣皆曰，嗣君卽位之後，當告宗廟，傳寶甚急。慈殿曰，傳寶大事，不可草草行禮，明日當於西廳，備禮行之。且無天朝之命，何以正位？宜權署國事。都承旨李德洞請對啓曰，國家危亂，幾至於亡，嗣君爲宗社大計，躬擐甲冑，舉此大事。人心已歸，天命已定，而傳寶之事，夜深不決，何也？若不速傳國寶，以正位號，何以鎮定？請亟傳國寶，以答臣民之望。慈殿曰，受寶有節次，何以暮夜，急迫傳授乎？卿等之言如此，須與大臣相議，當以何寶傳之乎？大臣曰，以昭信寶受命寶，傳之宜當，諱書寶，亦可傳授。上曰，臣無才德，不敢當。慈殿曰，王室至親，臣民愛戴，非德而何？嗣君自此，可爲聖主，實宗社之洪福也。乃命承傳色金天霽等，奉御寶跪傳於上，上拜受。侍臣啓曰，既已傳寶，宜亟出御正殿，以正大位。慈殿曰，初欲備禮，從容傳授，卿等之言，不可違，故如是行之矣。仍謂上曰，逆魁之罪，知之乎？惟我德薄，不能盡母子之道，使倫紀數滅，國家幾亡，賴嗣君孝，上安宗社，下雪讎怨，感激何極？又謂諸臣曰，逆魁父子，今置何處乎？對曰，皆在闕下矣。慈殿曰，不共戴天之讎，忍之久矣，願親听渠父子之頭，以祭亡靈。幽囚十餘年，至今不死者，蓋待今日耳，願得甘心焉。諸臣啓曰，自古廢黜之君，臣子不敢以刑戮擬議，無道之主，莫如桀紂，而湯武放之。今此下教，臣等所不忍聞也。德洞曰，慈聖之於廢君，天倫已定，子雖不孝，母不可以不慈也。此下教，非徒不忍聞，亦不敢奉承。慈殿曰，吾與嗣君，同御正殿，則當雪吾讎，今嗣君卽位，能體我心，爲吾復讎，則可謂孝矣。上曰，百官在，臣何敢擅也？慈殿曰，嗣君年已壯長，豈受

조선왕조실록

광해군 ~ 순종 시기 원문-번역문 병렬 코퍼스 구축 완료

승정원일기

인조 ~ 정조 6년 시기 원문 데이터 및 인조 시기 병렬 코퍼스 확보

진행 사항 02: 지식베이스 (KB) 및 DB 구축

 **고전 특화 지식베이스:** 역사적 인물, 관직, 지명 간의 관계를
정형화된 DB로 구축

 **인물정보 사전:** 양반들의 다양한 호칭(자, 호, 시호)을 하나의
식별자로 통합 관리

✓ **동명이인 해소 기초:** 활동 연대 및 가계 정보를 포함한 메타데이터
수집

```
{ } id_lookup.json > ...
1 {
2   "M_00000002": {
3     "한글_명": "강겸",
4     "한자_명": "姜謙",
5     "본관_표준": "진주",
6     "활동_시작": 1480,
7     "활동_종료": 1504,
8     "관직_리스트": [
9       "좌랑(佐郎)",
10      "직강(直講)",
11      "성균관직강(成均館直講)",
12      "봉훈랑지평(奉訓郎持平)",
13      "홍문관교리(弘文館校理)",
14      "시독관(侍讀官)",
15      "봉훈랑사헌부지평(奉訓郎司憲府持平)",
16      "봉훈랑수사헌부지평(奉訓郎守司憲府持平)",
17      "군기시참정(軍器寺僉正)",
18      "장령(掌令)",
19      "장령(將領)",
20      "정랑(正郎)"
21    ]
22  },
23 }
```

```
{ } person_master.json ×
malmoi > { } person_master.json > { } 0
⚠ This document contains many invisible unicode characters Disable Invisible Highlight ×
1 [
2   {
3     "인물아이디": "M_00000002",
4     "한글_명": "강겸",
5     "한자_명": "姜謙",
6     "본관_표준": "진주",
7     "활동_시작": 1480,
8     "활동_종료": 1504,
9     "관직_리스트": [
10      "봉훈랑지평(奉訓郎持平)",
11      "군기시참정(軍器寺僉正)",
12      "장령(將領)",
13      "좌랑(佐郎)",
14      "봉훈랑수사헌부지평(奉訓郎守司憲府持平)",
15      "시독관(侍讀官)",
16      "장령(掌令)",
17      "봉훈랑사헌부지평(奉訓郎司憲府持平)",
18      "정랑(正郎)",
19      "홍문관교리(弘文館校理)",
20      "직강(直講)",
21      "성균관직강(成均館直講)"
22    ]
23  },
24 ]
```

```
{ } inverted_index.json > ...
2 "姜謙": [
3   "M_00000002",
4   "M_0000220",
5   "M_0000438",
6   "M_0000599",
7   "M_0000956",
8   "M_0011140",
9   "M_0013803",
10  "M_0015169",
11  "M_0024457",
12  "M_0026381",
13  "M_0032931",
14  "M_0034230",
15  "M_0037928",
16  "M_0047970",
17  "M_0050757",
18  "M_0055209",
19  "M_0059322",
20  "M_0060740",
21  "M_0065666"
22 ],
23 "강겸": [
24   "M_00000002"
25 ]
26 }
```

진행 사항 03: SillokBERT 사전 학습 수행

50% 샘플링 데이터로 3 Epoch 추가 사전학습(CPT)을 시작합니다...
[2143/24546 28:00 < 4:53:06, 1.27 it/s,

Epoch 0.26/3]

Step	Training Loss
------	---------------

100	5.800383
-----	----------

200	5.606960
-----	----------

300	5.323060
-----	----------

400	5.592158
-----	----------

500	5.345621
-----	----------

600	5.134069
-----	----------

700	5.171187
-----	----------

800	5.606387
-----	----------

900	5.274819
-----	----------

사전 학습(Pre-training) 프로세스:

 승정원일기 원문(인조~정조 6년분)을 활용한 MLM 학습

 현재 모델 가중치 최적화 및 안정화 작업 진행 중

 한문의 구문론적 특징과 문맥을 체화하는 단계

※ 현재 사전학습이 진행 중이며, 완료 후 구체적 성능 지표 도출 예정

Ⅱ. 수정 사항

전략적 모델 변경 및 최적화



SillokBERT 모델 도입

SikuBERT 기반 사전학습 대신, **조선왕조실록**에 특화된 **SillokBERT**를 발견하여 프로젝트의 도메인 정밀도를 높임



Gemma 디코더 채택

Solar Pro 3 사용이 불가함에 따라, 다국어 처리와 지시 이행 능력이 뛰어난 **구글의 Gemma 3**를 번역 디코더로 최종 확정

Ⅲ. 향후 계획

개체명 인식 및 팩트 체크 고도화

01. NER 전문가 모델 튜닝

Sillok NER 코퍼스를 활용한 미세 조정을 통해 원문 내 인명, 관직명의 **추출 정확도가 비약적으로 개선될 예정입니다**. 이는 번역의 뼈대를 세우는 핵심 과정이 될 것입니다.

02. 엔티티 링킹 & 동명이인 해소

기사 작성 시점과 인물의 생물 연도를 대조하는 시계열 기반 알고리즘을 도입하여, **동명이인 오역 문제를 획기적으로 해결**하고 번역의 역사적 무결성을 확보할 것입니다.

지식 주입형 기계 번역

Prompt Augmentation + Gemma 3

- 💡 식별된 개체의 현대어 명칭을 프롬프트에 주입
- 🚫 LLM의 임의적 생성을 억제하는 제약 부여
- 🔧 고유명사 오역을 차단하고 **매끄러운 현대 국어 번역문** 산출

"역사 전문가 수준의 팩트 체크가 번역에 녹아드는 단계"



프로젝트 기대 성과 및 비전



조선 시대 문맥에 최적화된 사전학습을
바탕으로, 기존 범용 모델보다 **더욱 정교한**
문맥 이해가 가능해질 것

지식 주입 방식을 통해 고유명사 오역을
최소화하고, 사료로서 **신뢰받을 수 있는 고품질**
번역을 제공할 것



파이프라인 자동화를 통해 승정원일기 **완역**
시점을 대폭 앞당겨 디지털 인문학 발전에 기여

감사합니다

