
A TIME SERIES IS WORTH 64 WORDS: LONG-TERM FORECASTING WITH TRANSFORMERS

트랜스포머를 활용한 장기 예측의 혁신

매크로팀

이찬영 구다연 이지수 이예현



CONTENTS

1

시계열 예측의
기존 한계점

2

Patching

3

Channel
Independence


4

성능 지표 및
SOTA 달성


5

프로젝트 적용


기존 시계열 모델의 구조적 한계




CNN



RNN



ANN



Transformer

LSTM


- 데이터를 한 점씩 순서대로 읽음
- 시퀀스가 길어지면 과거 정보를 유실함

Transformer

- 데이터를 '점' 단위로 인식
- 금융 데이터의 노이즈에 취약하고 연산 효율이 낮음

패칭 (Patching)


1. 포인트 wise Approach (Traditional)




문제점: 단일 데이터 점은 노이즈에 취약하며, 연산 복잡도 가 제곱($O(L^2)$)으로 증가해 장기 학습 비효율

PatchTST: 의미 있는 덩어리로 인식
→ 추세(Trend) 파악 유리데이터 압축
→ 장기 데이터 학습 가능

2. 패치 단위 접근 (Patch-wise, PatchTST)



채널 독립성



기존 방식



- 다변량 지표를 하나로 묶어 연산
- 변수 간 상호 간섭 발생 및 학습 효율 저하

PatchTST 방식

- 각 채널을 독립적으로 Transformer에 입력
- 데이터 고유의 패턴 유지 및 모델의 성능 극대화

패칭 기반 연산 복잡도

P4-1. Patch-based Computational Complexity Innovation: Breaking the Quadratic Barrier



1. BREAKING THE QUADRATIC ATTENTION BARRIER




2. UNLOCKING LONG-TERM TEMPORAL DEPENDENCIES AT SCALE

L^2 연산 복잡도 한계를 극복하여, 초장기 시계열 데이터 학습의 기술적 특이점을 달성

Masked Autoencoder 기반 자기 지도 학습


P4-2. Masked Autoencoder Pre-training: Unleashing Self-Supervised Repr. Learning

Baseline Supervised Forecasting




PatchTST Self-Supervised pre-training


[cite: image_13]



1. **Self-supervised pre-training** on reconstruction task captures subtle, noise-resilient correlations.
2. **Downstream Forecasting Fine-tuning** benefits from superior feature representations, maximizing predictive accuracy for KODEX 200' [cite: 14, 2211.14730]

BTC Price Prediction with LSTM (On-chain Integrated)





SOTA 달성

P6. Performance Validation: Achieving State-of-the-Art (SOTA) in Long-term Forecasting

1. COMPREHENSIVE SOTA RESULTS (8 LARGE-SCALE DATASETS)

'BEST-IN-CLASS' performance, surpassing previous SOTA models across diverse multivariate time series' [cite: 2211.14730, image_12]


Dataset		MSE	MAE	P	MSE	MAE
Electricity	PatchTST	0.27★	0.19★	0.62	0.27	0.91★
	Informer	0.95	0.14	0.30	0.20	0.33
	Autoformer	0.33	0.25	0.16	0.32	0.32
	FEDformer	0.38	0.30	0.32	0.28	0.39
Weather	PatchTST	0.35★	0.33★	0.97★	0.27	0.87★
	Informer	0.22	0.18	0.30	0.26	0.86
	Autoformer	0.28	0.32	0.03	0.20	0.34
Traffic	FEDformer	0.69	0.16	0.14	0.09	0.79
	Stationary	0.17	0.23	0.48	0.21	0.38
Traffic	PatchTST	0.55★	0.08	0.48★	0.37	0.37
	Informer	0.68	0.19	0.16	0.34	0.31
	Autoformer	0.31	0.32	0.46	0.41	0.33
ETTM2	FEDformer	0.65	0.23	0.40	0.26	0.32
	FEDformer	0.88	0.31	0.38	0.39	0.36
Exchange	Stationary	0.79	0.22	0.39	0.29	0.38
	PatchTST	0.39	0.34	0.65★	0.65	0.43★



Ranked #1 in overall predictive accuracy

[cite: image_12]

2. SUPERIOR LONG-TERM FORECASTING ROBUSTNESS



GLOBAL #1 IN PRED. ACCURACY



OPTIMIZED FOR EXTENDED HORIZONS

[cite: 14, 2211.14730]

메크로에 어떻게 적용할 것 인가_1

데이터 구조 및 학습 전략

멀티모달 데이터 통합: 12종의 기술적 지표와 32차원의 뉴스 심리 벡터를 결합.

채널 독립성의 실전 적용: 서로 성격이 다른 '가격 데이터'와 '뉴스 데이터'가 학습 과정에서 섞여 발생하는 상호 오염을 원천 차단.

패칭 효과: 일일 가격 노이즈를 상쇄하고, 주간 단위의 거시적 추세를 추출하여 KODEX 200의 방향성 예측력을 제고.

메크로에 어떻게 적용할 것 인가_2

2. 모델 설명 가능성 (XAI: DeepSHAP)

핵심 로직: DeepSHAP 알고리즘을 PatchTST의 인코더 출력단에 결합하여, 특정 시점의 예측값에 가장 큰 영향을 미친 핵심 패치를 역추적.

시각화 방안: KODEX 200 차트 위에 예측 기여도가 높은 구간을 하이라이트 처리.

기대 효과: 단순 수치 제공을 넘어, "왜 지금 상승/하락을 예측하는가"에 대한 논리적 근거 도출.



Thank You!