

DAT 7th 매크로 프로젝트 진행상황 발표

KODEX 200 ETF의 수익률 예측

금융시장의 거시경제 변수와 뉴스 심리를
통합 분석하여 ETF 향방을 예측

이찬영 · 구다연 · 이예현 · 이지수

HUFS DAT 7th

뉴스 데이터를 활용한 금융 시계열 예측 데이터 전처리 파이프라인 구축

프로젝트 목적:

뉴스 텍스트 데이터에 내재된 시장의 감성(Sentiment)과 정보를 추출하여
주가 예측 모델의 입력 피처로 활용

데이터 소스:

빅카인즈(BigKinds) 뉴스 데이터

핵심 과제:

텍스트의 벡터화(Embedding)와 시계열 데이터의 시간축 정렬

데이터 로드 및 타임스탬프 보정

시장 시간에 맞춘 데이터 정렬

문제 인식:

뉴스는 24시간 발생하지만, 주식 시장은 15:30에 마감됨.

해결 방법:

뉴스 식별자에서 시/분/초 정보 정밀 추출.

장후 뉴스 처리:

15:30 이후 뉴스는 '내일'의 주가에 영향을 미치므로 BDay(1)을 적용해
다음 영업일 데이터로 보정.

기대 효과:

데이터 누수(Data Leakage) 방지 및 모델의 예측 신뢰도 향상.

KR-FinBert 임베딩

금융 특화 언어 모델 활용

기술 스택:

snunlp/KR-FinBert (한국어 금융 도메인 최적화 모델).

작업 내용:

제목과 본문을 결합하여 토크나이징 (Max Length 512).

[CLS] 토큰 추출:

문장 전체의 의미를 응축한 768차원의 고차원 벡터 획득.

* 일반 BERT보다 금융 용어 이해도가 높은 모델을 사용해 정보의 질을 높임.

일별 평균 Pooling

정보의 압축과 일관성 확보

문제 인식:

하루에 발행되는 뉴스 기사 수는 가변적임 (어떤 날은 10개, 어떤 날은 100개).

해결 방법:

`groupby('일자').mean()`을 통해
하루치 뉴스 벡터들을 평균(Mean) 내어 단일 벡터로 변환.

결과:

'일자별' 뉴스 분위기를 대표하는 고유한 768차원 피쳐 생성.

FC Layer 차원 축소

차원의 저주 해결 및 효율화

기술 스택: PyTorch Linear Layer.

구조: 768(Input) $\rightarrow$ 64(Hidden) $\rightarrow$ 32(Output).

이유:

768차원은 모델 학습 시 연산 부담이 크고 노이즈가 섞일 수 있음.
핵심 특징만 추출하여 32차원으로 압축(Master Data 구축).

결과: XGBoost 등 머신러닝 모델에 즉시 입력 가능한 2D 형태의 데이터 완성.

LSTM용 3D 시계열 변환

과거의 문맥을 기억하는 데이터

작업 내용: Sliding Window 기법 적용.

설정:

TIME_STEPS = 5 (과거 5일간의 뉴스 흐름을 하나의 샘플로 구성).

데이터 형태 변환: (Samples, 5, 32)의 3D 텐서 구조.

의미: 단발성 뉴스가 아닌, 5일간의 누적된 시장 분위기와 추세를 LSTM 모델이 학습할 수 있도록 준비 완료.

모델 맞춤형 데이터셋 이원화

2D(XGBoost)와 3D(LSTM) 데이터의 공존

작업 내용: 전처리의 최종 결과물을 두 가지 형태(master_data_xgboost, X_lstm)로 이원화하여, 모델의 특성에 맞는 최적의 학습 환경을 구축함.

모델 유연성 확보:

정적인 수치 분석에 강한 머신러닝(XGBoost)과 동적인 흐름 분석에 강한 딥러닝(LSTM)을 모두 테스트하여 최적의 앙상블 모델을 찾기 위함.

비용과 성능의 조화:

가벼운 XGBoost 모델로 빠른 피처 중요도를 파악하고, 복잡한 LSTM 모델로 정교한 시계열 문맥을 파악하는 두 트랙 전략 가능.

모델 맞춤형 데이터셋 이원화

2D(XGBoost)와 3D(LSTM) 데이터의 공존

구분	XGBoost용 마스터 데이터	LSTM용 시퀀스 데이터
차원(Shape)	2D Matrix (일수 × 32)	3D Tensor (샘플수 × 5 × 32)
데이터 특징	특정 날짜의 뉴스 정보를 독립적으로 보유	과거 5일간의 뉴스 흐름을 하나의 묶음으로 보유
변환 방식	FC Layer를 거친 직후의 압축 데이터	Sliding Window 기법 적용 (Time Steps=5)
활용 모델	XGBoost, LightGBM, Random Forest 등	LSTM, GRU, RNN 등 딥러닝 모델


빅카인즈 뉴스 활용 금융 시계열 예측 전처리 파이프라인 (XGBoost/LSTM 데이터 이원화)

1. Timestamp Correction (장중/장후 시간 보정)



장후 처리 로직


```
if time > 15:30,  
Date = Next Business Day  
(pd.tseries.offsets.BDay(1))
```





2. KR-FinBERT Embedding (768차원 추출)



4. Compression (일별 평균 Pooling & nn.Linear)



5. Sliding Window (past context memory) & Dual Data Output



향후 계획

베이스라인 구축

모델링:

구축된 X_lstm 데이터를 활용한 주가 등락 예측 모델 학습 및 하이퍼파라미터 튜닝.

검증:

기존 기술적 지표(이동평균선 등)와 뉴스 임베딩 피처를 결합했을 때의 성능 향상 폭 측정.

고도화:

뉴스 본문 내 핵심 키워드 가중치 부여(Attention) 적용 검토.

DAT 7th 매크로 프로젝트 진행상황 발표

KODEX 200 ETF의 수익률 예측

Q&A

HUFS DAT 7th