

KR-FinBERT 와 PatchTST 기반의 다중 모달 융합을 통한 KODEX 200 수익률 예측 및 변동성 분석

매크로팀(이찬영, 구다연, 이예현, 이지수)

요약

본 프로젝트는 KR-FinBERT 기반의 뉴스センチメント 분석과 최신 시계열 변환 모델인 PatchTST 를 결합하여, KODEX 200 ETF 의 수익률 예측 및 시장 변동성을 분석하는 다중 모달 융합(Multi-modal Fusion) 프레임워크 구축을 목적으로 한다.

전통적인 정형 데이터 중심 예측의 한계를 극복하기 위해, 본 프로젝트는 2021 년부터 2026 년까지의 5 개년 금융 데이터(가격 및 13 종의 거시경제 지표)와 주요 방송사(KBS, MBC, SBS, YTN)의 뉴스 데이터를 통합한 데이터셋을 구축하였다.

데이터셋 구축의 기초 단계로 금융 원본 데이터 수집과 파생 변수 생성, 그리고 데이터 지표 체계 정리를 수행하였다. 먼저 KODEX 200 ETF 의 가격 데이터와 주요 거시경제 지표를 수집하여 분석에 필요한 기초 데이터를 구성하였고, 이후 단순 가격 정보의 한계를 보완하기 위해 로그 수익률, 변동성 지표, 모멘텀 및 추세 지표 등 다양한 파생 변수를 생성하여 모델 학습에 적합한 형태로 재구성하였다.

뉴스 데이터 처리 과정에서는 장 마감 이후 및 주말 발생 정보를 익일 영업일로 정합시키는 과정에서 특히 주말 발생 정보가 희석되는 문제를 해결하고자 L2 Attention 기반 Pooling 기법을 적용하여 핵심 정보의 보존력을 극대화하였다.

모델 아키텍처 측면에서는 정형 데이터와 뉴스 임베딩 간의 정보 오염을 방지하기 위해 각 모달리티를 독립적인 네트워크에서 학습시킨 후 결합하는 후기 융합(Late Fusion) 방식을 채택하였다. 실험의 객관성을 위해 데이터셋은 시계열 특성을 반영한 70:15:15 비율의 시간순 분할 방식을 적용하였으며, 모델링에는 XGBoost 를 채택하고 롤링 윈도우 기법을 통해 단기 및 장기 수익률 예측 시나리오를 구성하였다.

그 결과, 기술적 지표만으로는 단기 변동성(5 일) 예측에 한계(방향성 정확도 48.3%)가 있음을 확인하였다. 이를 보완하기 위해 비정형 뉴스 데이터를 결합한 LSTM 및 PatchTST 모델을 설계하고자 한다.

본 프로젝트는 단순 오차 지표(MAE, R-squared)뿐만 아니라, DM Test 를 통한 통계적 유의성 검증, SHAP 분석을 이용한 변수 기여도 해석, 그리고 Sharpe Ratio 및 MDD 를 포함한 실전 투자 백테스팅을 통해 모델의 경제적 유효성을 종합적으로 입증하고자 한다. 이를 통해 뉴스에 내재된 투자 심리와 거시적 충격이 한국 시장의 비선형적 변동성을 포착하는 데 핵심적인 역할을 수행함을 규명한다.

1. 프로젝트 개요

현대 금융 시장에서 가격 데이터만을 활용한 시계열 예측은 시장의 복잡성과 효율적 시장 가설(EMH)에 따른 비선형적 변동성을 설명하는 데 한계가 있다. 특히 한국 시장은 대외 의존도가 높아 거시경제 지표뿐만 아니라 뉴스에 내재된 투자 심리와 외부 충격에 매우 민감하게 반응한다.

이에 본 프로젝트는 비정형 데이터(뉴스)와 정형 데이터(거시경제 지표)의 융합이 시장 예측력을 유의미하게 향상시킨다는 선행연구¹를 바탕으로, 한국 시장에 특화된 뉴스 임베딩과 최신 시계열 트랜스포머 모델을 결합한 예측 분석을 주제로 모델의 통계적 유의성을 검증하는 것을 목적으로 진행하고자 한다.

모델의 아키텍처 특성에 최적화된 학습을 위해 데이터셋을 2D(XGBoost), 3D(LSTM, PatchTST) 두 가지 형태로 이원화하여 구축하였으며, 특히 뉴스 데이터 처리 시, 개장 외 시간 및 주말 발생 데이터를 익일 영업일로 매핑하는 과정에서 발생하는 정보 희석을 방지하고자 L2 Attention 기반의 Pooling 기법을 적용하여 핵심 정보의 보존력을 극대화하였다. 또한 뉴스 임베딩(KR-FinBERT)과 시계열 지표를 초기 단계에서 결합할 경우 발생할 수 있는 정보 오염을 방지하기 위해 후기 융합(Late Fusion) 방식을 채택하였다. 각 모달리티를 독립적인 네트워크에서 병렬적으로 학습시킨 후, 최종 출력층에서 결합함으로써 각 데이터 소스의 고유한 특성을 유지하면서도 예측의 정밀도를 높이하고자 한다. 따라서 프로젝트의 목표는 다음과 같다.

(1) 변수별 정보 기여도 산출 및 해석

다양한 데이터 소스가 예측 결과에 미치는 영향력을 분석하기 위해 SHAP 분석을 수행한다. 이를 통해 정형 데이터와 비정형 데이터 중 어떤 요소가 모델의 판단에 더 지배적인 역할을 하는지 규명하고, 거시적 이벤트 발생 시 각 정보의 기여도 변화를 동적으로 파악한다.

(2) 모델 아키텍처별 시계열 예측 성능 비교

순환 신경망 기반의 LSTM과 최신 트랜스포머 구조인 PatchTST 모델의 성능을 단기 및 장기 예측 시나리오별로 비교 분석한다. 두 모델 간 예측 성능 차이의 통계적 유의성을 확보하기 위해 DM Test로 모델 간 성능 차이가 통계적으로 유의미한지 검증한다.

(3) 뉴스 데이터의 추가적 유효성 검증

비정형 정보의 효용성을 격리하여 평가하기 위해, 기술적 지표만을 학습한 Baseline

¹ IKNet: Interpretable Stock Price Prediction via Keyword-Guided Integration of News and Technical Indicators

모델과 뉴스 임베딩을 추가한 Proposed 모델의 성과를 비교분석하여 뉴스정보의 도입이 시장의 비선형적 변동성을 포착하는 데 유의미한 영향을 미치는지 검증한다.

(4) 실전 투자 성과 및 안정성 평가

모델의 높은 예측 정확도가 실제 금융 수익으로 직결되는지 검증하기 위해 정교한 백테스팅을 수행한다. 누적 수익률, 리스크 대비 수익률을 나타내는 샤프 지수(Sharpe Ratio), 최대 낙폭(MDD) 등의 지표를 산출함으로써, 통계적·경제적 유의성을 동시에 확보한 최적의 모델을 판별한다.

2. 데이터셋 구성 및 변수 설정

본 연구에서는 시장의 정량적 지표뿐만 아니라 뉴스에 내재된 정성적 정보를 통합하여 분석의 정밀도를 높였다. 데이터셋은 2021년 3월 10일부터 2026년 3월 10일까지 총 5개년의 일간 데이터를 기준으로 구성되었으며, 수집된 데이터는 크게 수치 기반의 '금융 데이터'와 텍스트 기반의 '뉴스 데이터'로 구분된다.

2-1. 원본 금융 데이터셋의 구성

금융 데이터는 자산의 직접적인 가격 움직임을 나타내는 가격 데이터와 외부 경제 환경을 대변하는 거시경제 지표로 분류된다.

<표 1> 금융 데이터 주요 지표

카테고리	지표명	설명	비고(의미)
가격 데이터	Close, Open, High, Low	해당 일자의 종가, 시가, 고가, 저가	시장의 기본적인 가격 흐름
	Gap	전일 종가 대비 당일 시가의 차이	시장의 심리적 괴리 및 충격 반영
	Amount	거래 대금 (또는 거래량)	시장 참여자들의 활동성 및 에너지
거시경제	DXY_Broad	주요국 통화 대비 달러 가치 (달러 인덱스)	글로벌 자산 시장의 위험 선호도 지표
	10Y_Bond_Yield	미국 10년 만기 국채 수익률	시장의 금리 전망 및 할인율의 기준
	VIX_Index	S&P 500 변동성 지수	시장의 불안정성 및 공포(하락 위험도)

	M2_Money_Supply	광의의 통화량 (M2)	시장의 유동성 공급 수준
	CPI_Inflation	소비자 물가 지수	실물 경제의 인플레이션 압력
	Fed_Rate	미국 연방준비제도 기준 금리	통화 정책의 방향성

3. 재구성 지표의 산출

머신러닝 모델의 학습 성능을 최적화하기 위해, 원시 데이터(Raw Data)를 기반으로 변화율이나 상대적 위치를 계산한 파생 변수를 생성하였다.

3.1. 수익률 및 변동성 (Returns & Volatility)

Log_Return 는 종가의 로그 수익률로, 데이터의 정규성을 높여 시계열 분석의 통계적 안정성을 확보하였으며, Return_Lag1 는 1 일 전의 수익률을 통해 가격 움직임의 관성 및 자기상관성을 파악하였다.

Vol_5 과 Vol_21 는 각각 5 일(1 주) 및 21 일(1 개월) 간의 수익률 표준편차로, 시장의 단기 및 중기 변동성을 나타낸다. 또한 RV_Trend_5_21 는 단기 변동성을 장기 변동성으로 나눈 비율로, 변동성 확대를 통한 추세 전환 신호를 식별한다.

3.2. 추세 및 모멘텀 (Trend & Momentum)

SMA_21_Disparity, SMA_63_Disparity (이격도)는 현재가와 이동평균선 간의 거리를 계산하여 과열(+) 및 과매도(-) 국면을 판단하는 상대적 지표로 활용한 변수이며, MACD 는 단기 및 장기 지수이동평균의 차이를 통해 가격 추세의 강도와 전환 방향을 포착한 변수이다.

Momentum_10D 는 10 일 전 가격 대비 현재가의 변화율로, 가격의 추진력을 측정한 변수이다. 상대강도지수를 나타내는 RSI 변수는 일정 기간의 상승/하락폭 비율을 산출하여 과매수 및 과매도 상태를 나타내었다.

3.3. 리스크 및 외부 충격 (Risk & Macro Changes)

ATR_Pct 변수는 평균실제범위(ATR)를 종가로 나눈 비율로, 자산의 절대 가격과 무관한 변동 비율을 통해 위험도를 평가하였다. VIX_Change, DXY_Return 은 공포지수와 달러인덱스의 변화율을 산출하여 시장에 가해진 외부 충격의 크기를 정량화하였다.

또한 Bond_Yield_Change 변수는 국채 금리의 변화량을 통해 금리 변동이 자산 가격에 미치는 즉각적인 영향을 모델에 반영하였다.

<표 2> 모델 학습을 위한 재구성 지표

분류	지표명	산출 방식 및 설명
수익률 및 변동성	Log_Return	종가의 로그 수익률
	Return_Lag1	1 일 전의 수익률
	Vol_5, Vol_21	5 일(1 주) 및 21 일(1 개월) 간 수익률 표준편차
	RV_Trend_5_21	단기 변동성(Vol_5)/장기 변동성 (Vol_21)
추세 및 모멘텀	SMA_21/63_Disparity	현재가와 이동평균선(21 일, 63 일) 간 이격도
	MACD	단기 및 장기 지수이동평균(EMA)의 차이
	Momentum_10D	10 일 전 가격 대비 현재가의 변화율
	RSI	일정 기간의 상승폭과 하락폭 비율 (0~100)
리스크 및 외부 충격	ATR_Pct	평균실제범위(ATR) / 당일 종가
	VIX_Change	공포지수(VIX)의 전일 대비 변화율
	DXY_Return	달러인덱스(DXY)의 전일 대비 변화율
	Bond_Yield_Change	국채 금리의 전일 대비 변화량(Diff)

4. 뉴스 데이터 수집 및 구성

시장에 내재된センチ먼트(Sentiment)와 핵심 정보를 추출하기 위해 비정형 데이터인 뉴스 데이터를 수집하였다. 뉴스 텍스트 내에 포함된 경제 관련 키워드와 어조를 분석함으로써, 단순 수치 지표가 반영하지 못하는 시장의 심리적 상태와 잠재적 리스크를 모델 학습에 반영하고자 한다.

4.1. 뉴스 데이터 수집

뉴스 빅데이터 분석 시스템인 빅카인즈(Big Kinds)를 활용하여 정보의 공신력과 시장 영향력을 고려하여 국내 주요 4 개 방송사(MBC, SBS, KBS, YTN)의 뉴스만을 선별하여 수집하였다. 이는 불필요한 노이즈를 제거하고 정제된 시장 담론을 포착하기 위함이다.

4.2. 뉴스 임베딩 구성

수집된 뉴스 데이터는 총 18,520 건이며, 각 행은 '일자', '제목', '본문', 제목과 본문이 통합된 'Text'의 4 개 열(Column)로 구성된다.

5. 데이터 전처리 및 피처 엔지니어링

본 프로젝트에서는 뉴스 텍스트 데이터와 가격 지표 간의 시계열적 정합성을 확보하고, 고차원 텍스트 정보의 효율적인 학습을 위해 다음과 같은 전처리 과정을 수행하였다.

5.1. 뉴스 데이터의 시계열 정합성 및 보정

뉴스 발생 시점과 실제 주가 반영 시점 사이의 간극을 해결하기 위해 타임스탬프 조정 과정을 거쳤다. 한국 거래소(KRX)의 장 마감 시간인 15:30 이후에 발생한 뉴스는 당일 주가에 반영될 수 없으므로, 이를 익일 영업일의 데이터로 할당하여 데이터 누수(Data Leakage)를 방지한다.

또한 주말(토, 일) 동안 축적된 뉴스는 월요일 장 초반에 일시적으로 반영되어 변동성을 증폭시키는 경향이 있다. 이를 해결하기 위해 금요일 15:30 이후부터 월요일 09:00 이전까지 발생한 모든 뉴스 데이터를 월요일 데이터로 통합(Aggregation)하여 처리하였다. 이는 주말 간의 정보 비대칭성을 해소하고 월요일 수익률과의 상관관계를 극대화하기 위함이다. 이는 이후 풀링 과정을 통해 더 자세하게 문제를 인식하고 해결하였다.

5.2. KR-FinBERT 를 활용한 임베딩 및 특성 추출

뉴스 텍스트의 문맥적 의미를 금융 도메인에 특화하여 이해하기 위해 서울대학교에서 공개한 KR-FinBERT 모델을 활용한다.

뉴스 제목과 본문을 결합하여 문맥 정보를 보존하며, 최대 길이는 512 토큰으로 제한하였으며, 사전 학습된 BERT 의 [CLS] 토큰을 추출하였다. 이 토큰은 문장 전체의 문맥 정보를 768 차원의 고차원 벡터로 응축하고 있어, 뉴스 기사 한 건의 핵심적인 의미를 대표한다.

5.3. 뉴스 벡터 풀링(Pooling) 및 정보 압축

일자별로 발생하는 뉴스 기사의 수는 가변적이므로, 이를 고정된 크기의 벡터로 변환하는 과정이 필요하다. 본 프로젝트에서는 단순 평균(Mean)이나 최대값(Max) 풀링 대신 L2 Attention(Weighted Sum) 방식을 채택한다. 모든 뉴스가 시장에 동일한 영향력을 미치지 않기 때문이다.

단순 평균 풀링은 중요한 호재/악재 기사의 영향력을 희석시키고 노이즈 텍스트의 비중을 높이는 단점이 있다. 반면, L2 Attention 방식은 특정 키워드나 문맥적 중요도에 따라 가중치를 부여함으로써, 당일 시장의 분위기를 가장 잘 대변하는 핵심 뉴스에 집중된 단일 대표 벡터를 생성한다.

또한 단순히 모든 주말 기사를 산술 평균하는 방식은 과거의 노이즈가 최신 정보를 오염시킬 위험이 있기 때문에 L2 Attention 방식을 통해 주말 동안 발생하는 수많은 뉴스 중 시장에 실질적 충격을 줄 만한 강한 신호(High L2 Norm)를 가진 기사에 가중치를 부여함으로써, 단순 노이즈(일상적 기사)의 영향력을 최소화한다.

5.4. 차원 축소 및 시계열 데이터 구성

768 차원의 임베딩 벡터는 모델의 복잡도를 높이고 '차원의 저주'를 유발할 수 있다. 이를 해결하기 위해 PyTorch의 Linear Layer를 통과시켜 핵심 특징만 추출한 32 차원의 저차원 벡터로 압축하였다. 이는 계산 효율성을 증대시키고 오버피팅을 방지한다.

단발성 뉴스에 의한 일시적 변동이 아닌, 지속적인 시장의 흐름을 학습하기 위해 Sliding Window 기법을 적용하였다. 과거 5 일간의 뉴스 벡터와 가격 데이터를 하나의 시퀀스 단위(3D Tensor: [Samples, Time Steps, Features])로 결합함으로써, 모델이 최근 5 일간의 시장 추세와 맥락을 기억하고 예측에 반영할 수 있도록 구조화하였다.

6. 베이스라인 실험 및 한계 분석

전통적인 금융 시계열 분석 방식인 정형 데이터와 머신러닝 모델을 활용하여 기초적인 예측 성능을 측정하고, 그 한계를 분석하여 베이스라인을 구축하는 과정을 거쳤다. RSI, MACD, VIX 등 시장 변동성과 추세를 반영하는 주요 기술적 지표 13 가지 변수를 활용하였다.

6.1. 베이스라인 실험 및 결과 분석

베이스모델은 비선형적 패턴 포착에 능한 XGBoost와 선형 규제를 통해 과적합을 방지하는 Ridge Regression을 비교 모델로 선정했지만, 성능이 더 우수한 XGBoost를 채택하였다. 분석 기법으로 롤링윈도우 기법을 적용하였으며, 예측 지평은 선행연구²에 따라 다음과 같이 설정하였다.

- 단기 모델: 과거 30일 데이터를 입력으로 사용, 미래 5일 누적 로그수익률 예측

² Selvin et al. (2017), Pang et al. (2020), Weytjens et al. (2020)

- 장기 모델: 과거 120일 데이터를 입력으로 사용, 미래 20일 누적 로그수익률 예측
금융 시장에서는 수익의 크기보다 방향성 예측이 투자 성과에 직접적으로 연결되므로, RMSE 보다 Sign Accuracy 가 중요한 평가 지표로 활용된다.

실험 결과는 다음 <표 3>과 같다.

<표 3> baseline 실험 결과 요약

구분	결정계수 (R2)	평균 절대 오차 (MAE)	최종 누적 수익률	Sign Accuracy
단기 모델 (5D)	-0.3201	0.0389	44.78%	48.3%
장기 모델 (20D)	-0.7639	0.0866	58.27%	75.0%

두 모델 모두 결정계수가 음수를 기록하였다. 이는 모델이 평균값으로 예측하는 것보다 성능이 낮음을 의미하며, 기술적 지표만으로는 주가 변동의 무작위성(Random Walk)을 설명하는 데 명확한 한계가 있음을 시사한다.

반면, 단기 모델의 정확도가 50%를 하회(48.3%)하는 결과를 보였다. 이는 5 일 단위의 초단기 주가 움직임이 기술적 지표만으로는 설명하기 어려운 노이즈임을 의미한다. 반면, 장기 모델은 75.0%라는 매우 높은 방향성 정확도를 기록하였다. 이는 20 일(약 1 개월) 단위의 누적 수익률 흐름에는 기술적 지표와 거시 경제 데이터가 반영하는 추세가 존재함을 의미한다.

따라서 단기 예측에서 뉴스 임베딩을 통한 '외부 충격' 데이터의 보완이 필요함을 비정형 데이터(뉴스)를 결합함에 따라 시장 참여자의 심리적 기제와 실시간 거시 경제 이슈를 반영한 프레임워크를 도입할 근거라고 판단한다.

6.2. 가상 투자 시뮬레이션 및 성과 분석의 한계

가상 투자 시뮬레이션은 단기 기준 40%를 상회하는 수익률을 기록하며 베이스라인 모델로서 안정적인 우상향 성능을 입증하였다.

다만, 현재의 수익률은 특정 테스트 구간에서의 성과이기에 모델의 일반화 능력을 완전히 대변하지 않는다. 따라서 현시점에서는 수익률 수치 자체보다 Sign Accuracy 와 같은 통계적 지표를 통해 모델의 근본적인 시장 파악 능력을 검증하는 데 집중하고자 한다. 또한 모델 고도화 이후 진행될 최종 백테스팅에서는 누적 수익률 외에도 Sharpe Ratio(위험 대비 수익) 및 MDD(최대 낙폭) 등의 지표를 도입하여 모델의 실전 투자 유효성을 평가할 계획이다.

7. LSTM 구축 및 검증

본 연구에서는 기술적 지표와 뉴스 정보를 통합적으로 활용하기 위해 LSTM(Long Short-Term Memory) 기반의 시계열 예측 모델을 설계하였다. 모델의 예측 지평은 모두 베이스 라인과 동일하게 단기 및 장기 예측을 모두 고려하여 두 가지 형태로 구성하였다.

7.1. 뉴스 임베딩 구성

뉴스 데이터는 사전 학습된 금융 특화 언어모델인 FinBERT를 기반으로 임베딩 벡터로 변환하여 사용한다. 각 뉴스 기사로부터 문장 수준의 의미 정보를 추출하고, 이를 일별 단위로 집계하여 하나의 뉴스 벡터를 생성한다. 이렇게 생성된 일별 뉴스 벡터는 시장에 영향을 줄 수 있는 사건, 감성, 정보 강도 등을 반영하는 표현으로 활용된다.

본 연구의 예측 모델은 원문 텍스트 자체를 직접 입력받는 구조가 아니라, FinBERT를 통해 사전에 생성된 뉴스 임베딩을 입력 특징으로 사용하는 방식이다. 따라서 FinBERT는 본 예측 모델 내부에서 추가 학습되는 것이 아니라, 뉴스 의미 정보를 추출하는 특징 생성 단계에서 활용된다.

7.2. 뉴스 벡터 차원 축소

일별로 구성된 뉴스 임베딩 벡터는 차원이 높기 때문에, 이를 그대로 시계열 모델에 입력할 경우 학습의 불안정성과 과적합 가능성이 커질 수 있다. 이를 완화하기 위해 다층 퍼셉트론(Fully Connected Layer)을 이용하여 뉴스 벡터의 차원을 축소하였다.

구체적으로 뉴스 벡터는 선형변환과 비선형 활성화 함수를 거치며 순차적으로 축소되며, 본 연구에서는 768차원의 뉴스 임베딩을 $64 \rightarrow 32 \rightarrow 16$ 구조로 변환하여 최종적으로 16차원의 저차원 뉴스 표현 벡터를 생성하였다. 마지막에는 Layer Normalization을 적용하여 표현의 안정성을 높였다. 이 과정은 고차원 뉴스 정보에서 예측에 유의한 특징만을 압축적으로 반영하기 위한 단계이다.

7.3. 시계열 입력 구성

각 시점 t 에서 모델 입력은 두 가지 정보로 구성된다. 첫째는 주가로부터 계산된 기술적 지표 벡터이며, 둘째는 차원 축소된 일별 뉴스 임베딩 벡터이다. 이 두 벡터를 결합하여 하나의 통합 feature 벡터를 구성하고, 이를 일정 기간 누적하여 시계열 입력으로 사용한다.

즉 각 일자별 입력은 기술적 지표와 뉴스 정보가 결합한 형태이며, 단기 모델에서는 최근 20일, 장기 모델에서는 최근 120일의 연속된 시계열 데이터가 LSTM의 입력으로 사용된다. 이를 통해 가격 기반 정보와 뉴스 기반 정보를 동일한 시간 축 위에서 함께 학습할 수 있도록 하였다.

7.4. LSTM 기반 시계열 학습

구성된 시계열 입력은 LSTM 네트워크에 입력된다. 본 연구에서는 2층으로 구성된 stacked LSTM 구조를 사용하였으며, 입력된 시계열로부터 과거 기간 동안의 동적 패턴과 시간적 의존성을 학습하도록 설계하였다.

첫 번째 LSTM 층은 기술적 지표와 뉴스 정보를 기반으로 기본적인 시계열 특징을 추출하고, 두 번째 LSTM 층은 이를 바탕으로 보다 추상적인 시간적 패턴을 학습한다. 이를 통해 뉴스와 가격 정보 간의 복합적인 상호작용을 보다 효과적으로 반영할 수 있도록 하였다.

모델은 최종 시점의 hidden state를 전체 입력 구간을 요약한 벡터로 사용한다. 이 hidden state는 과거 일정 기간의 시장 정보와 뉴스 흐름을 압축한 표현으로 볼 수 있으며, 이후 출력층의 입력으로 전달된다.

7.5. 출력층(MLP)

LSTM에서 생성된 최종 hidden state는 다층 퍼셉트론(MLP)에 입력되어 최종 예측값을 생성한다. 출력층은 선형변환과 비선형 활성화 함수를 통해 시계열 요약 벡터를 한 단계 더 가공한 뒤, 최종적으로 1개의 연속형 값을 출력한다. 이 출력값은 미래 구간의 누적 로그수익률 예측치에 해당한다.

7.6. 학습 대상 파라미터

본 연구에서 학습되는 주요 구성 요소는 뉴스 벡터 차원 축소를 위한 FC layer, 시계열 패턴 학습을 위한 LSTM, 그리고 최종 예측을 수행하는 MLP이다. 반면 뉴스 임베딩 자체는 사전에 생성된 특징으로 입력되므로, 본 예측 모델 내부에서는 별도의 언어모델 미세 조정을 수행하지 않는다.

이를 통해 사전 학습된 뉴스 의미 표현을 유지하면서 모델 경량화에 집중하면서도, 시계열 예측 목적에 적합한 하위 예측 구조를 효율적으로 학습할 수 있도록 하였다.

7.7. 앙상블 기반 확장 구조

본 연구에서는 단일 모델의 예측 불안정성을 완화하고 보다 안정적인 예측 성능을 확보하기 위해, 서로 다른 하이퍼파라미터 설정을 가진 복수의 LSTM 모델을 결합하는 앙상블 구조를 적용하였다. 각 모델은 독립적으로 학습되며, 학습 과정에서 서로 다른 초기값, 학습률, hidden dimension 등의 설정을 통해 다양한 시계열 표현을 학습한다.

각 모델의 예측 결과는 validation 데이터를 기준으로 방향성을 보정한 후, 평균을 통해 결합된다. 이를 통해 개별 모델의 편향을 줄이고, 금융 시계열 예측에서 중요한 안정성과 일반화 성능을 향상시킬 수 있다.

결과적으로 본 연구의 최종 예측 구조는 단일 LSTM 모델이 아닌, 다수의 LSTM 기반 시계열 모델을 결합한 앙상블 형태의 구조로 구성된다.

7.8. 모델의 목적

본 모델은 기술적 지표와 뉴스 정보를 하나의 시계열 입력 공간에서 통합적으로 학습함으로써, 가격의 과거 흐름과 뉴스 이벤트 효과를 동시에 반영하는 예측 구조를 구현하는 것을 목표로 한다. 이를 통해 금융시장의 복합적 정보 구조를 보다 효과적으로 반영하고, 미래 수익률 예측의 정확도와 안정성을 높이고자 한다.

8. 앞으로의 방향

향후에는 Transformer 기반 시계열 모델인 PatchTST 를 도입하여 금융 시계열 데이터에 대한 예측 성능을 고도화하고자 한다. PatchTST 는 시계열을 일정 길이의 패치(patch) 단위로 분할하여 처리함으로써 장기 시퀀스 학습의 효율성을 높이고, 개별 시점이 아닌 구간 단위의 흐름을 학습할 수 있어 노이즈가 많은 금융 데이터의 패턴을 보다 안정적으로 포착할 수 있다는 장점을 가진다. 또한 다변량 시계열 데이터를 변수별 독립 채널로 처리함으로써 변수 간 간섭을 최소화하고, 각 지표의 고유한 정보를 효과적으로 반영할 수 있다.

이를 바탕으로 기존에 구축된 금융 데이터셋과 뉴스 임베딩 데이터를 입력으로 활용하여 PatchTST 모델을 설계 및 학습하고, 시계열 입력 구조와 모델 아키텍처에 따른 예측 특성을 분석할 예정이다. 특히 입력 시퀀스 길이, 패치 크기, 스트라이드(stride) 등 PatchTST 의 핵심 하이퍼파라미터를 중심으로 다양한 실험을 수행함으로써 금융 데이터에 최적화된 모델 구조를 탐색하고자 한다.

또한, 단기 및 장기 예측을 반영한 LSTM 모델을 구축하고, 동일한 데이터셋과 예측 구조 하에서 베이스라인, LSTM, PatchTST 모델의 성능을 비교 분석할 예정이다.

각 모델은 단순 예측 오차뿐 아니라 실제 투자 전략에 적용하여 백테스팅을 수행하며, 누적 수익률, Sharpe Ratio, 최대 낙폭(MDD) 등의 지표를 통해 성과를 평가한다. 또한 Buy and Hold 전략과의 비교를 통해 제안 모델의 초과 성과 여부를 검증하고자 한다.

모델 간 예측력 차이에 대해서는 Diebold-Mariano(DM) 검정을 통해 통계적 유의성을 확보하고, SHAP 분석을 활용하여 기술적 지표, 거시경제 변수, 뉴스 정보가 예측에 미치는 기여도를 정량적으로 분석함으로써 모델의 설명력을 강화할 예정이다.

성능 평가는 결정계수와 평균 절대 오차 외에도 투자 의사결정의 정합성을 판단하는 방향성 정확도와 누적 수익률을 주요 지표로 산출할 것이다. 이는 숫자 데이터만으로

설명하기 어려운 주가 변동의 무작위성을 증명하며, 비정형 뉴스 데이터 결합의 통계적 근거를 제공한다.

궁극적으로 본 연구는 예측 정확도, 투자 성과, 통계적 유의성, 그리고 설명가능성을 종합적으로 검토함으로써, 멀티모달 금융 예측 모델의 실질적 유효성을 다각도로 검증하는 방향으로 확장될 것이다.