

Unsupervised Rhythm and Voice Conversion of Dysarthric to Healthy Speech for ASR

구음장애 발화의 비지도 리듬·음색 변환을 통한 음성인식 성능 향상

이제학 · 멀티센스 · 2026.05.28

Karl El Hajal, Enno Hermann, Ajinkya Kulkarni, Mathew Magimai.-Doss
Idiap Research Institute / EPFL

목차

01

연구 배경

ASR 의 구조적 한계 · 기존 접근의 한계

02

문제 인식 및 연구 목표

리듬 문제 · 음색 문제 · Zero-shot 목표

03

핵심 제안 — RnV 프레임워크

전체 파이프라인 (논문 Fig.1)

04

핵심 제안 — Rhythm 변환

3 유형 분류 (논문 Fig.2) · 두 가지 변환 방식

05

핵심 제안 — Voice 변환 (kNN-VC)

SSL 원리 · Rhythm → Voice 순서

06

결과 도출

발화속도 · 감마분포 (Fig.3) · WER 비교 (Fig.4)

07

논문 결론 및 시사점

의의 · 한계 · 확장 가능성

08

우리 프로젝트 적용 방향

파이프라인 통합 · 3 가지 발전 방향

연구 배경

ASR의 구조적 한계

ASR은 정상 발화 패턴으로만 학습

구음장애 특유의 느린 속도 · 조음 오류에 취약

중증 케이스에서 WER 200% 이상 폭등

Whisper 등 대형 모델도 환각 반복 발생

기존 접근의 한계

발화 속도 보정 → 강제 정렬 기반

전사 (Transcription) 데이터에 의존

새로운 화자 (Unseen Speaker) 에게 적용 불가

화자마다 재학습 필요 → 확장성 한계

문제 인식 및 연구 목표

문제 1 — 리듬 (Rhythm)

구음장애 화자는 정상인 대비 발화 속도가 느리고 음절 간 지속 시간이 불규칙합니다 .

ASR 모델은 정상 발화 속도에 최적화되어 있어 Sonorant·Silence 구간이 비정상적으로 길어지면 Whisper 가 같은 단어를 무한 반복하는 환각을 일으킵니다 .

문제 2 — 음색 (Voice)

화자 개인의 조음 특성 (음색 · 억양) 이 정상인 분포에서 크게 벗어나 ASR 이 동일 음소를 다른 단어로 오인식합니다 .


단순 속도 보정만으로는 음색 도메인 불일치를 해결할 수 없습니다 .

연구 목표

전사 데이터 없이 (Zero-shot, Unsupervised)
구음장애 음성의 리듬과 음색을 동시에 정상인 수준으로 변환하여
별도의 Fine-tuning 없이 기존 ASR 성능을 향상시킬 수 있는가 ?

핵심 제안 — RnV (Rhythm and Voice) 프레임워크

Fig. 1 — 논문 원본 프레임워크 다이어그램



① SSL Encoder

WavLM-Large 6 번째 레이어
화자 + 음소 정보 동시 추출

② Rhythm Converter

Urhythmic 기반
리듬을 정상인 분포로 매핑

③ kNN-VC


프레임 단위 Zero-shot
음색 변환 (Any-to-Any)

④ HiFi-GAN Vocoder

이산 표현에서
최종 파형 복원

핵심 제안 — Rhythm 변환 (Urhythmic)

Fig. 2 — 구음장애 화자 M02 의 파형 분절 결과



Silence

목음 구간
VAD 와 최다 겹침

Sonorant

공명음 (모음류)
음절 핵심 단위

Obstruent

장애음 (자음류)
나머지 구간

두 가지 변환 방식

Global — 전체 속도 조정

Sonorant-per-second 로 발화 속도 추정
전체 발화를 단순 비율로 Time-Stretch
→ 빠르고 단순, 전체적 속도만 보정

Fine-grained — 구간별 개별 조정

각 유형별 지속 시간을 감마 분포로 모델링
CDF → PPF 매핑으로 구간별 개별 Time-Stretch
비정상적으로 긴 Sonorant·Silence 를
정상인 분포로 정밀 교정

핵심 제안 — Voice 변환 (kNN-VC)

핵심 원리 — SSL 의 특성 활용

서로 다른 화자라도
같은 음소 내용을 발화하면
벡터 공간에서 가깝게 클러스터링

이 특성 덕분에 전사 없이도 음소 수준 매핑이 가능합니다.

변환 과정 :

구음장애 화자의 각 프레임을
정상인 (LJSpeech) 의 유닛 DB 와 코사인 거리로 비교
→ $k=8$ 최근접 프레임 선택 후 가중 평균 교체

왜 Rhythm → Voice 순서인가 ?

1 kNN-VC 의 구조적 한계

프레임 단위 교체 방식이므로
발화 길이 (리듬) 는 변하지 않음
→ 리듬을 먼저 정규화 필수

2 Rhythm 변환 선행

느린 발화를 정상 속도로 먼저 조정한 뒤
kNN-VC 로 음색을 정상인 화자로 변환
→ 두 도메인 불일치를 순서대로 해소

3 Zero-shot 완성

전사 데이터 없이
End-to-End 변환 완성
새 화자에게 즉시 적용 가능

결과 도출

Fig. 3 — 중증도별 발화속도 및 유형별 감마 분포 (정상인 MC01 vs 구음장애 M01)




Fig. 3: Visualization of segmented rhythm models. (a) Global speaking rates for each Torgo speaker, categorized by severity.

Fig. 4 — 중증도별 WER 비교




Fig. 4: WER results on Torgo, grouped by severity level

핵심 발견

- ① 리듬 변환이 핵심 — 중증일수록 WER 감소 폭 가장 큼
- ② Whisper 환각이 발화 속도 정규화만으로 억제됨
- ③ 음색 (kNN-VC) 단독 효과는 제한적, 리듬이 선행 필수

논문의 결론 및 시사점

결론

전사 데이터 없이도 비지도 리듬·음색 변환으로 구음장애 ASR 성능 향상 기능을 최초 증명.
Zero-shot 적용 가능 → 데이터 수집이 어려운 구음장애 도메인에 최적화된 접근법.

✓ 핵심 성과

- 중증 케이스에서 WER 대폭 감소
- Whisper 환각 현상 억제 확인
- 전사 없이도 유효한 변환 달성

⚡ 확장 가능성

- 구음장애 중증도 탐지
- 진행 상태 모니터링
- 치료 보조 도구로 응용

⚠ 한계 및 향후 과제

- 중증에서 WER 여전히 높음
- 구음장애 특화 분절 정확도 개선 필요
- 영어 외 다국어 적용 검증 필요

우리 프로젝트에서의 적용, 발전 방향

파이프라인 통합

RnV 변환 — 이 논문 (2 차 논문 휴지 분석 연계)



ASR → N-best 출력



Judge-Editor 교정 (1 차 논문)



SelfCheckGPT Safety (3 차 논문)



최종 의도 복원 출력

2 차 논문 파라미터 연계

01

검증된 200ms 기준 + 30dB 임계값을
RnV Silence/Sonorant 분류 파라미터에 직접 연결
→ 구음장애 특화 분절 정밀도 향상

한국어 적용

02

현재 영어 (LJSpeech) 타겟을
한국어 정상 화자 코퍼스로 교체
HuBERT-Korean 등 Korean SSL 인코더 활용

중증도별 Dynamic Target

03

WSLD Score 그룹에 따라 변환 강도 차등 적용
경증 : Fine Rhythm 만 / 중증 : Rhythm + Voice 폴 변환
→ 개인화된 변환 전략 완성

감사합니다

Q & A

멀티센스 (Multi-Sense) · 이제학