


구음장애 음성인식 멀티모달 파이프라인 연구

4차 발표

Gold Standard 구축 · 파이프라인 재설계 · 실험 설계

멀티센스 | 2026.05



목차

01

데이터 구조 재파악

AI Hub 낭독 데이터 분석 → 교차 화자 매칭 전략 수립

02

Gold Standard 구축 — 앵커 매칭 파이프라인

Before/After 비교 · 4단계 캐스케이드 · 핵심 코드

03

Gold Standard — L4 청취 & 최종 현황

노이즈 판별 로직 · gold_final.csv 9,832건

04

파이프라인 핵심 설계 결정

N-best beam_size=5 구현 · Judge 재정의 · Late Fusion → Soft Fusion

05

실험 설계 & 다음 단계

A/B Ablation · WSLD · 로드맵

01 데이터 구조 재파악

447,730

전체 발화 건수

19,882

고유 문장 수

95.4%

중복률 (여러 화자 낭독)

전략적 전환

불완전 발화의 정답이 '다른 화자의 깨끗한 버전'에 존재함
→ 교차 화자 매칭(Cross-Speaker Matching)으로 Gold Standard 자동 생성 가능 — 직접 청취 최소화

원본 JSON 구조 & 한계

```
{
  "playTime": 772.16,
  "Transcript": "전체 발화가 하나의 문자열로...",
  "Test_info": {
    "TestMethod": "Read aloud scripts"
  }
}
```

X 타임스탬프 없음 → 문장 단위 자동 분절 불가

X 정답 지문(스크립트 원본) 없음 → 전사문에서만 확인

✓ → 앵커 매칭으로 두 제약 동시 우회

02 Gold Standard 구축 — 앵커 매칭 파이프라인

기존 정제 방식의 문제

Raw: "아들과 병원에 가보니 하필 늑막염이+
이었다."
정제 후: "아들과 병원에 가보니 하필 이었다." ←
단어 탈락!

앵커 방식 (기호만 제거, 글자 보존)

앵커: "아들과 병원에 가보니 하필 늑막염이 이었다."
→ "늑막염이었다"와 편집거리 매칭 → 정답 발견 ✓

매칭 캐스케이드 (4단계)

T1 Exact	앵커 ≥ 0.90	정확 매칭	82.7%
T2 Partial	0.80~0.90	부분 매칭	11.9%
T3 Fuzzy	0.70~0.80	유사도 매칭	3.0%
L4 Fail	< 0.70	직접 청취	청취

핵심 코드

```
def anchor(text):  
    return re.sub(  
        r'[+*/]', '', str(text)  
    ).strip()  
  
def best_match(a, pool):  
    candids = set()  
    for g in ngrams(a, 3):  
        candids |= inv_idx.get(g,  
set())  
    best, bm = 0.0, None  
    for i in candids:  
        r = ratio(a, pool[i])  
        if r > best:  
            best, bm = r, pool[i]  
    return best, bm
```

03 Gold Standard — L4 청취 & 최종 현황

L4 직접 청취 & 노이즈 판별

청취 대상

234건

청취 완료

202건

노이즈 처리

32건

최종 Gold 현황 (gold_final.csv)

9,832건

평가 가능 발화 (99.7%)

노이즈 판별 로직

```
def is_noise(s):  
    # 전자 불가  
    if re.search(r'\bu/', s):  
        return True  
    # 개인정보 마스킹  
    if re.search(r'000|00\s*띠', s):  
        return True  
    # 스크립트 빈칸  
    if re.search(r'\(예시', s):  
        return True  
    return False
```

Tier	설명	건수	비율
T0_human	직접 청취	202	2.0%
T1_exact	자동 정확 (≥ 0.90)	8,156	82.7%
T2_partial	자동 부분 (0.80~0.90)	1,178	11.9%
T3_fuzzy	자동 유사도 (0.70~0.80)	296	3.0%
T_noise	노이즈 (영구 제외)	20	0.2%

* T3는 보수적($T1+T2$) / 관대한($T1+T2+T3$) 두 버전으로 평가 예정

04 파이프라인 핵심 설계 결정

①

발표 후 연결

N-best: beam_size=5로 구현

Why: faster-whisper: beam_size=5 → 5개 가설 생성, Judge가 span 단위로 비교

How: Whisper 전사문 생성(발표 후) → N-best 가설을 Judge에 연결 → 원래 설계대로 구현 예정

②

개념 재적용

Judge 역할 재정의

Why: 논문의 Judge = N-best 비교, beam_size=5로 N-best 확보 → 원래 Judge 역할 그대로 적용

How: 기호(+/*/) → span 신뢰도 신호로 재정의
+: 반복 더듬음 | *: 발음 불분명 | /: 음절 탈락

③

구현 대안

Late Fusion → Soft Fusion

Why: Qwen2.5-72B API 구조상 어텐션 직접 접근 불가

How: 오디오 피쳐(더듬음 횟수·시간, 의도적 휴지)를 자연어 메타데이터로 변환 → 프롬프트에 주입

05 실험 설계 & 다음 단계

Baseline 교정 없음	v2 텍스트 전용	v3 오디오 주입
AI Hub 전사문	AI Hub 전사문 + 기호 신뢰도 규칙	AI Hub 전사문 + librosa 오디오 피쳐
하한선 (Lower Bound)	텍스트만의 교정 효과 측정	멀티모달 기여분 측정

$$\text{오디오 기여분} = \text{BERTScore (v3)} - \text{BERTScore (v2)}$$

● Judge-Editor 프롬프트 v2/v3 확정 및 테스트	대기
● Whisper 전사문 생성 → LLM 입력 교체	예정
● 전체 9,832건 실험 실행	예정
● Validation Set (1,207건) 최종 1회 평가	예정
● Safety Trigger 설계	선택