

Report Review | Medical Speech-AI

SelfCheckGPT: Zero-Resource Hallucination Detection for LLMs

에이전트 기반 구음장애 발화 교정의 신뢰성 확보 전략

이제학 | 멀티센스

2026. 05. 07

목차

01

연구 배경

LLM 환각 현상의 정의 및 구음장애 도메인에서의 위험성

02

문제 인식

기존 외부 지식 기반 탐지 모델의 한계점 분석

03

핵심 제안

SelfCheckGPT: 자체 일관성 검증 메커니즘

04

결과 도출

인간 판단과의 상관관계 및 탐지 성능 지표

05

결론 및 시사점

Zero-resource 환경에서의 실용성 증명

06

프로젝트 적용

Safety Trigger 및 N-best 일관성 분석 로드맵

1. 연구 배경

LLM의 본질적 한계: 환각

- 확률적 생성의 부작용: 모델이 사실이 아닌 정보를 매우 자신감 있게 생성하는 현상
- 구음장애 도메인의 특수성: 환자의 개인적 의도는 위키피디아 등 외부 DB에 존재하지 않음
- 오류의 연쇄 효과: 잘못된 교정 결과는 환자 돌봄 시스템에서 치명적인 오작동 유발



2. 문제 인식 및 연구 목표

기존 방식의 한계

외부 지식(Knowledge Base)에 의존하여 대조하는 방식은 개인화된 대화나 최신 정보에 대응이 불가능함

블랙박스 모델(GPT-4 등)의 내부 확률값에 접근할 수 없는 환경에서의 탐지 기술 부재

연구 목표

→ 외부 자원 없이(Zero-Resource) 모델 스스로 환각을 탐지할 수 있는가?

→ 여러 샘플 간의 의미론적 일관성이 사실 여부와 상관관계가 있는가?

→ 다양한 NLP 메트릭(NLI, BERTScore)을 활용한 최적의 탐지 알고리즘 개발

3. 핵심 제안 - 작동 원리



Stochastic Sampling

동일 프롬프트에 대해 높은 변동성 (Temperature)을 주어 여러 개의 답변 후보를 생성



Consistency Check

생성된 샘플들 사이의 정보가 서로를 뒷받침하는지, 아니면 충돌하는지 분석




Hallucination Score

일관성이 낮은 구간을 '환각'으로 분류하고 최종 신뢰도 점수를 산출

"알고 있는 사실은 여러 번 물어도 답이 같지만, 지어낸 사실은 매번 답이 다르다"는 가설에 기반

3. 핵심 제안 - 탐지 기법



1) NLI (Natural Language Inference)

문장 간의 함의(Entailment)와 모순(Contradiction)을 판별하여 논리적 일치도 확인

2) BERTScore / LLM Prompting

문맥적 벡터 유사도를 측정하거나, LLM에게 직접 두 문장의 일치 여부를 질문

4. 결과 도출

환각 탐지 기법별 성능 비교 (AUC-PR)



*인간의 사실성 평가(Human Factuality Rating)와 가장 높은 상관관계를 보인 것은 NLI 기반 방식임

5. 결론 및 시사점

핵심 결론

자체 샘플링만으로도 외부 지식 없이 고도의 환각 탐지가 가능함을 입증. 이는 API만 제공되는 블랙박스 모델에서도 적용 가능한 실용적인 솔루션임

임상적 시사점

의료 및 돌봄 AI에서 답변의 '확신도'를 정량적으로 측정할 수 있는 기준 마련

기술적 시사점

N-best 가설군이 이미 존재하는 ASR 시스템에 즉시 통합 가능한 구조

6. 프로젝트 적용 - SAFETY TRIGGER

의미론적 거리 기반 Rejection

- Step 1: ASR이 출력한 N-best 가설들을 SelfCheckGPT의 '샘플'로 간주
- Step 2: Judge 에이전트가 가설 간의 NLI 점수를 계산하여 일관성 확인
- Step 3: 일관성 점수가 임계값(0.5) 미만일 경우 즉시 출력 거부
- Result: "REJECT: 재질의 필요" 트리거 발동

Hardening AI Systems

Governance

Model

Prompts/Context

Tools/Actions

Policy

Governance

6. 프로젝트 적용 - 고도화 로드맵



물리적 신호 결합

휴지(Pause) 시간 정보와
SelfCheck 점수를 결합한 멀티모
달 환각 탐지



개인화 임계값

환자의 구음장애 심각도(Grade)에
따른 Dynamic Threshold 설정



의도 달성 평가

단순 글자 일치가 아닌, 의도(SLU)
보존 여부를 최종 평가지표로 채택

Q & A

발표를 들어주셔서 감사합니다.
