

DAT 7기 캡스톤 중간발표 보고서

구음장애 발화의 의도 복원을 위한 멀티모달 음성인식 파이프라인 연구

: 오디오 피쳐 심각도 검증 및 LLM 기반 의도 복원 실험을 중심으로

DAT 7기

멀티센스(Multi-Sense)

이제학

허다교

정주희

DAT 7기 캡스톤 중간발표 보고서

구음장애 발화의 의도 복원을 위한 멀티모달 음성인식 파이프라인 연구

: 오디오 피쳐 심각도 검증 및 LLM 기반 의도 복원 실험을 중심으로

Multimodal Pipeline for Dysarthric Speech Recognition – Severity
Validation via Audio Features and LLM-based Intent Restoration

이 보고서를 캡스톤 중간발표 보고서로 제출합니다.

2026년 4월 8일

DAT 7기

멀티센스(Multi-Sense)

이제학

허다교

정주희

DAT 7기 캡스톤 중간발표 보고서

구음장애 발화의 의도 복원을 위한 멀티모달 음성인식

파이프라인 연구

: 오디오 피쳐 심각도 검증 및 LLM 기반 의도 복원 실험을 중심으로

Multimodal Pipeline for Dysarthric Speech Recognition – Severity Validation via Audio Features and LLM-based Intent Restoration

국문 요약

구음장애는 신경계 질환, 언어청각장애, 후두장애 등으로 발화 기관의 운동 기능이 저하되어 일상적 의사소통을 심각하게 제한한다. 현재 ASR 시스템은 비장애인 화자 중심으로 학습되어 구음장애 발화에 취약하다. 본 연구는 AI Hub 구음장애 데이터 6,104건을 대상으로 텍스트 오류 패턴과 오디오 비유창성 신호를 결합한 멀티모달 사후 교정 파이프라인의 타당성을 검증하였다. 두 피쳐 간 스피어만 상관계수는 $r=0.377\sim0.400$ 으로 독립적 상관성이 확인되었으며, Qwen2.5-72B 기반 Judge-Editor 에이전트 적용 결과 BERTScore가 0.8140에서 0.9752로 약 16.1% 향상되었다.

Abstract

Dysarthria severely limits communication, yet current ASR systems remain inadequate for dysarthric speakers. This study validates a multimodal post-ASR correction pipeline integrating text and audio disfluency features across 6,104 utterances. The two modalities showed independent complementarity ($r=0.377\sim0.400$), and a Qwen2.5-72B-based Judge-Editor agent improved BERTScore from 0.8140 to 0.9752 (+16.1%).

DAT 7기

멀티센스(Multi-Sense)

이제학

허다교

정주희

목차

제 1장 서론.....	- 1 -
제 1절 연구 배경 및 필요성	- 1 -
제 2절 연구 목적 및 제안 모델 개요.....	- 2 -
제 3절 연구 대상 및 범위	- 3 -
제 2장 데이터 소개	- 4 -
제 1절 선행연구 분석	- 4 -
제 2절 분석 데이터셋 구성 및 특성	- 5 -
제 3장 분석 방법	- 6 -
제 1절 멀티모달 피처 추출 및 심각도 정량화 분석	- 6 -
제 2절 LLM 에이전트 기반 의도 복원 및 실효성 평가.....	- 7 -
제 4장 분석 결과	- 8 -
제 1절 발화 심각도 기반 텍스트 피처 분석.....	- 8 -
제 2절 오디오 피처(음향학적 비유창성 지표) 통계 특성	- 9 -
제 3절 멀티모달 피처 간 상관관계 및 타당성 검증	- 10 -
제 4절 LLM 기반 의도 복원 실험 및 실효성 검증 (Pilot Test).....	- 12 -
제 5장 결론.....	- 14 -
제 1절 중간 연구 성과 및 의의	- 14 -
제 2절 향후 연구 계획	- 14 -
참고문헌	- 16 -

표 목차

Table 1. WSLD Score 기술통계량..... - 8 -

Table 2. 문장 개선 정도 (pilot)..... - 13 -

그림 목차

Figure 1. Project Pipeline..... - 2 -

Figure 2. 더듬음 횟수 및 시간(sec) 분포 - 9 -

Figure 3. 의도적 휴지 횟수 및 시간(sec) 분포..... - 10 -

Figure 4. 발화 심각도 그룹별 더듬음 시간 비율 (Box-plot) ... - 11 -

Figure 5. WSLD Score와 오디오 피쳐(Hesitation) 간 상관관계 산점
도..... - 12 -

제 1장 서론

제 1절 연구 배경 및 필요성

뇌졸중·파킨슨병 등 신경계 질환, 후두 절제술을 포함한 두경부 질환, 청각 및 언어 처리 장애 등 다양한 원인에 의해 발생하는 구음장애는 발화 기관의 운동 기능 저하를 유발하여 환자의 일상적 의사소통 능력을 심각하게 제한한다. 국내에서는 2022 년 한 해만 11 만여 건의 뇌졸중이 새로 발생하였으며(질병관리청, 2024), 급성기 뇌졸중 환자의 22~58%에서 구음장애가 동반되는 것으로 보고된다(ASHA, 2021). 두경부 악성 종양 역시 국내에서 연간 1,254 건의 후두암이 새로 발생하는 등(보건복지부 중앙암등록본부, 2026) 그 규모가 적지 않으며, 후두 절제술 이후 발성 기능의 상실은 환자의 사회적 고립과 삶의 질 저하로 이어진다.

자동 음성인식(Automatic Speech Recognition, 이하 ASR) 기술의 급격한 발전은 이러한 구음장애 환자의 의사소통 보조 수단으로서 높은 잠재력을 지닌다. 그러나 현재 상용화된 ASR 시스템의 대부분은 정상 화자의 발화 패턴을 기반으로 학습되어 있어 구음장애 특유의 조음 오류와 비유창성에 취약하다는 근본적인 한계를 지닌다(Marini et al., 2021).

이러한 문제를 해결하기 위한 선행 연구들은 주로 구음장애 화자 데이터를 활용한 음향 모델의 미세조정, 또는 적대적 생성 신경망(GAN)을 활용한 데이터 증강 방식에 집중해왔다 (Shahamiri et al., 2023; Liu et al., 2024). 그러나, 음향 모델 단독의 접근은 발화자의 조음 특성에 따라 과적합되기 쉽고, 신규 화자가 유입될 때마다 재학습이 필요하다는 확장성의 한계가 있다(Qing et al., 2025). 또한, 대본 낭독 환경에서 수집된 데이터와 실제 자유 발화 환경 사이의 난이도 격차를 음향 모델만으로 극복하는 것은 구조적으로 어렵다. 최근에는 대형 언어 모델(LLM)의 강력한 문맥 추론 능력을 ASR 과 결합, 인식 오류를 사후 교정하려는 시도가 등장하고 있으나(Aboeitta et al., 2025) 구음장애 발화의 특수성을 고려한 체계적인 설계는 아직 초기 단계에 머물러 있다.

본 연구는 위와 같은 한계를 극복하기 위해 ASR 음향 인식 결과, 오디오 피쳐 기반 발화 심각도 정보, LLM 문맥 추론을 결합한 멀티모달 파이프라인을 설계하고 그 타당성을 검증한다.

제 2절 연구 목적 및 제안 모델 개요

본 연구는 기존 ASR 모델들이 구음장애 음성에서 보이는 인식의 한계를 극복하기 위해, 불완전하게 인식된 텍스트 결과를 사후에 교정하여 화자의 본래 의도를 복원하는 'LLM 기반 멀티모달 사후 교정(Post-ASR Correction) 파이프라인' 구축을 최종 목적으로 한다. 구체적으로는 훈련 데이터 전수 분석을 통한 오디오 및 텍스트 피처 추출, 두 피처 간 상관성 및 독립성의 통계적 검증, 그리고 LLM Judge-Editor 에이전트의 의도 복원 가능성 실증을 중간 연구 목표로 설정한다.




Figure 1. Project Pipeline

본 연구의 제안 모델은 별도의 음향 모델(ASR)을 직접 구축하거나 및 미세조정하는 대신에, 기존 ASR 인식 결과의 텍스트 오류 패턴과 원천 오디오의 비유창성(Dysfluency) 신호를 결합하여 LLM 이 이를 정교하게 교정하는 Judge-Editor 에이전트 아키텍처를 채택한다(그림 1] 참조). 에이전트는 오류 식별자인 Judge와 문맥 복원자인 Editor로 역할이 분리된다. Judge(판단자)는 ASR이 생성한 N-best 가설들 간의 일관성을 분석하여 가설 간 합의가 높은 구간은 신뢰도가 높은 것으로 판단해 원형을 보존하고, 가설 간 충돌이 발생하는 불확실 구간만을 선별적으로 표시한다. Editor는 Judge가 표시한 구간에 대해 주변 문맥과 언어적 타당성을 바탕으로 최적의 의미로 재작성을 수행한다.

오디오 피처는 LLM 프롬프트에 메타데이터 형태로 주입되는 Late Fusion 방식을 채택한다. 구체적으로 더듬음 횟수, 더듬음 시간 비율, 의도적 휴지 횟수 등의 오디오 비유창성 지표를 발화 심각도 정보로 변환하여 프롬프트에 포함시킴으로써, LLM이 음향적으로 불확실한 구간을 인지하고 해당 구간의 교정에 더 높은 주의를 기울이도록 유도한다. 이를 통해 텍스트 오류 패턴과 오디오 비유창성 지표가 상호 보완적으로 작용하여 신뢰도가 낮은 구간을 정밀히 보정한다.

아울러 LLM의 자의적 문장 생성을 방지하기 위해 세 가지 교정 원칙을 엄격히 적용한다. 첫째, Last-Attempt Wins 원칙은 화자가 더듬으며 반복 시도한 단어 중 가장 마지막에 발화한 것만을 정답으로 채택하는 방식이다. 둘째, No Deletion 원칙은 특수기호가 붙어 있지 않고 정상적으로 인식된 단어는 한 글자도 삭제하지 않도록 제한한다. 셋째, No Creation 원칙은 미완성된 문장 뒤에 임의의 내용을 지어내어 문장을

완성하는 행위를 금지한다. 이 세 원칙을 통해 LLM 이 화자의 실제 발화 범위를 벗어난 내용을 생성하지 않도록 제한함으로써 의도 복원의 신뢰성을 확보한다.

제 3절 연구 대상 및 범위

본 연구의 분석 대상은 AI Hub 에서 제공하는 '구음장애 음성인식 데이터'이다. 해당 데이터셋은 실제 임상 현장에서 수집된 7,874 건의 데이터로 구성되어 있으며, 연구의 객관성과 안정성을 확보하기 위해 훈련용 6,667 건과 검증용 1,207 건으로 구분하여 사용하였다. 특히 화자의 질환별 발화 특성을 고르게 반영하기 위해 '뇌신경장애(TS01) 425 건/62557 분', '언어청각장애(TS02) 1,228 건/91192 분', '후두장애(TS03) 4,472 건/146718 분'으로 대상을 구체화하였으며, 정밀 필터링을 통해 최종적으로 6,104 건의 유효 발화 데이터를 연구 범위로 설정하였다.

연구의 기술적 범위는 ASR 인식 이후의 의도 복원 및 이를 위한 멀티모달 피처의 타당성 검증에 한정된다. 세부적인 범위는 다음과 같다.

첫째, 오디오 피처 추출 및 규격화 단계에서는 Librosa 라이브러리를 활용하여 음성 신호 내의 침묵 구간을 분리한다. 이때 배경 소음과 음성을 구분하기 위해 진폭 임계값을 30dB 로 설정하고, Hall et al.(1999)의 기준에 따라 1.5 초 미만의 구간은 '더듬음(Hesitation)', 1.5 초 이상의 구간은 '의도적 휴지(Intentional Pause)'로 정의하여 비유창성을 정량화한다.

둘째, 텍스트 심각도 검증 및 상관성 분석 범위로서 전사 데이터 내 특수기호(+, *, /)를 기반으로 발화의 훼손 정도를 점수화하는 WSLD(Weighted S-L-D) Score 를 산출한다. 이를 오디오 피처와 비교 분석하여 텍스트의 오류 심각도와 음향적 비유창성 간의 독립적 상관성을 검증하는 단계까지를 포함한다.

셋째, 의도 복원 성능 평가 범위로서 Qwen2.5-72B 기반 에이전트의 교정 결과물에 대해 원본 가설(Raw Sentence)과 정답 대본(Gold Standard) 간의 BERTScore 및 WER 을 비교 측정한다.

이를 통해 제안하는 사후 교정 파이프라인이 구음장애 음성 인식 시스템의 실효성을 얼마나 향상시켰는지 실증적으로 입증하는 것을 최종 연구 범위로 규정한다.

제 2장 데이터 소개

제 1절 선행연구 분석

구음장애 음성인식 분야의 선행연구는 크게 음향 모델 개선, 평가 지표 한계 인식, LLM 기반 사후 교정의 세 흐름으로 구분할 수 있다.

첫 번째 흐름은 음향 모델의 미세조정 및 데이터 증강을 중심으로 한 접근이다. 구음장애 화자 데이터를 활용한 Wav2Vec22, HuBERT, Whisper 등 자기지도 학습 기반 모델의 미세조정 연구가 활발히 진행되어 왔으며, 데이터 희소성 문제 극복을 위해 GAN 기반 데이터 증강 기법도 도입되었다(Liu et al., 2024). 그러나 이러한 접근은 특정 화자의 조음 패턴에 과적합되기 쉬우며 신규 화자 유입 시 재학습이 필요하다는 확장성의 한계를 내포하며, 대규모 데이터 없이는 일반화 성능이 제한적이라는 구조적 문제가 지적되어 왔다(Shahamiri et al., 2023).

두 번째 흐름은 기존 평가 지표의 한계에 대한 문제 제기이다. 단어 오류율(WER)은 구음장애 음성인식 시스템의 실질적 효용성을 온전히 반영하지 못한다는 비판이 제기되어 왔다. 구음장애 발화에서는 음소 왜곡이나 반복이 발생하더라도 화자의 의도가 명확히 전달되는 경우가 많아, WER 이 높더라도 의사소통 성공률은 높을 수 있기 때문이다. 이에 따라 BERTScore, 자연어 추론(NLI) 기반 의미 스코어, Slot Filling 성공률 등을 결합한 다면적 평가 프레임워크의 필요성이 강조되고 있다(Zheng et al., 2026).

세 번째 흐름은 LLM 을 활용한 사후 교정(Post-ASR Correction) 연구로, 본 연구와 가장 직접적으로 연관된다. Zheng et al.(2026)은 구음장애 음성인식을 위한 LLM 기반 Judge-Editor 에이전트를 제안하여, ASR 의 상위 k 개 가설 중 신뢰도가 높은 구간은 보존하고 불확실한 구간만 선택적으로 재작성하는 방식으로 WER 을 14.51% 감소시키는 동시에 의미 보존 성능을 크게 향상시켰다. 또한 엔트로피 기반 신뢰도 점수를 LLM 프롬프트에 주입하여 불확실 구간을 선택적으로 교정하는 신뢰도 가이드 프레임워크가 제안되었으며, 이는 단순 LLM 교정 대비 WER 을 10% 추가 감소시키는 효과를 보였다. 아울러 Whisper 와 LLM 을 결합한 디코딩 방식이 언어적 제약을 활용하여 음소 복원과 문법 정확도를 개선하는 데 효과적임이 확인되었다.

그러나 기존 연구들은 주로 영어권 데이터를 기반으로 하며, 조사와 어미 변화에 따라 의사소통 성공률이 크게 달라지는 한국어의 언어적 특수성을 반영한 연구는 아직 초기 단계에 머물러 있다. 또한 오디오 비유창성 피처를 LLM 교정 프로세스에 직접 주입하는

멀티모달 접근은 대부분의 선행연구에서 시도되지 않았다는 점에서 본 연구의 차별성이 있다.

제 2절 분석 데이터셋 구성 및 특성

본 연구에서 활용하는 AI Hub 구음장애 음성인식 데이터는 총 7,874건으로, 훈련용 6,667건과 검증용 1,207건으로 구분된다. 훈련 데이터는 뇌신경장애(TS01) 425건(62,557분), 언어청각장애(TS02) 1,228건(91,192분), 후두장애(TS03) 4,472건(146,718분)으로 구성되며, 세 질환군 모두 대본 낭독(read-aloud scripts) 환경에서 수집되었음을 전수 조사를 통해 확인하였다. 훈련 데이터와 검증 데이터는 발화 과제가 동일하나 화자가 상이하며, 파일 단위 중복이 관찰되지 않아 데이터 누수 위험이 낮은 것으로 판단된다. 원천 음성 데이터의 총 용량은 약 400GB이다.

유효 발화 선별을 위해 두 단계의 필터링을 적용하였다. 1단계에서는 단음절 단어의 나열이나 종결어미 및 마침표가 부재한 구조적 비문장을 제거하는 언어학적 필터링을 수행하여 562건을 제외하였으며, 긍정 및 부정의 핵심 의도 발화(네, 아니요 등)는 예외적으로 보존하였다. 2단계에서는 RAM 초과로 인한 시스템 예외 처리 파일 1건을 추가 제외하였다. 최종적으로 전체 훈련 데이터의 91.5%에 해당하는 6,104건이 분석 대상으로 확정되었다.

제 3장 분석 방법

제 1절 멀티모달 피쳐 추출 및 심각도 정량화 분석

구음장애 환자의 발화 특성을 데이터 차원에서 규명하기 위해, 텍스트 차원의 오류 밀도와 오디오 차원의 물리적 비유창성을 동시에 추출하여 정량화하는 분석을 수행한다. 먼저 텍스트 분석 단계에서는 AI Hub에서 제공하는 훈련 데이터 6,104건의 전사 데이터 (Transcript)를 전수 조사하여, 발화의 중단과 반복을 의미하는 특수기호(+, *, /)를 단순 노이즈가 아닌 핵심 분석 지표로 식별한다. 발화의 훼손 정도를 객관적으로 수치화하기 위해 Ambrose와 Yairi(1999)가 제안한 WSLD(Weighted Stuttering-Like Disfluencies) 공식을 응용하여 난이도 채점 시스템을 구축하였다. WSLD 공식은 다음과 같이 정의된다.

$$WSLD = [(PW + SS) \times \text{평균}RU] + (2 \times DP)$$

여기서 PW와 SS는 반복 유형을, RU는 반복 횟수를, DP는 막힘 및 연장 등의 비유창성을 나타낸다. 본 연구는 AI Hub 전사 데이터의 조음 역학적 의미(특수기호 체계)에 대응시켜 재스코어링 시스템을 구축하였다.

‘+’기호는 형태소 수준의 재시작 패턴인 PW+SS에 해당하며 가중치 1.5를 부여하였다. 이는 반복 패턴이 비유창성 DP보다 상대적으로 낮은 가중치를 갖는다는 원본 공식의 배점 비율을 준용한 잠정적 기준값이다. ‘*’ 기호는 발음이 불분명하거나 조사가 끊기는 조음 파열 현상으로, 원본 공식의 DP 가중치인 2점을 그대로 적용하였다. ‘/’ 기호는 원본 공식에 명시적 대응 항목이 없는 경기한 추임새나 단절로 판단하여 0.5의 보정 가중치를 부여하였다. 최종 심각도 산출은 위 가중치 합계에 전체 단어 수 대비 기호의 비중인 오류 밀도 (Error Density) 보정값을 더하는 방식을 취한다.

이와 동시에 음성 신호 이면에 존재하는 조음 준비 과정과 호흡의 불규칙성을 측정하기 위해 오디오 피쳐 추출을 병행한다. Librosa 라이브러리를 통해 16,000Hz로 로드된 원천 음성 신호에서 미세한 조음 단절까지 포착할 수 있도록 진폭 임계값을 30dB로 설정하여 침묵 구간을 분리한다. Librosa의 경우 진폭 기본값이 60dB이나, 본 연구에서는 미세 단절까지 포착하기 위하여 진폭 임계값을 비교적 보수적인 30dB로 설정하였다. 분리된 침묵 구간은 1.5초를 기준으로 더듬음과 의도적 휴지로 세분화한다. Hall(1999)에 따르면, 화자가 의미 단위 경계에서 숨을 고르거나 다음 발화를 준비하는 정상 휴지는 통상 1초에서 2초 사이에 분포한다. 반면 조음 기관의 마비나 근육 경직으로 인한 비의도적 말 막힘은 그보다 짧은 시간 내에 불규칙하게 연속 발생하는 경향이 있다. 1.5초는 이 두 구간의 중간값으로, 병리적 더듬음과 의도적 휴지를 구분하는 임계값으로서 이론적 타당성을 갖는다.

최종적으로 이렇게 도출된 텍스트 기반의 WSLD Score와 오디오 기반의 더듬음 시간 비율 간의 상관관계를 통계적으로 검증하여, 독립적으로 포착된 멀티모달 피쳐들이 향후 LLM의 교정 단서로 활용될 수 있는지를 실증 분석한다.

제 2절 LLM 에이전트 기반 의도 복원 및 실효성 평가

앞선 단계에서 추출된 텍스트 가설과 오디오 피쳐를 결합하여, 불완전한 인식 결과를 본래의 의도로 복원하는 에이전트 기반 사후 교정 시스템을 설계하고 그 실효성을 평가한다. 본 연구는 단일 언어 모델이 문장을 통째로 다시 쓰는 과정에서 발생하는 환각(Hallucination) 현상을 억제하고자, 에이전트 기반의 워크플로우 최적화 구조(Ma et al., 2026)를 Qwen2.5-72B 모델에 적용하여 인퍼런스 단계를 분리한다. 모델 추론 시 temperature 를 0.1 로 설정하여 출력의 다양성을 억제함으로써 환각 발생을 최소화하고자 하였으며, 이는 No Creation 원칙과 일관된 설계이다. 판단자(Judge) 에이전트가 인식 결과 중 논리적 충돌이나 불확실성이 높은 구간을 식별하면, 편집자(Editor) 에이전트가 문맥 및 오디오 피쳐 정보를 활용해 해당 블록만을 국소적으로 수정함으로써 전체 문장의 일관성을 유지한다(Ma et al., 2026). 특히나, 에이전트가 임의로 내용을 창작하는 것을 원천 차단하기 위해 '마지막 발화 채택(Last-Attempt Wins)', '정상 단어 보존(No Deletion)', '미완성 보존(No Creation)'이라는 3대 철칙을 프롬프트 시스템 규칙으로 엄격하게 강제한다.

시스템의 성능과 안전성을 평가함에 있어서는 기존 음성 인식 분야의 획일적인 단어 오류율(WER) 지표를 탈피하고 의미론적 보존에 중점을 둔다. 우선 BERTScore(F1)를 도입하여 LLM 이 교정한 문장과 실제 정답 대본 간의 의미적 일치도를 정량적으로 측정(Zhang et al., 2020)함으로써 의도 복원 파이프라인의 실효성을 수치화한다. 나아가 의료 및 돌봄 환경에서 잘못된 정보가 전달되는 것을 막기 위한 물리적 안전 트리거(Safety Trigger)를 구현한다. 이는 LLM 이 출력한 최종 교정문과 기존 ASR 가설 간의 의미론적 거리(Semantic Distance)를 계산하여, 그 차이가 사전에 설정된 신뢰도 임계값을 초과할 경우 시스템이 무리한 추론을 포기하고 사용자에게 재질의(Reject)를 유도하도록 하는 분석 논리이다. 이를 통해 단순한 인식률 향상을 넘어 실제 의사소통의 신뢰성과 효용을 극대화하는 것을 최종 분석 방법론으로 삼는다.

제 4장 분석 결과

제 1절 발화 심각도 기반 텍스트 피쳐 분석

본 절에서는 AI Hub 구음장애 데이터셋에서 추출한 6,104 건의 훈련 데이터를 대상으로, 전사 데이터(Transcript)에 나타난 언어적 오류 패턴을 정량화한 결과를 기술한다. 분석의 핵심은 단순한 기호의 개수 산출을 넘어, 각 오류 기호의 임상적 특성과 문장의 전체 길이를 고려한 WSLD 재스코어링 수치를 도출하는 데 있다.

4.1.1. 유효 발화 필터링 및 데이터 정제 결과

전체 원천 데이터 6,667 건 중 음성 신호의 결손이나 전사 데이터 부재 등 시스템 예외 항목을 제외하고, 최종적으로 6,104 건(수율 91.5%)의 유효 발화를 분석 대상으로 확정하였다. 필터링 과정에서는 '꼴', '낫'과 같은 단음절 연속 발화나 종결어미가 없는 비구조적 문장을 제거함으로써 데이터의 품질을 확보하였으며, 동시에 '네', '아니요'와 같은 핵심 의도 발화는 보존하여 실용적 분석 가치를 유지하였다. 정제된 데이터셋은 후두장애(4,472 건), 언어청각장애(1,228 건), 뇌신경장애(425 건) 순으로 구성되어 다양한 질환군의 발화 특성을 고르게 반영하고 있다.

4.1.2. WSLD Score 기술 통계 및 분포 특성

Ambrose & Yairi(1999)의 공식을 응용하여 산출한 WSLD Score 는 화자의 발화 심각도를 객관적인 연속형 변수로 제시한다. 훈련 데이터 전체에 대한 기술 통계 분석 결과, 평균 점수는 3.50 점(± 2.26)으로 집계되었다. 점수의 분포를 사분위수로 세분화하면 제 1 사분위(25%)는 2.27 점, 중위값(50%)은 2.93 점, 제 3 사분위(75%)는 4.00 점으로 나타나 대다수의 발화가 2 점에서 4 점 사이의 심각도 구간에 분포함을 확인하였다.

mean	3.495286
std	2.256610
min	0.544000
25%	2.269000
50%	2.929000
75%	4.000000
max	51.500000

Table 1. WSLD Score 기술통계량

표 1에서 주목할 점은 중위값 대비 최대값(51.50)이 매우 높게 형성된 극단적 우편향 분포이다. 이는 일부 중증 환자군에서 발생하는 심각한 수준의 비유창성을 반영하며, 이러한 고난이도 발화 구간은 향후 LLM 에이전트가 집중적으로 복원해야 할 핵심 타겟으로 분류된다.

4.1.3. 발화 심각도 그룹화 및 오류 패턴 분석

산출된 점수를 바탕으로 발화의 난이도를 범주화한 결과, 오류 기호가 탐지되지 않은 '완전 발화'가 전체의 약 52%를 차지하였다. 불완전 발화의 경우 Imperfect Rate의 사분위수를 기준으로 경증(2% 이하), 중등도(2~6%), 중증(6% 초과) 그룹으로 세분화하였다. 분석 결과, 심각도가 높은 그룹일수록 문장 내 반복(+)과 발음 불분명(*) 기호의 밀도가 단조 증가하는 경향을 보였으며, 특히 중증 그룹은 문장의 통사적 구조가 해체된 양상을 띠어 단순 음성 인식만으로는 의도 파악이 어려움을 데이터로 증명하였다. 이러한 언어적 특성 분석 결과는 이어지는 오디오 피처와의 상관성 분석을 위한 정량적 기초 자료로 활용된다.

제 2절 오디오 피처(음향학적 비유창성 지표) 통계 특성

본 절에서는 6,104 건의 유효 발화 데이터를 대상으로 Librosa 라이브러리를 통해 추출한 오디오 피처의 통계적 분포와 물리적 특성을 분석한다. 구음장애 발화의 핵심 지표인 침묵 구간을 정밀하게 포착하기 위해 30dB의 진폭 임계값을 적용하였으며, 이를 통해 도출된 더듬음과 의도적 휴지의 양상을 기술한다.

4.2.1. 더듬음(Hesitation) 분포의 극단적 비대칭성

발화 중 발생하는 1.5 초 미만의 짧은 정지 구간인 '더듬음' 지표를 분석한 결과, 횟수와 시간 모두에서 강한 우편향(Right-skewed) 분포가 관찰되었다. 더듬음 횟수의 경우 중앙값은 3.0 회에 불과하나 평균은 20.3 회로 집계되었으며, 지속 시간 또한 중앙값 1.1 초 대비 평균이 7.1 초로 높게 나타나 두 지표 모두 중앙값과 평균 사이의 격차가 매우 크게 형성되었다. 이러한 비대칭적 분포는 대다수의 화자가 비교적 안정적인 발화 상태를 유지하는 반면, 일부 중증 환자군이나 특정 발화 샘플에서 수치가 비정상적으로 높게 나타나는 구음장애 특유의 불규칙성을 물리적으로 입증한다.




Figure 2. 더듬음 횟수 및 시간(sec) 분포

4.2.2. 의도적 휴지(Intentional Pause)의 완만한 분포 특성

더듬음과 달리 1.5 초 이상의 지속 시간을 갖는 '의도적 휴지' 지표는 상대적으로 완만한 분포 양상을 보였다. 의도적 휴지의 횟수는 중앙값 10.0 회, 평균 13.9 회로 나타났으며, 휴지 시간 역시 중앙값 5.9 초, 평균 8.6 초로 산출되어 더듬음 지표에 비해 중앙값과 평균의 격차가 상대적으로 작았다. 이는 의도적 휴지가 극단적인 수치에 덜 치우쳐 있으며, 발화 과정에서 문장을 구성하거나 호흡을 가다듬는 인지적 준비 시간이 비교적 일정한 범위 내에서 발생하고 있음을 시사한다.




Figure 3. 의도적 휴지 횟수 및 시간(sec) 분포

4.2.3. 지표 분리의 유효성 및 음향적 독립성

1.5 초의 임계값을 기준으로 구분된 두 지표(더듬음 vs 의도적 휴지)는 서로 다른 분포 형태를 나타내어, 발화의 물리적 끊김을 다각도로 분석하려는 본 연구의 접근이 유효함을 확인하였다. 특히 30dB 설정을 통해 미세한 단절까지 포착한 결과물은 텍스트상에 나타나지 않는 화자의 음향적 고충을 독립적으로 반영한다. 이러한 오디오 피처의 통계적 특성은 단순한 소음 제거를 넘어, 향후 LLM 에이전트가 발화의 불확실성을 예측하고 정밀한 보정을 수행하기 위한 핵심적인 메타데이터로 기능하게 된다.

제 3절 멀티모달 피처 간 상관관계 및 타당성 검증

본 절에서는 앞서 산출한 텍스트 기반의 발화 심각도(WSLD Score)와 오디오 기반의 음향학적 비유창성 지표(Hesitation) 간의 관계를 분석하여, 본 연구가 제안하는 멀티모달 데이터 융합의 기술적 타당성을 검증한다. 분석은 심각도 그룹별 피처 비교와 전체 지표 간의 상관분석으로 나누어 진행하였다.

4.3.1. 발화 심각도 그룹에 따른 음향 지표의 단조 증가 경향

텍스트상의 오류 밀도를 기준으로 분류한 4개 그룹(완전 발화, 경증, 중등도, 중증)에 따라 오디오 피쳐인 '더듬음 시간 비율(Hesitation Time / Active Time)'을 비교 분석하였다. 분석 결과, 발화의 심각도가 높아질수록 오디오상의 더듬음 시간 비율이 '0.003(완전 발화)' → '0.009(경증)' → '0.010(중등도)' → '0.019(중증)'로 뚜렷하게 단조 증가하는 양상을 확인하였다.




Figure 4. 발화 심각도 그룹별 더듬음 시간 비율 (Box-plot)

이러한 결과는 텍스트 차원의 비유창성과 오디오 차원의 물리적 단절이 서로 밀접하게 연동되어 있음을 의미하며, 특히 중증 발화로 갈수록 음성 신호 내의 비정상적 휴지 구간이 텍스트 오류의 핵심 원인으로 작용하고 있음을 시사한다.

4.3.2. 멀티모달 피쳐 간 상관관계 및 기술적 시사점

WSLD Score와 오디오 피쳐(더듬음 횟수 및 시간) 간 스피어만 상관계수를 산출한 결과, 더듬음 횟수와 상관은 $r=0.377(p=4.497 \times 10^{-49})$, 더듬음 시간과의 상관은 $r=0.400(p=1.968 \times 10^{-55})$ 으로 나타났으며, 심각도 그룹 간 차이는 Kruskal-Wallis 검정에서 $p=1.068 \times 10^{-130}$ 으로 확인되었다. 이는 중간 수준의 유의미한 양의 상관으로, 두 피쳐가 동일한 현상을 중복 측정하지 않고 각각 독립적인 정보를 포착하고 있음을 시사한다. 만약 두 피쳐 간 상관성이 0.9 이상이었다면 중복 측정의 가능성이 높아 멀티모달 융합의 필요성이 약화되었을 것이나, $r \approx 0.4$ 라는 중간 수준의 독립적 상관성은 텍스트와 오디오 피쳐를 결합하는 Late Fusion 설계의 핵심 타당성 근거가 된다.




Figure 5. WSLD Score와 오디오 피쳐(Hesitation) 간 상관관계 산점도

이러한 독립적 상관성은 본 연구의 멀티모달 파이프라인 설계에 중요한 타당성을 부여한다. 즉, LLM 기반의 에이전트가 교정 작업을 수행할 때, 텍스트 정보만으로는 판별하기 어려운 모호한 구간을 오디오 피쳐라는 독립적인 음향 단서를 통해 보완함으로써 더욱 정밀한 의도 복원이 가능해짐을 데이터로 입증한 것이다. 결과적으로 본 분석은 텍스트 심각도와 음향 지표의 결합이 구음장애 음성 인식 성능 향상을 위한 필수적인 요소임을 확인시켜 준다.

제 4절 LLM 기반 의도 복원 실험 및 실효성 검증 (Pilot Test)

본 절에서는 전체 멀티모달 파이프라인 구축에 앞서, 대형 언어 모델(LLM)이 구음장애 특유의 불완전 발화 텍스트를 얼마나 정교하게 복원할 수 있는지 확인하기 위해 수행한 Pilot Test 결과를 기술한다. 본 실험은 임의로 추출된 고난도 발화 문장 15 개*를 대상으로 우선 실시되었다. 여기서 추출된 고난도 발화 문장 15 개는 Pilot Test로서 ‘기후 전후로 동일 단어/어간 2 회 반복 시’ 5 점, ‘조사가 붙은 채로 끊긴 경우(예: 은+, 는+)’ 3 점, ‘발음이 불분명할 경우(*)’ 2 점, ‘오류 밀도 (특수 기호 수 / 전체 단어 수)*10’라는 임의의 계산을 통해 가장 훼손이 심한 극단적 오류를 추출한 상위 15 개 문장이며, 향후 제 3 장 1 절에서 언급한 WSLD Scoring 기법을 적용하여 고난도 문장을 선별할 예정이다.

4.4.1. Judge-Editor 에이전트 설계 및 규칙 기반 복원 실험

실험에는 Qwen2.5-72B 모델을 활용하였으며, 모델이 문장을 자의적으로 창작하거나 요약하는 환각(Hallucination) 현상을 방지하기 위해 'Judge-Editor' 역할을 부여하였다. 특히 환자가 여러 번 더듬은 경우 마지막 발화만 정답으로 채택하는 'Last-Attempt Wins', 정상 단어 보존, 미완성 문장의 임의 종결 금지라는 3 대 절대 규칙을 프롬프트에 기계적으로 적용하였다.

실험 결과, "양은냄비+ 꺼내+ 양은냄비를+ 꺼내+"와 같이 반복이 심한 문장이 "양은냄비를 꺼내"로 교정되는 등 텍스트 내의 조음 오류 기호를 효과적으로 제거하며 화자의 본래 의도를 성공적으로 복원하였다. 다만, 일부 결과에서 원문에 없는 표현이 추가되거나 기존 정보가 삭제되는 문제가 여전히 관찰되어, 단순 규칙 기반 복원 이상의 정교한 제어가 필요함을 확인하였다. 주요 오류 패턴을 크게 두 가지로 분류되었다. 첫째, 미완성 문장에서 모델이 문장을 완성하려는 시도로 원문에 없는 술어나 목적어를 생성하는 창작 오류이다. 둘째, 어절 단위 정보가 통째로 누락되는 삭제 오류이다. 이 두 유형의 오류는 각각 No Creation, No Deletion 원칙의 강화와 오디오 피쳐 기반 신뢰도 가중치 주입을 통해 완화할 수 있을 것으로 판단되며, 이는 향후 Late Fusion 구현의 핵심 동기가 된다.

4.4.2. BERTScore 기반의 정량적 실효성 수치화

복원 성능을 객관적으로 측정하기 위해 정답 대본(Gold Standard)과 복원 결과 간의 BERTScore(F1)를 산출하여 비교 분석하였다. BERTScore 산출에는 bert-base-multilingual-cased 모델(L9, no-idf)을 사용하였으며, 이는 104 개 언어를 지원하는 다국어 BERT 모델로 한국어를 포함한다.

Complexity_Score	Raw_Sentence	Gold_Standard	Judge_Output	Baseline_BERTScore	Judge_BERTScore	Score_Improvement
32.83	큰+ 빗을+ 저서	큰 빗을 저서 맞	큰 빗을 저서 맞	0.756	1.000	0.244
28.55	양은냄비+ 꺼내	양은냄비를 꺼내	양은냄비를 꺼내	0.807	1.000	0.193
27.48	진료+ 과정은+	진료 과정은 다름	진료 과정은 다	0.773	1.000	0.227
26	상대가+ 싫어하	상대가 싫어하는	상대가 싫어하는	0.844	1.000	0.156
24.67	큰 빗을+ 빗을	큰 빗을 저서 맞	큰 빗을 저서 맞	0.869	1.000	0.131
24.33	으름장을 높여	으름장을 높여	으름장을 높여	0.745	0.856	0.111
24	서른여덟의+ 여	서른여덟의 김유	서른여덟의 김유	0.836	1.000	0.164
23.38	환자에서 환이	환자에서 환이 아	환자는 아프니까	0.887	0.903	0.015
23.29	당신의+ 전화	당신의 전화가 지	당신의 전화가	0.819	0.995	0.176
22.85	외상존은+ 금융	외상존은 금융업	외상존은 금융업	0.820	0.971	0.150
22.53	아이 옷을+ 벗	아이 옷을 벗기고	아이 옷을 벗기	0.844	1.000	0.156
22	버스에+ 사람이	버스에 사람이 많	버스에 사람이	0.772	1.000	0.228
22	카메라와+ 쿠키	카메라와 쿠키를	카메라와 쿠키를	0.768	0.969	0.201
21.86	의사의 촉각금	의사는 촉의금과	의사는 촉의금과	0.806	1.000	0.194
21	음운론을 가르	음운론을 가르치	음운론을	0.863	0.934	0.071

Table 2. 문장 개선 정도 (pilot)

본 파일럿 테스트에서 Gold Standard는 데이터 제공 업체로부터 원본 대본을 확보하지 못하여 연구자가 원천 음성을 직접 청취하여 전사한 전사문을 사용하였다. 단일 전사자의 의한 전사이므로 전사자 간 신뢰도 검증이 수행되지 않았으며, 본 학기 내 원본 대본 확보 시 재평가를 수행하여 수치를 확정할 예정이다. 총 15 개의 고난도 문장을 대상으로 한 파일럿 테스트 결과, 사후 교정을 거치지 않은 ASR 전사 원본(Baseline)의 BERTScore는 0.8140으로 측정되었다. 반면, 제안하는 Qwen2.5-72B 기반의 Judge-Editor 에이전트를 거쳐 교정된 결과의 점수는 0.9752로 비약적으로 상승하였다. 결과적으로 사후 교정을 거치지 않은 원본 대비 약 16.1%의 의미 복원 성능 향상이 확인되었다. 이는 LLM을 활용한 사후 교정 방식이 단순한 오타 수정을 넘어, 구음장애 음성인식 시스템의 실용성과 본래 의도 전달력을 획기적으로 높일 수 있음을 실증적으로 시사한다.

제 5장 결론

제 1절 중간 연구 성과 및 의의

본 연구는 구음장애인의 비유창성을 단순 잡음으로 취급하여 배제하던 기존의 방식에서 벗어나, 이를 데이터적 자산으로 활용하여 화자의 본래 의도를 복원하는 멀티모달 파이프라인의 실효성을 입증하였다. 연구의 중간 성과로서 AI Hub의 구음장애 음성 데이터 7,874 건 중 학습 데이터로서 6,104 건(수율 91.5%)의 유효 발화셋을 확보하고, 이에 대한 전수 분석을 통해 텍스트와 음향 지표 간의 유기적 관계를 규명하였다. 특히 본 연구가 제안한 WSLD Score 기반의 발화 심각도가 높아질수록 오디오상의 더듬음 시간 비율이 0.003에서 0.019로 단조 증가한다는 사실을 밝혀냄으로써, 음향적 비유창성 지표가 텍스트 오류의 심각도를 독립적으로 포착할 수 있다는 기술적 타당성을 확보하였다.

나아가 고난도 불완전 발화 15건을 대상으로 수행한 Pilot Test 결과, 사후 교정을 거치지 않은 원본(Baseline)의 BERTScore는 0.8140이었으나, Qwen2.5-72B 기반의 Judge-Editor 에이전트를 적용한 결과 0.9752로 상승하여 약 16.1%의 의미 복원 성능 향상을 달성하였다. 이는 LLM을 활용한 사후 교정 아키텍처가 구음장애 음성인식 시스템의 실용성을 비약적으로 높일 수 있음을 시사하며, 단순한 자구 수정을 넘어 화자의 발화 맥락을 이해하고 복원하는 ‘의도 중심’ 인식 시스템으로의 패러다임 전환 가능성을 확인했다는 점에서 큰 의의가 있다.

제 2절 향후 연구 계획

본 연구는 중간 결과에서 확인된 성과를 바탕으로, 시스템의 정밀도와 안전성을 극대화하기 위해 다음과 같은 고도화 작업을 수행할 예정이다.

첫째, **멀티모달 Late Fusion 아키텍처의 완성**이다. 앞선 파일럿 테스트는 본 연구에서 고안한 WSLD Score 시스템을 본격적으로 도입하기 전, 임의로 선정된 15개의 고난도 발화만을 대상으로 수행되었다. 이로 인해 음성 인식 결과(Hypothesis) 자체가 완전히 훼손되어 텍스트 정보가 극도로 부족한 경우, 모델이 정답을 도출하는 데 물리적 한계가 존재함을 확인하였다. 이를 극복하기 위해 향후 연구에서는 본 연구에서 도출한 WSLD Score 시스템을 전수 적용하여 분석 대상이 되는 고난도 발화의 표본을 대폭 확대하고, 오디오 분석을 통해 정밀하게 추출된 더듬음 및 휴지 시간 정보를 LLM의 어텐션 메커니즘에 신뢰도 가중치로 직접 주입하는 Late Fusion 로직을 구현할 것이다. 이러한

접근은 모델이 언어적 문맥과 음향학적 단절 정보를 동시에 판단하게 함으로써, 인식이 뭉개진 최종증 발화 구간에서도 의도 복원의 정확도를 획기적으로 향상시킬 것으로 기대된다.

둘째, **의미 거리 기반의 Safety Trigger(Reject 로직) 구현**이다. 의료 및 돌봄 환경에서 사용되는 시스템의 특성상 AI가 자의적으로 문장을 생성하는 환각 현상은 치명적인 위협이 된다. 따라서 LLM의 최종 교정 결과와 원본 가설 간의 의미론적 거리를 계산하여, 신뢰도가 임계값 이하일 경우 무리하게 결과를 출력하는 대신 사용자에게 재질의를 요청하는 안전 장치를 설계하여 시스템의 신뢰성을 확보할 예정이다.

셋째, **검증 데이터셋(Validation Set) 분석 및 범용성 평가**이다. 현재까지 학습 데이터(6,104 건)에 대해 구축된 피쳐 추출 알고리즘을 아직 분석되지 않은 1,207 건의 검증 데이터셋에 동일하게 적용하여 모델의 강건함(Robustness)을 테스트할 예정이다. 이를 통해 특정 환자나 질환군에 편향되지 않은 보편적인 구음장애 의사소통 지원 시스템으로서의 완성도를 높여 나갈 것이다.

참고문헌

- 질병관리청. (2025). *2022년 심뇌혈관질환 발생통계 주요 결과*. 질병관리청.
- 보건복지부 중앙암등록본부. (2026). *2023년 국가암등록통계*. 국가암지식정보센터.
https://www.cancer.go.kr/lay1/program/S1T211C223/cancer/view.do?cancer_seq=5333&menu_seq=5338 (접속일: 2026.04.06.)
- ASHA. (2021). *Dysarthria in adults*. American Speech-Language-Hearing Association.
- Marini, M., Vanello, N., & Fanucci, L. (2021). Optimising speaker-dependent feature extraction parameters to improve automatic speech recognition performance for people with dysarthria. *Sensors*, 21(19), 6460. <https://doi.org/10.3390/s21196460>
- Wang, H., Jin, Z., Geng, M., Hu, S., Li, G., Wang, T., Xu, H., & Liu, X. (2024). Enhancing pre-trained ASR system fine-tuning for dysarthric speech recognition using adversarial data augmentation. *arXiv preprint arXiv:2401.00662*.
- Xiao, Q., et al. (2025). Cross-learning fine-tuning strategy for dysarthric speech recognition via CDSDB database. *arXiv preprint arXiv:2508.18732*.
- Aboeitta, A., Sharshar, A., Nafea, Y., & Shehata, S. (2025). Bridging ASR and LLMs for dysarthric speech recognition: Benchmarking self-supervised and generative approaches. *Interspeech 2025*, 2123-2127.
<https://doi.org/10.21437/Interspeech.2025-1994>
- Hall, K. D., Amir, O., & Yairi, E. (1999). A longitudinal investigation of speaking rate in preschool children who stutter. *Journal of Speech, Language, and Hearing Research*, 42(6), 1367-1377. <https://doi.org/10.1044/jslhr.4206.1367>
- Ambrose, N. G., & Yairi, E. (1999). Normative disfluency data for early childhood stuttering. *Journal of Speech, Language, and Hearing Research*, 42(4), 895-909.
<https://doi.org/10.1044/jslhr.4204.895>
- Ma, Z., Zhao, Z., Hua, C., Berto, F., & Park, J. (2026). JudgeFlow: Agentic workflow optimization via block judge. *arXiv preprint arXiv:2601.07477*.
- Zheng, X., Dong, S., Phukon, B., Hasegawa-Johnson, M., & Yoo, C. D. (2026). Towards robust dysarthric speech recognition: LLM-agent post-ASR correction beyond WER. *arXiv preprint arXiv:2601.21347*.