

구음장애 발화의 의도 복원을 위한 멀티모달 음성인식 파이프라인 연구

WSLD 기반 발화 심각도 정량화 · LLM Judge-Editor Post-ASR Correction

BERTScore +3.84%

0.9402 → 0.9763

Gold Standard

9,832건 자동 구축

Kruskal-Wallis

$H=491.3$ $p=2.1 \times 10^{-107}$

배경 연구 배경 및 접근 방식

문제 — 현행 ASR의 구조적 한계

- 구음장애 (뇌졸중·파킨슨·후두질환) 비유창성
= 반복·막힘·조음파열
- Whisper·Conformer 등 상용 ASR: 정상 화자 분포에 과적합
- 음향 모델 재학습 → 화자별 반복 fine-tuning 필요
→ 임상 확장성 低
- 한국어 구음장애 평가 자산 부재

접근 — Post-ASR Correction

- 음향 모델 재학습 없이 LLM 추론 단계에서 의도 복원
- 비유창성을 잡음이 아닌 복원 가능한 신호로 재정의
- 텍스트(WSLD) + 오디오(Hesitation) 멀티모달 융합
- 교차 화자 앵커 매칭으로 Gold Standard 자동 구축

연구 목표 4단계

01 피처 추출·정량화

02 통계적 타당성 검증

03 Gold Standard 구축

04 LLM Judge-Editor 실증

피처 추출 → 통계 검증 → 벤치마크 구축 → 복원 실증

데이터셋 개요 및 피쳐 설계

6,104건

분석 대상

7,874건 원본 → 필터링

3그룹

질환 그룹

TS01·TS02·TS03

19,882개

고유 문장 수

중복률 95.4% - Gold Standard 기반

16kHz

오디오 처리

30dB 임계값 Librosa

텍스트 피쳐 — WSLD Score

Ambrose & Yairi (1999) 재설계 · 한국어 전사 기호 매핑

$$\text{WSLD} = [(\text{PW} + \text{SS}) \times \text{RU_avg}] + (2 \times \text{DP}) + \epsilon$$

+	반복 더듬음	×1.5
*	발음 불분명	×2.0
/	음절 탈락	×0.5

Imperfect Rate: Clean(0%) · Mild(≤2%) · Severe(>2%)

오디오 피쳐 — Hesitation_per_word

$H_w = \Sigma T_hes / N_word$ (< 1.5초 = 더듬음 / ≥ 1.5초 = 휴지)

발화 길이 교란 제거를 위한 어절 단위 정규화

그룹	평균 H_w	증강값	증감
Clean (0%)	0.0528	0.0255	baseline
Mild (≤2%)	0.0789	0.0537	↑ +49%
Severe (>2%)	0.1277	0.0941	↑ +142%

→ 심각도 증가에 따라 단조 증가 — 오디오가 독립적 심각도 정보를 운반

Gold Standard 구축 — 교차 화자 앵커 매칭

핵심 원리: 전체 447,730건 중 고유 문장 19,882개 — 중복률 95.4%

동일 낭독 대본을 다수 화자가 반복 발화 → 불완전 발화의 정답이 '다른 화자의 깨끗한 버전'에 존재


4단계 캐스케이드 매칭

T1 Exact	sim $\geq$ 0.90	8,156건		82.7%
T2 Partial	0.80~0.90	1,178건		11.9%
T3 Fuzzy	0.70~0.80	296건		3%
T0 Human	< 0.70 직접 청취	202건		2%
T_noise	노이즈 제외	20건		0.2%

최종 Gold Standard: 9,832건 (99.7%) 자동화

자동 커버리지 97.6% (T1+T2+T3) · 수동 의존 2.0% · 노이즈 0.2%

LLM Judge-Editor 파이프라인



JUDGE — 불확실 구간 탐지

- N-best 가설 간 span 단위 일관성 비교
- 합의 高 구간 → 원형 보존
- 충돌 구간 → UNCERTAIN 표시
- 전사기호(+.*./)를 신뢰도 신호로 재정의

EDITOR — 국소 재작성 + 3대 규칙

- UNCERTAIN 구간만 재작성 (문맥 + Soft Fusion 오디오)
- R1 Last-Attempt Wins — 마지막 시도어만 채택
- R2 No Deletion — 정상 단어 삭제 금지
- R3 No Creation — 미완성 문장 임의 완성 금지

Soft Fusion: 오디오 피쳐 → 자연어 메타데이터 → LLM 프롬프트 주입 (폐쇄형 API 환경 최적화)

통계 검증 — 텍스트와 오디오는 독립적이지만 상관된 신호

Test 1 · Kruskal–Wallis H-test

3그룹(Clean/Mild/Severe) 간 H_w 분포 차이

H 통계량 **491.255**

p-value **2.11×10^{-107}**

Test 2 · Spearman ρ (WSLD $\leftrightarrow$ 오디오)

텍스트 WSLD와 오디오 피처의 단조 관계 — $\rho \approx 0.4$

더듬음 횟수 **$r = 0.377$** $p = 4.50 \times 10^{-49}$

더듬음 시간 **$r = 0.400$** $p = 1.97 \times 10^{-55}$

Test 3 · rank-biserial 효과크기 — 심각도 분류의 임상 변별력

Clean vs. Mild  **$r = 0.338$ (중간 효과)**

Mild vs. Severe  **$r = 0.254$ (작은 효과)**

Clean vs. Severe  **$r = 0.522$ (큰 효과 ★)**

→ $\rho \approx 0.4$: 두 모달이 부분적으로만 겹침 = 보완 신호 확인 → Soft Fusion 타당성 핵심 근거

BERTScore A/B Ablation 결과 (n=9,832)

C0 · Baseline

0.9402

faster-whisper 1-best
교정 없음

C1 · LLM Rule ★

0.9763

Judge-Editor + 3 invariants
텍스트 채널 단독

▲ +3.84% vs. C0

C2 · LLM Multimodal

0.9755

C1 + 오디오 Soft Fusion

▲ +3.75% ▼ -0.08% vs. C1

H1 ✓ LLM 사후 교정의 유효성 입증

- Judge-Editor 텍스트 규칙만으로 +3.84%p 향상
- 음향 모델 재학습 없이 BERTScore 개선 달성
- 교정 예시: '양은냄비+ 꺼내+ 양은냄비를+ 꺼내+'
→ '양은냄비를 꺼내'

H2 ✗ Soft Fusion의 한계 노출

- 오디오 주입 시 c1 대비 -0.08%p 미세 하락
 - 자연어 메타 변환 과정에서 음향 시그니처 소실
 - 폐쇄형 API 환경의 구조적 제약
- frame-level acoustic embedding 결합 필요

결과 ③ Tier별 분석 및 한계

Table 6. Tier별 BERTScore — 오디오 기여의 조건부 효용

Tier	Baseline	Rule	Multimodal	오디오 기여
T0_human (직접청취)	0.8755	0.9540	0.9565	+0.0025 ✓
T1_exact (≥ 0.90)	0.9503	0.9818	0.9809	-0.0009
T2_partial (0.80~0.90)	0.9007	0.9549	0.9541	-0.0008
T3_fuzzy (0.70~0.80)	0.8630	0.9263	0.9247	-0.0016

→ 오디오 기여는 텍스트 손상 정도에 따라 조건부 발현.
T0_human(가장 심각한 구간)에서만 +0.0025 개선 — 음향 단서가 텍스트 규칙을 보완.

방법론적 한계

L1 · Soft Fusion 정보 손실

프레임 단위 음향 시그니처 소실 → hard fusion 필요

L2 · 단일 전사자·IRR 미측정

T0 계층 inter-annotator agreement(κ) 검증 부재

L3 · Safety Trigger 미구현

hallucination 구조적 차단 장치 (Reject 로직) 부재

L4 · 표본 편향·외적 타당도

TS03 73% 편중 · Validation Set 평가 미수행

결론 연구 기여 및 향후 과제

01 패러다임 전환

비유창성을 신호로 재정의.
한국어 WSLD 정량 척도 구체화.

02 벤치마크 공개

Gold Standard 9,832건
· WSLD Score 및 H_w 지표
→ 한국어 구음장애 ASR 평가 기준 후보

03 성능 실증

BERTScore +3.84%p
음향 재학습 없이 의사소통 보조 가능성

향후 과제 ROADMAP

F1 · Frame-level 음향 임베딩

Soft Fusion 한계 극복 · hard fusion 채널

F2 · Safety Trigger 도입

불확실성 임계 초과 시 Reject 로직 설계

F3 · Cross-corpus 검증

AI Hub 外 코퍼스 · 질환군 균형 표본

F4 · 임상 보조 시스템화

재활·언어치료 현장 실시간 의사소통 보조

비유창성은 잡음이 아니라 신호다 — 정량화 가능하고, 복원 가능하다