

DAT 7기 캡스톤 최종발표 보고서

구음장애 발화의 의도 복원을 위한
멀티모달 음성인식 파이프라인 연구

: WSLD 기반 발화 심각도 정량화, LLM Judge-Editor 실험을 중심으로

DAT 7기

멀티센스(Multi-Sense)

이제학

허다교

정주희

DAT 7기 캡스톤 최종발표 보고서

구음장애 발화의 의도 복원을 위한
멀티모달 음성인식 파이프라인 연구

: WSLD 기반 발화 심각도 정량화, LLM Judge-Editor 실험을 중심으로

Multimodal Pipeline for Dysarthric Speech Recognition -
WSLD Severity Quantification and LLM Judge-Editor Agent Experiment
이 보고서를 캡스톤 최종발표 보고서로 제출합니다.

2026년 06월 01일

DAT 7기

멀티센스(Multi-Sense)

이제학

허다교

정주희

DAT 7기 캡스톤 최종발표 보고서

구음장애 발화의 의도 복원을 위한 멀티모달 음성인식 파이프라인 연구

: WSLD 기반 발화 심각도 정량화, LLM Judge-Editor 실험을 중심으로

Multimodal Pipeline for Dysarthric Speech Recognition - WSLD Severity Quantification and LLM Judge-Editor Agent Experiment

국문 요약

구음장애는 신경계 질환, 언어청각장애, 후두장애 등으로 발화 기관의 운동 기능이 저하되어 일상적 의사소통을 심각하게 제한하는 복합 증후군이다. 현행 음성인식(ASR) 시스템은 비장애인 화자 중심으로 학습되어 구음장애 발화에 내재된 조음 오류와 비유창성에 취약하다는 구조적 한계를 지닌다. 본 연구는 AI Hub 구음장애 음성인식 데이터 6,104건을 대상으로 두가지 접근을 병행하였다. 첫째, 전사 데이터의 특수기호를 재설계한 WSLD 공식 구조로 발화 심각도를 정량화하고, 둘째, Librosa 기반 텍스트-오디오 간 멀티모달 독립성을 통계적으로 검증하였다. 분류 결과, Kruskal-Wallis $H=491.255$, 효과크기 $r=0.34\sim0.52$ 로 유의한 단조 증가가 확인되었다. 이와 병행하여 데이터셋 전체(447,730건)의 교차 화자 낭독 구조를 활용한 파이프라인으로 Gold Standard 9,832건을 구축하였으며, LLM 사후 교정을 통해 BERTScore(F1)가 0.9402에서 0.9763으로 약 3.84% 향상되었다($n=9,832$).

Abstract

Dysarthria impairs speech-motor function, and ASR systems trained on non-disordered speech handle it poorly. We quantified utterance severity via a redesigned WSLD score and verified its link to acoustic dysfluency (Kruskal-Wallis $H=491.255$, $r=0.34\sim0.52$). On a 9,832-sentence cross-speaker Gold Standard, an LLM Judge-Editor raised BERTScore from 0.9402 to 0.9763 (+3.84%).

DAT 7기

멀티센스(Multi-Sense)

이제학

허다교

정주희

목차

제 1장 서론.....	- 1 -
제 1절 연구 배경 및 필요성	- 1 -
제 2절 연구 목적 및 제안 모델 개요	- 2 -
제 3절 연구 대상 및 범위.....	- 3 -
제 2장 데이터 소개	- 4 -
제 1절 선행연구 분석.....	- 4 -
제 2절 분석 데이터셋 구성 및 특성.....	- 5 -
제 3절 용어의 정의 및 개념적 틀.....	- 6 -
제 3장 분석 방법	- 8 -
제 1절 멀티모달 피처 추출 및 심각도 정량화 분석	- 8 -
제 2절 Gold Standard 구축 - 교차 화자 앵커 매칭 파이프라인	- 9 -
제 3절 LLM 에이전트 기반 의도 복원 및 실효성 평가	- 10 -
제 4장 분석 결과	- 11 -
제 1절 발화 심각도 기반 텍스트 피처 분석.....	- 11 -
4.1.1. 유효 발화 필터링 및 데이터 정제 결과	- 12 -
4.1.2. WSLD Score 기술 통계 및 분포 특성.....	- 12 -
4.1.3. 발화 심각도 그룹화 및 오류 패턴 분석	- 13 -
제 2절 오디오 피처(음향학적 비유창성 지표) 통계 특성.....	- 14 -
4.2.1. 더듬음(Hesitation) 분포의 극단적 비대칭성.....	- 14 -
4.2.2. 의도적 휴지(Intentional Pause)의 완만한 분포 특성	- 15 -
4.2.3. 지표 분리의 유효성 및 음향적 독립성.....	- 15 -
4.2.4. Hesitation_per_word 정규화 결과	- 15 -
제 3절 멀티모달 피처 간 상관관계 및 타당성 검증	- 16 -

4.3.1. 발화 심각도 그룹에 따른 음향 지표의 단조 증가 경향.....	- 16 -
4.3.2. 멀티모달 피처 간 상관관계 및 기술적 시사점	- 17 -
제 4절 LLM 기반 의도 복원 실험 및 실효성 검증	- 17 -
제 5장 결론.....	- 19 -
제 1절 연구 성과 및 의의.....	- 19 -
제 2절 정책적 제언 및 시사점	- 20 -
제 3절 한계 및 향후 연구 방향.....	- 21 -
참고문헌.....	- 22 -

Figure 목차

Figure 1. Project Pipeline -----	2
Figure 2. 발화 심각도 그룹 분포 (훈련 데이터, N=6,667) 및 전사 기호 유형별 발생 분포 -----	4
Figure 3. Gold Standard 구축 파이프라인 결과 - Tier별 구성 및 자동화율 -----	8
Figure 4. Judge-Editor 에이전트 BERTScore 성능 검증 및 A/B Ablation 실험 설계 개 요-----	9
Figure 5. Whisper N-best 가설 다양성 분석 - 후보 수 분포 및 후보 간 평균 텍스트 유 사도 (N=27) -----	10
Figure 6. WSLD Score 분포 및 심각도 그룹 간 비교 (불완전 발화 n=1,458) -----	11
Figure 7. Whisper 실험 대상 데이터(N=81) 심각도별 WSLD Score 및 Imperfect Rate 상관관계 -----	11
Figure 8. 더듬음 횟수 및 시간(sec) 분포 -----	12
Figure 9. 의도적 휴지 횟수 및 시간(sec) 분포 -----	13
Figure 10. 발화 심각도 그룹별 Hesitation_per_word 분포 (Kruskal-Wallis H=491.255,	

p= 2.11×10^{-107}) -----	14
Figure 11. WSLD Score와 오디오 피쳐(Hesitation) 간 상관관계 산점도 -----	14
Figure 12. A/B Ablation: LLM 사후 교정의 BERTScore -----	16

표 목차

Table 1. Gold Standard 구축 현황 (gold_final.csv) -----	8
Table 2. WSLD Score 기술통계량 -----	10
Table 3. 더듬음 횟수 및 시간(sec) 분포 -----	12
Table 4. 그룹별 Hesitation_per_word 기술통계 (Imperfect Rate 2% 기준) -----	13
Table 5. A/B Ablation BERTScore 결과 (n=9,832) -----	15
Table 6. 오디오 메타데이터 분석 중 Tier별 분석 -----	16

제 1장 서론

제 1절 연구 배경 및 필요성

뇌졸중·파킨슨병 등 신경계 질환, 후두 절제술을 포함한 두경부 질환, 청각 및 언어 처리 장애 등 다양한 원인에 의해 발생하는 구음장애는 발화 기관의 운동 기능 저하를 유발하여 환자의 일상적 의사소통 능력을 심각하게 제한한다. 국내에서는 2022 년 한 해만 11 만여 건의 뇌졸중이 새로 발생하였으며(질병관리청, 2025), 급성기 뇌졸중 환자의 22~58%에서 구음장애가 동반되는 것으로 보고된다(ASHA, 2021). 두경부 악성 종양 역시 국내에서 연간 1,254 건의 후두암이 새로 발생하는 등(보건복지부 중앙암등록본부, 2026) 그 규모가 적지 않으며, 후두 절제술 이후 발성 기능의 상실은 환자의 사회적 고립과 삶의 질 저하로 이어진다.


자동 음성인식(Automatic Speech Recognition, 이하 ASR) 기술의 급격한 발전은 이러한 구음장애 환자의 의사소통 보조 수단으로서 높은 잠재력을 지닌다. 그러나 현재 상용화된 ASR 시스템의 대부분은 정상 화자의 발화 패턴을 기반으로 학습되어 있어 구음장애 특유의 조음 오류와 비유창성에 취약하다는 근본적인 한계를 지닌다(Marini et al., 2021).

이러한 문제를 해결하기 위한 선행 연구들은 주로 구음장애 화자 데이터를 활용한 음향 모델의 미세조정, 또는 적대적 생성 신경망(GAN)을 활용한 데이터 증강 방식에 집중해왔다 (Shahamiri et al., 2023; Liu et al., 2024). 그러나, 음향 모델 단독의 접근은 발화자의 조음 특성에 따라 과적합되기 쉽고, 신규 화자가 유입될 때마다 재학습이 필요하다는 확장성의 한계가 있다(Qing et al., 2025). 또한, 대본 낭독 환경에서 수집된 데이터와 실제 자유 발화 환경 사이의 난이도 격차를 음향 모델만으로 극복하는 것은 구조적으로 어렵다. 최근에는 대형 언어 모델(LLM)의 강력한 문맥 추론 능력을 ASR 과 결합, 인식 오류를 사후 교정하려는 시도가 등장하고 있으나(Aboeitta et al., 2025) 구음장애 발화의 특수성을 고려한 체계적인 설계는 아직 초기 단계에 머물러 있다.

본 연구는 위와 같은 한계를 극복하기 위해 ASR 음향 인식 결과, 오디오 피쳐 기반 발화 심각도 정보, LLM 문맥 추론을 결합한 멀티모달 파이프라인을 설계하고 그 타당성을 검증한다.

제 2절 연구 목적 및 제안 모델 개요

본 연구는 기존 ASR 모델들이 구음장애 음성에서 보이는 인식의 한계를 극복하기 위해, 불완전하게 인식된 텍스트 결과를 사후에 교정하여 화자의 본래 의도를 복원하는 'LLM 기반 멀티모달 사후 교정(Post-ASR Correction) 파이프라인' 구축을 최종 목적으로 한다. 이를 위해 본 연구는 다음 네 가지 연구 목표를 설정한다. 첫째, 훈련 데이터 전수 분석을 통한 오디오 및 텍스트 피처 추출과 정량화이다. 둘째, 두 피처 간 상관성 및 독립성의 통계적 검증이다. 셋째, 교차 화자 앵커 매칭을 통한 신뢰도 높은 Gold Standard 구축이다. 넷째, LLM Judge-Editor 에이전트의 의도 복원 가능성 실증이다.



-Figure 1. Project Pipeline

본 연구의 제안 모델은 별도의 음향 모델(ASR)을 직접 구축하거나 및 미세조정하는 대신에, 기존 ASR 인식 결과의 텍스트 오류 패턴과 원천 오디오의 비유창성(Dysfluency) 신호를 결합하여 LLM 이 이를 정교하게 교정하는 Judge-Editor 에이전트 아키텍처를 채택한다([그림 1] 참조). 에이전트는 오류 식별자인 Judge와 문맥 복원자인 Editor로 역할이 분리된다. Judge(판단자)는 faster-whisper의 beam_size=5로 생성된 N-best 가설들 간 일관성을 span 단위로 분석하여, 가설 간 합의가 높은 구간은 신뢰도가 높은 것으로 판단해 원형을 보존하고, 충돌이 발생하는 불확실 구간만을 선별적으로 표시한다. 전사 기호(+: 반복 더듬음, *: 발음 불분명, /: 음절 탈락)는 span 신뢰도 신호로 재정의된다. Editor(편집자)는 Judge가 표시한 구간에 대해 주변 문맥과 오디오 피쳐 정보를 활용해 최적의 의미로 재작성을 수행한다.

오디오 피쳐는 LLM 프롬프트에 메타데이터 형태로 주입되는 Soft Fusion 방식을 채택한다. Soft Fusion은 더듬음 횟수·시간 및 의도적 휴지 정보를 자연어로 변환하여 프롬프트에 포함시키는 방식으로, 모델 파라미터 수정 없이 음향 메타데이터를 유연하게 주입할 수 있다는 실용적 이점을 지닌다. 어텐션 가중치 직접 주입(Late Fusion) 방식은 폐쇄형 API 환경에서 구현이 제한되는 데 반해, Soft Fusion은 표준 API를 통해 동일한 오디오 컨텍스트를 전달하면서도 모델이 음향적 불확실 구간을 인지하고 해당 구간의 교정에 집중하도록 유도할 수 있다.

아울러 LLM의 자의적 문장 생성을 방지하기 위해 세 가지 교정 원칙을 엄격히 적용한다. 첫째, Last-Attempt Wins 원칙은 화자가 더듬으며 반복 시도한 단어 중 가장 마지막에 발화한 것만을 정답으로 채택하는 방식이다. 둘째, No Deletion 원칙은 특수기호가 붙어 있지 않고 정상적으로 인식된 단어는 한 글자도 삭제하지 않도록 제한한다. 셋째, No Creation 원칙은 미완성된 문장 뒤에 임의의 내용을 지어내어 문장을 완성하는 행위를 금지한다. 이 세 원칙을 통해 LLM이 화자의 실제 발화 범위를 벗어난 내용을 생성하지 않도록 제한함으로써 의도 복원의 신뢰성을 확보한다.

제 3절 연구 대상 및 범위

본 연구의 분석 대상은 AI Hub에서 제공하는 '구음장애 음성인식 데이터'이다. 해당 데이터셋은 실제 임상 현장에서 수집된 7,874 건의 데이터로 구성되어 있으며, 연구의 객관성과 안정성을 확보하기 위해 훈련용 6,667 건과 검증용 1,207 건으로 구분하여 사용하였다. 특히 화자의 질환별 발화 특성을 고르게 반영하기 위해 '뇌신경장애(TS01) 425 건/62557 분', '언어청각장애(TS02) 1,228 건/91192 분', '후두장애(TS03) 4,472 건/146718 분'으로 대상을 구체화하였으며, 정밀 필터링을 통해 최종적으로 6,104 건의 유효 발화 데이터를 연구 범위로 설정하였다.

연구의 기술적 범위는 ASR 인식 이후의 의도 복원 및 이를 위한 멀티모달 피처의 타당성 검증에 한정된다. 세부적인 범위는 다음과 같다.

첫째, 오디오 피처 추출 및 규격화 단계에서는 Librosa 라이브러리를 활용하여 16,000Hz로 로드된 원천 음성 신호에서 진폭 임계값 30dB로 침묵 구간을 분리하고, 1.5초 기준으로 더듬음과 의도적 휴지를 구분한다. 추출된 raw Hesitation_Time은 발화 길이에 의한 교란을 제거하기 위해 어절 수로 정규화한 Hesitation_per_word 지표로 변환하여 사용한다.

둘째, 텍스트 심각도 검증 및 상관성 분석 범위로서 전사 데이터 내 특수기호를 기반으로 Ambrose & Yairi(1999)의 WSLD 공식 구조를 재설계하여 발화 심각도(WSLD Score)를 산출하고, Hesitation_per_word와의 독립적 상관성을 검증한다.

셋째, Gold Standard 구축 범위로서 데이터셋 내 교차 화자 낭독 구조를 활용한 앵커 매칭 파이프라인을 설계하여 9,832 건의 평가용 Gold Standard를 확보한다.

넷째, 의도 복원 성능 평가 범위로서 Qwen2.5-72B 기반 Judge-Editor 에이전트의 교정 결과에 대해 BERTScore(F1) 및 WER을 측정하고 A/B Ablation을 통해 오디오 기여분을 정량화한다.

이를 통해 제안하는 사후 교정 파이프라인이 구음장애 음성 인식 시스템의 실효성을 얼마나 향상시켰는지 실증적으로 입증하는 것을 최종 연구 범위로 규정한다.

제 2장 데이터 소개

제 1절 선행연구 분석

구음장애 음성인식 분야의 선행연구는 크게 음향 모델 개선, 평가 지표 한계 인식, LLM 기반 사후 교정의 세 흐름으로 구분할 수 있다.

첫 번째 흐름은 음향 모델의 미세조정 및 데이터 증강을 중심으로 한 접근이다. 구음장애 화자 데이터를 활용한 Wav2Vec22, HuBERT, Whisper 등 자기지도 학습 기반 모델의 미세조정 연구가 활발히 진행되어 왔으며, 데이터 희소성 문제 극복을 위해 GAN 기반 데이터 증강 기법도 도입되었다(Liu et al., 2024). 그러나 이러한 접근은 특정 화자의 조음 패턴에 과적합되기 쉬우며 신규 화자 유입 시 재학습이 필요하다는 확장성의 한계를 내포하며, 대규모 데이터 없이는 일반화 성능이 제한적이라는 구조적 문제가 지적되어 왔다(Shahamiri et al., 2023).

두 번째 흐름은 기존 평가 지표의 한계에 대한 문제 제기이다. 단어 오류율(WER)은 구음장애 음성인식 시스템의 실질적 효용성을 온전히 반영하지 못한다는 비판이 제기되어 왔다. 구음장애 발화에서는 음소 왜곡이나 반복이 발생하더라도 화자의 의도가 명확히 전달되는 경우가 많아, WER 이 높더라도 의사소통 성공률은 높을 수 있기 때문이다. 이에 따라 BERTScore, 자연어 추론(NLI) 기반 의미 스코어, Slot Filling 성공률 등을 결합한 다면적 평가 프레임워크의 필요성이 강조되고 있다(Zheng et al., 2026).

세 번째 흐름은 LLM 을 활용한 사후 교정(Post-ASR Correction) 연구로, 본 연구와 가장 직접적으로 연관된다. Zheng et al.(2026)은 구음장애 음성인식을 위한 LLM 기반 Judge-Editor 에이전트를 제안하여, ASR 의 상위 k 개 가설 중 신뢰도가 높은 구간은 보존하고 불확실한 구간만 선택적으로 재작성하는 방식으로 WER 을 14.51% 감소시키는 동시에 의미 보존 성능을 크게 향상시켰다. 또한 엔트로피 기반 신뢰도 점수를 LLM 프롬프트에 주입하여 불확실 구간을 선택적으로 교정하는 신뢰도 가이드 프레임워크가 제안되었으며, 이는 단순 LLM 교정 대비 WER 을 10% 추가 감소시키는 효과를 보였다. 아울러 Whisper 와 LLM 을 결합한 디코딩 방식이 언어적 제약을 활용하여 음소 복원과 문법 정확도를 개선하는 데 효과적임이 확인되었다.

그러나 기존 연구들은 주로 영어권 데이터를 기반으로 하며, 조사와 어미 변화에 따라 의사소통 성공률이 크게 달라지는 한국어의 언어적 특수성을 반영한 연구는 아직 초기 단계에 머물러 있다. 또한 오디오 비유창성 피처를 LLM 교정 프로세스에 직접 주입하는 멀티모달 접근은 대부분의 선행연구에서 시도되지 않았다는 점에서 본 연구의 차별성이 있다.

제 2절 분석 데이터셋 구성 및 특성

본 연구에서 활용하는 AI Hub 구음장애 음성인식 데이터는 총 7,874건으로, 훈련용 6,667건과 검증용 1,207건으로 구분된다. 훈련 데이터는 뇌신경장애(TS01) 425건(62,557분), 언어청각장애(TS02) 1,228건(91,192분), 후두장애(TS03) 4,472건(146,718분)으로 구성되며, 세 질환군 모두 대본 낭독(read-aloud scripts) 환경에서 수집되었음을 전수 조사를 통해 확인하였다. 훈련 데이터와 검증 데이터는 발화 과제가 동일하나 화자가 상이하며, 파일 단위 중복이 관찰되지 않아 데이터 누수 위험이 낮은 것으로 판단된다. 원천 음성 데이터의 총 용량은 약 400GB이다.

유효 발화 선별을 위해 두 단계의 필터링을 적용하였다. 1단계에서는 단음절 단어의 나열이나 종결어미 및 마침표가 부재한 구조적 비문장을 제거하는 언어학적 필터링을 수행하여 562건을 제외하였으며, 긍정 및 부정의 핵심 의도 발화(네, 아니요 등)는 예외적으로 보존하였다. 2단계에서는 RAM 초과로 인한 시스템 예외 처리 파일 1건을 추가 제외하였다. 최종적으로 전체 훈련 데이터의 91.5%에 해당하는 6,104건이 분석 대상으로 확정되었다.

한편 전체 데이터셋(447,730건)의 구조 분석 결과, 고유 문장 수는 19,882개로 중복률이 95.4%에 달하는 것을 확인하였다. 이는 동일한 낭독 대본을 여러 화자가 반복 발화하는 구조로, Gold Standard 구축의 핵심 전략적 기반이 된다(제 3장 제 2절 참조).

Figure A. 발화 심각도 그룹 분포 (전체 훈련 데이터, N=6,667)




Figure B. 전사 기호 유형별 발생 분포 분석 (N=6,667)




Figure 2. 발화 심각도 그룹 분포 (훈련 데이터, N=6,667) 및 전사 기호 유형별 발생 분포

제 3절 용어의 정의 및 개념적 틀

본 연구에서 사용하는 핵심 개념들은 다음과 같이 정의된다. 이는 분석 방법론의 이해를 돕기 위한 개념적 틀이며, 각 지표의 세부 산출 방식은 제 3장에서 상술한다.

2.3.1. 구음장애와 비유창성(Dysfluency)

구음장애(Dysarthria)는 신경계 손상으로 인해 발화 기관의 근육 운동 조절이 저하되어 발생하는 말소리 장애이다. 비유창성(Dysfluency)은 발화 과정에서 나타나는 반복, 연장, 막힘, 삽입 등의 불규칙적 중단 현상을 총칭하며, 구음장애 발화에서는 이러한 비유창성이 특히 빈번하고 비정형적으로 나타난다. 본 연구에서는 비유창성을 오류 정보가 아닌 화자의 발화 심각도를 반영하는 핵심 신호로 재정의하여 분석 자료로 활용한다.

2.3.2. WSLD Score

WSLD(Weighted Stuttering-Like Disfluencies) Score는 Ambrose & Yairi(1999)가 제안한 말더듬 유사 비유창성 가중 점수 공식으로, 비유창성 유형별 임상적 심각도에 따라 차등 가중치를 부여하여 발화의 훼손 정도를 단일 수치로 정량화한다. 본 연구에서는 원공식의 구조적 원리만을 차용하고, 가중치 및 구간 기준을 AI Hub 전사 기호 체계와 성인 구음장애 특성에 맞게 독자적으로 재설계한 '재설계 WSLD Score'를 사용한다.

2.3.3. Hesitation_per_word

더듬음(Hesitation)은 발화 중 발생하는 1.5초 미만의 짧은 음성 공백으로, 조음 기관의 근육 경직 또는 순간적 차단으로 인한 비의도적 정지를 의미한다. raw Hesitation_Time(초)은 발화 길이에 의해 교란될 수 있으므로, 본 연구는 더듬음 총 시간을 발화 어절 수로 나눈 Hesitation_per_word를 오디오 피처의 핵심 지표로 사용한다. 이는 발화 길이에 무관하게 단어당 평균 더듬음 부담을 반영하는 정규화된 비유창성 지표이다.

2.3.4. Judge-Editor 에이전트 아키텍처

Judge-Editor 에이전트는 단일 LLM이 전체 문장을 재작성하는 방식 대신, 오류 식별(Judge)과 국소 교정(Editor)을 역할 분리한 2단계 아키텍처이다. Judge는 ASR의 N-best 가설들 간 충돌 구간을 탐지하고, Editor는 해당 구간만 문맥과 오디오 피처를 참조하여 선택적으로 재작성한다. 이 구조는 환각(Hallucination) 억제와 원문 보존을 동시에 달성하기 위해 설계되었다.

2.3.5. Soft Fusion

Soft Fusion은 오디오 피처를 자연어 메타데이터로 변환하여 LLM 프롬프트에 주입하는 방식으로, 모달리티 간 정보를 텍스트 수준에서 결합한다. 어텐션 가중치 직접 조작이 불가능한 API 기반 대형 언어 모델 환경에서 멀티모달 정보를 효과적으로 통합하기 위한 현실적 대안이다. 본 연구에서는 더듬음 횟수·시간, 의도적 휴지 정보를 자연어 문장으로 변환하여 프롬프트 내 심각도 컨텍스트로 제공한다.

2.3.6. Gold Standard 및 BERTScore

Gold Standard는 모델 평가의 정답 기준이 되는 참조 텍스트를 의미하며, 본 연구에서는 교차 화자 낭독 구조를 활용한 앵커 매칭 파이프라인으로 자동 구축된 9,832건의 참조 문장을 사용한다. BERTScore(F1)는 BERT 임베딩 기반의 의미론적 유사도 지표로, 단어 수준의 정합 여부를 측정하는 WER과 달리 문장의 의미적 보존 정도를 정량화한다(Zhang et al., 2020). 구음장애 발화처럼 표층 형태가 불완전하더라도 의미가 유지되는 경우를 정확히 평가하기 위해 주 평가 지표로 채택하였다.

제 3장 분석 방법

제 1절 멀티모달 피쳐 추출 및 심각도 정량화 분석

3.1.1. 텍스트 피쳐 - WSLD Score 재설계

구음장애 환자의 발화 심각도를 텍스트 차원에서 정량화하기 위해 Ambrose & Yairi(1999)의 WSLD(Weighted Stuttering-Like Disfluencies) 공식을 AI Hub 전사 데이터의 특수기호 체계에 맞게 재설계하였다. 원본 WSLD 공식은 다음과 같이 정의된다.

$$\text{WSLD} = [(PW + SS) \times \text{평균 RU}] + (2 \times DP)$$

여기서 PW와 SS는 반복 유형을, RU는 반복 횟수를, DP는 막힘 및 연장 등의 비유창성을 나타낸다. 단, Ambrose & Yairi(1999)는 유아(2~5세) 발달성 말더듬을 대상으로 한 연구로, 신경학적 손상에 의한 성인 구음장애와 모집단이 근본적으로 상이하다. 따라서 본 연구는 원본 공식의 가중치 부여 및 빈도 정규화라는 구조적 원리만을 차용하며, 구간 기준은 본 연구 데이터에 대한 독자적 통계 검증을 통해 설정함을 명시한다.

AI Hub 전사 데이터의 특수기호는 다음과 같이 재매핑하였다. '+' 기호는 형태소 수준의 재시작 패턴인 PW+SS에 해당하며 가중치 1.5를 부여하였다. '*' 기호는 발음이 불분명하거나 조사가 끊기는 조음 파열 현상으로, 원본 공식의 DP 가중치인 2점을 그대로 적용하였다. '/' 기호는 원본 공식에 명시적 대응 항목이 없는 경기한 추임새나 단절로 판단하여 0.5의 보정 가중치를 부여하였다. 최종 심각도 산출은 위 가중치 합계에 전체 단어 수 대비 기호의 비중인 오류 밀도(Error Density) 보정값을 더하는 방식으로 수행된다.

3.1.2. 오디오 피쳐 - Hesitation_per_word 정규화

오디오 차원의 비유창성 지표 추출을 위해 Librosa 라이브러리를 활용하여 16,000Hz로 로드된 원천 음성 신호에서 침묵 구간을 분리한다. 배경 소음과 음성을 구분하기 위해 진폭 임계값을 30dB로 설정하였다(Librosa 기본값 60dB 대비 보수적 설정). 분리된 침묵 구간은 Hall(1999)의 기준에 따라 1.5초 미만의 구간은 '더듬음(Hesitation)', 1.5초 이상의 구간은 '의도적 휴지(Intentional Pause)'로 정의하여 비유창성을 정량화한다.

초기 분석에서 raw Hesitation_Time(초)을 오디오 피쳐로 사용하였을 때, 발화 길이가 교란변수로 작용하는 것을 확인하였다. 경증 그룹의 평균 발화 길이(973어절)가 중증 그룹(517어절)의 약 2배에 달해, raw 피쳐 기준으로는 경증 그룹의 더듬음 절대 시간이 중증보다 높게 나타나는 역전 현상이 발생하였다. 이를 보정하기 위해 더듬음 시간을 발화 어절 수로 나눈 Hesitation_per_word 지표를 도입하여 발화 길이 교란을 제거하였다.

3.1.3. 그룹 분류 및 통계 검증 설계

WSDL Score 기반 그룹 분류는 Imperfect Rate(전체 단어 대비 오류 기호 비중) 2%를 기준으로 완전 발화(Imperfect Rate = 0), 경증(Imperfect Rate $\leq$ 2%), 중증(Imperfect Rate > 2%)의 3개 그룹으로 분류하였다. 이 기준은 본 연구 데이터에 대한 ANOVA 유의성 검증을 통해 독자적으로 설정되었다. 그룹 간 Hesitation_per_word 분포 차이를 검증하기 위해 Kruskal-Wallis 검정을 적용하고, 사후검정으로 Dunn-Bonferroni 보정을 수행하며, 효과크기는 rank-biserial r로 산출한다.

제 2절 Gold Standard 구축 - 교차 화자 앵커 매칭 파이프라인

3.2.1. 데이터 구조 재파악 및 전략

AI Hub 구음장애 음성인식 데이터의 전체 구조 분석 결과, 데이터셋 내 447,730건의 발화 중 고유 문장 수가 19,882개(중복률 95.4%)에 달하는 것을 확인하였다. 이는 동일한 낭독 대본을 다수의 구음장애 화자가 반복 발화하는 구조로, 불완전한 발화에 대응하는 정답이 '다른 화자의 깨끗한 버전'에 존재함을 의미한다. 본 연구는 이를 활용하여 교차 화자 매칭(Cross-Speaker Matching)으로 Gold Standard를 자동 생성하는 전략을 수립하였다. 원본 JSON 구조상 타임스탬프가 없어 문장 단위 자동 분절이 불가능하고 정답 지문도 없는 두 가지 제약을, 앵커 매칭 방식으로 동시에 우회한다.

3.2.2. 4단계 캐스케이드 매칭 파이프라인

앵커 매칭은 특수기호만 제거하고 한글 글자를 보존하는 방식으로 앵커 텍스트를 생성한 후, 4단계 캐스케이드로 정답을 탐색한다. 1단계(T1: Exact, 유사도 $\geq$ 0.90)는 정밀 앵커 매칭으로 82.7%를 처리하였고, 2단계(T2: Partial, 0.80~0.90)에서 11.9%, 3단계(T3: Fuzzy, 0.70~0.80)에서 3.0%를 추가로 매칭하였다. 자동 매칭에 실패한 4단계(L4: <0.70) 234건은 연구자가 직접 청취하여 202건을 전사하고 32건을 노이즈로 처리하였다.

노이즈 판별 기준은 전사 불가 발화(u/ 기호), 개인정보 마스킹(000 패턴), 스크립트 빈칸((예시) 패턴) 세 가지이다. 최종적으로 gold_final.csv에 9,832건(99.7%)의 평가 가능 Gold Standard가 확보되었다.

Tier	설명	건수	비율
T0_human	직접 청취 전사	202	2.0%
T1_exact	자동 정확 ($\geq$ 0.90)	8,156	82.7%
T2_partial	자동 부분 (0.80~0.90)	1,178	11.9%
T3_fuzzy	자동 유사도 (0.70~0.80)	296	3.0%
T_noise	노이즈 (연구 제외)	20	0.2%
합계	평가 가능 발화	9,832	99.7%

Table 1. Gold Standard 구축 현황 (gold_final.csv)

T3(Fuzzy) 구간은 보수적(T1+T2) 및 관대한(T1+T2+T3) 두 버전으로 평가를 수행할 예정이다.




Figure 3. Gold Standard 구축 파이프라인 결과 - Tier별 구성 및 자동화율

제 3절 LLM 에이전트 기반 의도 복원 및 실효성 평가

3.3.1. Judge-Editor 에이전트 아키텍처

앞선 단계에서 추출된 텍스트 가설과 오디오 피처를 결합하여 불완전한 인식 결과를 본래의 의도로 복원하는 에이전트 기반 사후 교정 시스템을 설계하였다. 단일 언어 모델이 문장을 통째로 재작성하는 과정에서 발생하는 환각(Hallucination) 현상을 억제하고자, 에이전트 기반의 워크플로우 최적화 구조(Ma et al., 2026)를 Qwen2.5-72B 모델에 적용하여 인퍼런스 단계를 분리한다. Judge 에이전트는 N-best 가설들 간 논리적 충돌이나 불확실성이 높은 구간을 식별하고, Editor 에이전트는 해당 구간만을 국소적으로 수정하여 전체 문장의 일관성을 유지한다.

오디오 피처는 Soft Fusion 방식으로 LLM 프롬프트에 자연어 메타데이터로 주입된다. 구체적으로 더듬음 횟수·시간, 의도적 휴지 횟수·시간 등의 음향 지표를 자연어 문장으로 변환하여 프롬프트 내에 포함시킴으로써, 모델이 음향적으로 불확실한 구간을 인지하고 집중적으로 교정하도록 유도한다.

3.3.2. A/B Ablation 실험 설계

오디오 피처의 기여분을 정량적으로 분리하기 위해 단계적 A/B Ablation 설계를 적용하였다. 교정을 수행하지 않은 AI Hub 전사문을 Baseline(하한선)으로 두고, 동일한 Qwen2.5-72B 기반 Judge-Editor 에이전트에 (1) 기호 신뢰도 규칙만 적용한 **Rule** 조건,

(2) librosa 기반 오디오 피쳐만을 단서로 제공한 **Audio** 조건, (3) 규칙과 오디오를 모두 결합한 **Multimodal** 조건을 각각 적용하여 비교하였다. 이를 통해 Rule-Baseline은 기호 규칙의 단독 기여를, Audio-Baseline은 음향 정보의 단독 기여를, Multimodal과 두 단일 조건 간 차이는 두 신호원의 상호작용을 측정한다. 모든 조건은 환각 억제에 $\text{temperature}=0.1$ 로 통제하였으며, 교차 화자 앵커 매칭으로 구축한 Gold Standard 9,832 건 전체를 대상으로 BERTScore(F1, bert-base-multilingual-cased, L9)로 복원 성능을 측정하였다. 오디오의 순수 기여분은 $\text{BERTScore}(\text{Multimodal}) - \text{BERTScore}(\text{Rule})$ 로 산출한다.




Figure 4. Judge-Editor 에이전트 BERTScore 성능 검증 및 A/B Ablation 실험 설계 개요




Figure 5. Whisper N-best 가설 다양성 분석 - 후보 수 분포 및 후보 간 평균 텍스트 유사도 (N=27)

제 4장 분석 결과

제 1절 발화 심각도 기반 텍스트 피쳐 분석

본 절에서는 AI Hub 구음장애 데이터셋에서 추출한 6,104 건의 훈련 데이터를 대상으로, 전사 데이터(Transcript)에 나타난 언어적 오류 패턴을 정량화한 결과를 기술한다. 분석의 핵심은 단순한 기호의 개수 산출을 넘어, 각 오류 기호의 임상적 특성과 문장의 전체 길이를 고려한 WSLD 재스코어링 수치를 도출하는 데 있다.

4.1.1. 유효 발화 필터링 및 데이터 정제 결과

전체 원천 데이터 6,667 건 중 음성 신호의 결손이나 전사 데이터 부재 등 시스템 예외 항목을 제외하고, 최종적으로 6,104 건(수율 91.5%)의 유효 발화를 분석 대상으로 확정하였다. 필터링 과정에서는 '꼴', '낫'과 같은 단음절 연속 발화나 종결어미가 없는 비구조적 문장을 제거함으로써 데이터의 품질을 확보하였으며, 동시에 '네', '아니요'와 같은 핵심 의도 발화는 보존하여 실용적 분석 가치를 유지하였다. 정제된 데이터셋은 후두장애(4,472 건), 언어청각장애(1,228 건), 뇌신경장애(425 건) 순으로 구성되어 다양한 질환군의 발화 특성을 고르게 반영하고 있다.

4.1.2. WSLD Score 기술 통계 및 분포 특성

재설계된 WSLD Score는 화자의 발화 심각도를 연속형 변수로 제시한다. 훈련 데이터 전체에 대한 기술통계 분석 결과, 평균 점수는 3.50점(± 2.26)으로 집계되었다. 점수의 분포를 사분위수로 세분화하면 제1사분위(25%)는 2.27점, 중위값(50%)은 2.93점, 제3사분위(75%)는 4.00점으로 나타나 대다수의 발화가 2점에서 4점 사이의 심각도 구간에 분포함을 확인하였다.

통계량	값
평균 (Mean)	3.50
표준편차 (SD)	2.26
최솟값 (Min)	0.00
제1사분위 (Q1)	2.27
중위값 (Median)	2.93
제3사분위 (Q3)	4.00
최댓값 (Max)	51.50

Table 2. WSLD Score 기술통계량

중위값 대비 최댓값(51.50)이 매우 높게 형성된 극단적 우편향 분포가 주목된다. 이는 일부 중증 환자군에서 발생하는 심각한 수준의 비유창성을 반영하며, 이러한 고난이도 발화 구간은 LLM 에이전트가 집중적으로 복원해야 할 핵심 타겟이다.

Figure C. WSLD Score 분포 및 심각도 그룹 간 비교




Figure 6. WSLD Score 분포 및 심각도 그룹 간 비교 (불완전 발화 n=1,458)

4.1.3. 발화 심각도 그룹화 및 오류 패턴 분석

WSLD Score를 바탕으로 Imperfect Rate 2% 기준의 3그룹 분류를 적용한 결과, 오류 기호가 탐지되지 않은 완전 발화가 전체의 약 52%(n=4,667)를 차지하였으며, 경증 (Imperfect Rate $\leq$ 2%, n=1,148)과 중증(Imperfect Rate > 2%, n=289)으로 세분화되었다. 본 연구에서 사용한 WSLD 기반 심각도 구간(Imperfect Rate 2% 기준)은 Ambrose & Yairi(1999)의 수식 구조를 참조하되, 구간 기준은 본 연구 데이터에 대한 ANOVA 유의성 검증을 통해 독자적으로 설정하였음을 명시한다.

분석 결과, 심각도가 높은 그룹일수록 문장 내 반복(+)과 발음 불분명(*) 기호의 밀도가 단조 증가하는 경향을 보였으며, 특히 중증 그룹은 문장의 통사적 구조가 해체된 양상을 띠어 단순 음성 인식만으로는 의도 파악이 어려움을 데이터로 확인하였다.




Figure 7. Whisper 실험 대상 데이터(N=81) 심각도별 WSLD Score 및 Imperfect Rate 상관관계

제 2절 오디오 피쳐(음향학적 비유창성 지표) 통계 특성

본 절에서는 6,104 건의 유효 발화 데이터를 대상으로 Librosa 라이브러리를 통해 추출한 오디오 피쳐의 통계적 분포와 물리적 특성을 분석한다. 구음장애 발화의 핵심 지표인 침묵 구간을 정밀하게 포착하기 위해 30dB의 진폭 임계값을 적용하였으며, 이를 통해 도출된 더듬음과 의도적 휴지의 양상을 기술한다.

4.2.1. 더듬음(Hesitation) 분포의 극단적 비대칭성

발화 중 발생하는 1.5초 미만의 짧은 정지 구간인 '더듬음' 지표를 분석한 결과, 횟수와 시간 모두에서 강한 우편향(Right-skewed) 분포가 관찰되었다. 더듬음 횟수의 경우 중앙값은 3.0 회에 불과하나 평균은 20.3 회로 집계되었으며, 지속 시간 또한 중앙값 1.1초 대비 평균이 7.1초로 높게 나타나 두 지표 모두 중앙값과 평균 사이의 격차가 매우 크게 형성되었다. 이러한 비대칭적 분포는 대다수의 화자가 비교적 안정적인 발화 상태를 유지하는 반면, 일부 중증 환자군이나 특정 발화 샘플에서 수치가 비정상적으로 높게 나타나는 구음장애 특유의 불규칙성을 물리적으로 입증한다.

mean	3.495286
std	2.256610
min	0.544000
25%	2.269000
50%	2.929000
75%	4.000000
max	51.500000

Table 2. 더듬음 횟수 및 시간(sec) 분포




Figure 3. 더듬음 횟수 및 시간(sec) 분포

4.2.2. 의도적 휴지(Intentional Pause)의 완만한 분포 특성

더듬음과 달리 1.5 초 이상의 지속 시간을 갖는 '의도적 휴지' 지표는 상대적으로 완만한 분포 양상을 보였다. 의도적 휴지의 횟수는 중앙값 10.0 회, 평균 13.9 회로 나타났으며, 휴지 시간 역시 중앙값 5.9 초, 평균 8.6 초로 산출되어 더듬음 지표에 비해 중앙값과 평균의 격차가 상대적으로 작았다. 이는 의도적 휴지가 극단적인 수치에 덜 치우쳐 있으며, 발화 과정에서 문장을 구성하거나 호흡을 가다듬는 인지적 준비 시간이 비교적 일정한 범위 내에서 발생하고 있음을 시사한다.




Figure 4. 의도적 휴지 횟수 및 시간(sec) 분포

4.2.3. 지표 분리의 유효성 및 음향적 독립성

1.5 초의 임계값을 기준으로 구분된 두 지표(더듬음 vs 의도적 휴지)는 서로 다른 분포 형태를 나타내어, 발화의 물리적 끊김을 다각도로 분석하려는 본 연구의 접근이 유효함을 확인하였다. 특히 30dB 설정을 통해 미세한 단절까지 포착한 결과물은 텍스트상에 나타나지 않는 화자의 음향적 고충을 독립적으로 반영한다. 이러한 오디오 피처의 통계적 특성은 단순한 소음 제거를 넘어, 향후 LLM 에이전트가 발화의 불확실성을 예측하고 정밀한 보정을 수행하기 위한 핵심적인 메타데이터로 기능하게 된다.

4.2.4. Hesitation_per_word 정규화 결과

그룹 간 비교를 위해 더듬음 시간을 어절 수로 나눈 Hesitation_per_word 지표를 산출한 결과, 세 그룹의 기술통계는 다음과 같다.

그룹	n	평균	중앙값
완전 발화	4,667	0.0528	0.0255
경증 (≤2%)	1,148	0.0789	0.0537

중증 (>2%)	289	0.1277	0.0941
----------	-----	--------	--------

Table 4. 그룹별 Hesitation_per_word 기술통계 (Imperfect Rate 2% 기준)

완전 발화에서 경증, 중증으로 갈수록 평균 및 중앙값이 모두 단조 증가하는 패턴이 명확히 확인된다. Imperfect Rate가 높을수록 단어당 망설임 시간도 통계적으로 유의미하게 증가함을 시사한다.

제 3절 멀티모달 피쳐 간 상관관계 및 타당성 검증

본 절에서는 앞서 산출한 텍스트 기반의 발화 심각도(WSLD Score)와 오디오 기반의 음향학적 비유창성 지표(Hesitation) 간의 관계를 분석하여, 본 연구가 제안하는 멀티모달 데이터 융합의 기술적 타당성을 검증한다. 분석은 심각도 그룹별 피쳐 비교와 전체 지표 간의 상관분석으로 나누어 진행하였다.

4.3.1. 발화 심각도 그룹에 따른 음향 지표의 단조 증가 경향

Imperfect Rate로 정의된 발화 심각도(완전 발화, 경증, 중증)와 Hesitation_per_word 간의 관계를 Kruskal-Wallis 검정으로 분석한 결과, $H=491.225(p=2.11 \times 10^{-107})$ 로 세 그룹 간 Hesitation_per_word 분포에 통계적으로 고도로 유의미한 차이가 확인되었다. Dunn-Bonferroni 사후검정에서 모든 쌍별 비교(완전 발화-경증, 완전 발화-중증, 경증-중증)에서 $p<0.001$ 로 전 쌍이 유의하였다. 효과크기(rank-biserial r)는 완전 발화 vs 경증 $r=0.3380$ (중간 효과), 완전 발화 vs 중증 $r=0.5219$ (큰 효과), 경증 vs 중증 $r=0.2540$ (작은 효과)로 산출되었다. 특히 완전 발화 그룹과 중증 그룹 간의 차이가 가장 크며, 경증과 중증 간에도 통계적으로 유의미한 차이가 확인된다.




Figure10. 발화 심각도 그룹별 Hesitation_per_word 분포 (Kruskal-Wallis $H=491.255$, $p=2.11 \times 10^{-107}$)

이러한 결과는 Imperfect Rate가 발화의 텍스트 비유창성을 잘 반영하는 지표이며, 오디오

오 차원의 Hesitation_per_word와 통계적으로 유의미한 관계를 가짐을 보여준다.

4.3.2. 멀티모달 피쳐 간 상관관계 및 기술적 시사점

WSLD Score 와 오디오 피쳐(더듬음 횟수 및 시간) 간 스피어만 상관계수를 산출한 결과, 더듬음 횟수와 상관은 $r=0.377(p=4.497\times 10^{-49})$, 더듬음 시간과의 상관은 $r=0.400(p=1.968\times 10^{-55})$ 으로 나타났으며, 심각도 그룹 간 차이는 Kruskal-Wallis 검정에서 $p=1.068\times 10^{-130}$ 으로 확인되었다. 이는 중간 수준의 유의미한 양의 상관으로, 두 피쳐가 동일한 현상을 중복 측정하지 않고 각각 독립적인 정보를 포착하고 있음을 시사한다. 만약 두 피쳐 간 상관이 0.9 이상이었다면 중복 측정의 가능성이 높아 멀티모달 융합의 필요성이 약화되었을 것이나, $r\approx 0.4$ 라는 중간 수준의 독립적 상관관계는 텍스트와 오디오 피쳐를 결합하는 Soft Fusion 설계의 핵심 타당성 근거가 된다.




Figure 5. WSLD Score와 오디오 피쳐(Hesitation) 간 상관관계 산점도

이러한 독립적 상관관계는 본 연구의 멀티모달 파이프라인 설계에 중요한 타당성을 부여한다. 즉, LLM 기반의 에이전트가 교정 작업을 수행할 때, 텍스트 정보만으로는 판별하기 어려운 모호한 구간을 오디오 피쳐라는 독립적인 음향 단서를 통해 보완함으로써 더욱 정밀한 의도 복원이 가능해짐을 데이터로 입증한 것이다. 결과적으로 본 분석은 텍스트 심각도와 음향 지표의 결합이 구음장애 음성 인식 성능 향상을 위한 필수적인 요소임을 확인시켜 준다.

제 4절 LLM 기반 의도 복원 실험 및 실효성 검증

4.4.1. Judge-Editor 에이전트 실험 설계 및 교정 결과

전체 멀티모달 파이프라인의 실효성을 검증하기 위해 Qwen2.5-72B 모델 기반 Judge-Editor 에이전트를 활용한 의도 복원 실험을 수행하였다. 에이전트가 문장을 자의적으로

창작하거나 요약하는 환각 현상을 방지하기 위해 Last-Attempt Wins, No Deletion, No Creation의 3대 절대 규칙을 프롬프트에 강제 적용하였으며, temperature=0.1로 설정하여 출력의 다양성을 억제하였다.

평가는 교차 화자 앵커 매칭으로 구축한 Gold Standard 9,832건(T1_exact 8,156 / T2_partial 1,178 / T3_fuzzy 296 / T0_human 202) 전체를 대상으로 수행하였다. 입력 문장의 87.3%에서 교정이 발생하였으며, 텍스트 전용 조건(v2)과 오디오 주입 조건(v3)의 출력이 상이한 비율은 15.8%로, 음향 메타데이터가 약 6건 중 1건의 교정 판단에 실질적으로 개입하였음을 보여준다.

실험 결과, '양은냄비+ 꺼내+ 양은냄비를+ 꺼내+'와 같이 반복이 심한 문장이 '양은냄비를 꺼내'로 교정되는 등, 텍스트 내의 조음 오류 기호를 효과적으로 제거하며 화자의 본래 의도를 성공적으로 복원하였다. 주요 오류 패턴은 미완성 문장에서 원문에 없는 술어나 목적어를 생성하는 창작 오류(No Creation 위반)와 어절 단위 정보가 통째로 누락되는 삭제 오류(No Deletion 위반)의 두 가지로 분류되며, 이는 Soft Fusion의 오디오 신뢰도 가중치 주입을 통해 개선될 수 있다.

4.4.2. BERTScore 기반 정량적 실효성 검증

복원 성능을 객관적으로 측정하기 위해 Gold Standard와 복원 결과 간의 BERTScore(F1, bert-base-multilingual-cased, L9)를 산출하여 비교 분석하였다. 평가는 교차 화자 앵커 매칭으로 구축한 Gold Standard 9,832건 전체를 대상으로 수행하였으며, 교정 처리(ASR 원본 대비 출력 변경)는 전체의 87.3%에서 발생하였다.

조건	BERTScore (F1)	개선폭	개선율
Baseline (ASR 원본, 교정 없음)	0.9402	-	-
Rule (규칙 기반)	0.9763	+0.0361	+3.84%
Multimodal (규칙+오디오)	0.9755	+0.0353	+3.75%

Table 5. A/B Ablation BERTScore 결과 (n=9,832)




Figure 12. A/B Ablation: LLM 사후 교정의 BERTScore

LLM 기반 사후 교정을 적용한 모든 조건에서 Baseline 대비 통계적으로 의미 있는 성능 향상이 확인되었다. 규칙 기반 교정(Rule)은 BERTScore 를 0.9402 에서 0.9763 으로 약 3.84% 향상시켰으며, 이는 Judge-Editor 에이전트가 더듬음·발음 불분명 구간을 효과적으로 정제하여 화자의 본래 의도에 근접한 문장을 복원함을 보여준다.

반면 오디오 메타데이터를 추가로 주입한 멀티모달 조건(Multimodal)은 0.9755 로, 규칙 기반 조건과 사실상 동등한 수준이었다(오디오 기여분 -0.0009). 그러나 Tier 별 분석에서는 상반된 양상이 나타났다.

Tier	Baseline	Rule	Multimodal
T0_human	0.8755	0.9540	0.9565
T1_exact	0.9503	0.9818	0.9809
T2_partial	0.9007	0.9549	0.9541
T3_fuzzy	0.8630	0.9263	0.9247

Table 6. 오디오 메타데이터 분석 중 Tier 별 분석

Baseline 점수가 낮고, 직접 청취로 Gold Standard 를 구해야 했던 구간 (T0_human)에서만 오디오 주입이 유일하게 성능을 개선(+0.0025)하였다. 이는 텍스트 신호의 신뢰도가 높은 구간에서는 오디오의 한계 효용이 미미하지만, 텍스트 손상이 심각하여 기호 규칙만으로 의도 파악이 어려운 구간에서는 음향적 불확실성 정보가 보완적 단서로 기능함을 시사한다.

제 5장 결론

제 1절 연구 성과 및 의의

본 연구는 구음장애인의 비유창성을 단순 잡음으로 취급하여 배제하던 기존 방식에서 벗어나, 이를 데이터적 자산으로 활용하여 화자의 본래 의도를 복원하는 멀티모달 파이프라인의 타당성과 실효성을 종합적으로 검증하였다.

첫째, WSLD Score 기반 발화 심각도 정량화 체계를 구축하였다. Ambrose & Yairi(1999)의 WSLD 수식 구조를 AI Hub 전사 특수기호에 맞게 재설계하고, 구간 기준은 본 연구 데이터에 대한 ANOVA 검증으로 독자 설정하였다. 이를 통해 구음장애 발화의 텍

스트 심각도를 연속형 변수로 객관화하는 평가 체계를 확립하였다.

둘째, 발화 길이 교란을 제거한 Hesitation_per_word 지표를 도입하여, 발화 심각도(완전 발화, 경증, 중증)가 높아질수록 단어당 망설임 시간이 Kruskal-Wallis $H=491.255(p=2.11 \times 10^{-107})$, 전 쌍 Dunn-Bonferroni $p < 0.001$, 효과크기 $r=0.34 \sim 0.52$ 로 통계적으로 고도로 유의하게 증가함을 입증하였다. 특히 WSLD Score와 Hesitation_per_word 간 스피어만 $r \approx 0.4$ 의 중간 수준 독립적 상관관계는 텍스트-오디오 멀티모달 융합의 핵심 타당성 근거가 된다.

셋째, 데이터셋 내 95.4%의 교차 화자 중복 구조를 활용한 앵커 매칭 파이프라인으로 9,832건(99.7%)의 신뢰도 높은 Gold Standard를 구축하였다. 4단계 캐스케이드(T1_exact 82.7%, T2_partial 11.9%, T3_fuzzy 3.0%, T0_human 2.0%) 설계로 직접 청취를 최소화하면서도 고품질 평가 기반을 마련하였다.

넷째, 교차 화자 앵커 매칭으로 구축한 Gold Standard 9,832건 전체에 대한 A/B Ablation 결과, LLM 기반 사후 교정이 BERTScore(F1)를 0.9402에서 0.9763으로 약 3.84% 향상시켰다. 이는 LLM 사후 교정 아키텍처가 단순 자구 수정을 넘어, 화자의 발화 맥락을 이해하고 복원하는 '의도 중심' 인식 시스템으로의 패러다임 전환 가능성을 9,832건 규모에서 실증한 결과이다. 한편 오디오 메타데이터의 단순 주입(Soft Fusion)은 평균적으로는 텍스트 기반 교정과 동등하였으나(기여분 -0.0009), 텍스트 손상이 심해 직접 청취가 필요했던 구간에서는 보완적 효과를 보여, 음향 정보의 효용이 발화 손상 정도에 따라 조건부로 발현됨을 확인하였다.

제 2절 정책적 제언 및 시사점

본 연구의 결과는 학술적 기여를 넘어 다음과 같은 정책적·실천적 시사점을 제공한다.

5.2.1. 의료·돌봄 현장에서의 활용 방안

제안하는 멀티모달 파이프라인은 별도의 음향 모델 재학습 없이 기존 ASR 시스템에 사후 교정 레이어로 탑재할 수 있어, 임상 현장 도입 비용이 낮다. 특히 병원 내 재활치료실, 장기요양 돌봄 환경, 언어치료 세션 등에서 구음장애 환자의 발화를 실시간으로 교정하여 의사소통 보조 도구로 활용 가능하다. WSLD Score 기반 발화 심각도 분류는 임상 언어치료사가 환자의 상태 변화를 객관적으로 모니터링하는 보조 지표로도 기능할 수 있다.

5.2.2. 한국어 구음장애 AI 생태계 구축을 위한 제언

현재 구음장애 음성인식 연구는 영어권 중심으로 집중되어 있으며, 한국어의 조사·어미 체계와 형태적 복잡성을 반영한 연구 기반은 부족하다. 본 연구에서 구축한 Gold Standard 9,832건과 WSLD Score 체계, Hesitation_per_word 지표는 향후 한국어 구음

장애 음성인식 연구의 벤치마크 자료로 공개 활용될 수 있다. 정부 및 연구기관 차원에서 한국어 구음장애 발화 데이터의 체계적 수집과 평가 기준 표준화를 추진하는 것이 필요하다.

5.2.3. AI 기반 보조기기의 안전성 기준 마련

본 연구에서 확인된 창작 오류(No Creation 위반) 및 삭제 오류(No Deletion 위반)는, 의료·돌봄 환경에서 AI가 자의적으로 문장을 변형하는 것이 치명적 정보 왜곡으로 이어질 수 있음을 시사한다. Safety Trigger(Reject 로직) 설계는 단순한 기술적 완성도 문제가 아니라 보조기기 안전 기준의 문제이다. AI 기반 언어 보조기기에 대한 의료기기 수준의 안전성 검증 체계와 정책적 가이드라인 마련이 필요하다.

제 3절 한계 및 향후 연구 방향

본 연구는 다음과 같은 한계를 내포하며, 향후 연구를 통해 보완할 예정이다.

첫째, 오디오 메타데이터의 단순 주입(Soft Fusion)이 전체 평균에서 텍스트 기반 교정 대비 유의미한 향상을 보이지 못한 점이 본 연구의 핵심 한계이다(오디오 기여분 -0.0009). 이는 더듬음 횟수·시간 등 요약된 음향 통계를 자연어로 변환하여 주입하는 방식이 모델의 교정 판단에 제한적으로만 반영됨을 시사한다. 또한 Gold Standard의 T0_human 계층은 앵커 매칭에 실패하여 연구자 1인의 직접 청취 전사에 의존하였고, 전사자 간 신뢰도(inter-rater reliability) 검증이 수행되지 않았다. 향후 요약 통계 대신 프레임 단위 음향 임베딩을 직접 활용하는 정교한 융합 구조와, 복수 전사자 기반의 Gold Standard 검증이 요구된다.

둘째, 의미 거리 기반 Safety Trigger 설계가 미완료 상태이다. 의료 및 돌봄 환경에서의 환각은 치명적 위협이 되므로, LLM 최종 교정 결과와 원본 가설 간의 의미론적 거리를 계산하여 신뢰도가 임계값 이하일 경우 사용자에게 재질의를 요청하는 Reject 로직을 설계·구현할 예정이다.

셋째, 본 연구의 분석이 학습 데이터 화자군에 집중되어 있어, 화자가 상이한 검증 데이터셋(Validation Set, 1,207건)에 대한 범용성 평가가 아직 수행되지 않았다. 향후 동일 파이프라인을 검증 데이터셋에 적용하여 특정 화자·질환군에 편향되지 않은 강건함(Robustness)을 확인할 필요가 있다.

참고문헌

- 질병관리청. (2025). *2022년 심뇌혈관질환 발생통계 주요 결과*. 질병관리청.
- 보건복지부 중앙암등록본부. (2026). *2023년 국가암등록통계*. 국가암지식정보센터.
https://www.cancer.go.kr/lay1/program/S1T211C223/cancer/view.do?cancer_seq=5333&menu_seq=5338 (접속일: 2026.04.06.)
- ASHA. (2021). *Dysarthria in adults*. American Speech-Language-Hearing Association.
- Marini, M., Vanello, N., & Fanucci, L. (2021). Optimising speaker-dependent feature extraction parameters to improve automatic speech recognition performance for people with dysarthria. *Sensors*, 21(19), 6460. <https://doi.org/10.3390/s21196460>
- Wang, H., Jin, Z., Geng, M., Hu, S., Li, G., Wang, T., Xu, H., & Liu, X. (2024). Enhancing pre-trained ASR system fine-tuning for dysarthric speech recognition using adversarial data augmentation. *arXiv preprint arXiv:2401.00662*.
- Xiao, Q., et al. (2025). Cross-learning fine-tuning strategy for dysarthric speech recognition via CDSDB database. *arXiv preprint arXiv:2508.18732*.
- Aboeitta, A., Sharshar, A., Nafea, Y., & Shehata, S. (2025). Bridging ASR and LLMs for dysarthric speech recognition: Benchmarking self-supervised and generative approaches. *Interspeech 2025*, 2123-2127.
<https://doi.org/10.21437/Interspeech.2025-1994>
- Hall, K. D., Amir, O., & Yairi, E. (1999). A longitudinal investigation of speaking rate in preschool children who stutter. *Journal of Speech, Language, and Hearing Research*, 42(6), 1367-1377. <https://doi.org/10.1044/jslhr.4206.1367>
- Ambrose, N. G., & Yairi, E. (1999). Normative disfluency data for early childhood stuttering. *Journal of Speech, Language, and Hearing Research*, 42(4), 895-909.
<https://doi.org/10.1044/jslhr.4204.895>
- Ma, Z., Zhao, Z., Hua, C., Berto, F., & Park, J. (2026). JudgeFlow: Agentic workflow optimization via block judge. *arXiv preprint arXiv:2601.07477*.
- Zheng, X., Dong, S., Phukon, B., Hasegawa-Johnson, M., & Yoo, C. D. (2026). Towards robust dysarthric speech recognition: LLM-agent post-ASR correction beyond WER. *arXiv preprint arXiv:2601.21347*.