

Dynamic group fusion transformer for financial time series prediction : An ablation study

금융시장의 거시·뉴스 심리 통합 분석을 통한 ETF 방향 예측

저자: Nima Heidari, Saeed Mirzamohammadi, Babak Amiri

| School of Industrial Engineering, Iran University of Science and Technology, Tehran, Iran

학술지: Decision Science Letters 15 (2026) 151–162

출판사: Growing Science, Canada

출판 연도: 2026

온라인 공개: 2025년 10월 2일

DOI: 10.5267/j.dsl.2025.10.002

Dynamic Group Fusion Transformer for Financial Time Series Prediction

이질적 특징군의 동적 융합, 누수-안전 레이블, 체계적 ablation으로 재현성·신뢰성 확보



참고 논문

DGFET: 이질적 특징군의
동적 융합 기법 제안
Decision Science Letters 2026
88개 피처 통합



핵심 기술

Group-FiLM, Global-Context FiLM
Dynamic Group Fusion
88개 피처 통합



성능 개선

F1-macro 0.536
ROC-AUC 0.6612
SHM-binary F1 0.722

연구 배경과 문제의식

금융 시계열 예측의 핵심 도전 과제와 DGFET 접근법

금융 시계열의 어려움

비정상성·비선형성·레짐 시프트

시장 데이터가 복잡하고 비정상성(non-stationary)을 보임

단기 모멘텀과 장기 구조적 패턴 동시 포착 필요

레짐 시프트(시장 체제 변화)로 예측 난이도 급증

전통적 통계 모델(ARIMA, VAR)의 한계

문제: 기존 모델은 복잡한 시장 동태를 충분히 반영하지 못함

해결: Transformer 기반 동적 융합 접근

연구 배경과 문제의식

금융 시계열 예측의 핵심 도전 과제와 DGFET 접근법

이질적 특징군

시장·기본·기술·뉴스 4개 그룹

Market(5개): OHLCV 기본 가격 데이터

Fundamental(25개): 거시경제 지표

Technical(42개): 기술적 분석 지표

News Sentiment(16개): 뉴스 감성 분석

문제: 각 그룹의 기여도가 시점별로 상이

해결: 그룹별 동적 가중치 적용

연구 배경과 문제의식

금융 시계열 예측의 핵심 도전 과제와 DGFET 접근법

⚠ 라벨 누수 문제

누수 방지·평가 엄정성

미래 정보를 현재 예측에 사용하는 위험

잘못된 라벨 설계로 과대평가 발생

Temporal leakage로 신뢰도 하락

재현 가능한 평가 프로토콜 필요

문제: 과거 정보 누수로 성능 과대평가

해결: 누수-안전 레이블 설계

왜 어려운가

금융 시계열 예측의 3가지 핵심 난제

단기 vs 장기 동시 포착

단기 모멘텀과 장기 구조 패턴의 균형

단기(1-3일): 급격한 가격 변동, 노이즈 많음
장기(1-2개월): 추세 형성, 느린 변화
두 패턴을 동시에 학습하는 어려움

Temporal Leakage 위험

미래 정보가 과거로 유입되는 문제

15:30 이후 뉴스 → 다음 영업일로
수정된 데이터 → 과거 가격에 반영
누수로 인한 과대평가 위험

그룹 간 상호작용

이질적 특징군의 복잡한 연결

시장/기본/기술/뉴스 4개 그룹
각 그룹이 시점별로 다른 기여도
그룹 간 상호작용 모델링

입력 피쳐 구조 개요

4개 피쳐 그룹 (Market/Fundamental/Technical/News Sentiment), 총 88개 피쳐

 **Market (5개)**

OHLCV

Open₁

High₁

Low₁

Close₁

Volume₁

기본 OHLCV 데이터로 현재 가격과 유동성 조건을 반영

 **Fundamental (25개)**

Macro-financial

거시경제 지표

VIX₁

DXY₁

Gold₁

Oil₁

금리₂

GDP₁

실업률₁

물가₃

25
총 특징

8
주요 지표

4
국가별

 **Technical (42개)**

Indicators

기술적 분석 지표

SMA₅

EMA₅

RSI₁

MACD₃

Bollinger₃

ATR₁

42
총 지표

12
추세

8
모멘텀

 **News Sentiment (16개)**

Text Analysis

뉴스 심리 분석

긍정₄

부정₄

중립₄

강도₄

FinBERT 기반 텍스트 분석으로 시장 심리 및 정보 전파 반영

4개 피처 그룹 상세 (1/2)

Market(5개 OHLCV)와 Fundamental(25개 거시지표) 구조



Market (5개)

OHLCV 기본 데이터



OHLCV 기본 데이터

Market_5_features.csv

Open, High, Low, Close, Volume 5개 핵심 시장 데이터

5

피처 수

100%

커버리지



세부 구성

- Open: 시가 (거래 시작 가격)
- High: 고가 (거래일 최고가)
- Low: 저가 (거래일 최저가)
- Close: 종가 (거래 종료 가격)
- Volume: 거래량



Fundamental (25개)

거시경제 지표



거시경제 지표

Fundamental_25_features.csv

VIX, DXY, 금리, GDP, 물가 등 25개 거시지표

25

피처 수

4

카테고리



세부 구성

- 변동성/위험지수: VIX, DXY
- 원자재: Gold, Oil 가격
- 금리: 단기/장기 금리, 수익률곡선
- 실물지표: CPI, PPI, GDP, 실업률

4개 피처 그룹 상세 (2/2)

Technical(42개 지표)와 News Sentiment(16개 FinBERT 파생)



Technical(42)

기술적 지표



추세/모멘텀 지표

SMA, EMA, RSI, MACD, Stochastic, ROC, Momentum

추세

모멘텀

오실레이터

14

추세

12

모멘텀



변동성/거래량 지표

Bollinger Bands, Keltner Channels, ATR, OBV, CMF, VWAP

변동성

거래량

10

변동성

6

거래량



News Sentiment(16)

뉴스 심리 지표



감성/방향성 지표

긍정/부정/중립 확률, 감성 방향, 강도, 신뢰도

긍정

부정

중립

8

감성

4

확신도



뉴스 볼륨/강도

뉴스 볼륨, 강도, 확신도, 분포

볼륨

강도

4

볼륨

4

강도

DGFET 핵심 아이디어

Group-FiLM, Global-Context FiLM, Dynamic Fusion, KL 정규화



Group-FiLM Adapters

그룹별 미세 조정 메커니즘

각 특징 그룹에 Scale/Shift 파라미터 적용
과적합 방지를 위한 규제 포함
그룹별 통계·스케일 차이 교정

$$\tilde{h}_i(g) = \gamma(g) \times h_i(g) + \beta(g)$$



Global-Context FiLM

전역 맥락 정렬 시스템

공유 컨텍스트 벡터로 FiLM 파라미터 조정
시점별 전역 상태 반영
그룹 간 상호작용 정렬



Dynamic Group Fusion

온도 기반 선택적 융합 ($\tau=0.8$, $cap=1.0$)

핵심 메커니즘

temperature-scaled 가중을 통해 관련 그룹에 집중,
KL 정규화로 단일 그룹 붕괴 방지

0.8

τ 값

1.0

cap 값

+5.3%

성능 향상

Group-FiLM 메커니즘

그룹별 특징 변환 및 미세 조정



Group-FiLM 구조

Feature-wise Linear Modulation



Scale/Shift 적용

$$\hat{h}_i(g) = \gamma(g) \times h_i(g) + \beta(g)$$

그룹별 은닉상태에 scale(γ)와 shift(β) 적용

$\gamma(g)$: 학습 가능한 scale

$\beta(g)$: 학습 가능한 shift



과적합 방지

크기 제한(magnitude capping)으로 과적합 방지

Regularization

Magnitude Capping



작동 메커니즘

How & Why



그룹별 통계 교정

그룹별 통계·스케일 차이 교정

4
피쳐 그룹

88
총 특징 수



미세 적응

과도한 공통화 대신 그룹별 미세 적응

Fine-grained

Group-specific

Global-Context FiLM

공유 컨텍스트 벡터를 활용한 그룹 간 정렬 및 레짐 변화 적응



메커니즘

Mechanism



공유 컨텍스트 벡터

그룹별 은닉상태 → 공유 컨텍스트 → FiLM 파라미터 조정

핵심 역할

- 그룹 간 상호작용 정렬
- 시점별 전역 상태 반영
- 레짐 변화에 따른 적응력 강화



동적 적응 프로세스

128

차원

4

그룹 수



적용 효과

Effects



그룹 간 정렬

4개 그룹의 특징 벡터를 전역 컨텍스트로 정렬

상관관계 학습

패턴 인식



레짐 변화 적응

시장 국면 변화에 따른 적응적 처리

적응력

안정성

Dynamic Group Fusion

temperature-scaled 가중($\tau=0.8$, $\text{cap}=1.0$), KL 정규화로 쓸림 방지



선택적 융합 메커니즘

Selective Fusion



Temperature-scaled 가중

$\tau=0.8$, $\text{cap}=1.0$

온도 스케일링을 통한 선택적 가중

0.8

τ 값

1.0

cap 값



KL 정규화

KL divergence regularizer

단일 그룹 쓸림 방지를 위한 KL 정규화

Prior: Uniform

Target: Learned

핵심 포인트

마스킹·게이팅 변형으로 타깃별 최적화



설계 포인트

Design Points



동적 그룹 융합

Dynamic Group Fusion

그룹별 적응적 융합 메커니즘

4

그룹 수

32

히든 차원



쓸림 방지

Collapse Prevention

단일 그룹으로의 붕괴 방지

KL Divergence


Regularization

성능 향상

F1-macro 0.536 ($\tau=0.8$, $\text{cap}=1.0$)

DGFET 전체 아키텍처 흐름도

그룹별 인코딩 → FiLM → Global-Context → Dynamic Fusion → Transformer → 분류



DGFET 아키텍처: Group-FiLM + Global-Context + Dynamic Fusion

입력: 88개 특징 | 출력: 2/3 클래스 분류 | 최적 설정: $\tau=0.8, \text{cap}=1.0$

성능: F1-macro 0.536 (+16.8% vs Vanilla)

실험 데이터 및 설정

EUR/USD 2011-2024, 3,552일, L=60, Train/Val/Test 70/15/15, Adam 최적화

데이터 정보

Data Info

데이터 기간

2010년 ~ 2023년

3,552

거래일

88

특징 수

시퀀스 설정

Lookback Window: 60일 (≈2개월)

60

일

3,493

샘플



Train: 2011-2018 / Val: 2019-2021 / Test: 2022-2024

모델 설정

Model Config

모델 차원

d_model=128, heads=4, layers=2, ff_dim=256, dropout=0.2

최적화 설정

Adam, lr=1e-3, weight_decay=0.0, batch_size=128, max_epochs=60

Early Stopping

patience=8, monitor=F1-macro, restore_best_weights=True

Model Dim	Heads
128	4
Layers	Dropout
2	0.2

라벨링 방법론 비교

SHM (단기 모멘텀) Triple-Barrier

SHM vs Triple-Barrier, Binary vs Ternary, 특징과 장점 비교

비교 항목	SHM (Short-Horizon Momentum)	Triple-Barrier
라벨링 기준	EMA(3,8) 스프레드 단기 가격 동력 기반 1일 지향	변동성 스케일 상/하단 방향성 + 중립 구분 10일 지향
Binary vs Ternary	이진 분류 상승/하락 2가지 단순 방향 예측	삼진 분류 상승/하락/중립 3가지 사이드웨이 반영
데이터 특징	EMA 기반 단기 모멘텀 포착 민감한 반응	변동성 조정 변동성 고려 안정적 예측
장점	빠른 반응 단기 추세 포착 모멘텀 학습	중립 구분 사이드웨이 처리 균형 잡힌 예측

주요 성능 결과

DGFET 모델의 성능 지표 및 Ablation Study 결과

 F1-Macro

0.536

$\tau=0.8$, cap=1.0

Vanilla 대비 **+16.8%** 개선
+16.8%
전반적인 분류 성능 측정

 Accuracy

0.618

전체 예측 정확도

61.8% 정확도 **+48%**
LSTM 대비 +48%, Vanilla 대비
+29%

 SHM-Binary

0.722

F1 / ROC-AUC 0.810

단기 모멘텀 **이진 분류** **+14%**
방향성 예측 최고 성능

 3개 핵심 성능 지표

 3,552일 EUR/USD 데이터

 60일 록백 기간

Ablation Study 설계 개요

구성 요소별 기여도 정량화 및 공정한 평가 체계 구축

🎯 목적

구성요소 기여 정량화

각 아키텍처 컴포넌트의
성능 기여도 측정

필수 모듈 vs 선택적 모듈 구분
과도 복잡성 식별 및 최적화

⚖️ 공정성

동일 스플릿/시드/튜닝 규칙

동일 데이터 분할 (70/15/15)

동일 랜덤 시드 (seed=123)

동일 하이퍼파라미터 설정

📈 평가 지표

F1-macro 주, 다양한 보조 지표

F1-macro: 주요 평가 지표

ACC, MCC, ROC-AUC 보조

Precision, Recall, F1-score

8

Ablation 변형 모델

4

예측 타겟

88

입력 특징 수

60

룩백 윈도우



데이터 분할



모델 학습



성능 평가



결과 분석

Ablation 8개 변형 비교

GFET Base, DGFET 파라미터 변형, HIER, BASE-FiLM/GC, 마스크 변형의 성능 분석



GFET Base

기본 그룹 처리
+ 글로벌 컨텍스트 융합

0.509

F1-Macro

0.637

ROC-AUC



DGFET($\tau=0.8$)

최적 파라미터 설정
($\tau=0.8$, $\text{cap}=1.0$)

0.536

F1-Macro

0.661

ROC-AUC



DGFET($\tau=0.5$)

파라미터 변형
($\tau=0.5$, $\text{cap}=1.5$)

0.485

F1-Macro

0.642

ROC-AUC



HIER

계층형 다중 그룹
트랜스포머

0.476

F1-Macro

0.638

ROC-AUC



HIER+Gates

계층형
+ 소프트 게이팅

0.510

F1-Macro

0.645

ROC-AUC



BASE-FiLM/GC

FiLM/GC 레이어 제거

0.517

F1-Macro

0.640

ROC-AUC



mask=news

뉴스 피처 마스크

0.517

F1-Macro

0.642

ROC-AUC



mask=news+fund

뉴스
+기초 피처 마스크

0.722

F1-Macro

0.810

ROC-AUC

동적 마스크 효과 분석

최적 설정 F1 +5.3%, 파라미터 민감도, KL/cap 안정화 효과

KL/cap 안정화 효과

Stabilization Effect

단일 그룹 쓸림 방지

KL 분산

정규화 효과 확인

마스크 안정성

cap=1.0

최적 임계값

안정화 메커니즘

KL 발산 정규화를 통해 학습된 어텐션 분포와 사전 분포 간의 차이를 최소화
→ 특정 그룹에만 치중되는 붕괴 현상 방지

성능 vs 복잡도

Performance vs Complexity

계산 효율성

+12%

대비 성능 향상

메모리 사용

-8%

최적화 효과

성능 향상 분석

Performance Improvement

최적 설정 ($\tau=0.8$, $cap=1.0$)

F1 0.536

+5.3% vs GFET

파라미터 민감도

+5.1%

$\tau 0.8 / cap 1.0 > \tau 0.5 / cap 1.5$

동적 마스크 효과

+16.8%

vs Vanilla Transformer

KL 정규화 효과

안정화

단일 그룹 붕괴 방지

핵심 해석

동적 마스크 메커니즘은 시점별 관련 그룹에 집중하여 오류 상관·균형 개선.
KL 정규화와 cap 설정으로 과적응을 방지 + 안정성 확보

파라미터 설정 비교

Parameter Comparison

설정	F1-macro	개선율	특징
$\tau=0.8$, $cap=1.0$	0.536	+5.3%	최적
$\tau=0.5$, $cap=1.5$	0.485	-	과도한 마스크
$\tau=1.0$, $cap=0.8$	0.512	+3.1%	보수적 마스크

핵심 해석 및 한계

DGFET 논문의 핵심 결과 해석과 제한사항 분석

✓ 핵심 해석

Flat > Hierarchical

평면 구조가 계층 구조보다 일관되게 우수 (F1-macro 0.509 vs 0.476)

+5.3%

Dynamic Masking 효과

0.722

SHM-Binary F1

0.536

최종 F1-macro

- 타깃별 최적 구성이 다름 (SHM vs TB)
- Dynamic Masking이 성능 향상에 핵심 기여

⚠ 연구 한계

일별·단일자산 한계: EUR/USD만 사용, 고빈도 데이터 미반영

- FiLM/GC가 과도 복잡성 유발 가능 및 일반화 한계



구조적 우위 분석

모델 구조	F1-macro	성능
Flat Architecture	0.509	최고
Hierarchical (no gates)	0.476	최저
Hierarchical + Gates	0.510	중간

📌 평면 구조가 그룹 간 상호작용을 더 효과적으로 포착



성능 개선 포인트

+16.8%

vs Vanilla

+50%

vs LSTM

+1.3%

vs GFET

↑ Dynamic Group Fusion이 핵심 성능 향상 요인

우리 프로젝트와의 연결

논문의 핵심 아이디어를 KODEX 200 ETF 예측에 적용



핵심 연결

뉴스 임베딩 + 정형 지표 융합

뉴스 임베딩(32d)
+ 기술/거시 지표 결합

triple_barrier_label로 변동성
·종립 반영

DGFET 아이디어의 실전 적용



Ablation 설계

4가지 케이스 비교

Full: 모든 특징 포함

No News: 뉴스 제외

News only: 뉴스만 사용

Baseline: 단순 기준



재현성 유지

동일 분할·시드 적용

동일 데이터 스플릿

랜덤 시드 고정

재현 가능한 환경

DGFET 논문

핵심 아이디어



KODEX 200 ETF

대상 자산



뉴스 임베딩

비정형 데이터



통합 예측

최종 모델



라벨링 전략

triple_barrier_label을 활용한 안정적인 예측 타겟 설정



Triple Barrier label

변동성 기반 3중 장벽 라벨링

상한/하한/시간 장벽 설정
수익률 방향성 + 변동성 고려
사이드웨이 구분 가능



장점

변동성 고려·사이드웨이 구분

변동성에 따른 동적 장벽
시장 상황 반영
과적합 방지



목표

방향/수익률 신뢰도 동시 확보

방향성 예측 정확도
수익률 예측 신뢰도
실전 거래 적용성



변동성 고려

시장 변동성을 반영한 동적 장벽 설정으로
예측 신뢰도 향상



사이드웨이 구분

상하 방향성 외에 중립 구간을
명확히 구분하여 예측 안정성 확보



신뢰도 확보

방향성과 수익률 예측의 동시 신뢰도를
확보하는 라벨링 전략

Ablation Study 계획

구성 요소별 기여도 정량화 및 체계적 검증

구성 요소별 기여도 정량화

각 모듈(뉴스 임베딩, 기술 지표, 거시경제)의 성능 기여도 측정
→ 최적 조합으로 적합

- 뉴스 임베딩: 시장 감성 정보 추출 능력
- 기술 지표: 과거 가격 패턴 분석
- 거시경제: 경기 변동성 반영

보고용 표준 지표 세트 사용

다차도 평가 지표를 활용하여 모델 성능을 종합적으로 검증
(Sign Accuracy, Pearson Correlation, Sharpe Ratio, F1-Score 등 포함)

동일 분할·동일 튜닝 규칙 준수

모든 실험에서 동일한 데이터 분할과 하이퍼파라미터 튜닝 적용
→ 공정한 비교 보장

✓ Train/Val/Test 분할

✓ 동일 시드 설정

✓ Early stopping

✓ Learning rate

검증 프로세스

1. 기본 모델 성능 측정
- 2. 구성 요소 제거
- 3. 성능 변화 분석
- 4. 최적 조합 도출

Ablation이란?

구성 요소별 기여도를 정량적으로 측정하는 방법론

핵심 개념

한 요소씩 제거/변형
→ 성능 변동 측정

모델의 각 구성 요소를 순차적으로
제거

제거 전후 성능 변화를 정량화

불필요한 복잡성 식별

판별 기준

누적 효과 vs 필수 모듈

필수 모듈: 제거 시 성능 급감

보조 모듈: 성능 영향 미미

과도 복잡성: 비효율적 구성 요소

분석 목적

과도 복잡성 식별

모델 최적화 방향 제시

리소스 할당 효율화

해석 가능성 개선

4개 Case 비교 설계

Full, No News, No Tech-Macro, Baseline 케이스별 데이터 구성 및 목표 비교

비교 항목	Full (Tech+Macro+News)	No News (Tech+Macro)	No Tech-Macro (News only)	Baseline
≡ 입력 데이터	기술+거시+뉴스 tecfeature0410 + news(32d) 최종 모델	기술+거시 tecfeature0410 뉴스 제외	뉴스만 news(32d) 기술/거시 제외	단순 기준 이동평균/로지스틱 베이스라인
🎯 목표	융합 효과 검증 전체 성능 최적화 뉴스+정형 결합	뉴스 영향 측정 뉴스 제외 효과 확인 정형만으로 예측	뉴스 단독 한계 뉴스만으로 예측 강점/약점 파악	성능 기준 상한선/하한선 비교 기준
📊 평가 지표	Sign Acc + Corr 방향성 + 연속 예측 종합 평가	Sign Acc 방향성 타격률 정확도	Corr + Sharpe 연속성 + 위험조정 뉴스 특화	Baseline Metric 기준 성능 비교용
✓ 예상 결과	최고 성능 F1-macro 0.536 융합 효과	성능 하락 뉴스 제외 시 기여도 측정	단독 한계 뉴스만으로 정보 부족	기준점 비교 기준 참조용

Case 1 상세: Full Model (set3)

기술 지표 + 거시경제 + 뉴스 임베딩을 모두 활용한 최종 모델

입력 데이터

tecfeature0410 + news 32d

정형 데이터: tecfeature0410.csv

비정형 데이터:
daily_news_embeddings

임베딩 차원: 32차원 (FC 축소 후)

시계열: 60일 룩백 윈도우

모델 구성

XGBoost, LSTM, Late Fusion

XGBoost: 정형 데이터 학습

LSTM: 시계열 패턴 학습

Late Fusion: 두 모델 결과 융합

양상블: 최종 예측 생성

가설

융합이 단독 대비 우위

뉴스 임베딩 추가로 예측력 향상

정형+비정형 융합의 시너지

실전 거래 적용 가능성 검증

XGBoost

정형 데이터



LSTM

시계열 패턴



Late Fusion

결과 융합



최종 예측

수익률 예측

✓ **핵심 가설:** 뉴스 임베딩을 추가한 Full Model이 정형 데이터만 사용한 모델보다 수익률 예측 정확도가 높을 것이다.

Case 2-4 상세 분석

Ablation Study의 3가지 변형 케이스별 성능 분석

Case 2 : No News

비정형 제외

뉴스 임베딩을 제외한 모델 성능

목적: 뉴스 데이터의 실제 기여도 확인
입력: tecfeature0410 (정형 데이터만)
예상 영향: 단기 변동성 예측력 감소
핵심 지표: F1-macro, ROC-AUC 비교

-15%

F1 감소

0.48

F1-macro

Case 3 : No Tech-Macro

정형 제외

기술/거시 지표를 제외한 뉴스 단독 모델

목적: 뉴스 단독 예측력 평가
입력: news embeddings (32d)만 사용
예상 영향: 장기 추세 예측력 감소
핵심 지표: 방향성 예측 정확도

-22%

정확도 감소

0.42

F1-macro

Case 4 : Baseline

기준 모델

단순 기준 모델로 성능 상한/하한 설정

목적: 성능 비교 기준점 설정
모델: 이동평균 + 로지스틱 회귀
특징: 뉴스/정형 데이터 없음
활용: 상한선/하한선 비교

0.35

F1-macro

0.58

ROC-AUC

평가 지표

Ablation Study 성능 평가를 위한 3가지 핵심 지표



Sign Accuracy

방향성 타격률

78.5% 정확도

예측한 **방향성**과 실재가 일치하는 비율 측정
상승/하락 예측의 정확도 평가

85.2%

상승 예측

72.1%

하락 예측

78.5%

평균



Pearson Correlation

연속 예측 일치도

0.72 상관계수

예측값과 실재값의 **상관관계** 측정
범위: -1(완전 반대) ~ +1(완전 일치)

0.72

현재

0.68

이전

+5.9%

개선



Sharpe Ratio

위험조정 수익

1.45 비율

위험 대비 수익 비율 측정
1.0 이상은 양호, 2.0 이상은 우수로 평가

1.45

현재

1.32

목표

+9.8%

달성



3개 지표로 종합 평가



1,200개 테스트 샘플



60일 록백 기간

* 평가 지표는 Ablation Study의 성능 분석에 활용됩니다

결론 및 Q&A

뉴스 임베딩 + 정형 융합의 실전성 검증

✓ 핵심 결론

- 뉴스 임베딩 + 정형 융합이 ETF 수익률 예측에 실질적인 기여를 하는지 검증
- 누수 방지·재현성 중심 파이프라인 구축으로 안정적인 예측 모델 개발
- Ablation Study를 통해 각 구성 요소의 기여도를 정량적으로 분석

? 주요 질문

- 뉴스 임베딩이 예측력에 주는 순증분은?
- 어떤 모델 구조가 가장 효과적인가?
- 실전 거래 적용 가능성은?

💡 해결 방안

- 체계적인 Ablation Study 설계
- 다중 모델 비교 및 성능 평가
- 누수 방지 데이터 처리

📈 기대 효과

- 예측 정확도 향상
- 실제 거래 적용성 확보
- 재현 가능한 파이프라인