

ICASSP 2026

Towards Robust Dysarthric Speech Recognition: LLM-Agent Post-ASR Correction Beyond WER

이제학
멀티센스
2026.03.19



목차

1. 연구 배경

2. 문제 인식 및 연구 목표

3. 핵심 제안

4. 결과 도출

5. 논문의 결과 및 시사점

6. 우리 프로젝트에서의 적용, 발전 방향

연구 배경

지표와 실제 효용의 불일치

자동 음성 인식(ASR) - 단어 오류율(WER)로 성능을 측정함. → 이를 낮추는데에만 집착
구음장애 음성 - 조음의 부정확함 때문에 핵심 단어가 아예 다른 단어로 바뀌는 경우가 많음.
→ 단어 한 두개 틀리는 것 자체보다, 그 틀린 단어 때문에 전체 문장의 의미가 왜곡될 수 ○

ASR 모델의 불완전한 출력 사용

기존 시스템은 ASR이 내놓은 단 하나의 최적 결과만을 믿고 교정을 시도함.
→ ASR이 내놓은 상위 여러 후보 안에는 정답에 가까운 것들이 있는데
이를 활용하지 못하는 경우가 많음

문제 인식 및 연구 목표

데이터 부족

구름 장애인을 위한 대규모 오류 교정용 데이터셋 부족함.

정보 유실

ASR이 출력하는 상위 N개의 후보(N-best) 중 정답에 가까운 정보가 있음에도 불구하고 1순위 결과만 사용하는 기존 방식의 한계점을 지적함.

연구 목표

단순 텍스트 변환을 넘어 문장의 의미적 가치를 보존하는 교정 시스템 구축

핵심 제안 – SAP Hypo512

SAP-Hypo512

구음장애 음성 교정을 위해 구축된 세계 최대 규모의 데이터셋

UASpeech 및 Torgo 데이터셋 활용
ASR 모델(Whisper 등)이 출력한 상위 512개의 가설을 포함

→ 연구의 재현성을 확보하고 다양한 오류 패턴 분석 O

*SAP (Segment-Align-Pair): 음성 인식 후보군들을 문장 단위가 아닌, 의미 있는 구간별로 정렬하여 정답과 쌍을 맞춤.

**Hypo512: 각 음성 샘플에 대해 ASR 모델이 내놓은 가설을 상위 1~2개가 아닌 512개까지 추출하여 포함.

핵심 제안 – SAP Hypo512

SAP-Hypo512

왜 512개나 모았는가?

오류 패턴의 다양성 확보 - 구음장애 음성은 오인식 양상이 다양한데 512개까지 확장하면 거기에는 발화자의 실제 의도가 담긴 단어 파편들이 포함되어 있을 확률이 높아짐.

LLM 에이전트 학습용 - LLM이 수많은 오답 후보 사이에서 공통된 맥락을 찾고 정답을 재구성하는 능력을 기르기 위한 오답 노트 역할을 함.

데이터셋 구성 및 특징

UASpeech, Torgo 등 검증된 구음장애 음성 코퍼스 활용
명료도에 따라 Very Low, Low, Mid, High 4개 그룹의 데이터를 고르게 포함하여 편향성 방지.

구음장애 음성 교정 분야에서는 유래가 없는 방대한 양의 후보군 데이터를 제공하여 연구의 재현성 높임.

핵심 제안 – Judge Editor 에이전트 아키텍처

Judge-Editor 에이전트 아키텍처

LLM을 판단자와 편집자라는 두 가지 역할로 분리

→ 문장을 확실한 부분과 의심스러운 부분으로 나누어
처리함으로써 원본 의도를 최대한 보존



핵심 제안 – Judge Editor 에이전트 아키텍처

Judge-Editor 에이전트 아키텍처

1단계 Judge (판단자) - 오류의 위치를 찾아내는 분석가
ASR이 생성한 상위 K의 후보를 입력받아 비교 분석

일관성 검사: 여러 후보군에서 공통적으로 나타나는 단어
나 구간은 신뢰구간으로 확정.

불확실성 식별: 후보들마다 내용이 다르거나 문맥적으로
충돌하는 지점을 수정 구간으로 선별.

2단계 Editor (편집자) - 문맥에 맞게 복원하는 숙련된 작가
Judge가 지정한 불확실 구간만 집중적으로 수정

재작성: 주변의 확실한 문맥을 바탕으로, 해당 구간에
가장 적절한 단어를 LLM을 통해 채워 넣음

융합: 후보군 데이터 속에 흩어져 있는 정답 파편들을
최적의 의미로 병합

결과 도출

성능 향상

제안된 에이전트 방식 사용 시
WER(단어오류율) 14.51% 감소

의미 보존

모든 중증도 구간에서 의미론적 점수와
SLU 성능이 비약적으로 향상됨

모드 비교

Zero-shot(사전 학습 없음) 환경에서도
높은 효율성을 보임.
Fine-tuned 시 성능 극대화

논문의 결론 및 시사점

결론

LLM 에이전트를 통한 후처리가 구음장애 음성 인식의 실용성을 획기적으로 높일 수 있음을 증명함.

시사점

구음장애 지원 시스템은 글자 일치보다 의미 보존과 에이전트 기반의 정밀 교정이 핵심 경쟁력

우리 프로젝트에서의 적용, 발전 방향

구조적 안정성 확보

LLM이 문장 전체를 생성하면 환각 발생 → Judge Editor 구조를 통해 틀린 구간만 고쳐야 한다.

우리는 N-best 가설들 간의 일관성을 분석하는 시스템을 기본 뼈대로 삼음
→ 모델이 멋대로 문장을 지어내는 것을 방지

텍스트를 넘어선 멀티모달 융합

논문에서는 텍스트만 보고 판단하므로 소리가 뭉개져 모든 후보군이 틀렸을 경우, LLM도 정답을 찾을 수 X

여기에 호흡 패턴이라는 생체 신호를 결합
발화 시의 호흡 주기와 끊김 정보를 Late Fusion 방식으로 주입하여 Judge Editor가 더 정확하게 판단하게 만듦

우리 프로젝트에서의 적용, 발전 방향

의미론적 거리 기반의 물리적 안전 트리거

논문 Editor가 수정한 결과물이 정말 정답인지
검증하는 단계가 부족

우리 Semantic Distance(의미론적 거리)
측정 기술을 추가함

→ LLM이 교정한 결과와 원본 음성 가설 간의 거리를 계
산해, 임계값을 넘으면 출력을 거부하고 사용자에게 다시
물어보는 Safety Trigger를 설계함

단순 인식에서 의도 복원으로

WER(단어 오류율)보다는 SLU(언어 이해)가 중요

우리는 이를 의도 달성 성공률로 구체화함.
단순히 글자를 맞추는 것이 아니라, 사용자가 "전등 켜"라고
했을 때 시스템이 실제로 기기를 제어했는지를 지표로 삼아
시스템의 실용성을 극대화함

Q & A