


Hybrid SARIMAX-LSTM 알고리즘을 이용한 시계열 자료 예측

통계 모델과 딥러닝의 결합을 통한 예측 성능 개선 연구



| 논문 소개

기존 통계 모델(**SARIMAX**)과 딥러닝 모델(**LSTM**)을 결합하여,
기존 모델들의 한계를 극복하고 예측 정확도와 연산 효율성을 동시에 개선한 연구입니다.



연구 목적

통계 모델의 논리성과 딥러닝의
유연성을 결합하여 **예측 정확도**와
연산 효율성을 동시에 달성



핵심 아이디어

시계열 데이터의 **선형 패턴**은
SARIMAX가 학습하고, 남은 복잡한
비선형 잔차는 LSTM이 학습하는 분담
구조



기대 효과

단일 모델 대비 뛰어난 **예측 성능**
향상뿐만 아니라, 딥러닝의 고질적
문제인 **학습/예측 시간 대폭 단축**

Long-term dependency(장기 의존성): 딥러닝, 특히 자연어 처리(NLP)나 시계열 데이터 분석에서 문장이나 시퀀스의 앞부분에 있는 정보가 뒷부분의 결과에 큰 영향을 미치지만, 그 거리가 멀어서 모델이 이를 제대로 연결하지 못하는 문제

배경 및 문제 제기



통계 모델 (ARIMA/SARIMAX)

+ 장점

- ✓ 오랫동안 검증된 예측 방법론
- ✓ 수식을 통한 결과의 해석이 용이함

- 한계점

- ⚠ 데이터가 선형적이지 않거나 복잡한 패턴을 가질 경우 예측력 저하



딥러닝 모델 (LSTM)

+ 장점

- ✓ 복잡한 비선형 패턴을 스스로 학습하는 강력한 능력 보유

- 한계점

- ⚠ 장기 의존성(Long-Term Dependency) 문제를 완전히 해결하기 어려움
- ⚠ 학습에 많은 컴퓨터 자원과 시간이 소모됨

VS



피처 엔지니어링(Feature Engineering):
도메인 지식을 활용해 원시 데이터(Raw Data)를 가공하여 머신러닝 모델의 성능을 향상시키는 핵심 과정

SARIMAX-LSTM 하이브리드 구조 (3단계)

논문의 핵심 구조인 **피처 엔지니어링**부터 **비선형 잔차 학습**까지의 순차적 흐름

Step 1



SARIMAX를 통한 피처 엔지니어링

- ✓ 자기상관성(AR), 이동평균(MA), 계절성(S) 추정
- ✓ 외생변수(X)의 통계적 유의성 검증

→ 정제된 예측 정보 생성

Step 2



LSTM 입력 데이터 재구성

- ✓ 과거 실제값 외에 추가 피처 구성
- ✓ SARIMAX의 선형 예측값과 계수, 잔차(Residual) 활용

→ LSTM의 정보 풍부화 달성

Step 3




비선형 잔차 학습 (LSTM)

- ✓ SARIMAX가 설명하지 못한 복잡한 오차 학습
- ✓ 선형적 가이드라인 위에서 미세 조정(Fine-tuning) 수행

→ 일반화 성능 및 학습 효율 극대화

실증 분석 및 결과

데이터 1: 지하철 승차객 수 (동대문역사문화공원역) - 강한 주기성 패턴




[그림 4.3] 시험 데이터 예측 그래프 (동대문역사문화공원역의 승차객 수)

[표 4.3] 시험 데이터 예측 결과 지표 (동대문역사문화공원역)

	RMSE
SARIMAX(2,0,1)(0,1,1) ₇	1625.56
LSTM	1510.63
Hybrid SARIMAX-LSTM	1098.21

데이터 2: 가정용 전력 사용량 (서울시) - 높은 변동성 및 기상 외생변수 영향



[그림 4.7] 시험 데이터 예측 그래프 (서울시 가정용 전력 사용량)

	RMSE
SARIMAX(1,0,2)(2,1,0) ₁₂	1685.65
LSTM	1372.15
Hybrid SARIMAX-LSTM	1220.04

결론 및 시사점



본 논문은 " 통계 모델의 논리성과 딥러닝의 유연성 "을 결합할 때 시계열 예측이 가장 효과적임을 입증했습니다.



핵심 성공 요인

- 외생변수 확보 품질이 전체 하이브리드 모델의 성능을 결정짓는 핵심 키입니다.
- 날씨, 공휴일 등 도메인에 맞는 적절한 외생변수를 통계적으로 검증하여 투입해야 합니다.



연구의 한계점

- 예측하려는 구간(미래)의 외생변수 데이터가 사전에 확보되어 있어야만 예측이 가능합니다.
- 외생변수 예측 오차가 발생할 경우, 최종 모델의 예측 결과에도 연쇄적인 오차가 발생할 수 있습니다.



실무 적용 가이드

- 데이터 전처리 및 외생변수 발굴 → SARIMAX 적합(선형 가이드라인 생성) → 하이브리드 데이터 재구성 → LSTM 잔차 학습의 파이프라인 구축 권장.

프로젝트 적용 (환율 예측)

랜덤워크(Random Walk): 미래 예측이 불가능하며, 시간이 지날수록 중심에서 멀어지고 분산이 선형적으로 증가하는 특징을 가진 비정상(Non-stationary) 시계열 데이터 모델



현재 프로젝트 현황: M2, MMF 등 유동성 변수를 학습시켰으나 직전 거래일 값을 그대로 사용하는 Naive 모델과 오차율이 유사. 환율 시장의 강한 랜덤워크(Random Walk) 특성을 극복하는 데 한계가 있음.

1

선형 가이드(Linear Guide)의 활용

노이즈가 심한 환율 데이터에 SARIMAX를 먼저 적용하여 환율의 추세와 계절성 같은 기본 틀을 잡아줍니다. 딥러닝(LSTM)은 그 남은 잔차만을 학습함으로써 모델이 무분별한 노이즈에 과적합(Overfitting)되는 것을 방지할 수 있습니다.

2

외생변수 영향력 정제 (Feature Selection)

SARIMAX의 외생변수 처리 기능을 활용해 유동성 지표(M2, MMF 등)의 통계적 기여도를 사전 검증합니다. 유의미한 변수만을 추출하여 LSTM에 전달함으로써, 훨씬 정교하고 설명 가능한 예측 모델로 발전시킬 수 있습니다.



기대 효과

- 랜덤워크 극복 및 예측 안정성 향상
- 통계적 검증을 통한 설명 가능성 (XAI) 부여
- 학습 파라미터 최적화로 학습 시간 단축